ใบอนุมัติโครงงานปริญญานิพนธ์
สาขาวิชาวิทยาการคอมพิวเตอร์ ภาควิชาคอมพิวเตอร์
คณะวิทยาศาสตร์ มหาวิทยาลัยศิลปากร

ชื่อปริญญานิพนธ์ การคัดแยกเกรดมะม่วงพันธุ์ฟ้าลั่นด้วยวิธีการประมวลผลภาพ
Quality Level Identification for Mangifera indica Linn (Falan Mango) using Image Processing Technique

ผู้จัดทำ นางสาวชัญญา มณีฉาย
ปีการศึกษา 2565

โครงงานปริญญานิพนธ์นี้ได้รับการอนุมัติให้เป็นส่วนหนึ่งของการศึกษาตาม
หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์
ภาควิชาคอมพิวเตอร์ คณะวิทยาศาสตร์ มหาวิทยาลัยศิลปากร

..... ประธานกรรมการสอบ
(รองศาสตราจารย์ ดร.ปานใจ ธารทัศนวงศ์)

..... กรรมการสอบ
(อาจารย์ ดร.สัจจาภรณ์ ไวจรรยา)

..... อาจารย์ที่ปรึกษาและกรรมการสอบ
(ผู้ช่วยศาสตราจารย์ ดร.ณัฐโชติ พรหมฤทธิ์)

การคัดแยกเกรดมะม่วงพันธุ์ฟ้าลั่นด้วยวิธีการประมวลผลภาพ

Quality Level Identification for Mangifera indica Linn (Falan Mango) using Image Processing Technique

ชัญญา มณีฉาย

ปริญญานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาในหลักสูตรวิทยาศาสตรบัณฑิต
สาขาวิชาวิทยาการคอมพิวเตอร์ ภาควิชาคอมพิวเตอร์
คณะวิทยาศาสตร์ มหาวิทยาลัยศิลปากร
ปีการศึกษา 2565

ชื่อปริญญานิพนธ์ การคัดแยกเกรดมะม่วงพันธุ์ฟ้าลั่นด้วยวิธีการประมวลผลภาพ
Quality Level Identification for Mangifera indica Linn (Falan Mango) using Image Processing Technique

ผู้จัดทำ นางสาวชัญญา มณีฉาย
อาจารย์ที่ปรึกษา ผู้ช่วยศาสตราจารย์ ดร.ณัฐโชติ พรหมฤทธิ์

ชื่อปริญญา วิทยาศาสตรบัณฑิต (วิทยาการคอมพิวเตอร์)
ปีการศึกษา 2565

บทคัดย่อ

ปริญญานิพนธ์นี้จัดทำขึ้นเพื่อนำเทคโนโลยีการเรียนรู้เชิงลึก (Deep learning) มาประยุกต์ใช้เพื่อการคัดแยกเกรดมะม่วงพันธุ์ฟ้าลั่นด้วยวิธีการประมวลผลภาพ (Quality Level Identification for Mangifera indica Linn (Falan Mango) using Image Processing Technique) โครงงานนี้มีวัตถุประสงค์หลักเพื่อคัดแยกเกรดมะม่วงพันธุ์ฟ้าลั่นผลขนาดใหญ่ ขนาดกลาง ขนาดเล็ก และผลมีตำหนิ ซึ่งแบบเดิมการคัดแยกเกรดมะม่วงปัจจุบันใช้สายตาของมนุษย์ในการคัดแยก ค่าสายตาของมนุษย์ในแต่ละบุคคลไม่เท่ากันทำให้เกิดความผิดพลาดในการแยกเกรดได้ เพื่อทำให้การคัดแยกเกรดมะม่วงฟ้าลั่นมีคุณภาพมากขึ้น พร้อมทั้งสามารถช่วยลดจำนวนคนที่ใช้สำหรับการคัดแยกเกรดมะม่วงฟ้าลั่น โดยการทำงานของระบบนี้มี 2 ส่วน คือ ระบบตรวจจับมะม่วงจาการแบ่งข้อมูลภาพ (Image Segmentation) และการทำนายเกรด (Classification) สร้างโมเดลที่ใช้ทำนายเกรดมะม่วง มีข้อมูลเข้าเป็นไฟล์ภาพมะม่วง ผลปกติ ผลแตก และผลลาย ชุดข้อมูลภาพที่ใช้สำหรับการทดสอบโปรแกรมที่พัฒนาใช้ข้อมูลจากการเก็บรวบรวมข้อมูลภาพ นำชุดข้อมูลภาพมาทดสอบเพื่อคัดแยกเกรด โดยได้ผลลัพธ์การจำแนกเกรดมะม่วงฟ้าลั่น ด้วยค่าความถูกต้อง 85.64% และการแยกขนาดมะม่วง ด้วยค่าความถูกต้อง 81.00%

คำสำคัญ : การเรียนรู้เชิงลึก, มาร์กอาซีเอ็นเอ็น, การแบ่งข้อมูลภาพ
Keyword : Deep Learning, Mask R-CNN, Image Segmentation

กิตติกรรมประกาศ

ปริญญานิพนธ์เรื่อง การคัดแยกเกรดมะม่วงพันธุ์ฟ้าลั่นด้วยวิธีการประมวลผลภาพ สามารถสำเร็จลุล่วงไปได้ด้วยดีนั้น เนื่องมาจากได้แนวทางการสนับสนุนและได้รับความรู้จากบุคคลตามที่ข้าพเจ้าจะขอกล่าวถึงดังต่อไปนี้

ขอกราบขอบพระคุณ ผู้ช่วยศาสตราจารย์ ดร.ณัฐโชติ พรหมฤทธิ์ อาจารย์ที่ปรึกษาโครงงาน รองศาสตราจารย์ ดร.ปานใจ ธารทัศนวงศ์ และ อาจารย์ ดร.สัจจาภรณ์ ไวจรรยา ผู้ให้คำปรึกษาและให้การแนะนำในการศึกษาค้นคว้าขั้นตอนและวิธีการจนประสบความสำเร็จลุล่วงตามวัตถุประสงค์

ขอกราบขอบพระคุณ นายนริศร์ พรหมบุตร ที่ช่วยให้คำแนะนำในการใช้งานโปรแกรม Outsystems สำหรับการสร้างแอปพลิเคชันแสดงผล การคัดแยกเกรดมะม่วงพันธุ์ฟ้าลั่น

ขอกราบขอบพระคุณทางเจ้าของสวนมะม่วงฟ้าลั่นที่อนุญาตให้เก็บข้อมูลมาใช้ในการจัดทำโครงงานปริญญานิพนธ์ การคัดแยกเกรดมะม่วงพันธุ์ฟ้าลั่นด้วยวิธีการประมวลผลภาพ

ท้ายนี้ผู้จัดทำขอกราบขอบพระคุณบิดา มารดา และทุกคนในครอบครัวที่ให้กำลังใจในทุกเรื่องเสมอมา ขอขอบคุณเพื่อน พี่ และน้อง ผู้เกี่ยวข้องทุกคนที่ช่วยทำให้โครงงานสำเร็จลุล่วงไปด้วยดี จึงขอกราบขอบพระคุณเป็นอย่างสูงมา ณ ที่นี้

นางสาวชัญญา มณีฉาย

สารบัญ

หน้า

บทคัดย่อ ..... ก
กิตติกรรมประกาศ ..... ข
สารบัญ ..... ค
สารบัญตาราง ..... จ
สารบัญรูป ..... ฉ
บทที่ 1 บทนำ 1
1.1 ที่มาและความสำคัญของปัญหา 1
1.2 วัตถุประสงค์ 1
1.3 ลักษณะและขอบเขต 2
1.4 อุปกรณ์และเครื่องมือที่ใช้ 2
1.4.1 ฮาร์ดแวร์ 2
1.4.2 ซอฟต์แวร์ 2
1.5 ผลที่คาดว่าจะได้รับ 2
บทที่ 2 ผลงานที่เกี่ยวข้อง 3
2.1 การคัดแยกเมล็ดพันธุ์ปนในถั่วเขียว โดยการวิเคราะห์ภาพถ่าย [1] 3
2.1.1 ข้อเด่นของระบบ 4
2.1.2 ข้อด้อยของระบบ 4
2.2 การคัดแยกเกรดยางพาราแผ่นรมควันโดยใช้วิธีการประมวลผลด้วยภาพ [2] 4
2.2.1 ข้อเด่นของระบบ 4
2.2.2 ข้อด้อยของระบบ 4
2.3 ระบบตรวจจับวัตถุและป้ายสำหรับผู้ที่บกพร่องทางการมองเห็น [3] 5
2.3.1 ข้อเด่นของระบบ 5
2.3.2 ข้อด้อยของระบบ 5
บทที่ 3 ทฤษฎีและความรู้ที่เกี่ยวข้อง 6
3.1 การแบ่งข้อมูลภาพ (Image Segmentation) [4] 6
3.2 การเรียนรู้เชิงลึก Deep Learning [7] 6
3.2.1 โครงข่ายประสาทเทียม (Artificial Neural Network: ANN) 7
3.2.2 โครงข่ายประสาทแบบคอนโวลูชัน (Convolution Neural Network : CNN) 7
3.2.3 การเรียนรู้แบบมีผู้สอน (Supervised Learning) 8
3.3 Mask R-CNN [5] 9
3.4 TensorFlow [6] 9
3.5 Make Sense [8] 10
3.6 วิธีการเพิ่มประสิทธิภาพการทำนายภาพด้วยเทคนิคการขยายภาพ (Image Data Augmentation) [3] 11

3.7 Outsystems [9] 12
บทที่ 4 ขั้นตอนและแผนการดำเนินงาน 13
4.1 ขั้นตอนการดำเนินงาน 13
4.1.1 คิดหัวข้อโครงงานและรวบรวมข้อมูล 13
4.1.2 กำหนดขอบเขตและวางแผนการดำเนินงาน 13
4.1.3 ศึกษาความรู้และทฤษฎีที่เกี่ยวข้อง 13
4.1.4 วิเคาะห์และออกแบบระบบ 13
4.1.5 พัฒนาระบบ 13
4.1.6 ทดสอบและปรับปรุงระบบ 13
4.1.7 จัดทำเอกสารประกอบโครงงาน 13
4.2 แผนการดำเนินงาน 14
บทที่ 5 การวิเคราะห์และออกแบบระบบ 15
5.1 หลักการทำงานของระบบ 15
5.2 แผนผังการทำงานโดยรวมของระบบ (Flow Chart Diagram) 16
5.3 วิธีการฝึกโมเดลทำนายเกรดมะม่วง 16
5.3 วิธีการฝึกฝนโมเดลแบ่งข้อมูลบนภาพด้วย Mask R-CNN 19
5.4 การวัดขนาดมะม่วง 22
5.5 API แสดงผล 23
5.6 การออกแบบหน้าเว็บแอปพลิเคชัน 25
บทที่ 6 ผลการดำเนินงาน ข้อจำกัด และข้อเสนอแนะ 28
6.1 ผลการดำเนินงาน 28
6.1.1 การทดสอบประสิทธิภาพส่วนการวัดขนาด 28
6.1.2 การทดสอบประสิทธิภาพส่วนการทำนายเกรดมะม่วง 30
6.1.3 สรุปผลการทดลองและผลการทดสอบ 30
6.2 ข้อจำกัด 31
6.3 ข้อเสนอแนะ 31
บรรณานุกรม 32
ภาคผนวก ก คู่มือการใช้งานเว็บแอปพลิเคชัน 33
ก.1 การใช้งานเว็ปแอปพลิเคชั่น 33

สารบัญตาราง

หน้า

ตารางที่ 4.1 ตารางขั้นตอนและแผนการดำเนินงาน 14
ตารางที่ 6.1 การคำนวณ Confusion matrix 28
ตารางที่ 6.2 Confusion matrix การแยกขนาดมะม่วง 29
ตารางที่ 6.3 precision, recall, f1- score การแยกขนาดมะม่วง 29
ตารางที่ 6.4 Confusion Matric Classify 30
ตารางที่ 6.5 precision, recall, f1- score Classify 30

สารบัญรูป

หน้า

รูปที่ 2.1 เมล็ดถั่วเขียวสายพันธุ์ชัยนาท 72 (10 x 10) 3
รูปที่ 2.2 เมล็ดถั่วเขียวสายพันธุ์กำแพงแสน 2 (10 x 10) 3
รูปที่ 2.3 Hu's Moments of the CN 72 3
รูปที่ 2.4 Hu's Moments of the KPS 2 3
รูปที่ 2.5 ตัวอย่างยางพาราแผ่นนมควัน RSS 1, RSS 2, RSS 3, RSS 4 และ RSS 5 4
รูปที่ 2.6 แอปพลิเคชั่นตวจจับวัตถุและป้ายสำหรับผู้ที่บกพร่องทางการมองเห็น 5
รูปที่ 3.1 การทำ Image Segmentations เพื่อแยกบุคคลทั้งหมดและแยกจำนวนบุคคลที่อยู่ในภาพ 6
รูปที่ 3.2 การเปรียบเทียบเซลล์ประสาทของมนุษย์กับเซลล์จำลองในโครงข่ายประสาทเทียม 7
รูปที่ 3.3 โครงข่ายประสาทแบบคอนโวลูชัน (Convolution Neural Network) 8
รูปที่ 3.4 การเปรียบเทียบ Object Detection ระหว่างตัวต้นแบบ Faster R-CNN และตัวต้นแบบ Mask R-CNN 9
รูปที่ 3.5 การใช้เครื่องมือ Make sense กำหนดขอบเขตลูกมะม่วงบนรูปภาพ 10
รูปที่ 3.6 ผลลัพธ์หลังจากกำหนดขอบเขตให้กับลูกมะม่วง ซึ่งเป็นไฟล์รูปแบบ json 10
รูปที่ 3.7 ตัวอย่างภาพจากการทดลอง 5 แบบ ในการวัดหาประสิทธิภาพในการรู้จำวัตถุ 11
รูปที่ 3.8 ตัวอย่างโปรแกรม Outsystems 12
รูปที่ 5.1 ภาพรวมการทำงานของระบบ 15
รูปที่ 5.2 แผนผังการทำงานโดยรวมของระบบ (Flow Chart Diagram) 16
รูปที่ 5.3 ขั้นตอนการเทรนโมเดล Classify 17
รูปที่ 5.4 แสดงโฟลเดอร์ในการเก็บภาพลูกมะม่วง 17
รูปที่ 5.5 การใช้เทคนิค Augmentation 18
รูปที่ 5.6 โครงสร้าง Layer ของตัวต้นแบบรู้จำในการฝึกฝน 18
รูปที่ 5.7 ขั้นตอนการเทรนโมเดล Mask R-CNN 19
รูปที่ 5.8 ตัวอย่างการ label ภาพมะม่วงด้วยโปรแกรม makesense 19
รูปที่ 5.9 ตัวอย่างการทำ visualization 20
รูปที่ 5.10 โครงสร้าง Layer ของตัวต้นแบบ Mask R-CNN 20
รูปที่ 5.11 ตัวอย่าง implement ภาพมะม่วง 21
รูปที่ 5.12 ตัวอย่างลูกมะม่วงที่ตัดได้ 21
รูปที่ 5.13 Flow Chart ส่วนการวัดขนาดมะม่วง 22
รูปที่ 5.14 ตัวอย่างการวัดขนาดมะม่วงด้วยการนับ pixel ภาพ 22
รูปที่ 5.15 ฟังก์ชัน process_image 23
รูปที่ 5.16 ฟังก์ชัน detect_result 23
รูปที่ 5.17 ฟังก์ชัน classify 23
รูปที่ 5.18 JSON ที่ส่งเป็น Payload ตอนเรียก API 24
รูปที่ 5.19 JSON ใน Body ของ Response จาก API 24

รูปที่ 5.20 ฟังก์ชัน summary 24
รูปที่ 5.21 JSON ที่ส่งเป็น total ตอนเรียก API 24
รูปที่ 5.22 JSON ใน Body ของ Response จาก API 25
รูปที่ 5.23 หน้าหลักของเว็บไซต์ 25
รูปที่ 5.24 หน้าจอแสดงผลลัพธ์มะม่วงปกติ 26
รูปที่ 5.25 หน้าจอแสดงผลลัพธ์มะม่วงแตก 26
รูปที่ 5.26 หน้าจอแสดงผลลัพธ์มะม่วงลาย 27
รูปที่ 5.27 หน้าจอแสดงผลลัพธ์ไม่ได้เลือกไฟล์ 27
รูปผนวกที่ ก.1 หน้าจอหลักของเว็ปแอปพลิเคชั่น 33
รูปผนวกที่ ก.2 หน้าเลือกไฟล์ 33
รูปผนวกที่ ก.3 หน้าแจ้งเตือน 34
รูปผนวกที่ ก.4 หน้าจอแสดงผลลัพธ์มะม่วงปกติ 34
รูปผนวกที่ ก.5 หน้าจอแสดงผลลัพธ์มะม่วงแตก 35
รูปผนวกที่ ก.6 หน้าจอแสดงผลลัพธ์มะม่วงลาย 35

บทที่ 1 บทนำ

1.1 ที่มาและความสำคัญของปัญหา

มะม่วงพันธุ์ฟ้าลั่นมีชื่อวิทยาศาสตร์คือ Mangifera indica Linn ชื่อสามัญ Falan Mango เป็นไม้ยืนต้นอยู่ในวงศ์ Anacardiaceae มะม่วงเป็นผลไม้ในเขตร้อนชื้น เจริญเติบโตได้ดีตั้งแต่เขตศูนย์สูตรขึ้น - ลงไปถึงเส้นรุ้ง 20 องศาเหนือและใต้ ประเทศที่ผลิตมะม่วงเป็นการค้าของโลกมีอยู่ประมาณ 87 ประเทศ ประเทศอินเดียผลิตได้มากที่สุดในโลก ประเทศไทยผลิตได้เป็นอันดับ 7 ของโลก

โดยทั่วไปแล้ว ต้นมะม่วงฟ้าลั่นจะมีความสูงเมื่อเติบโตเต็มที่ประมาณ 10 - 15 เมตร มีทรงพุ่มกว้างราว 5 เมตร มีลักษณะลำต้น ผิวเปลือกสีน้ำตาลลำต้นขรุขระ เห็นร่องเปลือกชัดเจน แตกกิ่งก้านมาก ลักษณะใบเป็นใบเดี่ยวออกวนรอบ ๆ กิ่ง ใบเรียวยาว ปลายใบแหลม ใบอ่อนมีสีแดง ใบแก่สีเขียวจัด ผิวสัมผัสเรียบลื่นไม่มีขน ลักษณะของดอก ดอกประกอบรูปฉัตร สีเหลืองนวล บานจากโคนช่อไปปลายช่อ มีกลิ่นหอม เมื่อร่วงจะมีผลเล็ก ๆ อยู่ภายใน ลักษณะของผล ค่อนข้างยาวปลายผลมน ผลแก่สีเขียวเข้มเคลือบด้วยสีขาวนวลคล้ายแป้ง เนื้อแน่นละเอียด มีรสมัน มักนิยมกินผลแก่ มะม่วงจะออกดอกติดผลในช่วงเดือน พฤศจิกายน – ธันวาคม และเก็บเกี่ยวในเดือน มีนาคม – เมษายน ในการออกผลโตเต็มที่มีขนาดประมาณ 3 - 4 ผล ต่อ 1 กิโลกรัม การขยายพันธุ์มะม่วงฟ้าลั่น สามารถทำได้ทั้งการเพาะเมล็ด ตอนกิ่งและทาบกิ่งเสียบยอด เหมือนมะม่วงทั่วไป และจัดเป็นหนึ่งในพันธุ์มะม่วงที่เกษตรกรนิยมทำการผลิตนอกฤดู เป็นพืชที่ชอบแสงแดด เจริญได้ดีในดินร่วนปนทราย

ในการคัดมะม่วงพันธุ์ฟ้าลั่นก่อนออกสู่ตลาดจะแบ่งระดับคุณภาพออกเป็น 4 เกรด คือ ผลขนาดใหญ่ ผลขนาดกลาง ผลขนาดเล็ก และผลมีตำหนิ คุณลักษณะที่ใช้ในการพิจารณาประกอบด้วยขนาดและรอยบนผิว สามารถเก็บเกี่ยวผลผลิตได้หลังจากเปิดตาดอกวันแรกนับไปอีก 105 - 110 วัน หากเก็บผลผลิตเพื่อส่งออกเวียดนาม หรือมาเลย์ จะเก็บลูกห่าม ๆ ที่อายุครบ 95 วัน เก็บผลสุกขายในประเทศและเก็บผลแก่ 70 - 80% เพื่อส่งออก

การคัดแยกเกรดของมะม่วงจำเป็นต้องอาศัยประสบการณ์และทักษะของผู้คัดเพื่อแยกแยะและตัดสินใจ จากการลงพื้นที่สอบถามเจ้าของสวนมะม่วงพันธุ์ฟ้าลั่นมีข้อผิดพลาดในการทำงานคือไม่สามารถคัดคุณภาพของมะม่วงได้ด้วยตนเองต้องรอคนคัดมะม่วงที่มีประสบการณ์มาคัดให้ ในการคัดแยกโดยใช้สายตาของมนุษย์มีโอกาสเกิดความผิดพลาดขึ้นได้สูง เนื่องจากช่วงสายตาของมนุษย์ในแต่ละบุคคลไม่เท่ากันส่งผลให้เกิดปัญหาการคัดม่วงไม่ได้มาตรฐาน ทำให้ได้ราคามะม่วงต่ำกว่าราคาจริงที่ควรได้รับจากการแยกขนาดผิดเกรด

ด้วยเหตุผลข้างต้น ผู้จัดทำจึงมีแนวคิดพัฒนาระบบที่สามารถคัดแยกเกรดมะม่วงพันธุ์ฟ้าลั่นออกเป็นเกรดต่าง ๆ ด้วยการใช้เทคนิคการประมวลผลภาพด้วยการเรียนรู้เชิงลึก (Deep Learning) โดยสามารถคัดแยกเกรดมะม่วงพันธุ์ฟ้าลั่นได้มาตรฐาน เพื่อช่วยแก้ปัญหาดังกล่าว

1.2 วัตถุประสงค์

1) เพื่อศึกษาและพัฒนาระบบการคัดแยกเกรดมะม่วงพันธุ์ฟ้าลั่นจากภาพถ่าย
2) เพื่อคัดแยกเกรดมะม่วงพันธุ์ฟ้าลั่นผลใหญ่ กลาง เล็ก และผลมีตำหนิ

1.3 ลักษณะและขอบเขต

ข้อมูลที่รับเข้าเป็นข้อมูลภาพ กำหนดความสูงถ่ายจากพื้นที่ 120 เซนติเมตร จากนั้นนำภาพที่ได้มาประมวลผล โดยแบ่งความสามารถออกเป็น 2 ลักษณะ ได้แก่

1) มะม่วงพันธุ์ฟ้าลั่นผลปกติ คือ ผลที่มีผิวเรียบไม่มีตำหนิ แบ่งได้ 3 ขนาด ได้แก่
    1. ผลขนาดใหญ่
    2. ผลขนาดกลาง
    3. ผลขนาดเล็ก
2) มะม่วงพันธุ์ฟ้าลั่นผลมีตำหนิ มี 2 ลักษณะ ได้แก่
    1. มะม่วงพันธุ์ฟ้าลั่นผลแตก คือ ผลที่มีลักษณะผลปริแตกเห็นเนื้อมะม่วง
    2. มะม่วงพันธุ์ฟ้าลั่นผลลาย คือ ผลที่เปลือกมะม่วงมีลายกระจายอยู่

1.4 อุปกรณ์และเครื่องมือที่ใช้

1.4.1 ฮาร์ดแวร์

คอมพิวเตอร์ที่มีคุณสมบัติดังนี้

- หน่วยประมวลผลกลาง Intel(R) Core(TM) i5-8265U CPU @ 1.60GHz 1.80 GHz
- หน่วยความจำ (RAM) 8 GB
- SSD M.2 512 GB
- ฮาร์ดดิสก์ 475 GB
- หน่วยประมวลผลกราฟฟิก NVIDIA GeForce GTX MX250

1.4.2 ซอฟต์แวร์

- ระบบปฏิบัติการ Window 11 Home
- Python Computer Programming Language
- Google Colab Pro
- Outsystems Service Studio 11
- Visual Studio Code

1.5 ผลที่คาดว่าจะได้รับ

1) ได้โปรแกรมที่สามารถแยกเกรดมะม่วงพันธุ์ฟ้าลั่นจากภาพถ่าย
2) สามารถแยกเกรดมะม่วงพันธุ์ฟ้าลั่นผลใหญ่ กลาง เล็ก และผลมีตำหนิได้

บทที่ 2 ผลงานที่เกี่ยวข้อง

ในบทนี้จะกล่าวถึงผลงานที่นำมาเป็นแนวทางในการพัฒนาโครงงานปริญญานิพนธ์นี้ จะอธิบายถึงคุณลักษณะข้อเด่น ข้อด้อย ของแต่ละงาน โดยมีผลงานที่เกี่ยวข้อง ดังนี้

2.1 การคัดแยกเมล็ดพันธุ์ปนในถั่วเขียว โดยการวิเคราะห์ภาพถ่าย [1]

เป็นงานวิจัยการคัดแยกเมล็ดพันธุ์ถั่วเขียวสายพันธุ์ชัยนาท และสายพันธุ์กำแพงแสนที่ปนกัน จากภาพโดยการวิเคราะห์ภาพถ่าย การแยกประเภท (Classification) จากคุณลักษณะโมเมนต์ของ Hu ในระดับที่ 5, 6, และ 7 โดยใช้เครื่องมือ SVM ช่วยในการจำแนกสายพันธุ์ โดยใช้เมล็ดถั่วเขียวสายพันธุ์ละ 100 เมล็ด ในการเทรนโมเดล ดังรูปที่ 2.1 และรูปที่ 2.2 ได้คุณลักษณะโมเมนต์ของ Hu สายพันธุ์ชัยนาท ดังรูปที่ 2.3 และ สายพันธุ์กำแพงแสน ดังรูปที่ 2.4

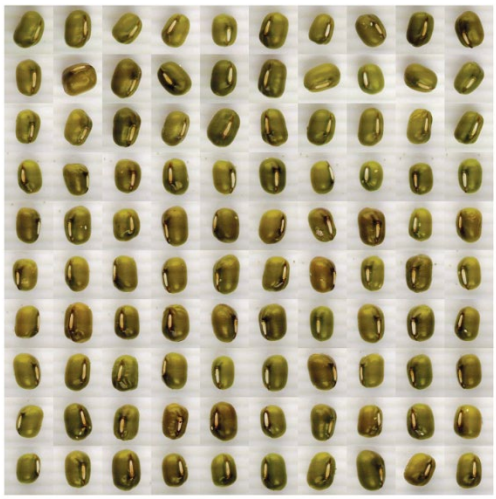

รูปที่ 2.2 เมล็ดถั่วเขียวสายพันธุ์ชัยนาท 72 (10 x 10)

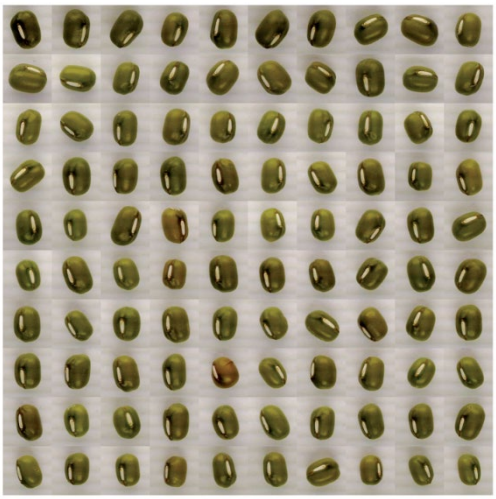

รูปที่ 2.1 เมล็ดถั่วเขียวสายพันธุ์กำแพงแสน 2 (10 x 10)

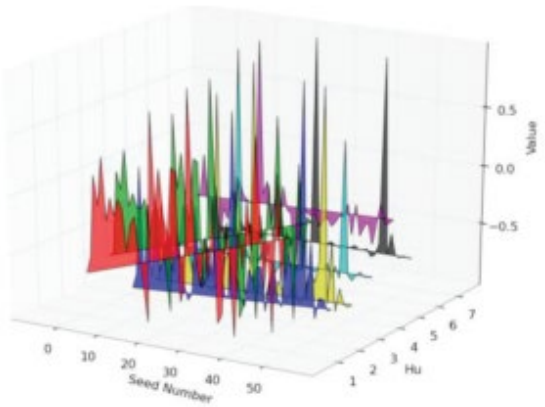

รูปที่ 2.3 Hu's Moments of the CN 72

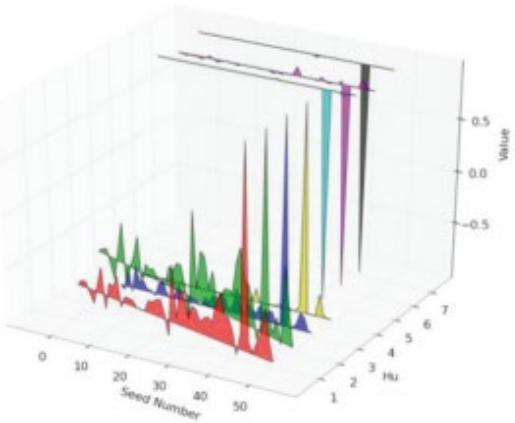

รูปที่ 2.4 Hu's Moments of the KPS 2

2.1.1 ข้อเด่นของระบบ

- สามารถแบ่งแยกชนิดของเมล็ดพันธุ์ถั่วเขียวได้
- สามารถแสดงจำนวนเมล็ดของสายพันธุ์ของถั่วเขียวที่นำมาทดสอบได้

2.1.2 ข้อด้อยของระบบ

- ต้องวางตัวเมล็ดถั่วเขียวตามรูปแบบที่กำหนด
- เมล็ดที่นำมาทดสอบต้องมีสมบูรณ์เท่านั้นระบบจึงวิเคราะห์ได้
- ไม่สามารถวิเคราะห์เมล็ดถั่วเขียวที่วางทับซ้อนกันได้
- วิเคราะห์เมล็ดถั่วเขียวได้รอบละ 100 เมล็ด

2.2 การคัดแยกเกรดยางพาราแผ่นรมควันโดยใช้วิธีการประมวลผลด้วยภาพ [2]

เป็นงานวิจัยการคัดแยกเกรดยางพาราโดยเทคนิคประมวลผลภาพ มาช่วยในการคัดแยกสกัดสิ่งสกปรกบนแผ่นยางจากภาพ การสกัดคุณลักษณะพิเศษจากภาพ (Feature Extraction) โดยใช้คุณสมบัติของความใส สิ่งสกปรก และความสม่ำเสมอของสีบนแผ่นยาง ดังรูปที่ 2.5

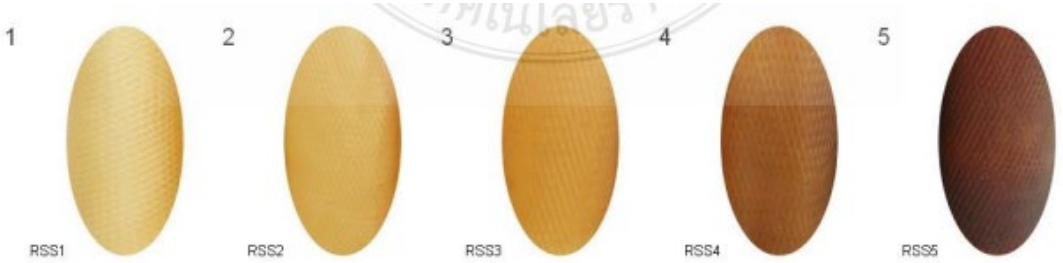

รูปที่ 2.5 ตัวอย่างยางพาราแผ่นนมควัน RSS 1, RSS 2, RSS 3, RSS 4 และ RSS 5

2.2.1 ข้อเด่นของระบบ

- สามารถแยกคุณภาพของยางพาราแผ่นรมควันได้

2.2.2 ข้อด้อยของระบบ

- การแยกภาพในระดับ Gray ได้ความถูกต้องที่ต่ำเนื่องจากแปลงมาจากระดับ RGB

2.3 ระบบตรวจจับวัตถุและป้ายสำหรับผู้ที่บกพร่องทางการมองเห็น [3]

ระบบตรวจจับวัตถุและป้ายสำหรับผู้บกพร่องทางการมองเห็น การทำงานของหลักของระบบมี 3 ส่วน ได้แก่ ส่วนที่ 1 คือ ระบบตรวจจับและจำแนกป้ายสัญลักษณ์ โดยการฝึกฝนตัวต้นแบบด้วยภาพป้าย สัญลักษณ์ 6 ประเภท ได้แก่ ป้ายห้องน้ำชาย ป้ายห้องน้ำหญิง ป้ายห้ามนำอาหารเข้า ป้ายห้ามนำสัตว์เลี้ยงเข้า ป้ายห้ามสูบบุหรี่ และป้ายห้ามถ่ายรูป มีการฝึกฝนตัวต้นแบบที่ใช้ในการแบ่งภาพป้ายออกจากรูปภาพโดยใช้เทคนิค Mask R-CNN ส่วนที่ 2 คือ ระบบการรู้จำภาพอักษร (OCR : Optical Character Recognition) ส่วนที่ 3 คือ ระบบสังเคราะห์ เสียงพูด เป็นระบบที่นำผลลัพธ์ข้อความจากส่วนที่ 1 และ 2 สังเคราะห์เป็นเสียงภาษาไทยแล้วส่งกลับไปยังอุปกรณ์สมาร์ท โฟนเพื่อให้ผู้ใช้ได้ยิน ดังรูปที่ 2.6

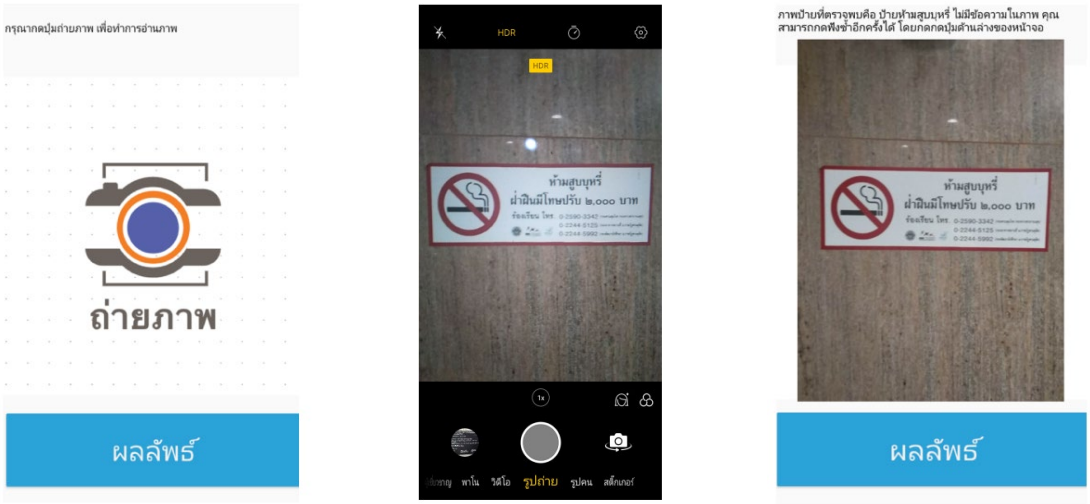

รูปที่ 2.6 แอปพลิเคชันตรวจจับวัตถุและป้ายสำหรับผู้ที่บกพร่องทางการมองเห็น

2.3.1 ข้อเด่นของระบบ

- ระบบสามารถอ่านข้อความ และประมวลผลออกมาเป็นเสียงได้
- ระบบสามารถแปลความหมายของป้ายสัญลักษณ์ได้
- ระบบสามารถเอื้ออำนวยความสะดวกให้ผู้ที่บกพร่องทางการมองเห็นสามรถเดินทางโดยลำพังได้

2.3.2 ข้อด้อยของระบบ

- แอปพลิเคชันรองรับระบบปฏิบัติการ Android เวอร์ชั่น 5.0 ขึ้นไปเท่านั้น
- เนื่องจาก Library Jaided Read OCR ความแม่นยำในการอ่านข้อความภาษาไทยยังไม่ครบถ้วนพอ มีบาง พยัญชนะ สระ วรรณยุกต์ขาดหายไปบ้าง แต่ยังพออ่านเข้าใจได้รู้เรื่อง
- ผู้ใช้จำเป็นต้องมีเครื่องมือเฉพาะในอุปกรณ์โทรศัพท์มือถือ Android ชื่อว่า Talkback ซึ่งเป็นเครื่องมือที่ช่วย ทำให้ผู้บกพร่องทางการมองเห็นสามารถใช้งานสมาร์ทโฟนได้
- การใช้งานแอปพลิเคชัน จำเป็นต้องเชื่อมต่อกับระบบเครือข่ายอินเทอร์เน็ต

บทที่ 3 ทฤษฎีและความรู้ที่เกี่ยวข้อง

ในการจัดทำโครงงานปริญญานิพนธ์เรื่องการคัดแยกเกรดมะม่วงพันธุ์ฟ้าลั่นโดยวิธีการประมวลผลภาพ ผู้พัฒนาได้ทำการค้นคว้าทฤษฎีและความรู้ที่เกี่ยวข้องกับโครงงานที่นำมาใช้พัฒนาระบบได้ ดังนี้

3.1 การแบ่งข้อมูลภาพ (Image Segmentation) [4]

การแบ่งข้อมูลภาพ (Image Segmentation) เป็นการแบ่งข้อมูลภาพออกเป็นส่วนย่อย ๆ ที่แต่ละส่วนจะมีพื้นที่ต่อกันไป แต่ละส่วนจะเป็นพื้นที่ซึ่งอาจจะแทนวัตถุที่อยู่ในภาพ เซ็กเม็นเตชันจะเสร็จเมื่อวัตถุที่ต้องการถูกแบ่งออกได้สมบูรณ์ ผลลัพธ์ที่ได้จากการเซ็กเม็นต์จะเป็นตัวชี้วัดความสำเร็จในขั้นตอนการวิเคราะห์ภาพด้วยคอมพิวเตอร์

การทำ Segmentation จะทำให้สามารถแยกข้อมูลภาพของส่วนที่ต้องการออกมาได้ (ข้อมูลที่มีลักษณะเหมือนกับข้อมูล ตัวอย่าง) วิธีการพื้นฐานสำหรับการ Segmentation คือการพิจารณา Image Amplitude (ได้แก่การพิจารณาความสว่างของ ภาพสำหรับภาพแบบ Gray Scale และความแตกต่างของสีสำหรับภาพสี) นอกจากนี้ขอบของภาพและลักษณะของ Texture ก็เป็นองค์ประกอบหนึ่งที่จะทำให้สามารถ Segmentation ได้สะดวกยิ่งขึ้น ลักษณะการแยกจะขึ้นอยู่กับวัตถุประสงค์ที่จะนำไปใช้งานต่อ เช่น เพื่อวิเคราะห์รูปลักษณะของวัตถุ เพื่อคำนวณขนาด ของวัตถุ เพื่อนับจำนวนวัตถุภายในภาพ ดังรูปที่ 3.1

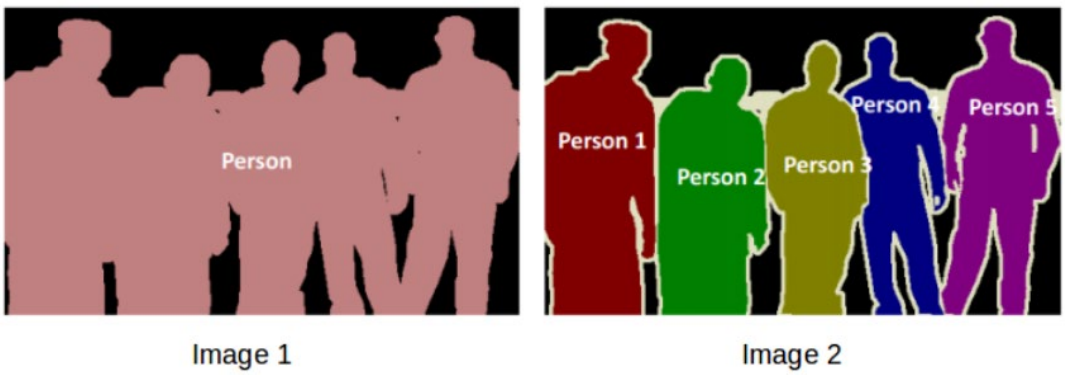

รูปที่ 3.1 การทำ Image Segmentations เพื่อแยกบุคคลทั้งหมดและแยกจำนวนบุคคลที่อยู่ในภาพ
(ที่มา : https://analyticsvidhya.com/blog/2019/04/introduction-image-segmentation-techniques-python)

3.2 การเรียนรู้เชิงลึก Deep Learning [7]

การเรียนรู้เชิงลึก เป็นสาขาของการเรียนรู้ของเครื่อง (Machine Learning) โดยใช้โครงข่ายประสาทเทียม (Artificial Neural Network) การเรียนรู้เชิงลึกนั้นถือว่าเป็นวิธีการที่มีศักยภาพสูงในการกับฟีเจอร์สำหรับการเรียนรู้แบบมีผู้สอน (Supervised Learning) หรือการเรียนรู้แบบไม่มีผู้สอน (Unsupervised Learning) ซึ่งในงานวิจัยนี้เป็นการเรียนรู้แบบมีผู้สอน คือ ผู้พัฒนาเป็นคนนำภาพที่ต้องการรู้จำ ไปฝึกฝนให้เครื่อง เสมือนคุณครูที่ต้องสอนหนังสือแล้วบอกว่าสิ่งนี้คืออะไร เมื่อนักเรียนจำคำตอบได้นักเรียนจะสามารถเรียนรู้และตอบได้ในการถามครั้งต่อไป

3.2.1 โครงข่ายประสาทเทียม (Artificial Neural Network: ANN)

โครงข่ายประสาทเทียม หมายถึง ระบบคอมพิวเตอร์ที่สร้างขึ้นเพื่อเลียนแบบเส้นใยประสาทของมนุษย์ ที่เรียกว่า นิวรอน (Neurons) เพื่อที่จะจำลองการทำงานของเครือข่ายประสาทในสมองมนุษย์ด้วยวัตถุประสงค์ที่จะสร้างเครื่องมือซึ่งมีความสามารถในการเรียนรู้จดจำเช่นเดียวกับความสามารถที่มีในสมองมนุษย์ แนวคิดเริ่มต้นของเทคนิคนี้ได้มาจากการศึกษาข่ายงานไฟฟ้าชีวภาพ (Bioelectric Network) ในสมอง ซึ่งประกอบด้วย เซลล์ประสาท หรือ นิวรอน (Neurons) และ จุดประสานประสาท (Synapses) แต่ละเซลล์ประสาทประกอบด้วยปลายในการรับกระแสประสาท เรียกว่า เดนไดร์ท (Dendrite) ซึ่งเป็น Input และปลายในการส่งกระแสประสาทเรียกว่า แอคซอน (Axon) ซึ่งเป็นเหมือน Output ของเซลล์

ในคอมพิวเตอร์ Neurons ประกอบด้วย Input และ Output โดยจำลองให้ Input แต่ละอันมี Weight เป็นตัวกำหนดน้ำหนักของ Input นำ Neurons แต่ละหน่วยมาต่อกันให้ทำงานร่วมกัน ดังรูปที่ 3.2 โดยโครงข่ายประสาทเทียมที่มี Hidden Layer ตั้งแต่ 3 Layer ขึ้นไปเรียกว่า Deep network หรือ Deep Learning

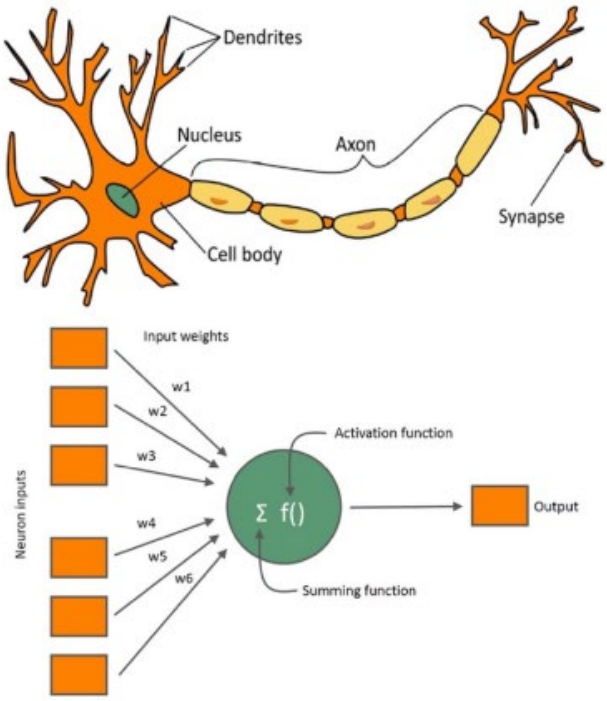

รูปที่ 3.2 การเปรียบเทียบเซลล์ประสาทของมนุษย์กับเซลล์จำลองในโครงข่ายประสาทเทียม
(ที่มา : https://www.ee.co.za/article/application-of-machine-learning-algorithms-in-boiler-plant-root-cause-analysis.html)

3.2.2 โครงข่ายประสาทแบบคอนโวลูชัน (Convolution Neural Network : CNN)

เป็นโครงข่ายประสาทเทียมหนึ่งในกลุ่ม Bio-Inspired โดยที่ CNN จะจำลองการมองเห็นของมนุษย์ที่มองพื้นที่เป็น พื้นที่ย่อย ๆ และนำกลุ่มของพื้นที่ย่อยมาผสานกัน การมองพื้นที่ย่อยของมนุษย์จะมีการแยกคุณลักษณะ (Feature) ของพื้นที่ย่อยนั้น เช่น การมองภาพใบหน้าคน เกิดจากการมองส่วนย่อย ๆ ไม่ว่าจะเป็น ดวงตา จมูก ปาก หูคิ้ว แล้วนำแต่ละส่วนย่อย เหล่านี้มาพิจารณาจากตำแหน่งและลักษณะว่าคือ ภาพหน้าคน โดยรูปที่ 3.5 นำภาพใบหน้าคนหนึ่งคน เป็นข้อมูลเข้าในชั้น Input Layer จากนั้นในแต่ละชั้นของ Hidden Layer สามารถพิจารณา

ส่วนต่าง ๆ ที่แตกต่างกัน โดย Hidden Layer 1 จะ พิจารณาภาพในส่วนของขอบ (Edges) ในมุมต่าง ๆ จากนั้นใน Hidden Layer 2 จะพิจารณาในส่วนที่ใหญ่ขึ้นไปคือนำขอบใน แต่ละอันมารวมกันเป็นอวัยวะหูตา จมูก ปาก และในชั้น Hidden Layer 3 จะพิจารณาถึงลักษณะของวัตถุที่ได้ก่อนจำแนก ออกมาทาง Output Layer ดังรูปที่ 3.3

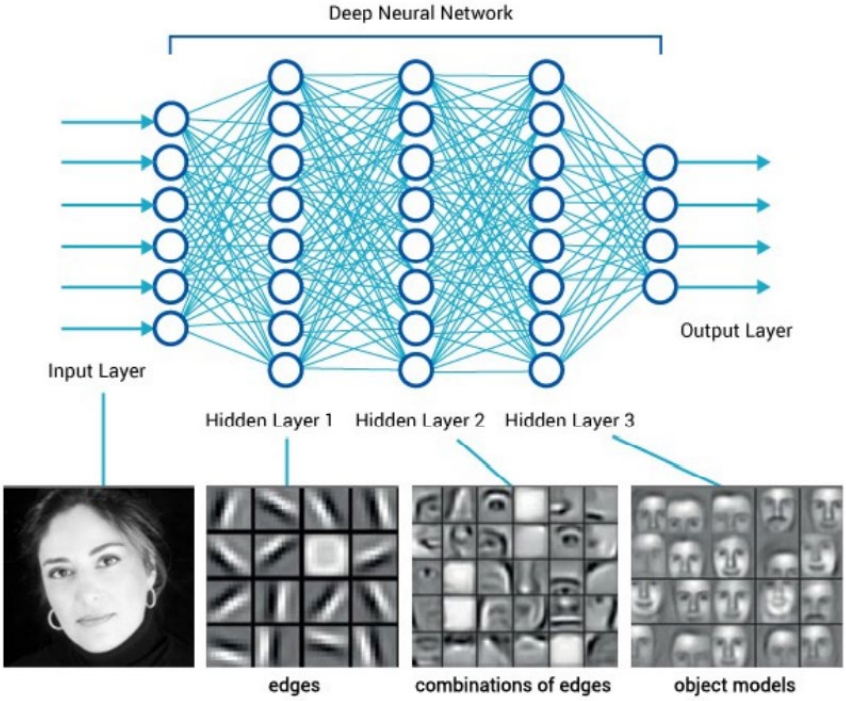

รูปที่ 3.3 โครงข่ายประสาทแบบคอนโวลูชัน (Convolution Neural Network)
(ที่มา : https://medium.com/diaryofawannapreneur/deep-learning-for-computer-vision-for-the-average-person-861661d8aa61)

3.2.3 การเรียนรู้แบบมีผู้สอน (Supervised Learning)

รูปแบบการเรียนรู้แบบมีผู้สอน เริ่มต้นด้วยการส่งสิ่งเร้าที่ใช้ในการสอนเข้าไปเป็น Input Data ในโครงข่ายประสาทเทียม เพื่อให้โครงข่ายประสาทเทียมสร้างผลตอบออกมาเป็น Output Data ซึ่งผลตอบจะเป็นอย่างไร ขึ้นอยู่กับสภาวะในตอนที่เริ่มเรียนรู้ของโครงข่ายประสาทเทียม ผลตอบดังกล่าวจะถูกนำมาเปรียบเทียบกับผลเฉลย (Target Output) ซึ่งผู้สอนจะเป็นผู้สร้างขึ้น หากผลตอบทั้งสองมีความแตกต่างกัน นั่นคือมีความคลาดเคลื่อน (Error) เกิดขึ้น ความคลาดเคลื่อนดังกล่าวถูกนำไปคำนวณการปรับแต่งค่าน้ำหนักต่าง ๆ ในโครงข่ายประสาทเทียม เพื่อลดความคลาดเคลื่อนลงให้เหลือน้อยที่สุด วิธีการส่วนใหญ่ของการเรียนรู้แบบมีผู้สอนนี้จะดัดแปลงมาจากวิธีการทางคณิตศาสตร์ในเรื่องของเทคนิคการหาค่าเหมาะสม (Optimization Technique)

3.3 Mask R-CNN [5]

Mask R-CNN คือ Instance Segmentation Model ที่ช่วยให้เราสามารถระบุตำแหน่ง Pixel ในภาพได้ฉลาดขึ้น คำว่า “Instance Segmentation” หมายถึง การแบ่งกลุ่มวัตถุแต่ละชิ้นภายในภาพโดยไม่คำนึงว่าเป็นวัตถุประเภทเดียวกัน เช่น การระบุรถยนต์แต่ละคัน การระบุบุคคลเป็นรายคน เป็นต้น Mask R-CNN นั้นแตกต่างจากตัวต้นแบบ Faster R-CNN ตรงที่ Mask R-CNN สามารถระบุ Class และตำแหน่งกล่องขอบเขต (Bounding Box) เหมือนกับ Faster R-CNN แต่ตัวต้นแบบ Mask R-CNN นั้นยังสามารถแสดง Pixel สีในขอบเขตเพื่อความชัดเจนในการแบ่งแยกวัตถุได้โดยตัวอย่าง รูปทางด้านซ้าย เป็นรูปที่ได้จากการ Detection ของ Faster R-CNN และรูปทางด้านขวาเป็นรูปที่ได้จากการ Detection ของ Mask R-CNN ซึ่งจะเห็นได้ว่ารูปที่ได้จากตัวต้นแบบ Mask R-CNN สามารถแสดงขอบเขตได้หลากสีเพื่อแบ่งแยกวัตถุให้ชัดเจนได้ ดังรูปที่ 3.4

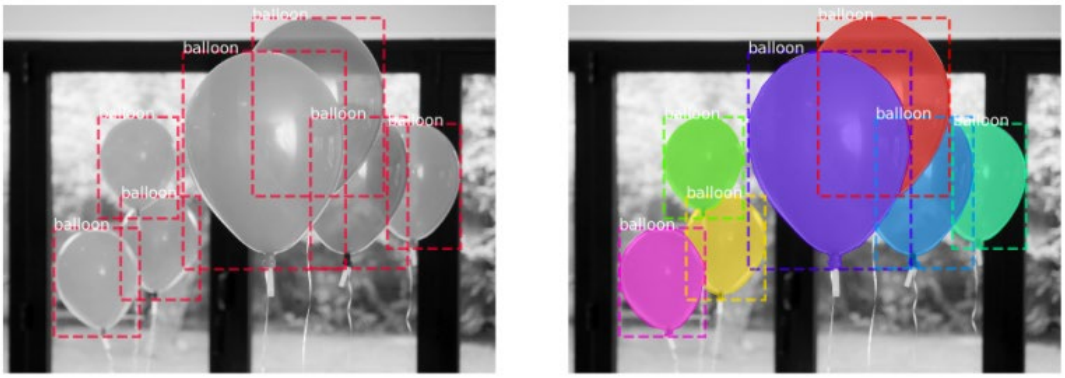

รูปที่ 3.4 การเปรียบเทียบ Object Detection ระหว่างตัวต้นแบบ Faster R-CNN และตัวต้นแบบ Mask R-CNN
(ที่มา : https://medium.com/@tibastar/mask-r-cnn-d69aa596761f)

3.4 TensorFlow [6]

TensorFlow คือ Deep Learning Library ซึ่งเป็นไลบรารีอย่างหนึ่ง ช่วยให้มีประสิทธิภาพทั้งในแง่ความเร็วของผลลัพธ์ แล ในแง่ผลลัพธ์ที่ถูกต้องแม่นยำมากขึ้น โดย Google เป็นคนสร้างเฟรมเวิร์คที่ชื่อว่า TensorFlow ขึ้นมา เพื่อให้นักวิจัย และนักพัฒนาทำงานกับโมเดล AI ได้ อีกทั้งยังทำไว้เพื่อสร้างสถาปัตยกรรมแบบ Deep Learning อย่าง CNN และ RNN โดย อัลกอริทึมเด่น ที่ TensorFlow รองรับ คือ Classification, Deep Learning Classification เป็นต้น โดยด้านสถาปัตยกรรม TensorFlow แบ่งเป็น 3 ส่วน

1. การเตรียมประมวลผล
2. การสร้างแบบจำลอง
3. ฝึกและ ประเมินแบบจำลอง

การที่ TensorFlow รับข้อมูลเป็นอาร์เรย์หลายมิติ หรือที่เรียกกันว่า Tensors และเรามีหน้าที่จัด เรียงลำดับการประมวลผลเป็น Flowchart (หรือที่เรียกว่ากราฟ) ข้อมูลที่ถูกป้อนไปจะผ่าน (Flow) กระบวนการจนออกมาเป็นผลลัพธ์ TensorFlow สามารถทำงานได้หลายแพลตฟอร์ทั้ง คอมพิวเตอร์ตั้งโต๊ะที่ใช้ระบบปฏิบัติการ Windows, MacOS or Linux, คลาวด์หรือเว็บเซอร์วิซ, มือถือทั้ง iOS and Android สามารถฝึก TensorFlow จากคอมพิวเตอร์หลายเครื่อง ทำงานได้จากหลากหลายอุปกรณ์ เมื่อมีโมเดลจำลองการฝึกแล้ว (Train Model) TensorFlow ถูกเขียนขึ้นจากภาษา C++ และ Python ฟีเจอร์สำคัญของ TensorFlow คือ Tensor Board เป็น GUI ช่วยให้นักพัฒนาเห็น กระบวนการทำงานของ TensorFlow ได้

3.5 Make Sense [8]

Make sense เป็นเครื่องมือที่ใช้ทำ Label ในการอธิบายข้อมูลภาพ ซึ่งเครื่องมือนี้ทำงานในเว็บเบราว์เซอร์เพียงอย่างเดียวและไม่จำเป็นต้องติดตั้งหรือตั้งค่าใด ๆ ความสามารถของ Make sense นั้นสามารถกำหนดรูปร่างของวัตถุ (Object) โดยใช้การลากเส้นรูปแบบต่าง ๆ มาวาดล้อมรอบวัตถุที่ต้องการ อาทิ จุด (Point) อิสระ (Polyline) อีกทั้งเราสามารถกำหนดคุณลักษณะ (Region Attributes) ให้วัตถุที่ได้กำหนดไว้แล้วได้ซึ่ง Region Attributes นี้จะนำไป Match กันกับ Class ใน Model ที่ใช้ในการฝึกรู้จำ โดยผลลัพธ์ที่ได้จากการใช้เครื่องมือนี้จะเป็นไฟล์ json ที่มีข้อมูลของการกำหนดรูปร่างของวัตถุเอาไว้เป็นตัวเลขบอกพิกัดในรูปแบบแกน x และ y รวมทั้งชื่อ คุณลักษณะต่าง ๆ ที่ได้กำหนดไว้ ดังรูปที่ 3.5 เป็นตัวอย่างการทำ Label ของลูกมะม่วง เมื่อเรากำหนดขอบเขตให้วัตถุเรียบร้อย ไฟล์ผลลัพธ์จะเป็นลักษณะ json ที่เก็บค่าคุณลักษณะของภาพที่ได้กำหนดไปแล้ว อาทิ ชื่อไฟล์ (File Name) ขนาด (Size) และขอบเขต (Regions) เป็นต้น ดังรูปที่ 3.6

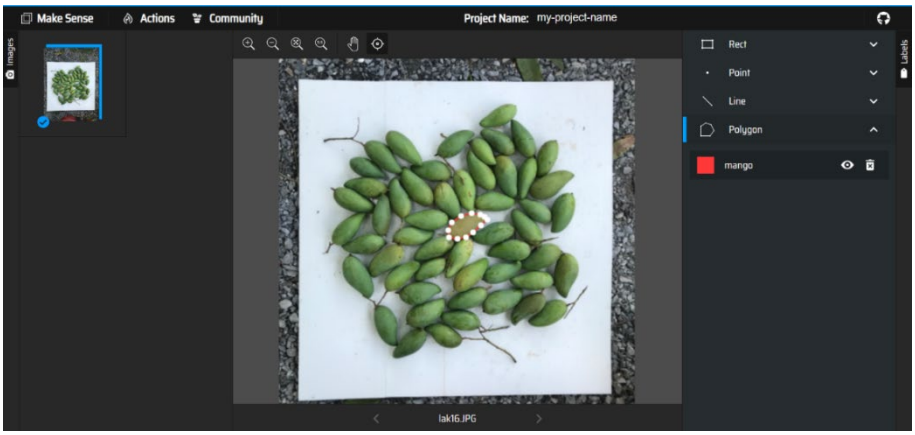

รูปที่ 3.5 การใช้เครื่องมือ Make sense กำหนดขอบเขตลูกมะม่วงบนรูปภาพ


```
{
    "lak16.JPG":{
        "fileref":"","size":258494,
        "filename":"lak16.JPG",
        "base64_img_data":"",
        "file_attributes":{},
        "regions":{
            "0":{
                "shape_attributes":{
                    "name":"polygon",
                    "all_points_x":[
                        215.171889232413,
                        214.27502824586594,
                        218.75933317860137,
                        230.41852600371345,
                        243.87144080191973,
                        254.63377264048475,
                        260.01493855976724,
                        263.6023825059556,
                        255.53063362703185,
                        245.6651627750139,
                        236.69655290954304,
                        225.93422107097803,
                        215.171889232413],
                    "all_points_y":[
                        312.70553178316794,
                        303.7369219176971,
                        293.8714510656792,
                        285.7997021867554,
                        282.21225824056705,
                        284.00598021366125,
                        286.6965631733025,
                        290.2840071194908,
                        297.4588950118675,
                        306.4275048773384,
                        312.70553178316794,
                        314.49925375626214,
                        312.70553178316794]},
                "region_attributes":{
                    "label":"mango"
                }
            }
```


รูปที่ 3.6 ผลลัพธ์หลังจากกำหนดขอบเขตให้กับลูกมะม่วง ซึ่งเป็นไฟล์รูปแบบ json

3.6 วิธีการเพิ่มประสิทธิภาพการทำนายภาพด้วยเทคนิคการขยายภาพ (Image Data Augmentation) [3]

วิธีการเพิ่มประสิทธิภาพการรู้จำภาพมาจากงานวิจัย “Learning Data Augmentation Strategies for Object Detection” โดยผู้พัฒนาคือ Barret Zoph, Ekin D. Cubuk, Golnaz Ghiasi, Tsung-Yi Lin, Jonathon Shlens และ Quoc V. Le จากทีมวิจัยของ Google, Brain Team ซึ่งงานวิจัยนี้ ทดลองเกี่ยวกับการใช้เทคนิคการขยายภาพ (Image Data Augmentation) แบบใดที่จะช่วยส่งผลให้ประสิทธิภาพการทำนายแม่นยำที่ดีขึ้น โดยการทดลองนี้ นำภาพมาเข้าเทคนิคการขยายภาพ 9 เทคนิค มาฝึกฝนรู้จำ แล้วดูผลลัพธ์ความแม่นยำหลังฝึก เพื่อหาว่าเทคนิคแบบใดให้ประสิทธิภาพที่ดีเหมาะแก่การใช้งานมากที่สุด วิธีการทดสอบ แบ่งเป็น 5 วิธีมีดังนี้

Sub-policy 1. (Color, 0.2, 8), (Rotate, 0.8, 10) เป็นการปรับช่วงสีและหมุนภาพ

Sub-policy 2. (BBox Only ShearY, 0.8, 5) เป็นการตัดภาพเฉพาะวัตถุโดยขยับตามแกน Y

Sub-policy 3. (SolarizeAdd, 0.6, 8), (Brightness, 0.8, 10) เป็นการเพิ่มแสงอาทิตย์และความสว่างให้กับภาพ

Sub-policy 4. (ShearY, 0.6, 10), (BBox Only Equalize,0.6, 8) เป็นการตัดภาพขยับตามแกน Y และเกลี่ยภาพเฉพาะวัตถุที่ได้ตีกรอบเอาไว้เท่านั้นให้มีความเข้มเท่ากันทั้งภาพ

Sub-policy 5. (Equalize, 0.6, 10), (TranslateX, 0.2, 2) เป็นการเกลี่ยภาพให้มีความเข้มเท่ากันทั้งภาพ และขยับย้ายภาพตามแกน X ดังรูปที่ 3.7

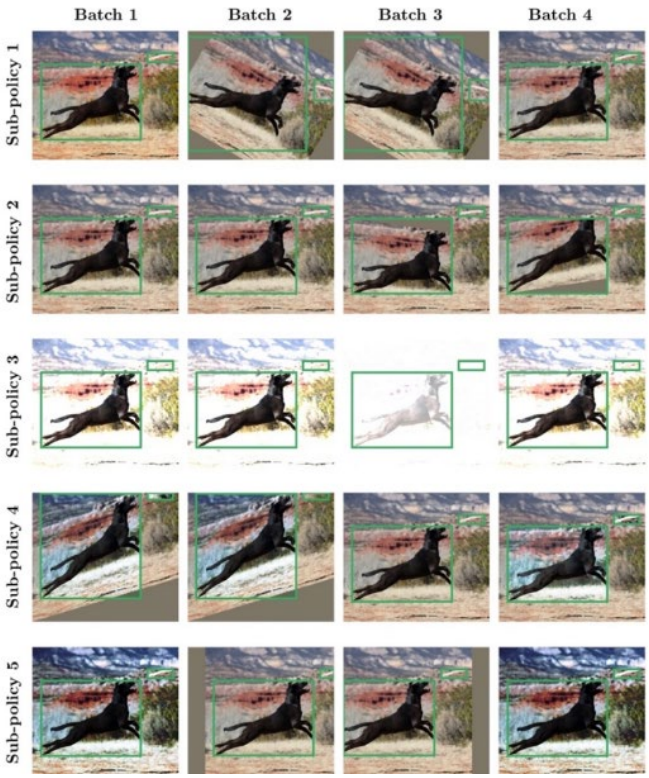

รูปที่ 3.7 ตัวอย่างภาพจากการทดลอง 5 แบบ ในการวัดหาประสิทธิภาพในการรู้จำวัตถุ

(ที่มา : https://deepai.org/publication/learning-data-augmentation-strategies-for-object-detection)

:

จากการทดลองของงานวิจัยที่ได้กล่าวถึงข้างต้น ผู้พัฒนาจาก Google ได้ให้ผลลัพธ์มาว่า การหมุน (Rotate) เป็นวิธีการที่ให้ผลลัพธ์การทดลองได้ดีที่สุด ในบรรดาการทดลองอย่างอื่น ๆ

3.7 Outsystems [9]

Outsystems เป็น Low-Code Development Platform เครื่องมือสำหรับพัฒนาโปรแกรม ใน Style Agile ที่เน้นความรวดเร็วด้านการสร้าง Mobile Application และ Web Application ผู้ใช้สามารถเลือกกำหนดหน้าจอการแสดงผลของ Application ด้วยตนเองได้, เลือกเชื่อมต่อกับระบบฐานข้อมูลที่เกี่ยวข้องภายในองค์กรเพื่อนำข้อมูลที่เกี่ยวข้องมาใช้ทำงานได้, เชื่อมต่อกับระบบต่าง ๆ ทั้งภายในและภายนอกองค์กรผ่าน API ที่มีอยู่ได้ และกำหนด Business Logic ในแต่ละส่วนของระบบ Application ได้ เมื่อทำการพัฒนาจนเสร็จผู้ใช้งานสามารถเลือกนำ Application ของตนเองนี้ไปเปิดใช้งานได้ทันที ทั้งภายใน Data Center ขององค์กรหรือบน Cloud และ Application ที่ถูกพัฒนาขึ้นนี้สามารถถูกเรียกใช้งานได้ทั้งบน Desktop และ Mobile โดยโปรแกรม Out Systems มีลักษณะดังรูปที่ 3.8

รูปที่ 3.8 ตัวอย่างโปรแกรม Outsystems

(ที่มา : https://www.techtalkthai.com/what-is-low-code-development-platform-by-outsystems/)

บทที่ 4 ขั้นตอนและแผนการดำเนินงาน

บทนี้ประกอบไปด้วยตารางแผนการปฏิบัติงานต่าง ๆ ที่แสดงถึงขั้นตอนการดำเนินงาน ระยะเวลาที่ใช้ในการดำเนินงาน และรายละเอียดของการดำเนินงานของโครงงานทั้งหมด

4.1 ขั้นตอนการดำเนินงาน

4.1.1 คิดหัวข้อโครงงานและรวบรวมข้อมูล

- คิดหัวข้อโครงงาน
- สัมภาษณ์หาปัญหาที่เกิดขึ้นกับเจ้าของสวนมะม่วง
- รวบรวมข้อมูลที่เกี่ยวข้องกับโครงงาน

4.1.2 กำหนดขอบเขตและวางแผนการดำเนินงาน

- กำหนดขอบเขตโครงงาน
- วางแผนการดำเนินงาน

4.1.3 ศึกษาความรู้และทฤษฎีที่เกี่ยวข้อง

- สืบค้นทฤษฎี และความรู้ที่เกี่ยวข้อง
- ศึกษาภาษา Python
- ศึกษาวิธีการเขียน Model
- ศึกษาการเขียนแอปพลิเคชัน

4.1.4 วิเคาะห์และออกแบบระบบ

- วิเคราะห์การทำงานในส่วนต่าง ๆ ของระบบ
- ออกแบบระบบของการทำงาน
- ออกแบบหน้าแอปพลิเคชัน

4.1.5 พัฒนาระบบ

- สร้างโปรแกรมด้วย Python
- เขียนแอปพลิเคชันตามที่ออกแบบ
- นำโปรแกรมรวมเข้ากับแอปพลิเคชัน

4.1.6 ทดสอบและปรับปรุงระบบ

- ทดสอบโปรแกรมที่พัฒนาขึ้น และตรวจสอบความผิดพลาดของโปรแกรม
- แก้ไขข้อผิดพลาดของโปรแกรม

4.1.7 จัดทำเอกสารประกอบโครงงาน

- จัดทำเอกสารรายละเอียดของโครงงาน ตั้งแต่เริ่มต้นจนถึงขั้นตอนสุดท้ายของโครงงาน

4.2 แผนการดำเนินงาน

ตารางที่ 4.1 ตารางขั้นตอนและแผนการดำเนินงาน

ขั้นตอนการดำเนินงาน	เดือน							
	เม.ษ. 2565	พ.ค. 2565	มิ.ย. 2565	ก.ค. 2565	ส.ค. 2565	ก.ย. 2565	ต.ค. 2565	พ.ย. 2565
1. คิดหัวข้อโครงงาน และรวบรวมข้อมูล	↔							
2. กำหนดขอบเขตและวางแผนการดำเนินงาน	↔	↔						
3. ศึกษาความรู้และทฤษฎีที่เกี่ยวข้อง		↔	↔	↔	↔			
4. วิเคาะห์และออกแบบระบบ		↔	↔	↔	↔			
5. พัฒนาระบบ		↔	↔	↔	↔	↔		
6. ทดสอบและปรับปรุงระบบ							↔	↔
7. จัดทำเอกสารประกอบโครงงาน		↔	↔	↔	↔	↔	↔	↔

บทที่ 5 การวิเคราะห์และออกแบบระบบ

ในบทนี้จะกล่าวถึงกระบวนการดำเนินงานของระบบ โครงสร้างการทำงานของระบบ โดยจะแสดงทั้งโครงสร้างภาพรวม และโครงสร้างแต่ละส่วนของระบบ

5.1 หลักการทำงานของระบบ

ระบบจะประกอบไปด้วย 2 กระบวนการหลัก คือ กระบวนการวิเคราะห์ภาพมะม่วงโดยทำ Image Segmentation ด้วยตัวต้นแบบ Mask R-CNN เพื่อแยกวัตถุในภาพ แยกผลมะม่วงออกจากพื้นหลังและกระบวนการ Classify เพื่อทำนายเกรดมะม่วง การทำงานส่วนแรกเริ่มจาก Label Dataset เพื่อจับมะม่วงในภาพได้เป็นไฟล์ json นำเข้ากระบวนการ Train Model Mask R-CNN เพื่อแยกวัตถุในภาพ (Image Segmentation) ส่วนที่สองเริ่มจาก Label Dataset แยกเป็น Train Test และ Validation เพิ่มความหลากหลายของ Dataset ด้วยการทำ Augmentation นำเข้ากระบวนการ Train Model Classify เพื่อทำนายเกรดมะม่วง ดังรูปที่ 5.1

การทำงานแอปพลิเคชันจะรับไฟล์ภาพเข้าจากอุปกรณ์ของผู้ใช้เข้าสู่กระบวนการแยกวัตถุในภาพ วัตถุที่แยกได้เข้าโมเดล Classify เพื่อทำนายเกรดมะม่วง ได้เป็น ผลปกติ ผลแตก ผลลาย และแยกขนาดมะม่วงเป็น ใหญ่ กลาง เล็ก ส่งผลลัพธ์ที่ได้ออกทางหน้าจอแอปพลิเคชันให้ผู้ใช้ทราบ

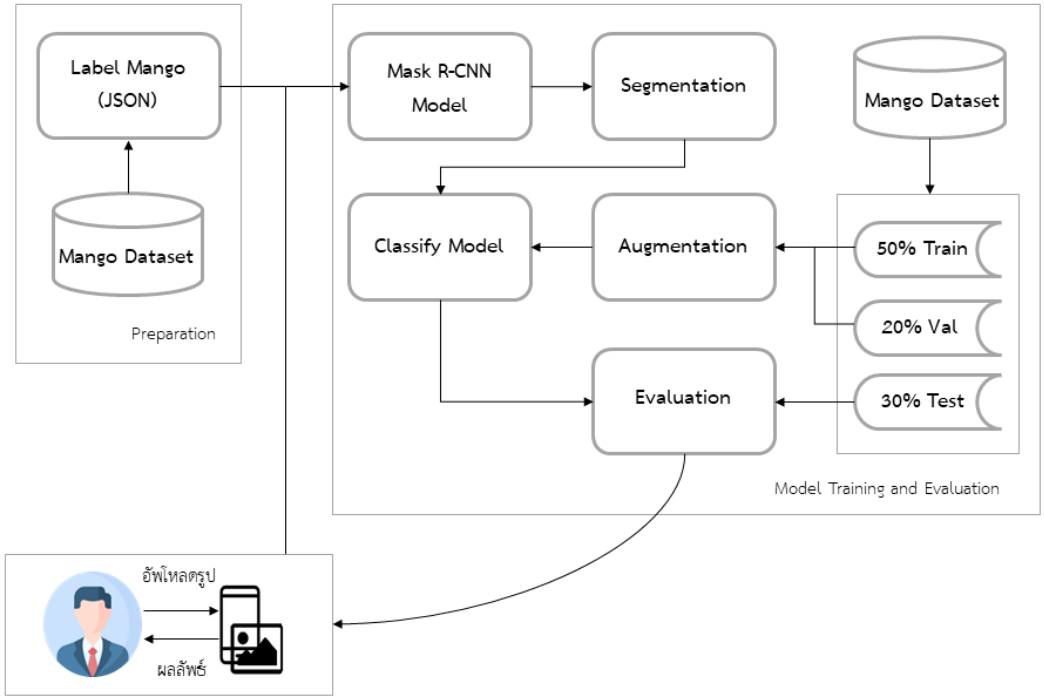

รูปที่ 5.1 ภาพรวมการทำงานของระบบ

5.2 แผนผังการทำงานโดยรวมของระบบ (Flow Chart Diagram)

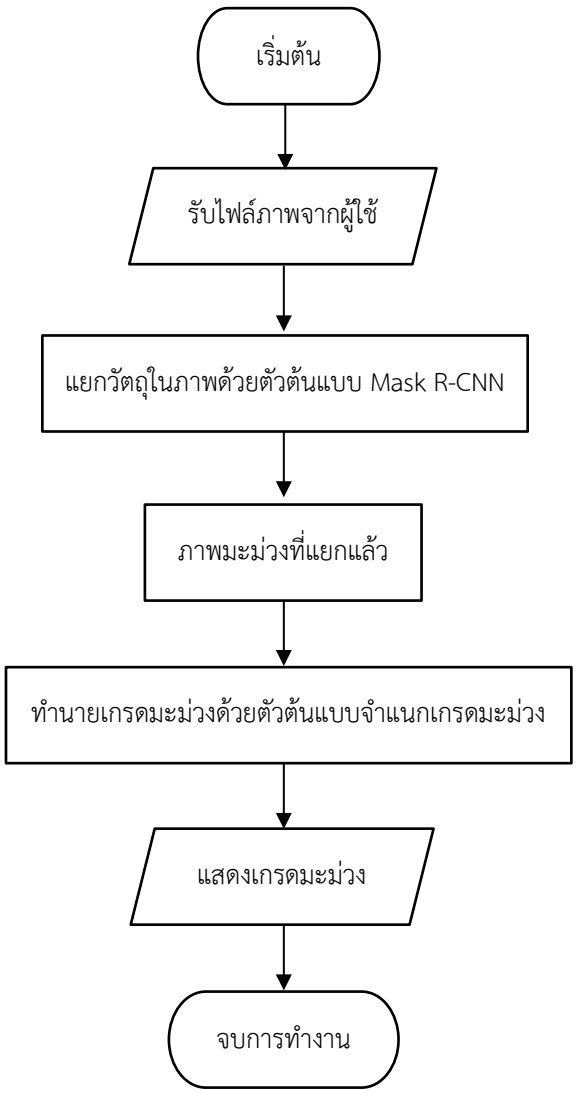

รูปที่ 5.2 แผนผังการทำงานโดยรวมของระบบ (Flow Chart Diagram)

จากรูปที่ 5.2 การทำงานของระบบจะรับไฟล์ภาพเข้าจากอุปกรณ์ของผู้ใช้ เข้าสู่กระบวนการแยกวัตถุในภาพ วัตถุที่แยกได้เข้าโมเดล Classify เพื่อทำนายเกรดมะม่วง ได้เป็น ผลปกติ ผลแตก ผลลาย และแยกขนาดมะม่วงเป็น ใหญ่ กลาง เล็ก ส่งผลลัพธ์ที่ได้ให้ผู้ใช้ทราบ

5.3 วิธีการฝึกโมเดลทำนายเกรดมะม่วง

การฝึกฝนโมเดลเพื่อใช้ในการทำนายเกรดมะม่วง 3 ประเภท ได้แก่ ผลปกติ ผลลาย และผลแตก ซึ่งภาพเหล่านี้ผู้จัดทำได้ทำการเก็บข้อมูลภาพแต่ละประเภทที่นำมาใช้ฝึกรู้จำจากสวนมะม่วงฟ้าลั่นของที่บ้าน

Dataset มะม่วง เข้าสู่กระบวนการรู้จำภาพ เพื่อจำแนกเกรดมะม่วง โดยภาพที่ใช้ฝึกเป็นภาพลูกมะม่วง ผลปกติ ผลลาย และผลแตก จำนวนภาพละ 300 250 และ 170 ตามลำดับ แบ่งข้อมูลภาพเป็น Train Test และ Validation 50:30:20

ซึ่งภาพที่ใช้ฝึกนั้นใช้เทคนิคการขยายภาพ (Image Data Augmentation) เพื่อให้ข้อมูลภาพมีความหลากหลายและ ช่วยลดปัญหาการเกิด Over Fitting ของการฝึกเรียนรู้จำโมเดล ดังรูปที่ 5.3

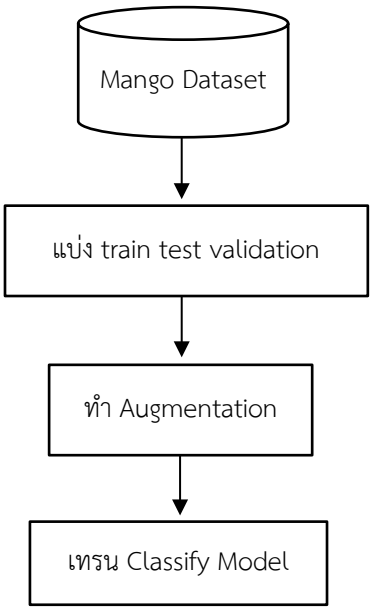

รูปที่ 5.3 ขั้นตอนการเทรนโมเดล Classify

จัดเตรียมข้อมูลภาพแยกเป็นผลปกติ ผลลาย และผลแตก สำหรับใช้ทำ Dataset ดังรูปที่ 5.4

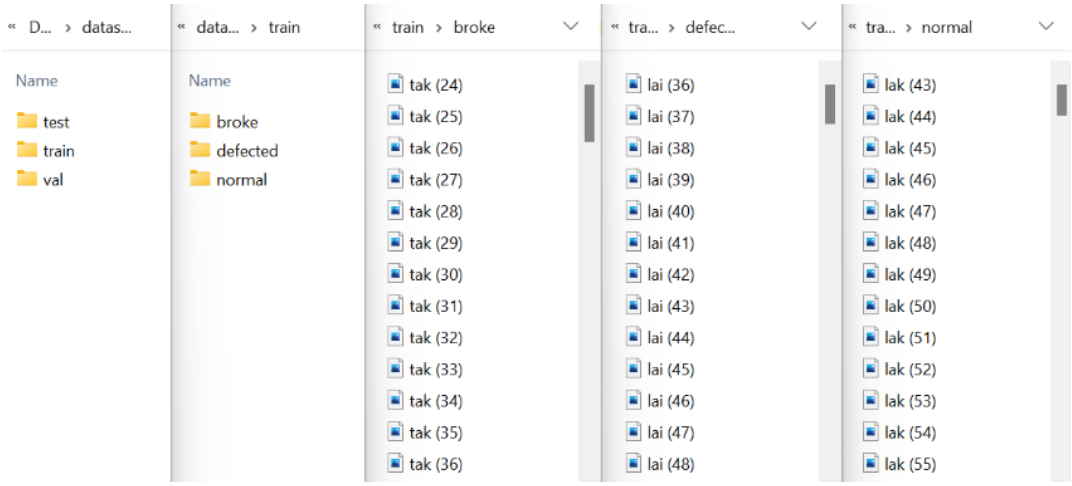

รูปที่ 5.4 แสดงโฟลเดอร์ในการเก็บภาพลูกมะม่วง

ใช้เทคนิคการขยายภาพ (Image Data Augmentation) ดังรูปที่ 5.5

```
[ ] datagen = ImageDataGenerator(rescale = 1. /255,
                                 height_shift_range = 0.2,
                                 width_shift_range = 0.2,
                                 shear_range = 0.2,
                                 zoom_range = 0.3,
                                 rotation_range = 30,
                                 vertical_flip = True,
                                 horizontal_flip=True)

    val_test_datagen = ImageDataGenerator(rescale = 1./255)
```

รูปที่ 5.5 การใช้เทคนิค Augmentation

โดยการฝึกฝนโมเดล ใช้จำนวนรอบการฝึก (Epoch) จำนวน 200 epoch ใช้ Batch Size คือ 32 ใช้ Optimizer (อัลกอริทึมที่ใช้สำหรับปรับค่าน้ำหนักในเส้นเชื่อม (Node)) คือ Adam และ ใช้ Loss Function (อัลกอริทึมที่ช่วยทำให้ค่า Loss น้อยลงและหมาะสม) คือ Categorical Crossentropy กำหนดชั้น Layer ที่ใช้ฝึกฝน ได้แก่

ชั้น Input ซึ่งเป็น Layer ที่รับข้อมูลภาพขนาด 64 x 64, ชั้น Conv2D เป็น Layer ที่ทำหน้าที่สกัดเอา Feature สำคัญ จากรูปภาพจาก 3 มิติให้กลายเป็น 2 มิติ

ชั้น Flatten เป็น Layer สำหรับแปลงข้อมูลสองมิติจากชั้นก่อนหน้า ให้เป็นเวคเตอร์ยาวขนาด 1 มิติ

ชั้น Dense ในที่นี้หมายถึงโครงสร้างแบบ Fully Connected ระหว่างชั้นที่ติดกัน โดยเลือกใช้ Activation Function ชนิด ReLu ซึ่ง ReLu เป็นฟังก์ชันที่มีคนนิยมใช้เนื่องจากฟังก์ชันนี้ช่วยส่งผลให้ค่าความแม่นยำดีขึ้น

ชั้น Dense เป็น Layer ที่กำหนด Activation Function ชนิด SoftMax นิยมถูกนำไปใช้บ่อยในงานประเภทจำแนกข้อมูล (Classification) Output สุดท้ายจากชั้นนี้จำแนกออกได้เป็น 3 ประเภท ตามประเภทมะม่วงทั้ง 3 แบบ ที่ได้กล่าวไว้ตอนต้น

Layer ในการฝึกฝนตัวต้นแบบรู้จำที่กล่าวมานั้นมีโครงสร้าง ดังรูปที่ 5.6

```
Model: "sequential"
_________________________________________________________________
 Layer (type)                Output Shape              Param #
=================================================================
 conv2d (Conv2D)             (None, 62, 62, 32)        320

 max_pooling2d (MaxPooling2D  (None, 31, 31, 32)       0
 )

 conv2d_1 (Conv2D)           (None, 29, 29, 64)        18496

 max_pooling2d_1 (MaxPooling  (None, 14, 14, 64)       0
 2D)

 conv2d_2 (Conv2D)           (None, 12, 12, 128)       73856

 max_pooling2d_2 (MaxPooling  (None, 6, 6, 128)        0
 2D)

 flatten (Flatten)           (None, 4608)              0

 dense (Dense)               (None, 128)               589952

 dense_1 (Dense)             (None, 64)                8256

 dense_2 (Dense)             (None, 3)                 195

=================================================================
Total params: 691,075
Trainable params: 691,075
Non-trainable params: 0
```

รูปที่ 5.6 โครงสร้าง Layer ของตัวต้นแบบรู้จำในการฝึกฝน

5.3 วิธีการฝึกฝนโมเดลแบ่งข้อมูลบนภาพด้วย Mask R-CNN

เริ่มการทำงานโดยการทำ Label ภาพมะม่วง ภาพที่ Label ได้ไฟล์ json นำมาใช้กับการเทรนโมเดล Mask R-CNN ในการแยกวัตถุในภาพ (Segmentation) ดังรูปที่ 5.7

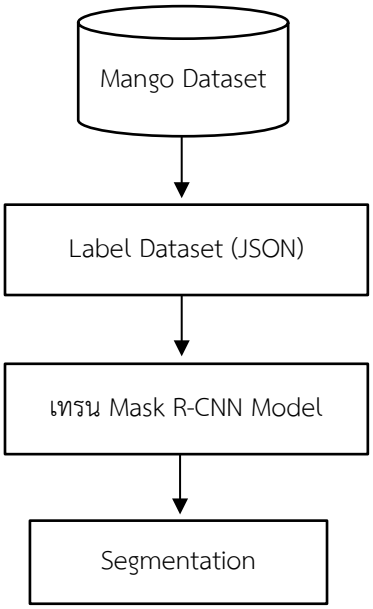

รูปที่ 5.7 ขั้นตอนการเทรนโมเดล Mask R-CNN

Label ภาพมะม่วงด้วยโปรแกรม Make Sense สามารถกำหนดรูปร่างของวัตถุ (Object) โดยใช้การลากเส้นรูปแบบต่าง ๆ มาวาดล้อมรอบวัตถุที่ต้องการ โดยได้ผลลัพธ์เป็นไฟล์ json ที่มีข้อมูลของการกำหนดรูปร่างของวัตถุเอาไว้เป็นตัวเลขบอกพิกัดในรูปแบบแกน x และ y รวมทั้งชื่อ คุณลักษณะต่าง ๆ ที่ได้กำหนดไว้ ก่อนนำไปเทรนกับโมเดล Mask R-CNN เพื่อจับมะม่วงในภาพ ดังรูปที่ 5.8

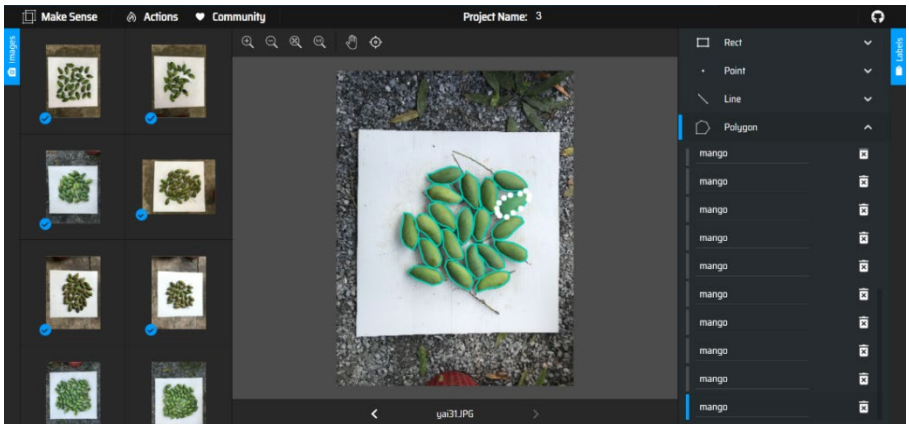

รูปที่ 5.8 ตัวอย่างการ label ภาพมะม่วงด้วยโปรแกรม makesense

ทำ Visualization ดูว่ามีรูปภาพและ Mask ของมะม่วงเป็นอย่างไรบ้างแสดงได้ ดังรูปที่ 5.9

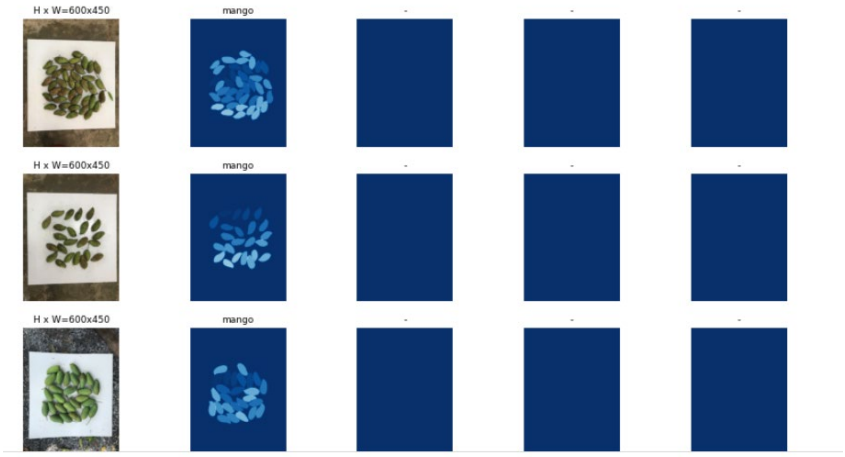

รูปที่ 5.9 ตัวอย่างการทำ visualization

เริ่มทำการให้โมเดลเรียนรู้ Weight โดย Train เฉพาะ Layers ท้าย ๆ โดยกำหนดให้ layers = ‘head’ ดังรูปที่ 5.10 train 4 epoch จนเสร็จสิ้น

```
Starting at epoch 0. LR=0.001

Checkpoint Path: /content/Mask_RCNN/logs/object20220601T1019/mask_rcnn_object_{epoch:04d}.h5
Selecting layers to train
fpn_c5p5               (Conv2D)
fpn_c4p4               (Conv2D)
fpn_c3p3               (Conv2D)
fpn_c2p2               (Conv2D)
fpn_p5                 (Conv2D)
fpn_p2                 (Conv2D)
fpn_p3                 (Conv2D)
fpn_p4                 (Conv2D)
In model:  rpn_model
    rpn_conv_shared        (Conv2D)
    rpn_class_raw          (Conv2D)
    rpn_bbox_pred          (Conv2D)
mrcnn_mask_conv1       (TimeDistributed)
mrcnn_mask_bn1         (TimeDistributed)
mrcnn_mask_conv2       (TimeDistributed)
mrcnn_mask_bn2         (TimeDistributed)
mrcnn_class_conv1      (TimeDistributed)
mrcnn_class_bn1        (TimeDistributed)
mrcnn_mask_conv3       (TimeDistributed)
mrcnn_mask_bn3         (TimeDistributed)
mrcnn_class_conv2      (TimeDistributed)
mrcnn_class_bn2        (TimeDistributed)
mrcnn_mask_conv4       (TimeDistributed)
mrcnn_mask_bn4         (TimeDistributed)
mrcnn_bbox_fc          (TimeDistributed)
mrcnn_mask_deconv      (TimeDistributed)
mrcnn_class_logits     (TimeDistributed)
mrcnn_mask             (TimeDistributed)
```

รูปที่ 5.10 โครงสร้าง Layer ของตัวต้นแบบ Mask R-CNN

จากนั้นเซฟ Weight ที่เทรนมาแล้ว ในชื่อ mask_rcnn_01.h5 เพื่อใช้ในการ Implement เลือกภาพใน Test set ที่เก็บไว้มาแสดง ดังรูปที่ 5.11

รูปที่ 5.11 ตัวอย่าง implement ภาพมะม่วง

แบ่งภาพด้วยตัวต้นแบบ Mask R-CNN รับไฟล์ภาพมะม่วงที่ต้องตัดและโหลดค่า Weight โมเดล Mask R-CNN ไฟล์ .h5 มาใช้จับภาพมะม่วง Contours ลูกมะม่วงในภาพ กำหนด x,y,w,h เพื่อตีกรอบและตัดลูกมะม่วงที่ Contours ได้ และวนลูปตัดภาพมะม่วงจนครบทุกลูก เพื่อนำไปเข้าสู่กระบวนการ Classify ต่อไป ดังรูปที่ 5.12

```
test_image = image.img_to_array(new_image)
# test_image = np.expand_dims(test_image,axis=0)
# result = model_predict_class.predict(test_image)
filename = f'/content/drive/MyDrive/newcut/mango{i}.jpg'
cv2.imwrite(filename , new_image)
cv2_imshow(new_image)
```

รูปที่ 5.12 ตัวอย่างลูกมะม่วงที่ตัดได้

5.4 การวัดขนาดมะม่วง

ในส่วนการวัดขนาดมะม่วง เมื่อรับไฟล์ภาพเข้ามาระบบจะตรวจสอบภาพมะม่วงได้ ภาพมะม่วงจะเข้าสู่กระบวนการแยกวัตถุในภาพมะม่วงด้วยตัวต้นแบบ Mask R-CNN ภาพมะม่วงที่แบ่งแล้วเข้าสู่การวัดขนาด ดังรูปที่ 5.13

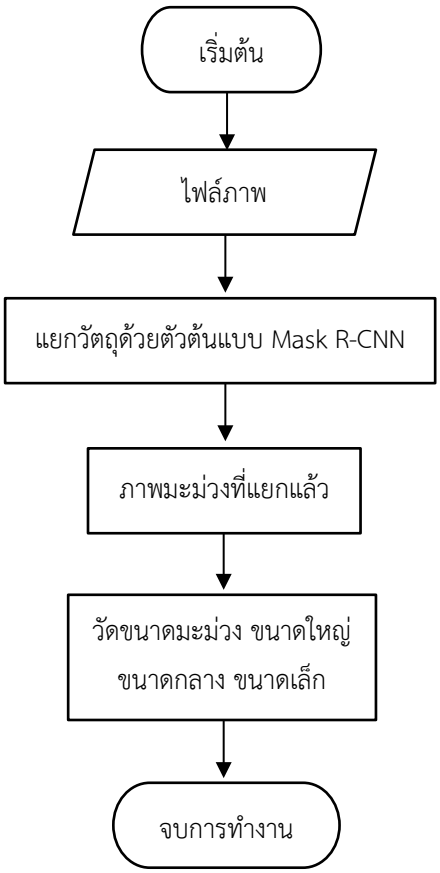

รูปที่ 5.13 Flow Chart ส่วนการวัดขนาดมะม่วง

วัดขนาดมะม่วงด้วยการนับ pixel ภาพ นับจำนวนกว้างคูณยาวของ pixel ในภาพ กำหนดช่วงของจำนวน pixel เป็น big (2201 ถึง 3800), mid (1643 ถึง 2200), small (800 ถึง 1642) และ unknown ดังรูปที่ 5.14

```
[16] if area in big:
           print("big")
           big_count=big_count+1
     elif area in mid:
           print("mid")
           mid_count=mid_count+1
     elif area in small:
           print("small")
           small_count=small_count+1
     else:
           print("unknown")
     cv2_imshow(new_image)

     mg_count = {"big":big_count,"mid":mid_count,"small":small_count}
     print(mg_count)
```

```
small
```

```
{'big': 0, 'mid': 0, 'small': 3}
```

รูปที่ 5.14 ตัวอย่างการวัดขนาดมะม่วงด้วยการนับ pixel ภาพ

5.5 API แสดงผล

พัฒนา API ด้วยไลบรารี Flask โดยรับ Request แบบ POST Method ที่มีฟังก์ชัน process_image จับคู่กับ url '/classify' ดังรูปที่ 5.15

```
@app.route("/classify", methods = ['POST'])
def process_image():
    global payload
    if request.method == 'POST':
        content = request.json
        detect_results(content['image64'])
        # return jsonify({'msg': 'succeed'})
        return jsonify(
                payload
        )
```

รูปที่ 5.15 ฟังก์ชัน process_image

เมื่อมีการเรียกใช้ API ไฟล์ภาพที่รับเข้ามาจะเข้าฟังก์ชัน detect_result ดังรูปที่ 5.16 ประมวลผลแยกวัตถุในภาพก่อน ภาพที่แยกได้จะเข้าฟังก์ชัน classify ดังรูปที่ 5.17 ทำนายเกรดมะม่วง ผลลัพธ์ที่ได้ในจะเก็บในตัวแปร payload

```
def detect_results(image64):
    global payload, total
    payload = []
    total = []

    decoded_data = base64.b64decode(image64)
    np_data = np.fromstring(decoded_data,np.uint8)
    img = cv2.imdecode(np_data,cv2.IMREAD_UNCHANGED)

    test_model, inference_config = load_inference_model(1, "C:/Users/chany/Music/Mask_RCNN/mrcnn/mask_rcnn_object_0005 (4) .h5")
    input_img = cv2.cvtColor(img, cv2.COLOR_BGR2RGB)

    r = test_model.detect([input_img])[0]
    colors = random_colors(80)

    object_count = len(r["class_ids"])
```

รูปที่ 5.16 ฟังก์ชัน detect_result

```
def classify(sf):
    global session
    global graph
    global model
    with graph.as_default():
        set_session(session)
        predictions = model.predict([prepare(sf)])
        label=['broke','defected','normal']
        i=np.argmax(predictions)
        prop=np.max(predictions)
        result=label[i]
        return result,prop
```

รูปที่ 5.17 ฟังก์ชัน classify

เริ่มการทำงานของ API ด้วยคำสั่ง python api.py runserver ในการทำงานจะรับ Request แบบ POST Method ที่ภายใน Body เป็น JSON ที่มีรูปแบบดังรูปที่ 5.18 มีคีย์เป็น “class” เก็บค่าคลาสที่ทำนายได้ คีย์ “confident” เก็บค่าความมั่นใจที่ทำนายออกมา คีย์ “image” เก็บรูปในรูปแบบ string และ คีย์ “size” เก็บค่าขนาดของผลมะม่วง

```
payload.append({"class":str(classify_mango[0]),
                "confident":float(classify_mango[1])
                "image":image_64_encode.decode("utf-8"),
                "size":mango_size})
```

รูปที่ 5.18 JSON ที่ส่งเป็น Payload ตอนเรียก API

และมี response กลับมาเป็น JSON ดังรูปที่ 5.19 ที่มีคีย์ “class” เก็บค่าคลาส คีย์ “confident” เก็บค่าความมั่นใจ คีย์ “image” เก็บรูปในรูปแบบ string และ คีย์ “size” เก็บค่าขนาดของผลมะม่วง


```
[
  {
    "class": "broke",
    "confident": 0.651581883430481,
    "image": "/9j/4AAQSkZJRgABAQAAAQABAAD/2wBDAAIBAQEBAQIBAQECAgICAgQDAgICAgUEBAMEBgUGBgYFBgYGBwkIBgcJBwYGCAsICQ
    "size": "mid"
  },
  {
```


รูปที่ 5.19 JSON ใน Body ของ Response จาก API

API แสดงผลรวมโดยรับ Request แบบ GET Method ที่มีฟังก์ชัน summary จับคู่กับ url ‘/total’ ดังรูปที่ 5.20 ข้อมูลใน Body เป็น JSON ดังรูปที่ 5.21 จำนวนผลรวมแต่ละขนาดของมะม่วง มีคีย์เป็น “TotalBig” เก็บค่าผลรวมขนาดใหญ่ “TotalMid” เก็บค่าผลรวมขนาดกลาง “Totalsmall” เก็บค่าผลรวมขนาดเล็ก จำนวนผลรวมแต่ละคลาส มีคีย์เป็น “Totalbroke” เก็บค่าผลรวมคลาสแตก “Totaldefected” เก็บค่าผลรวมคลาสลาย “Totalnormal” เก็บค่าผลรวมคลาสปกติ และมี Response กลับมาเป็น JSON ที่มีคีย์เป็น response ดังรูปที่ 5.22

```
@app.route("/total", methods = ['GET'])
def summary():
    global total
    if request.method == 'GET':
        return jsonify(
                total
        )
```

รูปที่ 5.20 ฟังก์ชัน summary

```
total.append({"TotalBig":big_count,"TotalMid":mid_count,"Totlalsmall":small_count,
              "Totlalbroke":predict_broke,"Totlaldefected":predict_defected,"TotlalNormal":predict_normal})
```

รูปที่ 5.21 JSON ที่ส่งเป็น total ตอนเรียก API

```
[
  {
    "TotalBig": 9,
    "TotalMid": 24,
    "TotlalNormal": 14,
    "Totlalbroke": 0,
    "Totlaldefected": 22,
    "Totlalsmall": 4
  }
]
```


รูปที่ 5.22 JSON ใน Body ของ Response จาก API

5.6 การออกแบบหน้าเว็บแอปพลิเคชัน

1) หน้าหลักของเว็บไซต์ มีปุ่ม Select File สำหรับให้ผู้ใช้เลือกใส่ไฟล์เข้ามา ดังรูปที่ 5.23

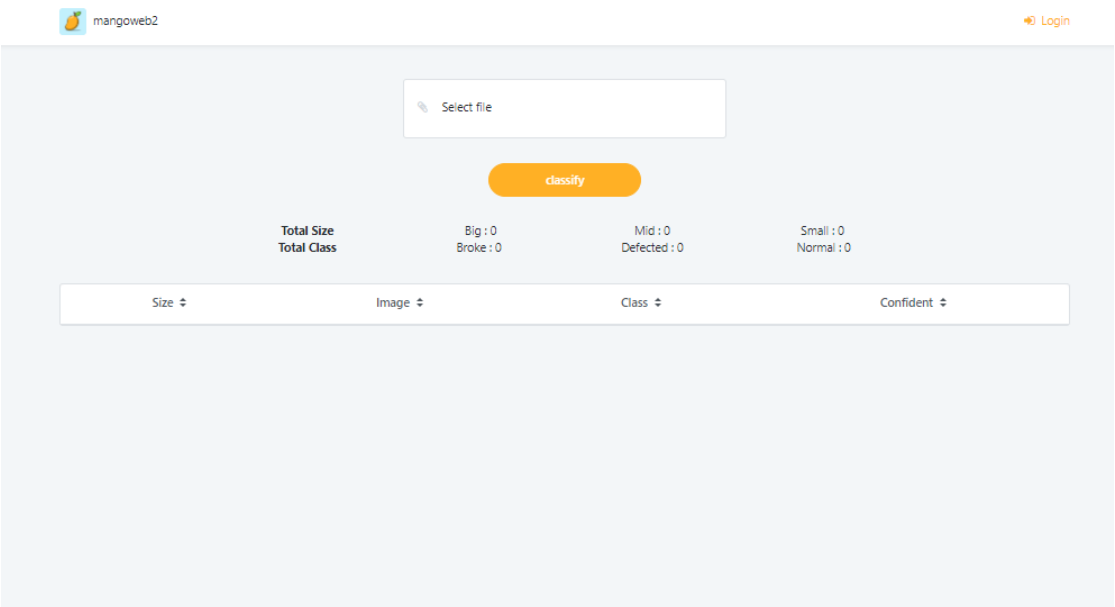

รูปที่ 5.23 หน้าหลักของเว็บไซต์

2) หน้าจอแสดงผลลัพธ์ แสดงชื่อไฟล์, Size, รูป, Class, ค่า Confident, จำนวนผลรวมแต่ละ Size และจำนวนผลรวมแต่ละ Class ดังรูปที่ 5.24 รูปที่ 5.25 และ รูปที่ 5.26

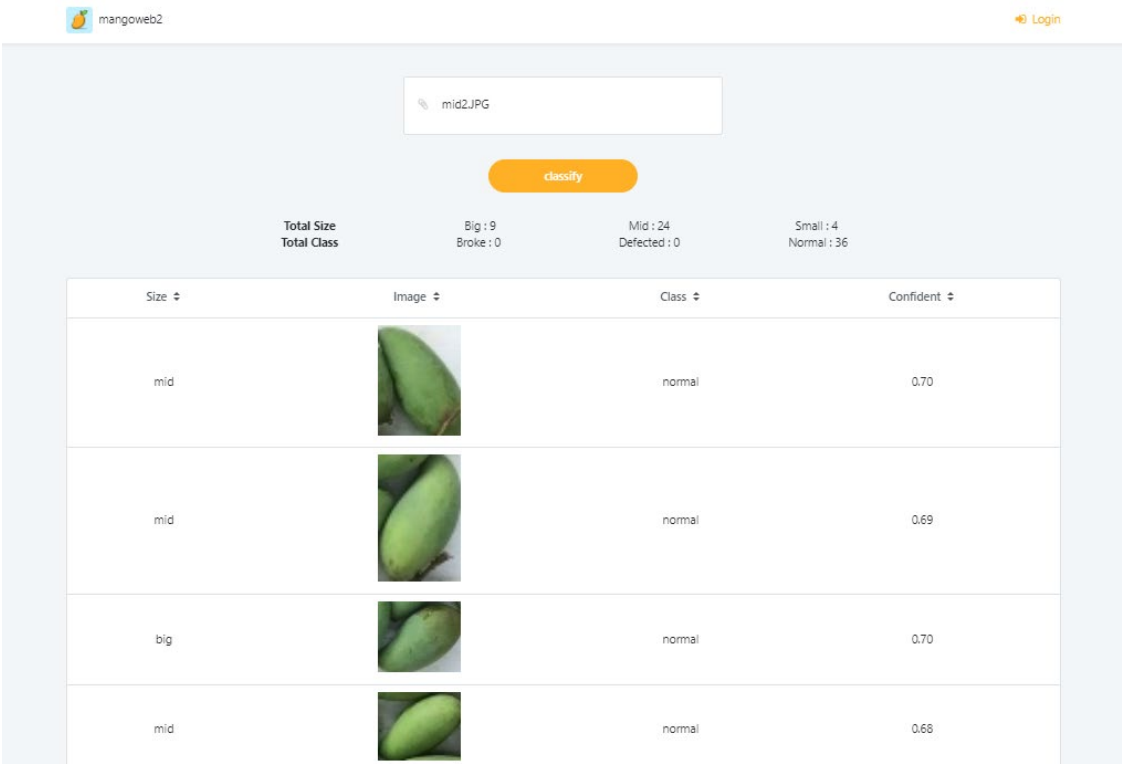

รูปที่ 5.24 หน้าจอแสดงผลลัพธ์มะม่วงปกติ

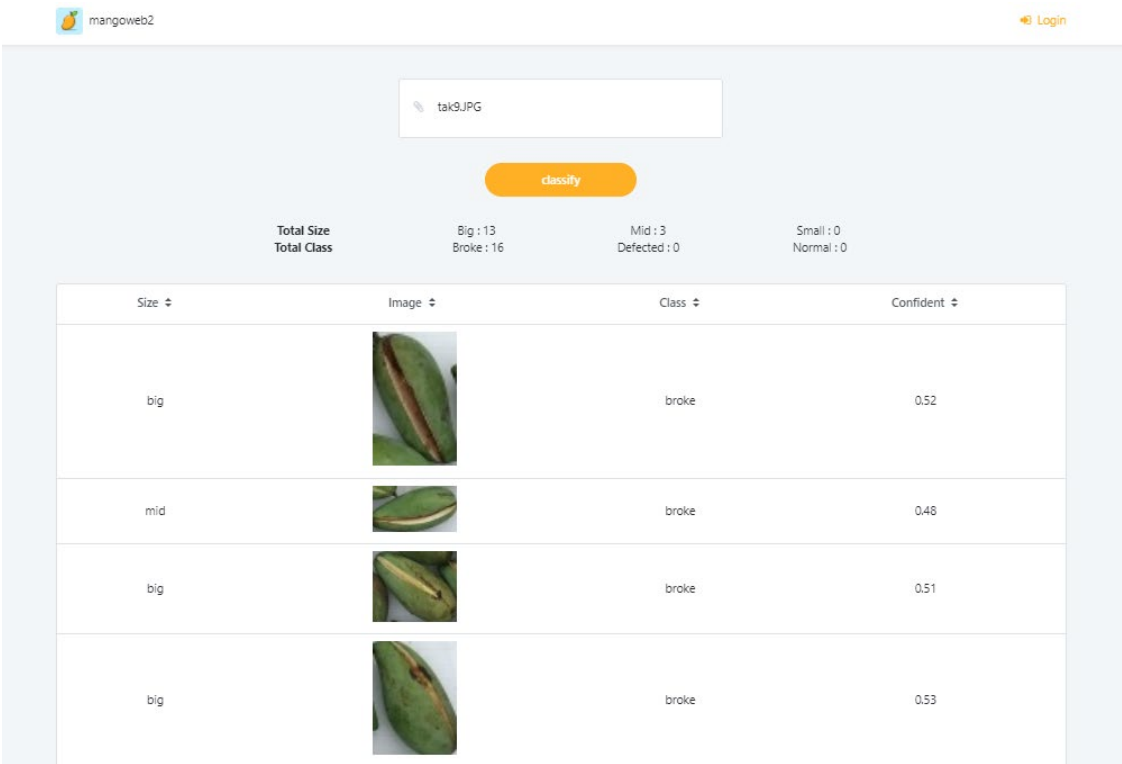

รูปที่ 5.25 หน้าจอแสดงผลลัพธ์มะม่วงแตก

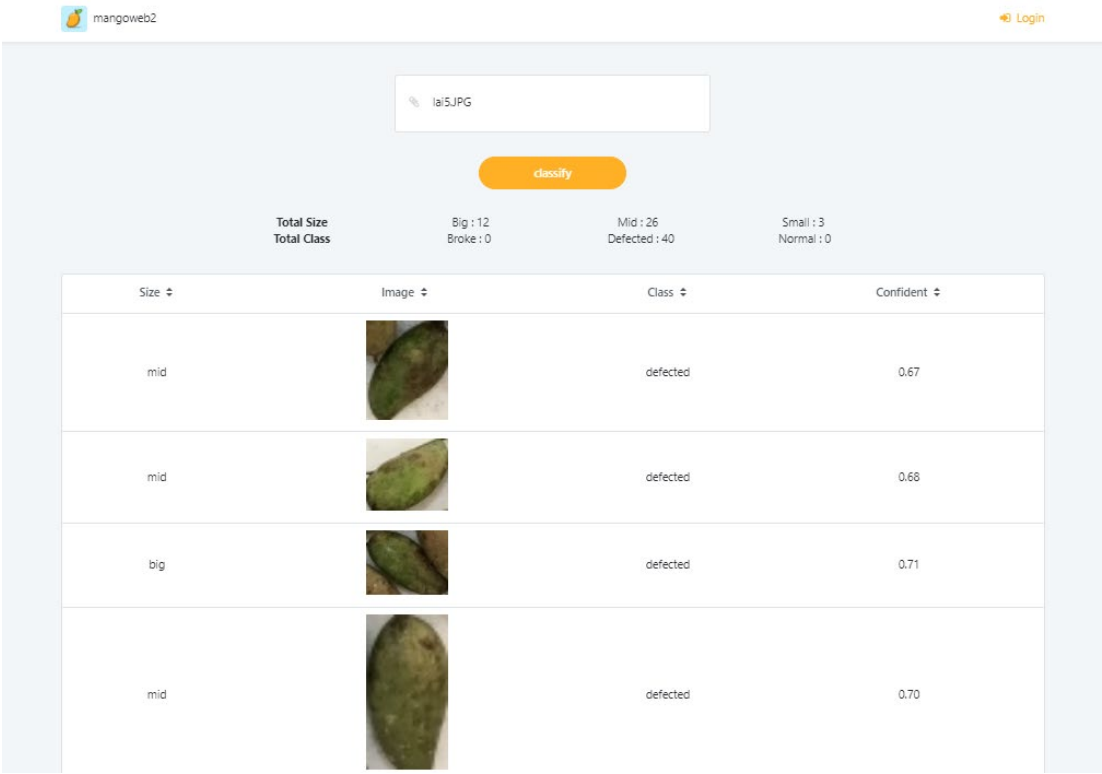

รูปที่ 5.26 หน้าจอแสดงผลลัพธ์มะม่วงลาย

3) หน้าจอแสดงผลเมื่อไม่ได้เลือกไฟล์ภาพ ดังรูปที่ 5.27

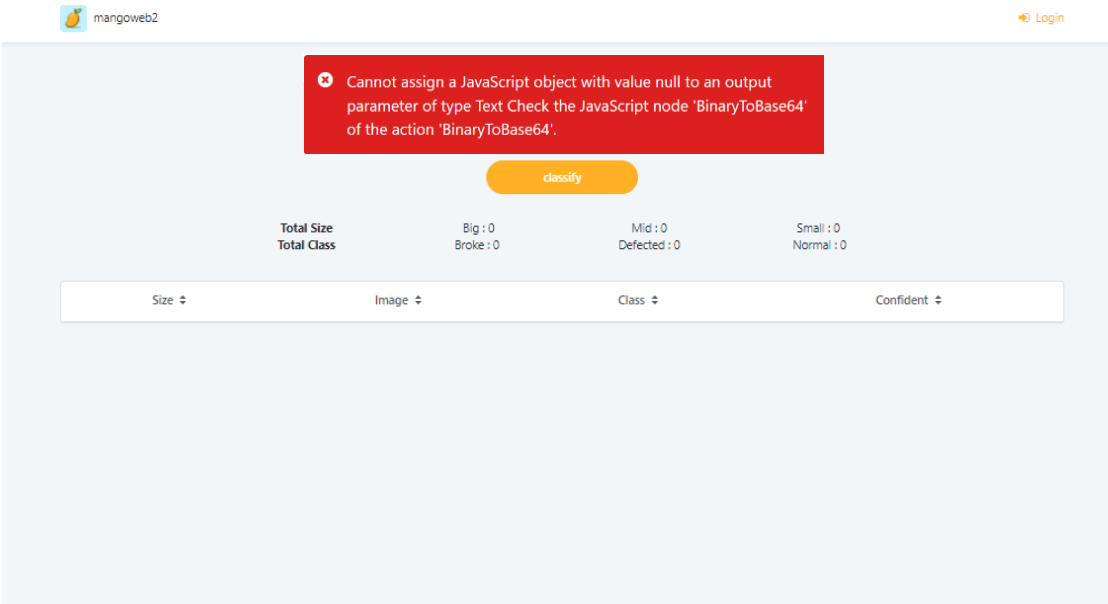

รูปที่ 5.27 หน้าจอแสดงผลลัพธ์ไม่ได้เลือกไฟล์

บทที่ 6 ผลการดำเนินงาน ข้อจำกัด และข้อเสนอแนะ

ในบทนี้จะอธิบายถึง ผลการดำเนินงาน ข้อจำกัด และข้อเสนอแนะ โดยแต่ละหัวข้อมีรายละเอียดดังต่อไปนี้

6.1 ผลการดำเนินงาน

6.1.1 การทดสอบประสิทธิภาพส่วนการวัดขนาด

แบ่งภาพที่ใช้ทดลองออกเป็น 3 ขนาด คือ ขนาดเล็ก ขนาดกลางและขนาดใหญ่ ประเภทละ 100 ภาพ รวมทั้งหมด 300 ภาพ

สมการที่ใช้คำนวณหาค่าความแม่นยำ (Precision) ดังสมการที่ (1) ค่าความระลึก (Recall) ดังสมการที่ (2)

$$Precision = \frac{\boldsymbol{TP}}{\boldsymbol{TP + FP}} \qquad (1)$$

$$Recall = \frac{\boldsymbol{TP}}{\boldsymbol{TP + FN}} \qquad (2)$$

เมื่อ TP คือ จำนวนผลลัพธ์ที่โปรแกรมตรวจได้ว่าจริงได้ถูกต้อง
TN คือ จำนวนผลลัพธ์ที่โปรแกรมตรวจได้ว่าไม่จริงได้ถูกต้อง
FP คือ จำนวนผลลัพธ์ที่โปรแกรมตรวจได้ว่าจริงซึ่งไม่ถูกต้อง
FN คือ จำนวนผลลัพธ์ที่โปรแกรมตรวจได้ว่าไม่จริงซึ่งไม่ถูกต้อง

P คือ จำนวนของที่ใช่ทั้งหมด ที่อยู่ในข้อมูล = TP + FN
N คือ จำนวนของที่ไม่ใช่ทั้งหมด ที่อยู่ในข้อมูล = FP + TN

ตารางที่ 6.1 การคำนวณ Confusion matrix

ระบบ / ความจริง	Positive	Negative
Positive	TP	FN
Negative	FP	TN

สมการคำนวณค่าความถูกต้อง (Accuracy) ของการทดสอบ ดังสมการที่ (3)

$$Accuracy = \frac{\boldsymbol{TP + TN}}{\boldsymbol{P + N}} \qquad (3)$$

หาค่า F1-Score คือค่าเฉลี่ยแบบ harmonic mean ระหว่าง precision และ recall เพื่อให้ได้ single metric ที่วัดความสามารถ ดังสมการที่ (4)

$$F1 = \frac{\mathbf{2} \cdot precision \cdot recall}{precision + recall} \qquad (4)$$

ผลของการทดลอง นำภาพมะม่วงมาวัดแยกขนาด หาค่า Confusion Matrix เพื่อมาคำนวณ Precision และ Recall ผลที่ได้ดังตารางที่ 6.2

ตารางที่ 6.2 Confusion matrix การแยกขนาดมะม่วง

ทำนาย / ความจริง	ขนาดใหญ่	ขนาดกลาง	ขนาดเล็ก	ผลรวม
ขนาดใหญ่	**95**	5	0	100
ขนาดกลาง	11	**76**	13	100
ขนาดเล็ก	0	28	**72**	100
ผลรวม	106	109	85	300

จากตารางที่ 6.2 คำนวณหาค่า Precision, Recall และ F1-Score จากสมาการที่ 1, 2 และ 4 ได้ตารางประเมินผลการทดลอง ดังตารางที่ 6.3

ตารางที่ 6.3 precision, recall, f1- score การแยกขนาดมะม่วง

	Precision	Recall	F1-Score
ขนาดใหญ่	0.8962	0.9500	0.9223
ขนาดกลาง	0.6972	0.7600	0.7272
ขนาดเล็ก	0.8470	0.7200	0.7783
ค่าความแม่นยำ			0.8100

จากสมการที่ 3 คำนวณค่าความถูกต้อง (Accuracy) ของการทดลองได้ดังนี้

$$Accuracy = \frac{\mathbf{243}}{\mathbf{300}} = \mathbf{0.81} \times \mathbf{100} = \mathbf{81}$$

ค่าความแม่นยำจากการทดลองแยกขนาด ให้ค่าความแม่นยำอยู่ที่ 81.00% ซึ่งถือว่าอยู่ในระดับที่ดี

6.1.2 การทดสอบประสิทธิภาพส่วนการทำนายเกรดมะม่วง

ใช้รูปภาพในการ Test ผลแตก ผลลาย และ ผลปกติ เป็น 51, 75 และ 90 ตามลำดับ โดยทำนายผลลัพธ์ได้เป็น ผลแตก 44 ผลลาย 59 และ ผลปกติได้ 84 ภาพ ได้ค่า Confusion Matrix ดังตารางที่ 6.4

ตารางที่ 6.4 Confusion Matric Classify

ทำนาย / ความจริง	broke	defected	normal
broke	**44**	1	6
defected	9	**59**	7
normal	2	4	**84**

จากตารางที่ 6.5 ใช้ทดสอบว่าโมเดลสามารถแยกประเภทมะม่วงทั้ง 3 ประเภทได้ดีแค่ไหน ดูผลจากการ Test โมเดล ด้วย Precision, Recall และ F1-Score ที่ใช้ข้อมูลจากตารางที่ 6.4 มาคำนวณ

ตารางที่ 6.5 precision, recall, f1- score Classify

	Precision	Recall	F1-Score
broke	0.8000	0.8627	0.8302
defected	0.9219	0.7867	0.8489
normal	0.8698	0.9333	0.8984

ได้ค่าความถูกต้อง (Accuracy) ของการ Test อยู่ที่ 0.8564 หรือ 85.64% ซึ่งถือว่าอยู่ในระดับที่ดี

6.1.3 สรุปผลการทดลองและผลการทดสอบ

จากการทดสอบการทำงานส่วนการวัดขนาดมะม่วง สามารถวัดขนาดได้ค่าความถูกต้องที่ 81.00% จากรูปที่นำมาทดสอบถูกต้อง 243 ผล จากทั้งหมด 300 ผล เนื่องจากเป็นการคัดแยกด้วยสายตาของมนุษย์ก่อนนำมาทดสอบอาจทำให้ผลการแยกขนาดผิดพลาดได้ตั้งแต่แรก หรือถ่ายรูปคลาดเคลื่อนจากความสูงที่ 120 เซนติเมตร เมื่อนำมาทดสอบด้วยการนับ Pixel ในภาพ ทำให้ผลลัพธ์คลาดเคลื่อนไป ส่งผลให้การทดสอบการวัดประสิทธิภาพการแยกขนาดมะม่วงไม่แม่นยำ 100%

การทำงานส่วนการทำนายเกรดมะม่วง สามารถทำนายได้ค่าความถูกต้องที่ 85.64% จากรูปที่ใช้ Test ถูกต้อง 187 ผล จากทั้งหมด 210 ผล เนื่องจากรูปที่นำมา Train โมเดลอาจขาดภาพที่มีการวางมะม่วงตามมุมและ

แนวต่าง ๆ ไปและรูปที่นำมาเทรนยังไม่มากพอ ส่งผลให้โมเดลทำนายลักษณะผิดพลาดไปบ้างไม่แม่นยำ 100% แต่ยังถือว่าโมเดลสามารถทำนายคลาสของมะม่วงออกมาในระดับที่ดี

การทำงานของระบบหลังบ้านเว็บแอปพลิเคชันสามารถทำงานกับไฟล์ภาพชนิด JPEG ได้ สามารถแสดง Size Class รูป ค่า Confident ได้ แอปพลิเคชันสามารถสามารถเรียกใช้ API การคัดแยกเกรดมะม่วงฟ้าลั่นได้ สามารถแสดงจำนวนผลรวมขนาดและคลาสได้ สามารถเลือกไฟล์ภาพเข้าจาก desktop ได้

6.2 ข้อจำกัด

1) ไฟล์รูปที่รับเข้าต้องถ่ายที่ความสูงจากพื้น 120 เซนติเมตร เท่านั้น จึงจะสามารถแยกขนาดมะม่วงได้ถูกต้อง
2) เนื่องจากตัวโมเดลไม่ได้ทำนายได้อย่างแม่นยำ 100% จึงทำให้การทำนายอาจไม่ตรง
3) ต้องมี Internet จึงจะสามารถใช้งานเว็ปแอปพลิเคชันได้

6.3 ข้อเสนอแนะ

1) พัฒนาให้สามารถถ่ายรูปที่ความสูงเท่าไหร่ก็ได้
2) เก็บรวบรวมรูปภาพแต่ละประเภทให้มีมุมต่าง ๆ มากขึ้น เพื่อนำไปใช้ในการ Training Model ซึ่งจะทำให้โปรแกรมเรียนรู้ได้มากขึ้น และสามารถคัดแยกเกรดมะม่วงในแต่ละประเภทได้อย่างมีประสิทธิภาพ

บรรณานุกรม

[1] ไพสิฐ วัฒนภัทราภรณ์, **"ระบบตรวจจับวัตถุและป้าย สำหรับผู้ที่มีปัญหาบกพร่องทางการมองเห็น,"** 2562.

[2] วรวุฒิ กังหัน, **"การคัดแยกเกรดยางพาราแผ่นรมควันโดยใช้วิธีการประมวลผลด้วยภาพ,"** 2557. [ออนไลน์]. Available: http://www.repository.rmutt.ac.th/handle/123456789/2527. [วันที่เข้าถึง 29 เมษายน 2565]

[3] อนล ไพศาล, **"การคัดแยกเมล็ดพันธุ์ปนในถั่วเขียว โดยการวิเคราะห์ภาพ,"** 2555. [ออนไลน์]. Available: https://dric.nrct.go.th/index.php?/Search/SearchDetail/259614. [วันที่เข้าถึง 29 เมษายน 2565]

[4] **"LOW-CODE DEVELOPMENT PLATFORM?,"** 29 March 2563. [ออนไลน์]. Available: https://www.techtalkthai.com/what-is-low-code-development-platform-by-outsystems/. [วันที่เข้าถึง 21 พฤษจิกายน 2565]

[5] P. Sharma, **"Computer Vision Tutorial: A Step-by-Step Introduction to Image Segmentation Techniques (Part 1),"** 1 Apri 2562. [ออนไลน์]. Available: https://www.analyticsvidhya.com/blog/2019/04/introduction-image-segmentation-techniques-python/. [วันที่เข้าถึง 29 เมษายน 2565]

[6] P.Skalski, **"Make Sense,"** 2562. [ออนไลน์]. Available: https://github.com/SkalskiP/make-sense. [วันที่เข้าถึง 29 เมษายน 2565]

[7] P. Tongpradit, **"มาทำความรู้จัก Tensorflow,"** 16 December 2561. [ออนไลน์]. Available: https://www.thaiprogrammer.org/2018/12/%e0%b8%a1%e0%b8%b2%e0%b8%97%e0%b8%b3%e0%b8%84%e0%b8%a7%e0%b8%b2%e0%b8%a1%e0%b8%a3%e0%b8%b9%e0%b9%89%e0%b8%88%e0%b8%b1%e0%b8%81-tensorflow/. [วันที่เข้าถึง 29 เมษายน 2565]

[8] V. Minaphinant, **"Deep Learning คืออะไร? อาชีพไหนจะตกงานบ้าง?,"** 16 March 2561. [ออนไลน์]. Available: https://medium.com/investic/deep-learning-%E0%B8%84%E0%B8%B7%E0%B8%AD%E0%B8%AD%E0%B8%B0%E0%B9%84%E0%B8%A3%E0%B8%AD%E0%B8%B2%E0%B8%8A%E0%B8%B5%E0%B8%9E%E0%B9%84%E0%B8%AB%E0%B8%99%E0%B8%88%E0%B8%B0%E0%B8%95%E0%B8%81%E0%B8%87%E0%B8%B2%E0%B8%99%E0%B8%9A%E0%B9%89%E0%B8%B2%E0%B8%87-499c250784a1. [วันที่เข้าถึง 29 เมษายน 2565]

[9] W. Sawangum, **"License-plate Detection With Mark R-CNN,"** 13 November 2562. [ออนไลน์]. Available:https://medium.com/@worrawoots/license-plate-detection-with-mark-r-cnn-a15707ff7578.

ภาคผนวก ก คู่มือการใช้งานเว็บแอปพลิเคชัน

ก.1 การใช้งานเว็ปแอปพลิเคชัน

หน้าหลักของเว็บไซต์ มีปุ่ม Select File สำหรับให้ผู้ใช้เลือกใส่ไฟล์เข้ามา และปุ่ม Classify สำหรับการทำนายภาพ ดังรูปผนวกที่ ก.1

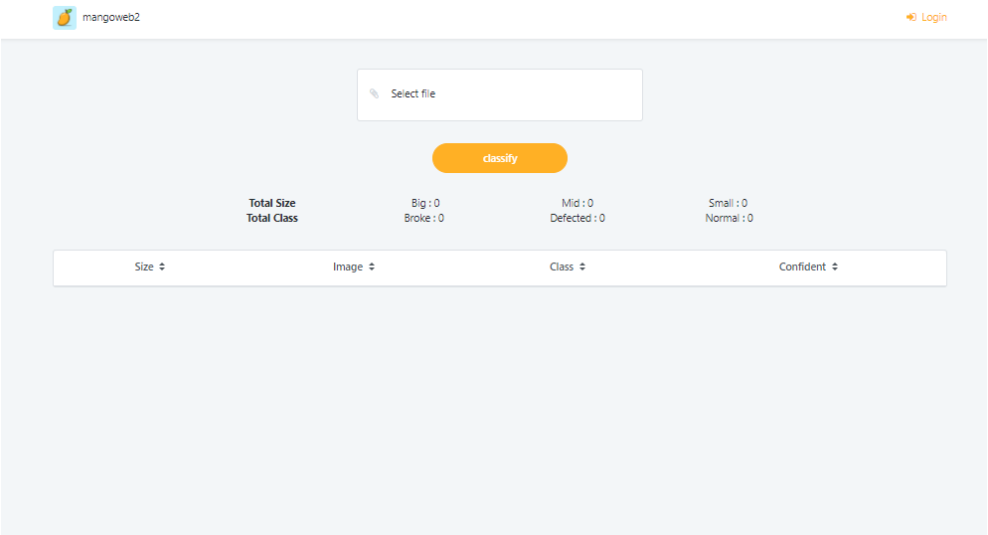

รูปผนวกที่ ก.1 หน้าจอหลักของเว็ปแอปพลิเคชั่น

ผู้ใช้สามารถกดปุ่ม Select File เพื่อเลือกไฟล์ภาพ ดังรูปผนวกที่ ก.2

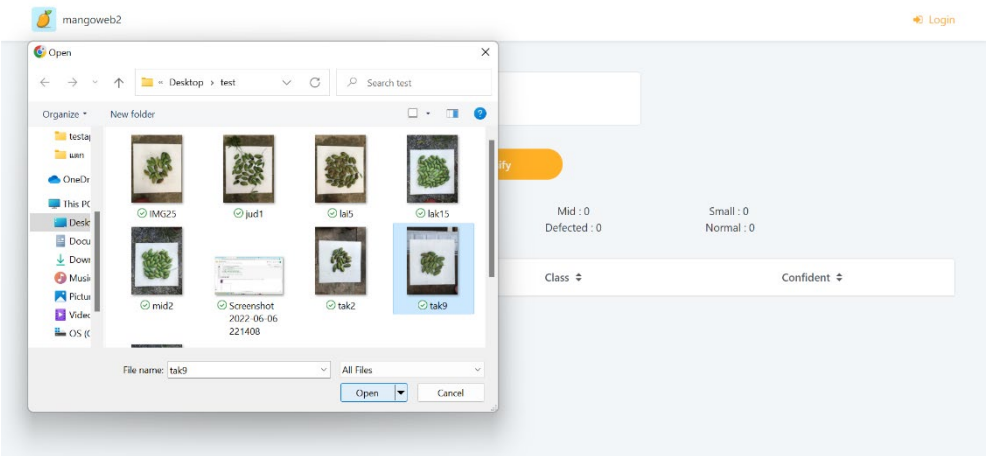

รูปผนวกที่ ก.2 หน้าจอเลือกไฟล์

หากผู้ใช้ไม่ได้เลือกไฟล์ภาพแต่กดปุ่ม Classify หน้าจอจะแสดงแถบแจ้งเตือนให้ทราบว่าผู้ใช้ไม่ได้เลือกไฟล์ภาพเข้ามา ดังรูปผนวกที่ ก.3

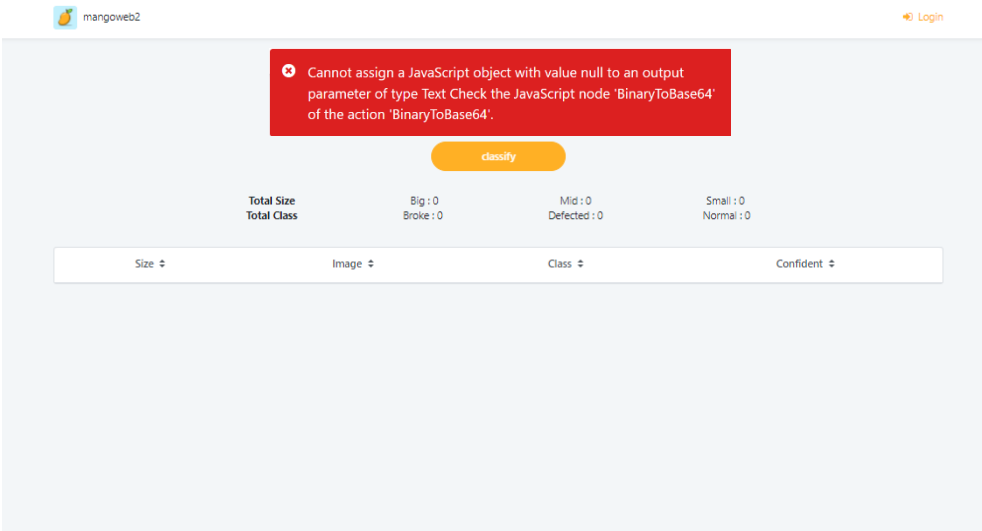

รูปผนวกที่ ก.3 หน้าแจ้งเตือน

หากผู้ใช้ใส่ไฟล์ภาพที่ถูกต้อง แล้วกดปุ่ม Classify ผลลัพธ์จะปรากฏบนหน้าจอที่แสดงว่าเป็นมะม่วงผลปกติ ผลแตกหรือผลลาย และเป็นมะม่วง Size ไหน หากผู้ใช้ต้องการเลือกไฟล์ภาพใหม่สามารถกดปุ่ม Select File เพื่อเลือกไฟล์ภาพ และกดปุ่ม Classify เพื่อทำนายผลใหม่ได้เลย ดังรูปผนวกที่ ก.4 ก.5 และ ก.6

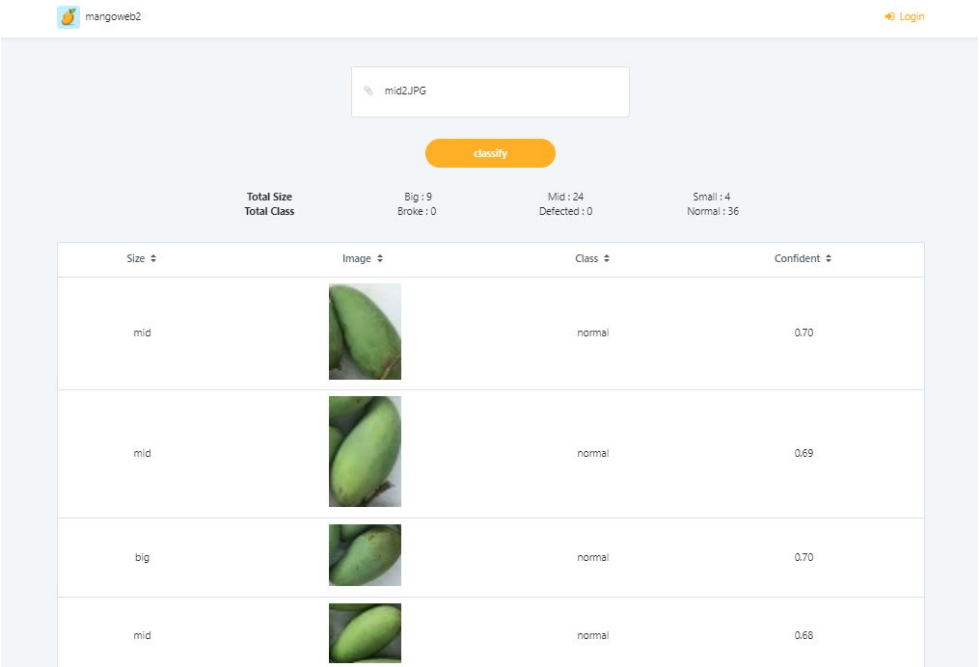

รูปผนวกที่ ก.4 หน้าจอแสดงผลลัพธ์มะม่วงปกติ

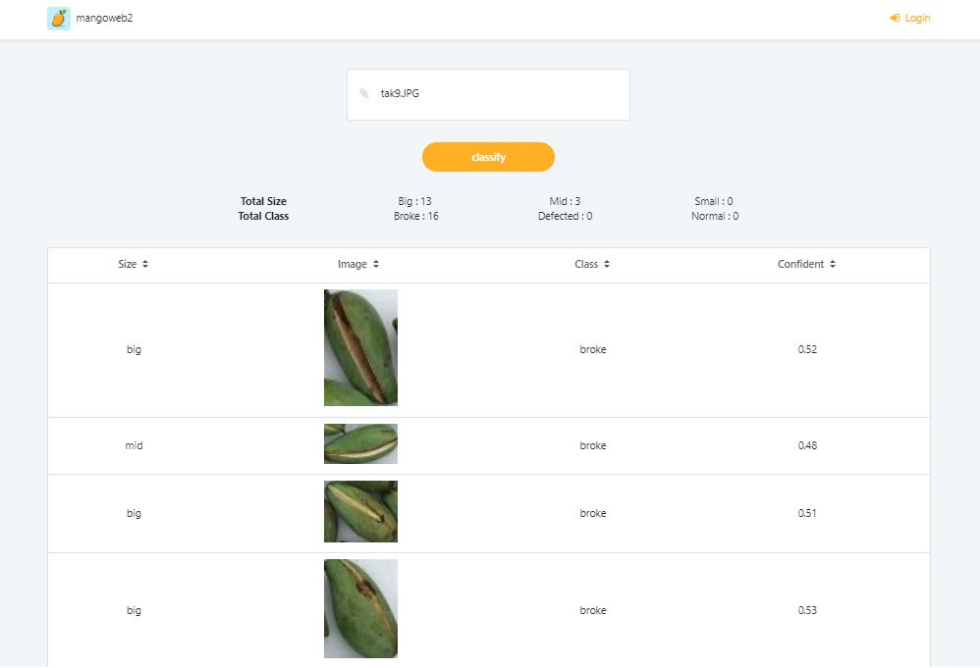

รูปผนวกที่ ก.5 หน้าจอแสดงผลลัพธ์มะม่วงแตก

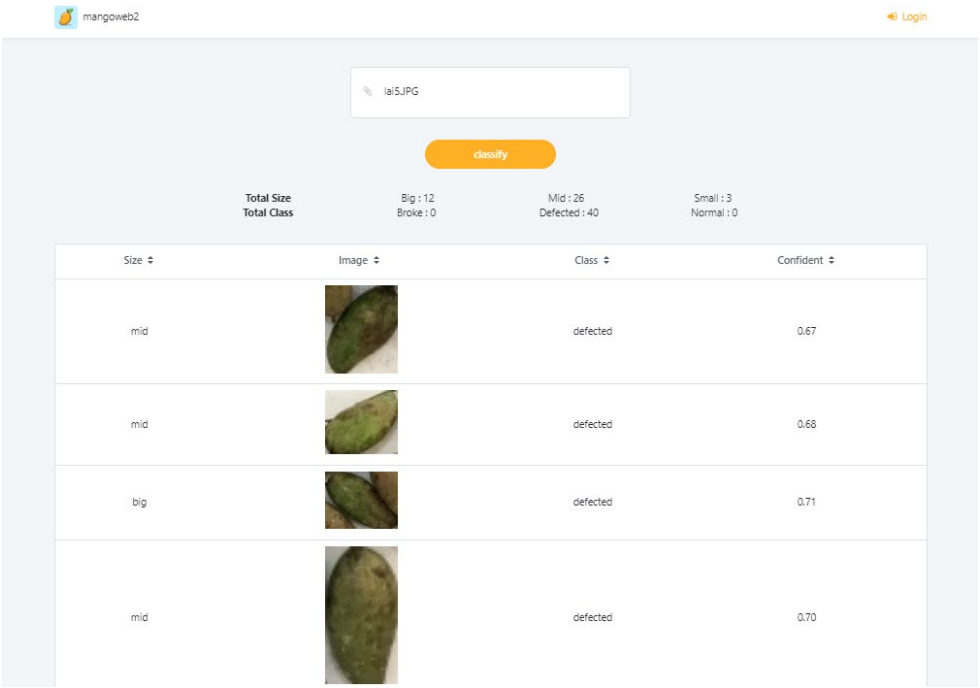

รูปผนวกที่ ก.6 หน้าจอแสดงผลลัพธ์มะม่วงลาย