ใบอนุมัติโครงงานปริญญานิพนธ์
สาขาวิชาเทคโนโลยีสารสนเทศ ภาควิชาคอมพิวเตอร์
คณะวิทยาศาสตร์ มหาวิทยาลัยศิลปากร

ชื่อปริญญานิพนธ์ แอปพลิเคชันการคัดแยกความสุกของถั่วเหลืองด้วยระบบปัญญาประดิษฐ์

Classification ripeness of Soybeans Application using Artificial Intelligence

ผู้จัดทำ นายภาณุวิชญ์ เอมชม

ปีการศึกษา 2565

โครงงานปริญญานิพนธ์นี้ได้รับการอนุมัติให้เป็นส่วนหนึ่งของการศึกษาตาม
หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาเทคโนโลยีสารสนเทศ
ภาควิชาคอมพิวเตอร์ คณะวิทยาศาสตร์ มหาวิทยาลัยศิลปากร

..... ประธานกรรมการสอบ
(อาจารย์ ดร.เสาวลักษณ์ อร่ามพงศานุวัต)

..... กรรมการสอบ
(ผู้ช่วยศาสตราจารย์บัณฑิต ภูริชิติพร)

..... อาจารย์ที่ปรึกษาและกรรมการสอบ
(ผู้ช่วยศาสตราจารย์ ดร.อรวรรณ เชาวลิต)

แอปพลิเคชันการคัดแยกความสุกของถั่วเหลืองด้วยระบบปัญญาประดิษฐ์

Classification ripeness of Soybeans Application using Artificial Intelligence

ภาณุวิชญ์ เอมชม

ปริญญานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาในหลักสูตรวิทยาศาสตรบัณฑิต
สาขาวิชาเทคโนโลยีสารสนเทศ ภาควิชาคอมพิวเตอร์
คณะวิทยาศาสตร์ มหาวิทยาลัยศิลปากร
ปีการศึกษา 2565

ชื่อปริญญานิพนธ์ แอปพลิเคชันการคัดแยกความสุกของถั่วเหลืองด้วยระบบปัญญาประดิษฐ์
Classification ripeness of Soybeans Application using Artificial Intelligence

ผู้จัดทำ นายภาณุวิชญ์ เอมชม

อาจารย์ที่ปรึกษา ผู้ช่วยศาสตราจารย์ ดร.อรวรรณ เชาวลิต

ชื่อปริญญา วิทยาศาสตรบัณฑิต (เทคโนโลยีสารสนเทศ)

ปีการศึกษา 2565

บทคัดย่อ

ในปัจจุบันประเทศไทยมีการนำเข้าถั่วเหลืองมากมาย เพื่ออุตสาหกรรมอาหารสัตว์ ด้วยสีของความสุกของถั่วเหลืองในแต่ละระดับ มีลักษณะที่คล้ายกันมาก และมีผลต่อปริมาณโปรตีนที่สัตว์จะได้รับ จึงทำให้การคัดแยกด้วยสายตาอาจไม่ถูกต้อง จึงทำให้เป็นอุปสรรคต่อการคัดแยก และส่งผลต่อปริมาณโปรตีนที่สัตว์จะได้รับ

จากปัญหาดังกล่าว ทางผู้จัดทำจึงได้พัฒนาแอปพลิเคชันคัดแยกความสุกของถั่วเหลืองขึ้น โดยใช้เทคนิคการเรียนรู้เชิงลึก (Deep Learning) โดยบนแอปพลิเคชันผู้ใช้สามารถนำรูปภาพถั่วเหลืองมาคัดแยกระดับความสุกได้ โดยการถ่ายรูปหรือเลือกจากอัลบั้มรูปภาพ พร้อมทั้งแสดงระดับความสุกของถั่วเหลือง และค่าความมั่นใจในการทำนาย

ในการดำเนินโครงงานนี้ ได้ทำการทดสอบระบบคัดแยกระดับความสุกของถั่วเหลือง โดยรูปภาพที่ใช้ฝึกสอนมีชุดข้อมูลทั้งหมด 1,000 รูป จำนวนรอบที่ใช้ในการฝึกสอนชุดข้อมูลทั้งหมด 300 รอบ และมีการทำ image augmentation ด้วยการซูมรูปภาพในช่วง 80% - 120% จากผลการทดสอบระบบสรุปได้ว่า โมเดลที่มีค่าความถูกต้องสูงที่สุดที่เลือกใช้โมเดล DenseNet คือโมเดลที่มีการกำหนดค่า dropout เท่ากับ 0.3 จำนวน 3 รอบ โดย layer Dense เท่ากับ 1024 512 และ 256 ซึ่งมีค่าความถูกต้องอยู่ที่ 0.92 และได้นำไปทดสอบกับผู้ใช้จำนวน 15 คน จากการประเมินระดับความพึงพอใจของผู้ใช้งานแอปพลิเคชันมีค่าเฉลี่ยรวมอยู่ที่ 4.36 ซึ่งผลการประเมินอยู่ในเกณฑ์ดี

คำสำคัญ: ถั่วเหลือง, ระดับความสุกของถั่วเหลือง, การเรียนรู้เชิงลึก

Keywords: soybean, ripeness of soybeans, Deep Learning

กิตติกรรมประกาศ

โครงงานปริญญานิพนธ์หัวข้อแอปพลิเคชันการคัดแยกความสุกของถั่วเหลืองด้วยระบบปัญญาประดิษฐ์ สามารถสำเร็จลุล่วงไปได้ด้วยดี เพราะเกิดจากความกรุณาของผู้ช่วยศาสตราจารย์ ดร.อรวรรณ เชาวลิต อาจารย์ที่ปรึกษาปริญญานิพนธ์ที่คอยให้คำแนะนำ คำชี้แนะต่าง ๆ ในการแก้ไขปัญหา และช่วยตรวจสอบความถูกต้องของเนื้อหางาน และรูปเล่มของของปริญญานิพนธ์มาโดยตลอด

ขอขอบพระคุณประธานกรรมการสอบและกรรมการสอบทุกท่าน ที่ช่วยชี้แนะให้เห็นถึงข้อบกพร่องของโครงงานปริญญานิพนธ์และคอยใส่ใจแนะแนวทางในการแก้ไขปัญหาเพื่อให้สามารถพัฒนาปริญญานิพนธ์ตลอดมา

ขอขอบพระคุณคณาจารย์ภาควิชาคอมพิวเตอร์คณะวิทยาศาสตร์ มหาวิทยาลัยศิลปากรทุกท่านที่ได้ถ่ายทอดวิชาความรู้และคำแนะนำต่าง ๆ ที่ก่อให้เกิดประโยชน์ต่อการทำปริญญานิพนธ์

ขอบคุณครอบครัวและเพื่อนๆที่ให้คำแนะนำเกี่ยวกับการทำงานของแอปพลิเคชันและเป็นกำลังใจที่ทำให้ปริญญานิพนธ์สำเร็จลุล่วงได้ด้วยดี

ภาณุวิชญ์ เอมชม

สารบัญ

หน้า

บทคัดย่อ ..... ก

กิตติกรรมประกาศ ..... ข

สารบัญ ..... ค

สารบัญรูป ..... ช

สารบัญตาราง ..... ฌ

บทที่ 1 บทนำ 1

1.1 ที่มาและความสำคัญของปัญหา 1

1.2 วัตถุประสงค์ 1

1.3 ลักษณะและขอบเขต 1

1.4 อุปกรณ์และเครื่องมือที่ใช้ 2

1.4.1 ฮาร์ดแวร์ 2

1.4.2 ซอฟต์แวร์ 2

1.5 ผลที่คาดว่าจะได้รับ 2

บทที่ 2 ผลงานที่เกี่ยวข้อง 3

2.1 PhotoAI - Mobile Image Classification [1] 3

2.1.1 ข้อดี 5

2.1.2 ข้อเสีย 5

2.2 GSTAI Image Classification [2] 5

2.2.1 ข้อดี 6

2.2.2 ข้อเสีย 6

2.3 การจำแนกความสดของเนื้อโคด้วยการวิเคราะห์ภาพ (Classification of beef freshness using image) [3] 6

2.3.1 ข้อดี 7

2.3.2 ข้อเสีย 7

2.4 Classification of Fruit Ripeness Grades using a Convolutional Neural Network and Data Augmentation .. 7
2.4.1 ข้อดี 7
2.4.2 ข้อเสีย 7
บทที่ 3 ทฤษฎีและความรู้ที่เกี่ยวข้อง 8
3.1 ถั่วเหลือง (Soybean) 8
3.1.1 ลักษณะทางพฤษศาสตร์ [5] 8
3.1.2 โครงสร้างของเมล็ดถั่วเหลือง [5] 8
3.1.3 ส่วนประกอบทางเคมีของถั่วเหลือง [5] 9
3.1.4 การตรวจสอบความสุก-ดิบของถั่วเหลืองด้วยการวิเคราะห์และทดสอบด้วยสารเคมี [6] 9
3.2 Deep Learning [7] 9
3.3 Convolutional Neural Network [8] 9
3.3.1 2D Convolutions Concept [8] 9
3.3.2 Stride และ Padding [8] 10
3.3.3 Pooling [8] 11
3.4 TensorFlow [10] 11
3.5 Image classification [11] 12
3.5.1 ข้อมูลภาพแบบควบคุม (Supervised classification) [11] 12
3.5.2 การจำแนกประเภทข้อมูลแบบไม่ควบคุม (Unsupervised classification) [11] 12
3.6 Confusion Matrix [13] 13
3.6.1 ค่า Accuracy [13] 13
3.6.2 ค่า Precision [13] 13
3.6.3 ค่า Recall 13
3.6.4 ค่า F1 Score [13] 14
3.7 การทำ Regularization [14] 14
3.7.1 Image Augmentation [14] 14
3.7.2 Batch Normalization [14] 14

3.7.3 Dropout [14] 15
3.8 Android Studio [15] 15
3.9 Post-Training Quantization [16] 15
3.9.1 Optimization options [16] 16
3.10 DenseNet [17] 16
บทที่ 4 ขั้นตอนและแผนการดำเนินงาน 18
4.1 ขั้นตอนการดำเนินงาน 18
4.1.1 วางแผนในการดำเนินงาน 18
4.1.2 ศึกษาและรวบรวมข้อมูล 18
4.1.3 วิเคราะห์และออกแบบระบบ 18
4.1.4 พัฒนาระบบ 18
4.1.5 ทดสอบระบบ 18
4.1.6 จัดทำเอกสาร 18
4.2 ระยะเวลาการดำเนินงาน 19
บทที่ 5 การวิเคราะห์และออกแบบระบบ 20
5.1 โครงสร้างและการทำงานของระบบ 20
5.1.1 โครงสร้างของระบบแอปพลิเคชัน 20
5.1.2 ขั้นตอนการสร้าง Model 21
5.1.3 User Interface 31
บทที่ 6 ผลการดำเนินงาน ข้อจำกัด และข้อเสนอแนะ 33
6.1 ผลการดำเนินงาน 33
6.1.1 ผลการทดสอบโมเดล 33
6.1.2 การประเมินความพึงพอใจผู้ใช้งาน 34
6.1.3 ผลการทดลองการประเมินผลวัดระดับความพึงพอใจของผู้ใช้งานแอปพลิเคชัน 34
6.2 ข้อจำกัด 35
6.3 ข้อเสนอแนะ 35

บรรณานุกรม 36
ภาคผนวก ก คู่มือการติดตั้งแอปพลิเคชันการคัดแยกความสุกของถั่วเหลือง 38
ภาคผนวก ข คู่มือใช้งานแอปพลิเคชันการคัดแยกความสุกของถั่วเหลือง 40
ข.1 ส่วนของการเข้าใช้งานของผู้ใช้งานแอปพลิเคชัน 40
ข.2 ส่วนการแสดงผลการทำนายของแอปพลิเคชัน 42
ภาคผนวก ค แบบประเมินความพึงพอใจของผู้ใช้งาน 43

สารบัญรูป

หน้า

รูปที่ 2.1 รูปแอป PhotoAI - Mobile Imgage Classifiction [1] 3
รูปที่ 2.2 รูปหน้าเลือกหมวดหมู่ภาพแอป PhotoAI - Mobile Image Classification [1] 3
รูปที่ 2.3 รูปหน้าเลือกวิธีการเลือกภาพแอป PhotoAI - Mobile Image Classification [1] 4
รูปที่ 2.4 รูปหน้าแสดงผลการทำนายแอป PhotoAI - Mobile Image Classification [1] 4
รูปที่ 2.5 รูปการแสดงผลการทำนายของแอป GSTAI Image Classification [2] 5
รูปที่ 2.6 รูปตัวอย่างเนื้อโค [3] 6
รูปที่ 3.1 รูปฝักถั่วเหลือง [5] 8
รูปที่ 3.2 รูป 2D Convolutions [9] 10
รูปที่ 3.3 รูป Stride และ Padding [9] 10
รูปที่ 3.4 รูปการทำ pooling [9] 11
รูปที่ 3.5 รูป TensorFlow [10] 11
รูปที่ 3.6 รูป Image Classification [12] 12
รูปที่ 3.7 รูป Confusion Matrix [13] 13
รูปที่ 3.8 รูปการทำ Image Augmentation ด้วยเทคนิค zoom [14] 14
รูปที่ 3.9 รูป Android Studio [15] 15
รูปที่ 3.10 รูปโครงสร้างการเชื่อมต่อของโมเดล densenet [18] 17
รูปที่ 5.1 รูปแสดงโครงสร้างของระบบแอปพลิเคชัน 20
รูปที่ 5.2 รูปแสดงขั้นตอนการสร้าง model 21
รูปที่ 5.3 รูปการแบ่งชุดข้อมูลสำหรับการฝึกโมเดลและการทดสอบโมเดล 22
รูปที่ 5.4 รูปการเข้ารหัส one hot encoding 22
รูปที่ 5.5 รูปการทำการ Image Augmentation ด้วยเทคนิค zoom 22
รูปที่ 5.6 รูปการสร้างโมเดลที่ 1 23
รูปที่ 5.7 รูปการสร้างโมเดลที่ 2 24
รูปที่ 5.8 รูปการสร้างโมเดลที่ 3 25
รูปที่ 5.9 รูปการสร้างโมเดลที่ 4 26
รูปที่ 5.10 รูปการ plot กราฟค่า loss และค่า accuracy 27
รูปที่ 5.11 รูปกราฟแสดงค่า loss และค่า accuracy ของโมเดลที่ 1 27
รูปที่ 5.12 รูปกราฟแสดงค่า loss และค่า accuracy ของโมเดลที่ 2 27
รูปที่ 5.13 รูปกราฟแสดงค่า loss และค่า accuracy ของโมเดลที่ 3 28
รูปที่ 5.14 รูปกราฟแสดงค่า loss และค่า accuracy ของโมเดลที่ 4 28

รูปที่ 5.15 รูปแสดงการวัดค่าประสิทธิภาพความถูกต้องของโมเดล 28
รูปที่ 5.16 รูป Confusion Matrix 29
รูปที่ 5.17 รูปค่า precision recall f1score และ support 29
รูปที่ 5.18 รูปการทำ Post-Training Quantization 30
รูปที่ 5.19 รูปการสร้างโมเดลเป็น .Tflite 30
รูปที่ 5.20 รูปหน้าหลักของแอปพลิเคชัน 31
รูปที่ 5.21 รูปหน้าแสดงผลการทำนาย 32
รูปผนวกที่ ก.1 ติดตั้ง Mr.Soybean 38
รูปผนวกที่ ก.2 แอปพลิเคชัน Mr.Soybean 39
รูปผนวกที่ ข.1 รูปหน้าหลักเลือกวิธีการเลือกภาพ 40
รูปผนวกที่ ข.2 รูปเลือกภาพจากคลังรูปภาพ 41
รูปผนวกที่ ข.3 รูปหน้าถ่ายรูปภาพ 41
รูปผนวกที่ ข.4 รูปแสดงผลการทำนายความสุกของถั่วเหลือง 42

สารบัญตาราง

หน้า

ตารางที่ 3.1 ตารางแสดง Optimization options [16] 16
ตารางที่ 4.1 ตารางระยะเวลาการดำเนินงาน 19
ตารางที่ 5.1 ตารางแสดงการเปรียบเทียบการทำงานทั้ง 4 โมเดล 31
ตารางที่ 6.1 ตารางเปรียบเทียบการทำงานโมเดล 33
ตารางที่ 6.2 ตารางเกณฑ์การให้คะแนนของผลการประเมิน 34
ตารางที่ 6.3 ตารางสรุปผลการประเมินความพึงพอใจของผู้ใช้งานแอปพลิเคชัน 34

บทที่ 1 บทนำ

1.1 ที่มาและความสำคัญของปัญหา

ปัจจุบันประเทศไทยมีการนำเข้าสินค้าเกษตรมากมาย หนึ่งในนั้นคือถั่วเหลือง เป็นวัตถุดิบที่สำคัญของอุตสาหกรรมหลายประเภท ทั้งอุตสาหกรรมแปรรูปผลิตภัณฑ์อาหาร อุตสาหกรรมสกัดน้ำมัน และอุตสาหกรรมอาหารสัตว์ ถั่วเหลืองเป็นพืชที่ให้ทั้งโปรตีนและน้ำมัน ซึ่งเป็นสินค้าเกษตรที่จำเป็นอย่างมากในประเทศไทย

เนื่องจากในประเทศไทยมีการผลิตถั่วเหลืองน้อย และผลผลิตถั่วเหลืองของประเทศไทยลดลงอย่างมาก จึงมีการนำเข้าถั่วเหลือง แต่ความสุกของถั่วเหลืองนั้นมีผลต่อโปรตีนที่จะได้รับ และการที่จะคัดแยกความสุกของถั่วเหลืองด้วยการตรวจสอบทางห้อง ปฏิบัติการนั้นจะเสียเวลาและทรัพยากร หรือคัดแยกความสุกของถั่วเหลืองด้วยตาของมนุษย์อาจมีความคลาดเคลื่อน

ดังนั้นเราจึงนำเทคโนโลยีปัญญาประดิษฐ์ (Artificial Intelligence หรือ AI) มาประยุกต์ใช้เพื่อสร้างแอปพลิเคชันนี้ขึ้นมาเพื่อคัดแยกความสุกของถั่วเหลือง โดยบนแอปพลิเคชันนี้ผู้ใช้สามารถนำรูปภาพถั่วเหลืองมาคัดแยกความสุกให้ง่ายขึ้นได้ โดยการถ่ายรูปหรือเลือกจากอัลบั้มรูปภาพ

1.2 วัตถุประสงค์

1. เพื่อคัดแยกความสุกของถั่วเหลือง
2. เพื่อลดความคลาดเคลื่อนในการคัดแยก

1.3 ลักษณะและขอบเขต

โครงงานวิจัยนี้มีจุดมุ่งหมายเพื่อใช้เทคโนโลยีปัญญาประดิษฐ์ในการคัดแยกความสุกของถั่วเหลือง โดยการพัฒนาโมเดลใช้เทคนิคการเรียนรู้เชิงลึก แอปพลิเคชันการคัดแยกความสุกของถั่วเหลืองด้วยระบบปัญญาประดิษฐ์ DenseNet ที่ถูกพัฒนาโดยใช้เทคนิค Convolutional Neural Network เพื่อสร้างโมเดลที่มีความแม่นยำและประสิทธิภาพในการคัดแยกความสุกของถั่วเหลือง โดยใช้ข้อมูลรูปภาพถั่วเหลืองที่มีความสุกแตกต่างกันอยู่ 10 class และจะทำการคัดแยกความสุกของถั่วเหลืองออกเป็น 10 ระดับ ในรูปแบบของเปอร์เซ็นต์ ได้แก่

1. ถั่วเหลืองสุก 10 เปอร์เซ็นต์
2. ถั่วเหลืองสุก 20 เปอร์เซ็นต์
3. ถั่วเหลืองสุก 30 เปอร์เซ็นต์
4. ถั่วเหลืองสุก 40 เปอร์เซ็นต์
5. ถั่วเหลืองสุก 50 เปอร์เซ็นต์
6. ถั่วเหลืองสุก 60 เปอร์เซ็นต์
7. ถั่วเหลืองสุก 70 เปอร์เซ็นต์
8. ถั่วเหลืองสุก 80 เปอร์เซ็นต์
9. ถั่วเหลืองสุก 90 เปอร์เซ็นต์

10. ถั่วเหลืองสุก 100 เปอร์เซ็นต์

ระบบนี้จะเป็น Mobile Application พัฒนาบนระบบปฏิบัติการ Android ที่ให้ผู้ใช้งานเลือกรูปภาพถั่วเหลืองโดยการถ่ายรูปหรือเลือกจากอัลบั้มรูปภาพ เพื่อให้แอปพลิเคชันทำการคัดแยกระดับความสุกของถั่วเหลืองออกมาในรูปแบบของเปอร์เซ็นต์และแสดงค่าความมั่นใจในการทำนาย

1.4 อุปกรณ์และเครื่องมือที่ใช้

1.4.1 ฮาร์ดแวร์

-ASUS TUF Gaming A15

หน่วยประมวลผลกลาง AMD Ryzen 7 4800H CPU @ 2.90 GHz

หน่วยความจำ 16 GB

ฮาร์ดดิสก์ 512 GB

1.4.2 ซอฟต์แวร์

- ระบบปฏิบัติการ: Windows 10
- ภาษาที่ใช้: Python, java
- โปรแกรมที่ใช้: Android Studio, JupyterLab

1.5 ผลที่คาดว่าจะได้รับ

1. ได้แอปพลิเคชันที่สามารถคัดแยกความสุกของถั่วเหลืองได้
2. ผู้จัดทำได้พัฒนาทักษะในการเขียนโปรแกรมเพื่อออกแบบและพัฒนาโมเดลและแอปพลิเคชัน

บทที่ 2 ผลงานที่เกี่ยวข้อง

การจัดทำแอปพลิเคชันการคัดแยกความสุกของถั่วเหลือง ประกอบไปด้วยผลงานที่เกี่ยวข้อง โดยแต่ละผลงานจะอธิบายลักษณะการทำงาน ข้อดีและข้อเสียของแต่ละผลงาน โดยมีรายละเอียดดังนี้

2.1 PhotoAI - Mobile Image Classification [1]

รูปที่ 2.1 รูปแอป PhotoAI - Mobile Imgage Classifiction [1]

PhotoAI - Mobile Image Classification เป็นแอปพลิเคชันที่อยู่บนระบบปฏิบัติการ Android เป็นแอปพลิเคชันที่ใช้สำหรับจำแนกประเภทของภาพถ่ายในสามหมวดหมู่ คือ สิ่งของทั่วไปในชีวิตประจำวัน สายพันธุ์สุนัข และประเภทดอกไม้ ผู้ใช้สามารถใช้งานแอปพลิเคชันนี้ได้โดยการถ่ายรูป หรือเลือกภาพจากอัลบั้มรูปภาพ หรือไลฟ์จากกล้องของมือถือ

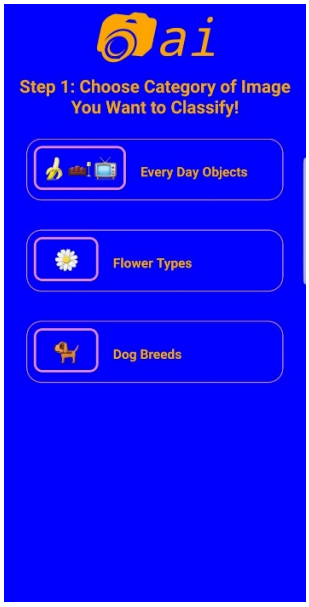

รูปที่ 2.2 รูปหน้าเลือกหมวดหมู่ภาพแอป PhotoAI - Mobile Image Classification [1]

แอปพลิเคชัน PhotoAI - Mobile Image Classification สามารถเลือกหมวดหมู่ของภาพที่จะนำมาทำนายได้ 3 หมวด คือ สิ่งของทั่วไปในชีวิตประจำวัน สายพันธุ์สุนัข และประเภทดอกไม้

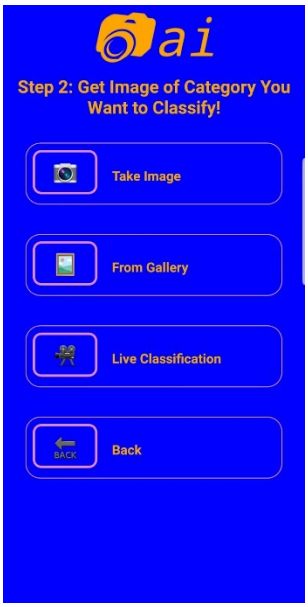

รูปที่ 2.3 รูปหน้าเลือกวิธีการเลือกภาพแอป PhotoAI - Mobile Image Classification [1]

แอปพลิเคชัน PhotoAI - Mobile Image Classification สามารถเลือกรูปภาพที่จะนำมาทำนายได้ 3 วิธี โดยการถ่ายรูป หรือเลือกภาพจากอัลบั้มรูปภาพ หรือไลฟ์จากกล้องของมือถือ

รูปที่ 2.4 รูปหน้าแสดงผลการทำนายแอป PhotoAI - Mobile Image Classification [1]

แอปพลิเคชัน PhotoAI - Mobile Image Classification จะแสดงผลการทำนายทั้งหมดออกมา พร้อมกับค่าความมั่นใจเป็นเปอร์เซ็นต์

2.1.1 ข้อดี

- แอปพลิเคชันมีฟังก์ชันการใช้งานที่เข้าใจง่าย

- มีให้เลือกหมวดหมู่ของภาพถึง 3 หมวด

2.1.2 ข้อเสีย

- เนื่องจากหมวดสิ่งของทั่วไปค่อนข้างกว้างและเยอะมาก จึงอาจมีการทำนายผิดพลาด

- การออกแบบสีหน้าจอการแสดงผลไม่ค่อยสวยงาม

2.2 GSTAI Image Classification [2]

GSTAI Image Classification เป็นแอปพลิเคชันที่อยู่บนระบบปฏิบัติการ Android เป็นแอปพลิเคชันจำแนกวัตถุต่าง ๆ ด้วยภาพจากกล้องหลังของโทรศัพท์มือถือ แอปพลิเคชันนี้จะนำภาพไปประมวลผลโดยใช้โมเดล Deep Learning ที่ถูกฝึกสอนด้วยการใช้เทคโนโลยี GSTAI (Generalized Space-Time Artificial Intelligence) ในการจำแนกภาพ โดยสามารถจำแนกได้หลายประเภท ได้แก่ ชนิดของสัตว์ ชนิดของพืช และวัตถุ

รูปที่ 2.5 รูปการแสดงผลการทำนายของแอป GSTAI Image Classification [2]

เมื่อเปิดแอปพลิเคชันขึ้นมาจะเป็นการเปิดกล้องหลังของโทรศัพท์มือถือทันที แอปพลิเคชันจะทำนายสิ่งที่เห็นจากกล้องหลังของโทรศัพท์มือถือ และแสดงออกมาเป็นผลลัพธ์ทั้งหมดที่ทำนายได้ พร้อมค่าความมั่นใจเป็นเปอร์เซ็นต์

2.2.1 ข้อดี

- สามารถจำแนกวัตถุต่าง ๆ ได้เยอะหลากหลายประเภท

- แอปพลิเคชันมีฟังก์ชันการใช้งานที่เข้าใจง่าย

2.2.2 ข้อเสีย

- แอปพลิเคชันไม่สามารถเลือกรูปภาพจากอัลบั้มได้

- แอปพลิเคชันไม่มีหน้าหลัก เมื่อกดเข้าแอปจะเป็นการเปิดกล้องทันที

2.3 การจำแนกความสดของเนื้อโคด้วยการวิเคราะห์ภาพ (Classification of beef freshness using image) [3]

เนื้อโคเป็นอาหารที่มาจากสัตว์ที่คนนิยมรับประทานกันมาก ความปลอดภัย คุณภาพและความสดของเนื้อสัตว์จึงเป็นสิ่งสำคัญ งานวิจัยนี้ศึกษาวิธีการวิเคราะห์ภาพเพื่อจำแนกความสดของเนื้อโค โดยมีการทดลองด้วยวิธีวิเคราะห์ภาพ PCA and SVM algorithms ซึ่งมีความแม่นยำอยู่ที่ 100% วิธีการทดลอง จับภาพเนื้อโคโดยกล้อง GigEPRO จากเทคโนโลยีอิเล็กทรอนิกส์ใหม่เป็นรุ่น GP1503C ความละเอียดของภาพคือ 2592×1944 พิกเซล อัตราการถ่ายโอนข้อมูลระหว่างกล้องและ DSP ขนาด 1 Gbps ภาพที่ได้มาแต่ละภาพเป็น RGB ภาพเนื้อโคจะถูกจับในแต่ละวันเพื่อสร้างชุดข้อมูล ภาพที่ถ่ายในช่วงเก้าวันถูกนำมาใช้เพื่อสร้างโมเดลการจำแนกประเภท และคำนวณพิกเซลจากแต่ละภาพ และโมเดลสี HSI ด้วย PCA and SVM algorithms ให้เป็นค่าทางสถิติ และนำมาเปรียบเทียบด้วยค่าการวัดโดยใช้ดวงตาของมนุษย์รับรู้สีของเนื้อ

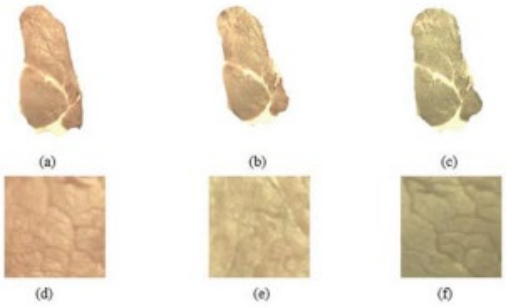

รูปที่ 2.6 รูปตัวอย่างเนื้อโค [3]

จากรูปแสดงถึงวิวัฒนาการของสีเนื้อโควันที่ 1 (a) ,วันที่ 4 (b) , วันที่ 9 (c) และ Region-of-interest (ROI) คือบริเวณที่เราสนใจบนเนื้อวันที่ 1 (d) ,วันที่ 4 (e) และ วันที่ 9 (f) จากผลการทดลองการจำแนกประเภทและการระบุความสดด้วยวิธีการ PCA และ SVM ได้อัตราความแม่นยำ 100%

2.3.1 ข้อดี

- ประสิทธิภาพการจำแนกมีความแม่นยำสูงมาก

2.3.2 ข้อเสีย

- ไม่สามารถตรวจวัดเนื้อได้ทุกส่วน

2.4 Classification of Fruit Ripeness Grades using a Convolutional Neural Network and Data Augmentation [4]

งานวิจัยนี้เป็นการจำแนกความสุกของผลไม้ 5 ชนิด ได้แก่ แอปเปิลแดง แอปเปิลเขียว กล้วย ส้ม และสตรอเบอร์รี่ โดยมีการใช้เทคนิคการประมวลผลภาพเชิงดิจิทัล Otsu Thresholding และ Data Augmentation ในการจำแนกความสุกของผลไม้เป็น 3 ประเภท ได้แก่ ไม่สุก สุกงอม และเน่าเสีย โดยมีตัวอย่างภาพความสุกของผลไม้แต่ละชนิด ชนิดละ 100 ภาพ โดยมีแบ่งข้อมูลเป็นสองชุดมาใช้ในการฝึก และใช้โครงข่ายประสาทเทียมแบบ 9 ชั้น โดยทำการฝึกทั้งหมด 3 โมเดล ได้แก่

1) ใช้เทคนิค CNN กับข้อมูลรูปภาพชุดที่ 1 โดยไม่มีการทำ Data Augmentation

2) ใช้เทคนิค CNN กับข้อมูลรูปภาพชุดที่ 1 โดยมีการทำ Data Augmentation

3) ใช้เทคนิค CNN กับข้อมูลรูปภาพชุดที่ 2 โดยมีการทำ Data Augmentation

จากผลการฝึก โมเดลแรกใช้ข้อมูลรูปภาพชุดที่ 1 มีค่าความถูกต้องอยู่ที่ 77.70 เปอร์เซ็นต์ และเมื่อมีการทำ Data Augmentation ในโมเดลที่สอง จะมีค่าความถูกต้องเพิ่มขึ้นมาที่ 96.34 เปอร์เซ็นต์ และเมื่อใช้ข้อมูลรูปภาพชุดที่ 2 และมีการทำ Data Augmentation ได้ค่าความถูกต้องอยู่ที่ 95.48 เปอร์เซ็นต์

ดังนั้นสรุปได้ว่าในงานวิจัยนี้โมเดลที่ 2 คือใช้เทคนิค CNN กับข้อมูลรูปภาพชุดที่ 1 และทำ Data Augmentation นั้นได้ค่าความถูกต้องที่ดีที่สุดอยู่ที่ 96.34 เปอร์เซ็นต์

2.4.1 ข้อดี

- มีความแม่นยำสูง

- จำแนกผลไม้ได้หลายชนิดทั้ง แอปเปิลแดง แอปเปิลเขียว กล้วย ส้มและสตรอเบอร์รี่

2.4.2 ข้อเสีย

- ข้อมูลที่ใช้ในการฝึกโมเดลมีจำนวนน้อยเกินไป มีแนวโน้มที่จะเกิด overfitting

บทที่ 3 ทฤษฎีและความรู้ที่เกี่ยวข้อง

ในบทนี้จะกล่าวถึงทฤษฎีและความรู้ที่เกี่ยวข้องที่มีความสำคัญต่อการออกแบบและการพัฒนาแอปพลิเคชัน

3.1 ถั่วเหลือง (Soybean)

ถั่วเหลือง [5] เป็นพืชตระกูลถั่วเมล็ดแห้ง ซึ่งอยู่ในกลุ่มพืชน้ำมัน สามารถนำมาแปรรูปเป็นผลิตภัณฑ์อาหารสัตว์ เพื่อเป็นแหล่งโปรตีน โดยความสุกของถั่วเหลืองนั้นมีผลต่อปริมาณโปรตีน

3.1.1 ลักษณะทางพฤษศาสตร์ [5]

ฝักถั่วเหลืองเป็นผลิตภัณฑ์ที่พัฒนามาจากรังไข่ ซึ่งมีลักษณะฝักยาวและโค้ง ภายในฝักจะประกอบด้วยเมล็ดถั่วเหลืองจำนวน 2 - 3 เมล็ด รูปร่างของเมล็ดถั่วเหลืองค่อนข้างกลม ขนาดของเมล็ดถั่วเหลืองแตกต่างกันไปตามพันธุ์ และสามารถเกิดความแตกต่างขึ้นได้จากปัจจัยต่าง ๆ เช่น ฤดูกาลปลูก ความอุดมสมบูรณ์ของดิน สภาพอากาศ และปริมาณน้ำที่ได้รับ โดยทั่วไปเมล็ดถั่วเหลืองจะมีขนาดประมาณ 100 เมล็ดต่อน้ำหนัก 5 - 20 กรัม

รูปที่ 3.1 รูปฝักถั่วเหลือง [5]

3.1.2 โครงสร้างของเมล็ดถั่วเหลือง [5]

เมล็ดถั่วเหลืองมีโครงสร้างแบบถั่วเมล็ดแห้ง ประกอบด้วยส่วนประกอบหลัก 2 ส่วนคือ

1. เปลือกนอกเมล็ด ห่อหุ้มเมล็ดไว้และมีหลายสี เช่น สีเหลืองอ่อน สีเหลืองแกมเขียว สีเขียว สีน้ำตาลอ่อน และสีดำ ฝักมี hilum หรือ seed scar ที่เป็นจุดเชื่อมต่อกับเมล็ด ซึ่งมีสีแตกต่างกันตามพันธุ์ เช่น สีดำ สีน้ำตาล และสีเหลืองเข้ม

2. ต้นอ่อนขณะอยู่ในเมล็ด ประกอบด้วย ใบเลี้ยง เป็นส่วนที่เป็นจุดเจริญของต้นอ่อน ที่จะเจริญไปเป็นใบจริง และลำต้นเอพิคอทิล (epicotyl) คือส่วนที่อยู่เหนือตำแหน่งที่ยึดติดกับใบเลี้ยง ส่วนนี้เมื่อเจริญเติบโตแล้วจะเป็นลำต้นใบ และดอก ไฮโพทอคิล (hypocotyl) คือส่วนที่อยู่ระหว่างตำแหน่งที่ติดของใบเลี้ยง กับตำแหน่งของรากแก้ว ส่วนนี้เมื่อเจริญเติบโตจะเป็นส่วนหนึ่งของลำต้น และเรดิเคิล (radicle) เป็นส่วนล่างสุดของเมล็ด อยู่ต่อจากไฮโพคอทิล

3.1.3 ส่วนประกอบทางเคมีของถั่วเหลือง [5]

ถั่วเหลืองมีสารอาหารหลายชนิดอยู่ในส่วนของใบเลี้ยง ซึ่งเป็นส่วนเนื้อใน ถั่วเหลืองประกอบด้วยโปรตีนสูงและน้ำมันสูงกว่าถั่วเมล็ดแห้งชนิดอื่น ๆ นอกจากนี้ยังมีวิตามินและแร่ธาตุอีกด้วย

3.1.4 การตรวจสอบความสุก - ดิบของถั่วเหลืองด้วยการวิเคราะห์และทดสอบด้วยสารเคมี [6]

การตรวจสอบถั่วเหลืองว่ามีความสุกพอและมีสารยับยั้งทริปซินหรือไม่นั้น สามารถทำได้โดยการตรวจสอบสารยับยั้งทริปซินโดยตรง หรือตรวจสอบน้ำย่อยยูเรีย โดยถั่วเหลืองที่มีความสุกเหมาะสำหรับใช้เป็นอาหารสัตว์ ควรจะมีสารยับยั้งทริปซินไม่เกิน 4 มิลลิกรัมต่อน้ำหนักกรัมถั่วเหลือง วิธีการตรวจสอบน้ำย่อยยูเรีย สามารถใช้วิธีการวัดค่าความแตกต่างของกรด-เบส (DpH) เพื่อบ่งบอกถึงปริมาณของสารยับยั้งทริปซินได้เช่นกัน แต่วิธีการนี้เป็นวิธีที่ยุ่งยาก ดังนั้นมักนิยมใช้วิธีการตรวจสอบน้ำย่อยยูเรียแทน โดยในฟาร์มสามารถตรวจสอบความสุกดิบของถั่วเหลืองได้ ด้วยการใช้น้ำยาตรวจสอบความสุกดิบ ซึ่งน้ำยาชนิดนี้ใช้เพื่อการวัดปริมาณน้ำย่อยยูเรียอย่างคร่าวๆ ในถั่วเหลือง ถ้าในถั่วเหลืองมีน้ำย่อยยูเรียอยู่ จะเกิดปฏิกิริยาย่อยยูเรียในสารละลายเป็นแอมโมเนีย ซึ่งจะทำปฏิกิริยากับสารละลายฟีนอลเรด และเกิดเป็นสีชมพู

3.2 Deep Learning [7]

Deep Learning เป็นการเรียนรู้เชิงลึก เรียนรู้แบบอัตโนมัติโดยใช้โครงข่ายประสาท (Neural Network) ที่ถูกสร้างขึ้นโดยจำลองการทำงานของโครงข่ายประสาทของมนุษย์ (Neurons) โดยระบบนี้สามารถทำการเรียนรู้จากข้อมูลตัวอย่างได้ เพื่อใช้จัดหมวดหมู่ข้อมูล หรือคัดแยกข้อมูล ด้วยความสามารถในการรับข้อมูลดิบเข้ามาและทำการประมวลผลเพื่อหาข้อมูลตัวอย่างที่จำเป็น โดย Deep Learning จะช่วยให้สามารถเรียนรู้ได้อย่างมีประสิทธิภาพ

3.3 Convolutional Neural Network [8]

Convolutional Neural Network เป็นโครงสร้างภายใน Deep Learning Model ที่ใช้แนวคิดของ Convolution เพื่อทำงานกับข้อมูล 2 มิติ เช่น Image Data โดยแต่ละ Pixel ของ Image จะมีความสัมพันธ์กันในเชิงพื้นที่ ลักษณะโครงสร้างของ CNN ถูกออกแบบมาเพื่อทำงานกับ Image Data โดยสามารถแสดงผลการตัดสินใจหรือการทำนายของ Model ด้วยภาพได้ดีกว่า Neural Network ชนิดอื่น ๆ

3.3.1 2D Convolutions Concept [8]

ใน 2D Convolution จะนำ Kernel ขนาดเล็กไป Slide บน Input Image 2 มิติ (สีฟ้า) โดยขณะที่ทาบ Kernel บน Input Image จะทำการคูณค่าแต่ละ Pixel ของ Input Image กับ Kernel แล้วนำผลลัพธ์ทั้งหมดมาบวกกันเป็น 1 จุด Pixel ของ Feature Map (สีเขียว)

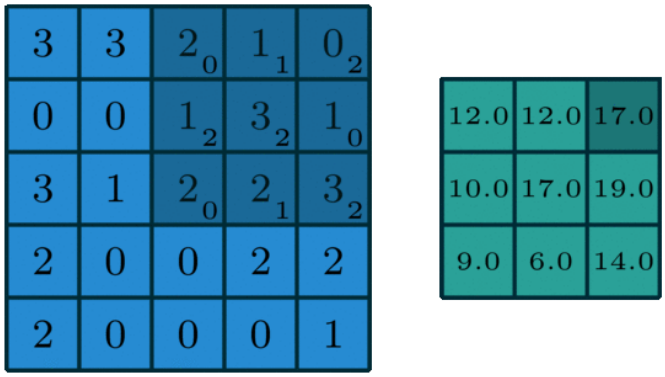

รูปที่ 3.2 รูป 2D Convolutions [9]

3.3.2 Stride และ Padding [8]

Stride [8] เป็นการกำหนดความห่างระหว่างการเลื่อนตัวกรอง (filter) ไปด้วยจำนวนขั้นต่อการเลื่อนหน้าของ Input Image หรือ Feature Map ที่ได้ โดยหากต้องการลดการทับซ้อนของพื้นที่ในการคำนวนหาคุณลักษณะ สามารถกำหนดค่า Stride ให้มากขึ้นได้เช่นกัน

Padding [8] เป็นการขยายขอบเขตของข้อมูลเข้า โดยใส่ค่า 0 หรือค่าอื่น ๆ เข้าไป เพื่อให้ Feature Map ที่ได้จากการทำ 2D Convolution ยังคงมีขนาดเท่ากับ Input

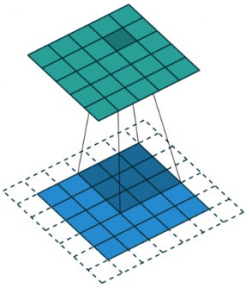

รูปที่ 3.3 รูป Stride และ Padding [9]

3.3.3 Pooling [8]

Pooling เป็นวิธีหนึ่งในการลดขนาดของภาพที่ใช้ในการประมวลผล CNN โดย Max Pooling หรือ Average Pooling จะเป็นกระบวนการภายนอก CNN Layer ซึ่งใช้ในการเลือกตัวแทนของภาพ โดยการหาค่าสูงสุดหรือค่าเฉลี่ยจาก Pixel ใน Window ตามขนาดที่กำหนด เช่น ขนาด 2x2 ทำให้มีการลดขนาดของภาพลงครึ่งหนึ่ง

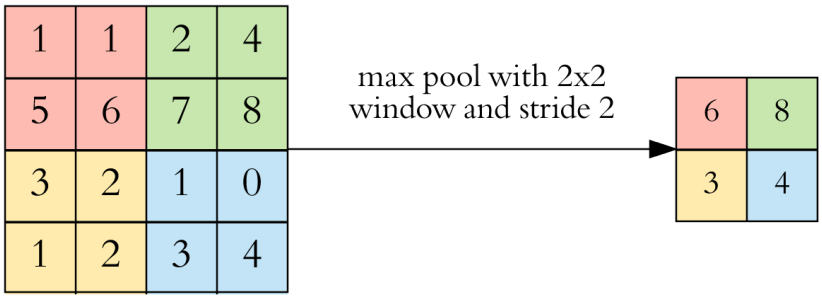

รูปที่ 3.4 รูปการทำ pooling [9]

3.4 TensorFlow [10]

TensorFlow คือไลบรารีสำหรับพัฒนา Machine Learning ที่พัฒนาโดยบริษัท Google ซึ่งได้รับความนิยมในการใช้งานสำหรับการสร้างและฝึกโมเดลเชิงลึก โดย TensorFlow เป็น Open source สำหรับการเรียนรู้เชิงลึกและการประมวลผลแบบคำนวณขนาดใหญ่และใช้ภาษา Python เป็นภาษาหลัก รองรับทั้ง Python 2 และ Python 3 และสามารถทำงานได้ทั้งบน CPU และ GPU รองรับระบบปฏิบัติการ Linux, macOS, Windows และ Android

TensorFlow

รูปที่ 3.5 รูป TensorFlow [10]

3.5 Image classification [11]

คือกระบวนการทำนายหรือจำแนกประเภทของภาพ โดยการแบ่งภาพออกเป็นกลุ่มหรือประเภทต่าง ๆ ที่มีคุณสมบัติคล้ายๆกัน วิธีการจำแนกภาพด้วยระบบคอมพิวเตอร์แบ่งออกเป็น 2 วิธี

3.5.1 ข้อมูลภาพแบบควบคุม (Supervised classification) [11]

คือการกำหนดลักษณะของประเภทของข้อมูลภาพ โดยผู้ใช้งานแล้วเลือกตัวอย่างของประเภทข้อมูลเพื่อส่งเข้าระบบ เครื่องจึงจะได้รับการเรียนรู้ และจำแนกประเภทของข้อมูลภาพตามที่ผู้ใช้งานกำหนด เรียกการจำแนกข้อมูลประเภทนี้ว่าเป็นวิธีแบบควบคุมโดยผู้วิเคราะห์ต้องควบคุมอย่างใกล้ชิด

3.5.2 การจำแนกประเภทข้อมูลแบบไม่ควบคุม (Unsupervised classification) [11]

เป็นวิธีการจำแนกประเภทข้อมูลที่ไม่ต้องกำหนดพื้นที่ตัวอย่างของข้อมูลให้กับคอมพิวเตอร์ โดยใช้เทคนิคการรวมกลุ่ม (Clustering) ซึ่งมักใช้ในกรณีที่ไม่มีข้อมูลเพียงพอในพื้นที่ที่ทำการจำแนก โดยจะสุ่มตัวอย่างของข้อมูลแบบคละ แล้วจึงนำกลุ่มข้อมูลดังกล่าวมาแบ่งเป็นประเภทต่าง ๆ

รูปที่ 3.6 รูป Image Classification [12]

ดังรูปที่ 3.6 แสดงถึงตัวอย่างการจำแนกภาพ โดยผลลัพธ์คือ car ทำนายด้วยความมั่นใจ 95%

3.6 Confusion Matrix [13]

Confusion Matrix

	Actually Positive (1)	Actually Negative (0)
Predicted Positive (1)	True Positives (TPs)	False Positives (FPs)
Predicted Negative (0)	False Negatives (FNs)	True Negatives (TNs)

รูปที่ 3.7 รูป Confusion Matrix [13]

Confusion Matrix [13] คือ ตารางที่ใช้แสดงผลประสิทธิภาพของโมเดลในการทำนาย จากรูปที่ 3.7 อธิบายตัวแปรได้ดังนี้

True Positive (TP) = สิ่งที่ทำนายถูกต้องและตรงกับสิ่งที่เกิดขึ้นจริง

True Negative (TN) = สิ่งที่ทำนายถูกต้องและตรงกับสิ่งที่ไม่เกิดขึ้นจริง

False Positive (FP) = สิ่งที่ทำนายไม่ถูกต้อง คือทำนายว่าจริง แต่สิ่งที่เกิดขึ้นคือไม่จริง

False Negative (FN) = สิ่งที่ทำนายไม่ถูกต้อง คือทำนายว่าไม่จริง แต่สิ่งที่เกิดขึ้นคือจริง

3.6.1 ค่า Accuracy [13]

คือค่าที่ใช้วัดความถูกต้องของโมเดล แทนด้วยสูตร : Accuracy = (TPs + TNs) / (TPs + TNs + FPs + FNs) กล่าวได้ว่า Accuracy = ผลรวมของค่า True Positive และ True Negative ใน Confusion Matrix / จำนวน observations ทั้งหมด

3.6.2 ค่า Precision [13]

เป็นค่าความแม่นยำที่วัดว่าโมเดลมีความสามารถในการทำนายให้ถูกต้องว่า จริง และก็เกิดขึ้นจริง (TP) เมื่อเทียบกับการทำนายว่า จริง แต่สิ่งที่เกิดขึ้น คือ ไม่จริง (FP)

สูตร : Precision = TPs / (TPs + FPs)

3.6.3 ค่า Recall [13]

เป็นค่าที่วัดว่าโมเดลสามารถจะตรวจจับ positive instances ทั้งหมดใน dataset ได้เท่าไหร่

สูตร : Recall = TPs / (TPs + FNs)

3.6.4 ค่า F1 Score [13]

เป็นค่าที่ใช้สำหรับวัดความสามารถของโมเดลในการทำนาย โดยเฉลี่ยแบบ harmonic mean ระหว่างค่า Precision และค่า Recall จุดประสงค์ของการสร้าง F1 คือเพื่อให้ได้ metric เดียวที่สามารถใช้วัดความสามารถของโมเดลได้อย่างเหมาะสม

สูตร : F1 = 2 x (Precision x Recall) / (Precision + Recall)

3.7 การทำ Regularization [14]

คือการปรับแต่งให้ Model มีประสิทธิภาพในการทำนายที่ดีขึ้น โดยเทคนิค Augmentation, Batch Normalization และ Dropout จะช่วยลดค่า Error ของข้อมูลใหม่ด้วยการเรียนรู้ของโมเดลจากชุดข้อมูลที่มีอยู่ จะช่วยลดปัญหา Overfitting เป็นปัญหาที่เกิดขึ้นเมื่อโมเดลเรียนรู้แม่นยำมากเกินไป ซึ่งจะทำให้โมเดลไม่สามารถทำนายข้อมูลใหม่ได้อย่างถูกต้อง

3.7.1 Image Augmentation [14]

คือกระบวนการเพิ่มข้อมูล โดยใช้เทคนิคต่าง ๆ เพื่อเพิ่มจำนวนข้อมูลให้มากขึ้น โดยเฉพาะสำหรับข้อมูลรูปภาพ และยังช่วยเพิ่มความหลากหลายและประสิทธิภาพในการ train โมเดล

รูปที่ 3.8 รูปการทำ Image Augmentation ด้วยเทคนิค zoom [14]

เทคนิค zoom เป็นเทคนิคในการ augmentation ภาพ โดยจะทำการซูมภาพให้เข้าใกล้มากขึ้นหรือขยายออกห่าง เพื่อเพิ่มความหลากหลายในชุดข้อมูล (dataset) ของภาพที่ใช้สำหรับการฝึกโมเดล ในการเรียนรู้เชิงลึก โดยจะทำการสุ่มเลือกภาพจากชุดข้อมูลที่มีอยู่แล้ว แล้วทำการ crop หรือตัดภาพออกมาเพื่อให้ได้ภาพตามความต้องการที่กำหนดไว้ ซึ่งการทำเทคนิค zoom นี้จะช่วยลด overfitting และเพิ่มความแม่นยำในการทำนายของโมเดลได้

3.7.2 Batch Normalization [14]

เป็นเทคนิคในการทำ Scaling Data เพื่อปรับค่าข้อมูลให้อยู่ในขอบเขตที่กำหนด ก่อนส่งออกเป็น Input ของ Layer ต่อไป การทำ Normalization เป็นการเพิ่มความเร็วในการ Train Model และทำให้ค่า Loss ลดลงเมื่อเทียบกันตอนที่ยังไม่ได้ทำ Normalization เพราะมีค่าข้อมูลที่เล็กกว่า

3.7.3 Dropout [14]

เป็นเทคนิคในการทำ Regularization ที่มีประสิทธิภาพสูง ซึ่งจะช่วยลด Overfitting และเพิ่มประสิทธิภาพในการทำนายของโมเดลได้ โดยการใช้ Dropout ใน Layer ที่กำหนดแล้วจะทำการสุ่มปิด Node ใน Layer นั้นในแต่ละรอบของ Forward Propagation และ Back-propagation ตามอัตราที่กำหนด ทำให้การเชื่อมต่อกับ Neuron Node ที่ถูกปิดนั้นไม่มีการ Update Weight

3.8 Android Studio [15]

Android Studio [15] เป็นเครื่องมือพัฒนา IDE (Integrated Development Environment) ที่ถูกสร้างขึ้นมาโดย Google เพื่อการพัฒนาแอนดรอยด์แอปพลิเคชัน มีฟีเจอร์ที่ช่วยเพิ่มประสิทธิภาพการทำงาน การเขียนโค้ดสะดวกสบายขึ้น เช่น ระบบการสร้าง Gradle ที่ยืดหยุ่น มีอีมูเลเตอร์ที่รวดเร็ว รองรับภาษา C++ มีการสนับสนุน Google Cloud Platform ง่ายต่อการผสานรวมกับ Google Cloud Messaging และ App Engine ทำให้นักพัฒนาแอปพลิเคชันสามารถพัฒนาแอปพลิเคชัน Android ได้อย่างรวดเร็วและมีประสิทธิภาพมากยิ่งขึ้น

รูปที่ 3.9 รูป Android Studio [15]

3.9 Post-Training Quantization [16]

การ Quantization เป็นเครื่องมือที่สำคัญในการปรับปรุงประสิทธิภาพของ Neural Network โดยลดขนาดของโมเดล การใช้ Memory พลังงาน และลดเวลาในการตอบสนอง โดยเฉพาะในการพัฒนาแอปพลิเคชันบนมือถือ เช่น การ Quantization สามารถลดขนาดของโมเดล densenet จาก 91 MB เหลือเพียง 23 MB หรือ 25% เท่านั้น

3.9.1 Optimization options [16]

ตัวเลือกการทำ Post-Training Quantization มีหลายแบบ มีประโยชน์และข้อจำกัดที่แตกต่างกัน ดังตารางด้านล่าง

ตารางที่ 3.1 ตารางแสดง Optimization options [16]

Technique	Benefits	Hardware
Weight quantization	4x smaller, 2-3x speedup, accuracy	CPU
Full integer quantization	4x smaller, 3x+ speedup	CPU, Edge TPU, etc.
Float16 quantization	2x smaller, potential GPU acceleration	CPU/GPU

จากตารางที่ 3.1 Weight quantization เป็นเทคนิคที่นิยมมากที่สุด เพราะยังคงค่า accuracy ไว้ ต่างจากเทคนิคอื่น ๆ ที่มีผลกระทบต่อค่า accuracy ที่มาก

3.10 DenseNet [17]

DenseNet คือ โมเดลการเรียนรู้เชิงลึก (deep learning model) สำหรับการประมวลผลภาพ (image processing) เป็นโมเดล CNN ที่มีโครงสร้างพิเศษ โดยมีการเชื่อมต่อระหว่างเลเยอร์ที่เป็นบล็อกกันแบบหนาแน่น ทำให้มีจำนวนพารามิเตอร์น้อยลง แต่ประสิทธิภาพสูงกว่าโมเดล CNN ทั่วไป โดยวิธีการเชื่อมต่อที่แตกต่างจากโมเดลอื่น ๆ นอกจากนี้ DenseNet ยังใช้เทคนิคที่เรียกว่า bottleneck layers เพื่อลดจำนวนพารามิเตอร์ที่ใช้ในโมเดล ซึ่งช่วยลดการใช้งานหน่วยความจำ และเพิ่มประสิทธิภาพในการเทรนโมเดล และยังใช้เทคนิคที่เรียกว่า growth rate เพื่อกำหนดจำนวนการเพิ่มของฟีเจอร์แมพในแต่ละชั้นของโมเดล ซึ่งช่วยให้โมเดลมีประสิทธิภาพในการเรียนรู้ และลดปัญหาการหายไปของ Gradient ในโมเดล CNN (Convolutional Neural Network) ที่มีความลึกมาก

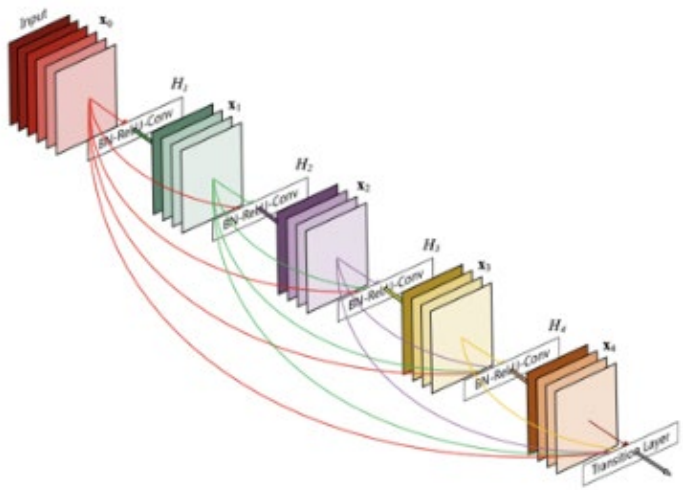

รูปที่ 3.10 รูปโครงสร้างการเชื่อมต่อของโมเดล densenet [18]

DenseNet จะมีการเชื่อมต่อทุกเลเยอร์กับเลเยอร์ที่อยู่ก่อนหน้า เป็นการเชื่อมต่อแบบย่อย (sub-connection) ทำให้สามารถใช้และฝึกโมเดลได้ง่ายขึ้น และทำให้เรียนรู้ได้ดีกว่าโมเดล CNN ปกติ และช่วยเพิ่มความเชื่อมั่นในการเรียนรู้ของโมเดล ด้วยนับว่าเป็นโมเดลที่นิยมใช้กันอย่างแพร่หลายในการประมวลผลภาพ เนื่องจากมีประสิทธิภาพสูง และมีขนาดเล็กกว่าโมเดลอื่นในกลุ่มเดียวกัน โดยสามารถใช้งานได้ดีกับภาพที่มีขนาดเล็กและมีเนื้อหาซับซ้อน

บทที่ 4 ขั้นตอนและแผนการดำเนินงาน

ในบทนี้จะแสดงถึงการทำงาน 2 ส่วน ในส่วนแรกคือรายละเอียดขั้นตอนการดำเนินงาน และส่วนที่สองคือระยะเวลาการดำเนินงาน

4.1 ขั้นตอนการดำเนินงาน

4.1.1 วางแผนในการดำเนินงาน

หาหัวข้อที่สนใจและนำไปเสนอให้กับอาจารย์ที่ปรึกษา

4.1.2 ศึกษาและรวบรวมข้อมูล

ศึกษาและรวบรวมข้อมูลที่เกี่ยวข้องกับการทำเอกสาร ได้แก่ เอกสารโครงงานวิจัย หรือแอปพลิเคชันที่เกี่ยวข้อง อัลกอริทึม และเครื่องมือที่จะนำมาใช้พัฒนาระบบ

4.1.3 วิเคราะห์และออกแบบระบบ

ออกแบบหน้า User Interface และขั้นตอนการทำงานของระบบ

4.1.4 พัฒนาระบบ

ติดตั้งโปรแกรมที่ใช้สำหรับพัฒนา และพัฒนาแอปพลิเคชัน

4.1.5 ทดสอบระบบ

ทดสอบระบบและปรับปรุงแก้ไขเมื่อมีข้อผิดพลาด

4.1.6 จัดทำเอกสาร

จัดทำเอกสารโครงงานปริญญานิพนธ์ให้ถูกต้องสมบูรณ์

4.2 ระยะเวลาการดำเนินงาน

ตารางที่ 4.1 ตารางระยะเวลาการดำเนินงาน

ขั้นตอนการดำเนินงาน	เดือน							
	กรกฎาคม 2565	สิงหาคม 2565	กันยายน 2565	ตุลาคม 2565	พฤศจิกายน 2565	ธันวาคม 2565	มกราคม 2566	กุมภาพันธ์ 2566
1. วางแผนในการดำเนินงาน								
2. ศึกษาและรวบรวมข้อมูล								
3. วิเคราะห์และออกแบบระบบ								
4. พัฒนาระบบ								
5. ทดสอบระบบ								
6. จัดทำเอกสาร								

บทที่ 5 การวิเคราะห์และออกแบบระบบ

5.1 โครงสร้างและการทำงานของระบบ

5.1.1 โครงสร้างของระบบแอปพลิเคชัน

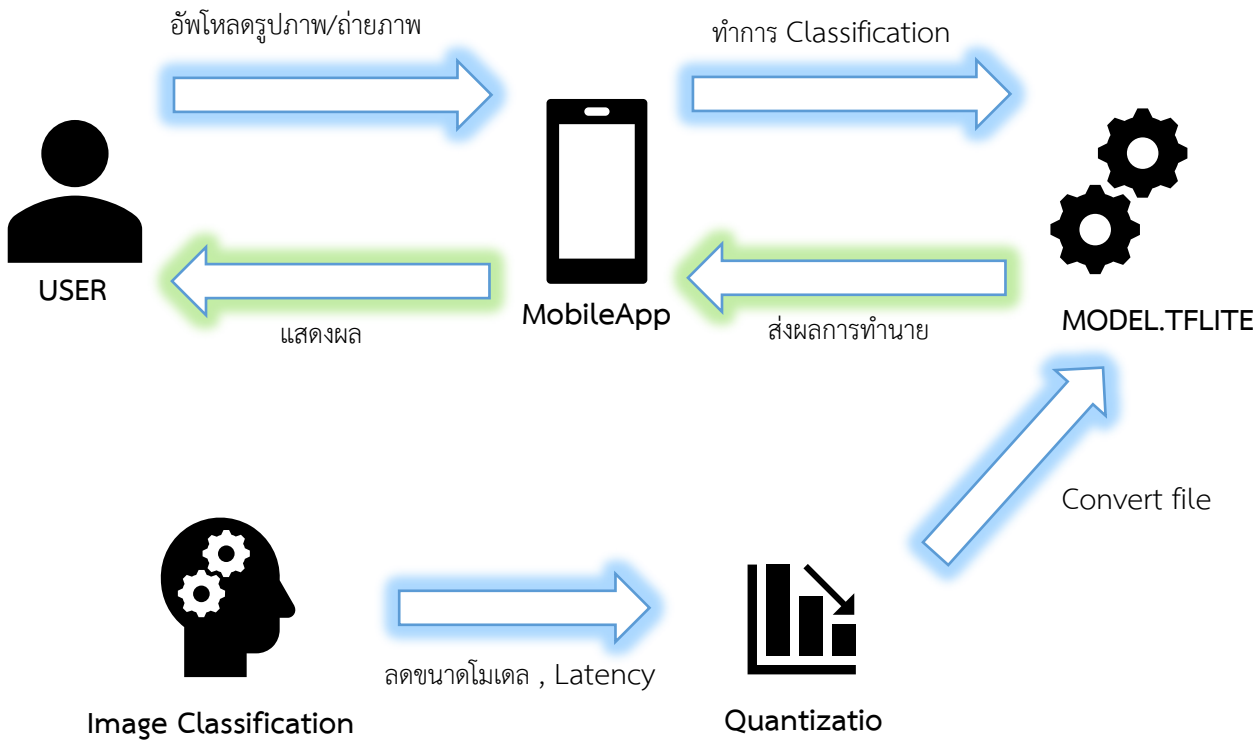

รูปที่ 5.1 รูปแสดงโครงสร้างของระบบแอปพลิเคชัน

จากรูปที่ 5.1 แสดงถึงโครงสร้างของระบบ โดยขั้นตอนแรกผู้ใช้งานจะทำการส่งรูปถั่วเหลืองที่ต้องการคัดแยกด้วยวิธีการถ่ายภาพ หรือนำรูปจากอัลบั้มบนโทรศัพท์นำเข้าไปที่แอปพลิเคชันการคัดแยกความสุกของถั่วเหลือง ต่อจากนั้นแอปพลิเคชันจะส่งรูปภาพไปให้โมเดลทำการคัดแยกระดับความสุกของถั่วเหลือง ที่ถูก convert file เป็น .Tflite เพื่อให้ไฟล์เหมาะสมในการใช้งานกับแอปพลิเคชัน เมื่อได้ผลการทำนายแล้วโมเดลจะทำการส่งผลการทำนายไปยังแอปพลิเคชัน จากนั้นแอปพลิเคชันจึงจะทำการแสดง ผลการทำนายแก่ผู้ใช้

5.1.2 ขั้นตอนการสร้าง Model

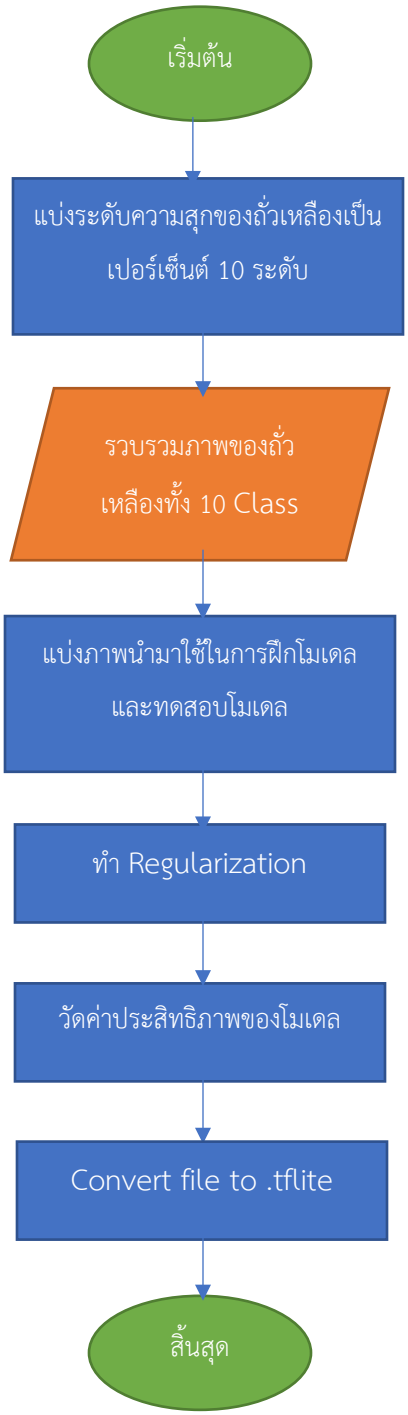

รูปที่ 5.2 รูปแสดงขั้นตอนการสร้าง model

5.1.2.1 การเตรียมข้อมูลสำหรับการฝึกโมเดล

กำหนดขนาดส่วนสูงและขนาดความกว้างของรูปภาพเท่ากับ 224 * 224 กำหนดขนาด batch size เท่ากับ 32 กำหนด path โดยใช้รูปภาพจำนวนทั้งหมด 1,000 รูป แบ่งเป็น 10 คลาส โดยใช้ข้อมูลการฝึกโมเดลจำนวน 760 รูป ข้อมูลสำหรับการทำ validate จำนวน 190 รูป และใช้ข้อมูลทดสอบโมเดล 50 รูป

```
[83]: X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.05, random_state=42,stratify=y)
      X_train, X_val, y_train, y_val = train_test_split(X_train, y_train, test_size=0.20, random_state=42,stratify=y_train)

[84]: y_train[:5]

[84]: array(['level08', 'level07', 'level09', 'level03', 'level08'], dtype='<U7')

[85]: X_train.shape

[85]: (760, 224, 224, 3)

[86]: X_test.shape

[86]: (50, 224, 224, 3)

[87]: X_val.shape

[87]: (190, 224, 224, 3)
```

รูปที่ 5.3 รูปการแบ่งชุดข้อมูลสำหรับการฝึกโมเดลและการทดสอบโมเดล

5.1.2.2 เข้ารหัส one hot encoding

ทำ Data Preprocessing โดยกำหนดการเข้าถึง labels ในแต่ละคลาสแบบ one-hot encoding ด้วยตัวเลข 0 และ 1

```
from sklearn import preprocessing
le = preprocessing.LabelEncoder()
le.fit(y_test)

y_train = le.transform(y_train)
y_test = le.transform(y_test)
y_val = le.transform(y_val)

y_train = keras.utils.to_categorical(y_train, NUM_CLASSES)
y_test = keras.utils.to_categorical(y_test, NUM_CLASSES)
y_val = keras.utils.to_categorical(y_val, NUM_CLASSES)
```

รูปที่ 5.4 รูปการเข้ารหัส one hot encoding

5.1.2.3 การทำ image augmentation ด้วยเทคนิค zoom

เป็นการเพิ่มความหลากหลายให้กับ dataset เพื่อเพิ่มประสิทธิภาพให้กับการสร้างโมเดล โดยเลือกใช้เทคนิค zoom ภาพโดยกำหนดให้ซูมรูปภาพเข้า 80% ของรูปภาพ และซูมรูปภาพออกไม่เกิน 120% ของรูปภาพ

```
train_datagen = ImageDataGenerator(zoom_range=[0.8,1.2],
                                   preprocessing_function=preprocess_input )

valtest_datagen = ImageDataGenerator(preprocessing_function=preprocess_input)
```

รูปที่ 5.5 รูปการทำการ Image Augmentation ด้วยเทคนิค zoom

5.1.2.4 สร้างโมเดล 4 โมเดล

5.1.2.4.1 โมเดลที่ 1

```
base_model = DenseNet121(
        input_shape=(img_width,img_height,3),
        weights="imagenet",
        include_top=False
        )
x = layers.GlobalAveragePooling2D()(base_model.output) # We can extend the model by calling .output and pass it to another layer
x = layers.BatchNormalization()(x)
x = layers.Dense(1024)(x)
x = layers.BatchNormalization()(x)
x = layers.Activation("relu")(x)
x = layers.Dropout(0.3)(x)
x = layers.Dense(512)(x)
x = layers.BatchNormalization()(x)
x = layers.Activation("relu")(x)
x = layers.Dropout(0.3)(x)
outputs = layers.Dense(NUM_CLASSES, activation='softmax')(x)

model = Model(inputs=base_model.input, outputs=outputs)
```

```
#model.summary()
```

```
model.compile(
    loss="categorical_crossentropy",
    optimizer=keras.optimizers.Adam(learning_rate=0.00001),
    metrics=["accuracy"],
)
```

รูปที่ 5.6 รูปการสร้างโมเดลที่ 1

1. กำหนดขนาดส่วนสูงและขนาดความกว้างของรูปภาพเท่ากับ 224 * 224 กำหนดขนาด batch size เท่ากับ 32

2. ทำ image augmentation ด้วยเทคนิคการซูมรูปภาพระหว่างช่วง 80% - 120%

3. ทำการใช้เทคนิค Average Pooling2D

4. กำหนดคุณสมบัติ Dense layer และใช้เทคนิค Batch Normalization กำหนดค่า dropout เท่ากับ 0.3 จำนวน 2 รอบโดย layer Dense เท่ากับ 1024 และ 512 ตามลำดับ

5. ทำการ compile model โดยใช้ Adam optimizers พร้อมกำหนดค่า learning rate เท่ากับ 0.00001

6. จากนั้นจึงทำการกำหนดจำนวนรอบในการฝึกโมเดลเท่ากับ 300 รอบ

5.1.2.4.2 โมเดลที่ 2

```
base_model = DenseNet121(
        input_shape=(img_width,img_height,3),
        weights="imagenet",
        include_top=False
        )
x = layers.GlobalAveragePooling2D()(base_model.output) # We can extend the model by calling .output and pass it to another layer
x = layers.BatchNormalization()(x)
x = layers.Dense(1024)(x)
x = layers.BatchNormalization()(x)
x = layers.Activation("relu")(x)
x = layers.Dropout(0.3)(x)
x = layers.Dense(512)(x)
x = layers.BatchNormalization()(x)
x = layers.Activation("relu")(x)
x = layers.Dropout(0.3)(x)
x = layers.Dense(256)(x)
x = layers.BatchNormalization()(x)
x = layers.Activation("relu")(x)
x = layers.Dropout(0.3)(x)
outputs = layers.Dense(NUM_CLASSES, activation='softmax')(x)

model = Model(inputs=base_model.input, outputs=outputs)
```

```
model.compile(
    loss="categorical_crossentropy",
    optimizer=keras.optimizers.Adam(learning_rate=0.00001),
    metrics=["accuracy"],
)
```

รูปที่ 5.7 รูปการสร้างโมเดลที่ 2

1. กำหนดขนาดส่วนสูงและขนาดความกว้างของรูปภาพเท่ากับ 224 * 224 กำหนดขนาด batch size เท่ากับ 32

2. ทำ image augmentation ด้วยเทคนิคการซูมรูปภาพระหว่างช่วง 80% - 120%

3. ทำการใช้เทคนิค Average Pooling2D

4. กำหนดคุณสมบัติ Dense layer และใช้เทคนิค Batch Normalization กำหนดค่า dropout เท่ากับ 0.3 จำนวน 3 รอบโดย layer Dense เท่ากับ 1024 512 และ 256 ตามลำดับ

5. ทำการ compile model โดยใช้ Adam optimizers พร้อมกำหนดค่า learning rate เท่ากับ 0.00001

6. จากนั้นจึงทำการกำหนดจำนวนรอบในการฝึกโมเดลเท่ากับ 300 รอบ

5.1.2.4.3 โมเดลที่ 3

```
base_model = DenseNet121(
        input_shape=(img_width,img_height,3),
        weights="imagenet",
        include_top=False
        )
x = layers.GlobalAveragePooling2D()(base_model.output) # We can extend the model by calling .output and pass it to another layer
x = layers.BatchNormalization()(x)
x = layers.Dense(1024)(x)
x = layers.BatchNormalization()(x)
x = layers.Activation("relu")(x)
x = layers.Dropout(0.4)(x)
x = layers.Dense(512)(x)
x = layers.BatchNormalization()(x)
x = layers.Activation("relu")(x)
x = layers.Dropout(0.4)(x)
outputs = layers.Dense(NUM_CLASSES, activation='softmax')(x)

model = Model(inputs=base_model.input, outputs=outputs)
```

```
model.compile(
    loss="categorical_crossentropy",
    optimizer=keras.optimizers.Adam(learning_rate=0.0001),
    metrics=["accuracy"],
)
```

รูปที่ 5.8 รูปการสร้างโมเดลที่ 3

1. กำหนดขนาดส่วนสูงและขนาดความกว้างของรูปภาพเท่ากับ 224 * 224 กำหนดขนาด batch size เท่ากับ 32

2. ทำ image augmentation ด้วยเทคนิคการซูมรูปภาพระหว่างช่วง 80% - 120%

3. ทำการใช้เทคนิค Average Pooling2D

4. กำหนดคุณสมบัติ Dense layer และใช้เทคนิค Batch Normalization กำหนดค่า dropout เท่ากับ 0.4 จำนวน 2 รอบโดย layer Dense เท่ากับ 1024 และ 512 ตามลำดับ

5. ทำการ compile model โดยใช้ Adam optimizers พร้อมกำหนดค่า learning rate เท่ากับ 0.0001

6. จากนั้นจึงทำการกำหนดจำนวนรอบในการฝึกโมเดลเท่ากับ 300 รอบ

5.1.2.4.4 โมเดลที่ 4

```
base_model = DenseNet121(
        input_shape=(img_width,img_height,3),
        weights="imagenet",
        include_top=False
        )
x = layers.GlobalAveragePooling2D()(base_model.output) # We can extend the model by calling .output and pass it to another layer
x = layers.BatchNormalization()(x)
x = layers.Dense(1024)(x)
x = layers.BatchNormalization()(x)
x = layers.Activation("relu")(x)
x = layers.Dropout(0.5)(x)
x = layers.Dense(512)(x)
x = layers.BatchNormalization()(x)
x = layers.Activation("relu")(x)
x = layers.Dropout(0.5)(x)
outputs = layers.Dense(NUM_CLASSES, activation='softmax')(x)

model = Model(inputs=base_model.input, outputs=outputs)
```

```
model.compile(
    loss="categorical_crossentropy",
    optimizer=keras.optimizers.Adam(learning_rate=0.00001),
    metrics=["accuracy"],
)
```

รูปที่ 5.9 รูปการสร้างโมเดลที่ 4

1. กำหนดขนาดส่วนสูงและขนาดความกว้างของรูปภาพเท่ากับ 224 * 224 กำหนดขนาด batch size เท่ากับ 32

2. ทำ image augmentation ด้วยเทคนิคการซูมรูปภาพระหว่างช่วง 80% - 120%

3. ทำการใช้เทคนิค Average Pooling2D

4. กำหนดคุณสมบัติ Dense layer และใช้เทคนิค Batch Normalization กำหนดค่า dropout เท่ากับ 0.5 จำนวน 2 รอบโดย layer Dense เท่ากับ 1024 และ 512 ตามลำดับ

5. ทำการ compile model โดยใช้ Adam optimizers พร้อมกำหนดค่า learning rate เท่ากับ 0.00001

6. จากนั้นจึงทำการกำหนดจำนวนรอบในการฝึกโมเดลเท่ากับ 300 รอบ

5.1.2.5 plot กราฟ ดูค่า loss และค่า accuracy

```
acc = history.history['accuracy']
val_acc = history.history['val_accuracy']

loss = history.history['loss']
val_loss = history.history['val_loss']

epochs_range = range(epochs)

plt.figure(figsize=(8, 8))
plt.subplot(1, 2, 1)
plt.plot(epochs_range, acc, label='Training Accuracy')
plt.plot(epochs_range, val_acc, label='Validation Accuracy')
plt.legend(loc='lower right')
plt.title('Training and Validation Accuracy')

plt.subplot(1, 2, 2)
plt.plot(epochs_range, loss, label='Training Loss')
plt.plot(epochs_range, val_loss, label='Validation Loss')
plt.legend(loc='upper right')
plt.title('Training and Validation Loss')
plt.show()
```

รูปที่ 5.10 รูปการ plot กราฟค่า loss และค่า accuracy

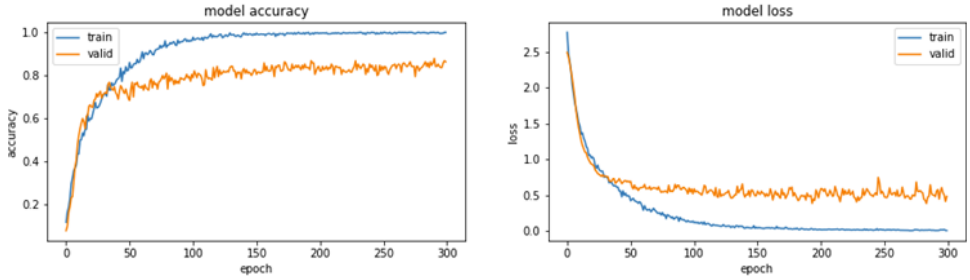

รูปที่ 5.11 รูปกราฟแสดงค่า loss และค่า accuracy ของโมเดลที่ 1

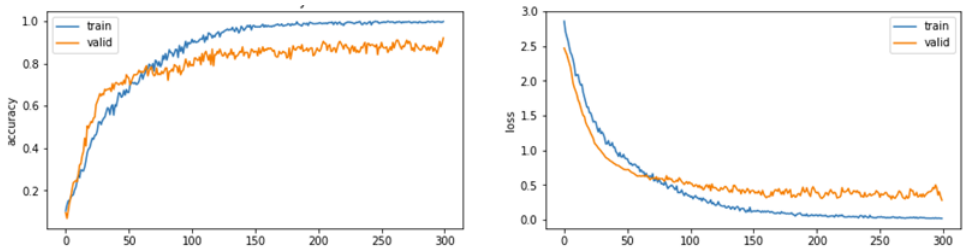

รูปที่ 5.12 รูปกราฟแสดงค่า loss และค่า accuracy ของโมเดลที่ 2

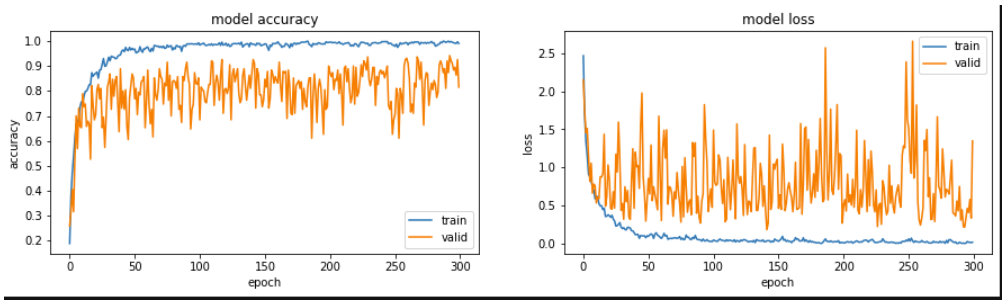

รูปที่ 5.13 รูปกราฟแสดงค่า loss และค่า accuracy ของโมเดลที่ 3

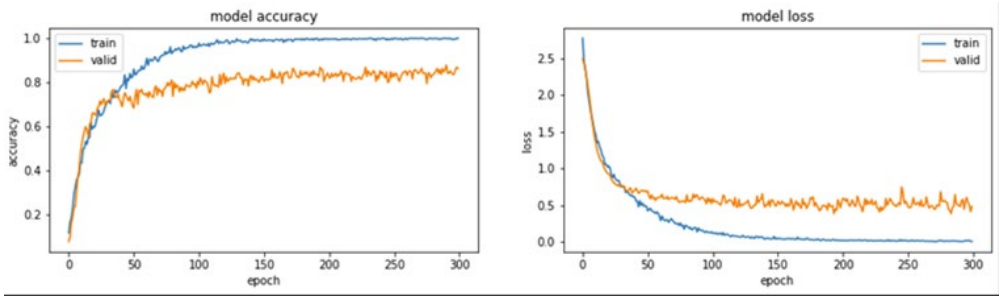

รูปที่ 5.14 รูปกราฟแสดงค่า loss และค่า accuracy ของโมเดลที่ 4

5.1.2.6 วัดค่าประสิทธิภาพความถูกต้องของโมเดล

```
model.load_weights('./model/'+file_name_ex+'.h5') #load saved weight
results = model.evaluate(test_generator)
print("test loss, test acc:", results)
```

```
2/2 [==============================] - 1s 432ms/step - loss: 0.1550 - accuracy: 0.9200
test loss, test acc: [0.1550123542547226, 0.9200000166893005]
```

รูปที่ 5.15 รูปแสดงการวัดค่าประสิทธิภาพความถูกต้องของโมเดล

จากรูปที่ 5.15 ค่าประสิทธิภาพความถูกต้องของโมเดล (Accuracy) เท่ากับ 0.92

5.1.2.7 Confusion Matrix

เป็นการสร้างตารางวัดค่าความสามารถของ machine learning ในการแก้ปัญหาการทำโมเดล classification โดยการสร้าง matrix จากโมเดลที่เราทำการสร้าง แล้วทำการแบ่งแยกคลาสออกเป็น 10 คลาส

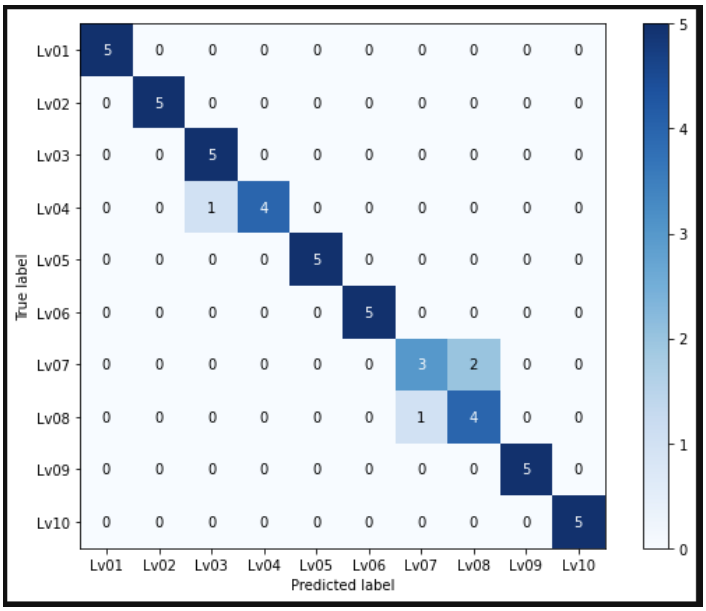

รูปที่ 5.16 รูป Confusion Matrix

จากรูปที่ 5.16 แสดงให้เห็นว่ามี 3 คลาส ที่มีการทำนายผิดพลาด คือคลาส Level04 จำนวน 1 รูป Level07 จำนวน 2 รูป และ Level08 จำนวน 1 รูป โดยโมเดลจะมีการทำนายผิดพลาดส่วนใหญ่ใน Level07 และ Level08

5.1.2.8 เรียกดูค่า precision recall f1score และ support

```
print(classification_report(y_true, predictions_2, digits=4))
              precision    recall  f1-score   support

     level01     1.0000    1.0000    1.0000         5
     level02     1.0000    1.0000    1.0000         5
     level03     0.8333    1.0000    0.9091         5
     level04     1.0000    0.8000    0.8889         5
     level05     1.0000    1.0000    1.0000         5
     level06     1.0000    1.0000    1.0000         5
     level07     0.7500    0.6000    0.6667         5
     level08     0.6667    0.8000    0.7273         5
     level09     1.0000    1.0000    1.0000         5
     level10     1.0000    1.0000    1.0000         5

    accuracy                         0.9200        50
   macro avg     0.9250    0.9200    0.9192        50
weighted avg     0.9250    0.9200    0.9192        50
```

รูปที่ 5.17 รูปค่า precision recall f1score และ support

จากรูปที่ 5.17 แสดงให้เห็นว่า precision และ recall ของ Level07 และ Level08 มีการทำนายสลับกันค่อนข้างเยอะ หมายความว่าโมเดลมีการทำนายผิดพลาดกับกลุ่มของข้อมูล Level07 และ Level08

5.1.2.9 การทำ Post-Training Quantization

เพื่อลดขนาดโมเดล ลด Memory ที่ใช้ และลดเวลาในการตอบสนอง (Latency) เพื่อนำไปใช้กับงานบนมือถือ โดยใช้เทคนิค Weight quantization ในการ Optimize โมเดล ด้วยการทำ Quantize ลดจำนวน Bit ของ Parameter ในโมเดลลง

```
# Intialize the TFLite converter to load the SavedModel
converter = tf.lite.TFLiteConverter.from_saved_model(SOYBEAN_SAVED_MODEL)
converter.experimental_new_converter = True

# Set the optimization strategy for 'size' in the converter
#converter.optimizations = [tf.lite.Optimize.OPTIMIZE_FOR_SIZE]
converter.optimizations = [tf.lite.Optimize.DEFAULT]
```

รูปที่ 5.18 รูปการทำ Post-Training Quantization

5.1.2.10 การสร้างโมเดลเป็น .Tflite

โดยจะทำการกำหนดชื่อโมเดลให้เป็นนามสกุล .Tflite จากนั้นจึงทำการ convert model ให้อยู่ในรูปแบบของ Tflite จากนั้นจึงทำการ save model.tflite

```
# Use the tool to finally convert the model
tflite_model = converter.convert()

tflite_model_file = 'converted_model_2.tflite'

with open(tflite_model_file, "wb") as f:
    f.write(tflite_model)
```

รูปที่ 5.19 รูปการสร้างโมเดลเป็น .Tflite

แสดงตารางเปรียบเทียบการทำงานทั้ง 4 โมเดล ดังนี้

ตารางที่ 5.1 ตารางแสดงการเปรียบเทียบการทำงานทั้ง 4 โมเดล

Model	Model spec	epoch	Learning Rate	Dropout	Layer Dense	Accuracy
1	Densenet121	300	0.00001	0.3	2	82.00
2	Densenet121	300	0.00001	0.3	3	92.00
3	Densenet121	300	0.0001	0.4	2	88.00
4	Densenet121	300	0.00001	0.5	2	84.00

จากตารางที่ 5.1 แสดงค่า evaluate ของทั้ง 4 โมเดล พบว่าโมเดลที่ดีที่สุด คือโมเดลที่ 2 ที่กำหนดค่า learning rate เท่ากับ 0.00001 ค่า dropout เท่ากับ 0.3 และกำหนด layer dense เท่ากับ 3 ชั้น ได้ค่าความแม่นยำ 92.00 เปอร์เซ็นต์

5.1.3 User Interface

รูปที่ 5.20 รูปหน้าหลักของแอปพลิเคชัน

จากรูปที่ 5.20 แสดงถึงหน้าที่ใช้ในการทำนายรูปภาพระดับความสุกของถั่วเหลือง โดยแอปพลิเคชันสามารถเลือกถ่ายรูปภาพ หรืออัปโหลดรูปภาพได้ ซึ่งไฟล์รูปภาพที่จะนำมาใช้ในการทำนาย จำเป็นต้องเป็นไฟล์รูปที่เป็นนามสกุล .jpg และ .png เท่านั้น

รูปที่ 5.21 รูปหน้าแสดงผลการทำนาย

จากรูปที่ 5.21 แสดงถึงผลการทำนายเมื่อผู้ใช้งานทำการถ่ายรูปภาพ หรืออัปโหลดรูปภาพ โดยแสดงรูปภาพของถั่วเหลือง ระดับความสุกของรูปภาพถั่วเหลือง และแสดงค่าความมั่นใจเป็นเปอร์เซ็นต์

บทที่ 6 ผลการดำเนินงาน ข้อจำกัด และข้อเสนอแนะ

6.1 ผลการดำเนินงาน

แอปพลิเคชันการคัดแยกความสุกของถั่วเหลือง สามารถคัดแยกความสุกของถั่วเหลืองว่าสุกในระดับกี่เปอร์เซ็นต์ พร้อมทั้งแสดงผลการคัดแยกความสุกของถั่วเหลือง และแสดงค่าความมั่นใจ ซึ่งแอปพลิเคชันการคัดแยกความสุกของถั่วเหลืองทำงานบนระบบปฏิบัติการ android

6.1.1 ผลการทดสอบโมเดล

การทดสอบโมเดลการคัดแยกความสุกของถั่วเหลือง จะทดสอบโดยการพัฒนาใช้โครงสร้างโมเดล DenseNet กำหนดขนาดส่วนสูงและขนาดความกว้างของรูปภาพเท่ากับ 224 * 224 และกำหนดขนาด batch size เท่ากับ 32 โดยใช้รูปภาพจำนวนทั้งหมด 1000 รูป แบ่งเป็น 10 คลาส โดยใช้ข้อมูลการฝึกโมเดลจำนวน 760 รูป ข้อมูลสำหรับการ ทำ validate จำนวน 190 รูป และใช้ข้อมูลทดสอบโมเดล 50 รูป ซึ่งจากการ ทดลองทั้ง 4 โมเดล เป็นดังตารางที่ 6.1 ดังนี้

ตารางที่ 6.1 ตารางเปรียบเทียบการทำงานโมเดล

Model	Model spec	epoch	Learning Rate	Dropout	Layer Dense	Accuracy
1	Densenet121	300	0.00001	0.3	2	82.00
2	Densenet121	300	0.00001	0.3	3	92.00
3	Densenet121	300	0.0001	0.4	2	88.00
4	Densenet121	300	0.00001	0.5	2	84.00

จากตารางเปรียบเทียบการทำงานโมเดลทั้ง 4 โมเดล โดยได้เลือกใช้ DenseNet121 ซึ่งใช้จำนวนรอบในการฝึกโมเดล 300 รอบ และกำหนดค่า learning rate ค่า dropout และจำนวนชั้น layer dense ที่แตกต่างกัน โมเดลที่ 1 กำหนดให้ค่า learning rate เท่ากับ 0.00001 ค่า dropout เท่ากับ 0.3 และ layer dense เท่ากับ 2 ชั้น ได้ค่าความแม่นยำอยู่ที่ 82.00 โมเดลที่ 2 กำหนดให้ค่า learning rate เท่ากับ 0.00001 ค่า dropout เท่ากับ 0.3 และ layer dense เท่ากับ 3 ชั้น ได้ค่าความแม่นยำอยู่ที่ 92.00 โมเดลที่ 3 กำหนดให้ค่า learning rate เท่ากับ 0.0001 ค่า dropout เท่ากับ 0.4 และ layer dense เท่ากับ 2 ชั้น ได้ค่าความแม่นยำอยู่ที่ 88.00 และโมเดลที่ 4 กำหนดให้ค่า learning rate เท่ากับ 0.00001 ค่า dropout เท่ากับ 0.5 และ layer dense เท่ากับ 2 ชั้นได้ค่าความแม่นยำอยู่ที่ 84.00

ผลการทดลองโมเดลจากตารางที่ 4 แสดงค่าพารามิเตอร์ทั้งหมดในแต่ละโมเดล พบว่าโมเดลที่ 2 มีประสิทธิภาพมากที่สุดในการคัดแยกความสุกของถั่วเหลืองตามเกณฑ์ที่ตั้งไว้

6.1.2 การประเมินความพึงพอใจผู้ใช้งาน

การประเมินความพึงพอใจผู้ใช้งานของแอปพลิเคชันการคัดแยกความสุกของถั่วเหลือง เป็นการทดสอบระดับประสิทธิภาพของระบบ เพื่อให้ผู้ใช้งานสามารถใช้งานแอปพลิเคชันได้ตรงกับความต้องการมากขึ้น จึงได้ทำการทดสอบระบบด้วย Usability Testing ซึ่งกำหนดเกณฑ์การให้คะแนนของผลการประเมินดังตารางที่ 6.2

ตารางที่ 6.2 ตารางเกณฑ์การให้คะแนนของผลการประเมิน

เกณฑ์การให้คะแนน		**คำอธิบายเกณฑ์**
ระดับความพึงพอใจ	**ช่วงคะแนน**	
ระดับน้อยมาก	1.00 – 1.50	ระบบที่พัฒนามีระดับความพึงพอใจในระดับน้อยมาก
ระดับน้อย	1.51 – 2.50	ระบบที่พัฒนามีระดับความพึงพอใจในระดับน้อย
ระดับปานกลาง	2.51 – 3.50	ระบบที่พัฒนามีระดับความพึงพอใจในระดับปานกลาง
ระดับดี	3.51 – 4.50	ระบบที่พัฒนามีระดับความพึงพอใจในระดับดี
ระดับดีมาก	4.51 – 5.00	ระบบที่พัฒนามีระดับความพึงพอใจในระดับดีมาก

6.1.3 ผลการทดลองการประเมินผลวัดระดับความพึงพอใจของผู้ใช้งานแอปพลิเคชัน

จากการประเมินความพึงพอใจในการใช้งานแอปพลิเคชันการคัดแยกความสุกของถั่วเหลืองจากผู้ใช้งานจำนวน 15 คน ได้ผลสรุปดังตารางที่ 6.3

ตารางที่ 6.3 ตารางสรุปผลการประเมินความพึงพอใจของผู้ใช้งานแอปพลิเคชัน

รายการประเมิน	**ระดับความพึงพอใจ**					**คะแนนเฉลี่ย**	**ผลการประเมิน**
	ดีมาก (5)	**ดี (4)**	**ปานกลาง (3)**	**น้อย (2)**	**น้อยมาก (1)**		
1. การออกแบบส่วนติดต่อกับผู้ใช้งาน							
1.1ความถูกต้องของแอปพลิเคชัน	8	7	-	-	-	4.53	ดีมาก
1.2 ความสวยงามของแอปพลิเคชัน	4	7	4	-	-	4.00	ดี
1.3 ความเหมาะสมของรูปแบบและตัวอักษร	8	6	1	-	-	4.47	ดี
2. การใช้งานแอปพลิเคชัน							
2.1 แอปพลิเคชันใช้งานง่าย	11	4	-	-	-	4.73	ดีมาก
2.2 การแสดงผลลัพธ์ถูกต้อง	6	7	2	-	-	4.27	ดี
3. ภาพรวมของแอปพลิเคชัน							
3.1 ประโยชน์ของแอปพลิเคชันและการนำไปใช้งานได้จริง	5	8	2	-	-	4.20	ดี
3.2 ความน่าสนใจของแอปพลิเคชัน	7	6	2	-	-	4.33	ดี

จากตารางที่ 6.3 ผลการทดลองที่ได้จากการประเมินความพึงพอใจของผู้ใช้งานจำนวน 15 คน โดยคะแนนมากที่สุดคือ แอปพลิเคชันใช้งานง่าย ซึ่งมีค่าเฉลี่ยอยู่ที่ 4.73 ซึ่งอยู่ในระดับดีมาก และคะแนนน้อยที่สุดคือความสวยงามของแอปพลิเคชัน ซึ่งมีค่าเฉลี่ยอยู่ที่ 4.00 ซึ่งอยู่ในระดับดี แสดงให้เห็นว่าในส่วนของแอปพลิเคชันการคัดแยกความสุกของถั่วเหลืองนั้น ยังมีส่วนที่ต้องปรับปรุงคือ ส่วนของความสวยงามของแอปพลิเคชัน

6.2 ข้อจำกัด

6.2.1 สามารถทำการจำแนกได้เพียงทีละ 1 รูปภาพ

6.2.2 แอปพลิเคชันสามารถใช้งานได้เฉพาะระบบปฏิบัติการ Android

6.2.3 การถ่ายรูปจากกล้องอาจเกิดการคลาดเคลื่อนในการทำทายเนื่องจากปัจจัยอื่น เช่น แสงหรือฟิลเตอร์กล้อง

6.3 ข้อเสนอแนะ

6.3.1 เพิ่มเติมข้อมูลรูปภาพถั่วเหลืองที่มีปัจจัยจากแสงใน dataset เพื่อให้การทำนายด้วยการถ่ายรูปจากกล้องมีความแม่นยำมากขึ้น

บรรณานุกรม

[1] ผ. พรเฉลิมพงศ์, “Food Network Solution,” [ออนไลน์]. Available: https://www.foodnetworksolution.com/wiki/word/1359/soybean-. [เข้าถึง 14 สิงหาคม 2565].

[2] สุกัญญา จัตตุพรพงษ์, “การตรวจสอบความสุกดิบของกากถั่วเหลือง,” วารสารศูนย์บางพระ, %14, pp. 4-5, 2539.

[3] อ.ดร.ณัฐโชติ พรหมฤทธิ์, “การทำ Regularization แบบสมัยใหม่ ด้วยเทคนิค Augmentation, Batch Normalization และ Dropout,” [ออนไลน์]. Available: https://blog.pjjop.org/modern-regularization-with-data-augmentation-batch-normalization-and-dropout/. [เข้าถึง 15 สิงหาคม 2565].

[4] อ.ดร.ณัฐโชติ พรหมฤทธิ์, “Visualizing Kernels and Feature Maps in Deep Learning Model (CNN),” ภาควิชาคอมพิวเตอร์ คณะวิทยาศาสตร์ มหาวิทยาลัยศิลปากร, 6 ตุลาคม 2563. [ออนไลน์]. Available: https://blog.pjjop.org/visualizing-filters-and-feature-maps-in-deep-learning-cnn/. [เข้าถึง 15 สิงหาคม 2565].

[5] A. GST, “GSTAI Image Classification,” 2 มิถุนายน 2563. [ออนไลน์]. Available: https://play.google.com/store/apps/details?id=gst.ailab.lite.examples.classification. [เข้าถึง14 สิงหาคม 2565].

[6] D. Sheel, “Deep Learning คืออะไร?,” ABB, 20 เมษายน 2020. [ออนไลน์]. Available: https://new.abb.com/news/detail/58004/deep-learning. [เข้าถึง 15 สิงหาคม 2565].

[7] Google, “TensorFlow,” Google, [ออนไลน์]. Available: https://www.tensorflow.org/. [เข้าถึง 15 สิงหาคม 2565].

[8] Google, “Android Studio,” Google, [ออนไลน์]. Available: https://developer.android.com/studio. [เข้าถึง 15 สิงหาคม 2565].

[9] I. Shafkat, “Intuitively Understanding Convolutions for Deep Learning,” [ออนไลน์]. Available: https://towardsdatascience.com/intuitively-understanding-convolutions-for-deep-learning-1f6f42faee1. [เข้าถึง 15 สิงหาคม 2565].

[10] K. Keshari, “TensorFlow Image Classification,” 18 เมษายน 2566. [ออนไลน์]. Available: https://www.edureka.co/blog/tensorflow-image-classification. [เข้าถึง 21 เมษายน 2566].

[11] k. Peeradon, “Classification of beef freshness using image,” ใน ภาควิชาสัตวศาสตร์ คณะเกษตรศาสตร์ มหาวิทยาลัยอุบลราชธานี. [เข้าถึง14 สิงหาคม 2565].

[12] LEARN, “การจำแนกประเภทข้อมูลภาพ (Image Classification),” [ออนไลน์]. Available: http://learn.gistda.or.th/2017/04/03/%E0%B8%81%E0%B8%B2%E0%B8%A3%E0%B8%88%E0%B8%B3%E0%B9%81%E0%B8%99%E0%B8%81%E0%B8%9B%E0%B8%A3%E0%B8%B0%E0%B9%80%E0%B8%A0%E0%B8%97%E0%B8%82%E0%B9%89%E0%B8%AD%E0%B8%A1%E0%B8%B9%E0%B8%A5%E0%B8%A0%E0%B8%B2/. [เข้าถึง15 สิงหาคม 2565].

[13] Mauricio Rodriguez, Franco Pastor and Willy Ugarte, “Classification of Fruit Ripeness Grades using a Convolutional Neural Network and Data,” ใน Universidad Peruana de. [เข้าถึง14 สิงหาคม 2565].

[14] P. Gatchalee, “Confusion Matrix เครื่องมือสำคัญในการประเมินผลลัพธ์ของการทำนาย ในMachine learning,” 3 ตุลาคม 2562. [ออนไลน์]. Available: https://medium.com/@pagongatchalee/confusion-matrix-%E0%B9%80%E0%B8%84%E0%B8%A3%E0%B8%B7%E0%B9%88%E0%B8%AD%E0%B8%87%E0%B8%A1%E0%B8%B7%E0%B8%AD%E0%B8%AA%E0%B8%B3%E0%B8%84%E0%B8%B1%E0%B8%8D%E0%B9%83%E0%B8%99%E0%B8%81%E0%B8%B2%E0%B8%A3%E0%B8%9B%E0%B8%A3%E0%B. [เข้าถึง 11 เมษายน 2566].

[15] S. Baldha, “Introduction to DenseNets (Dense CNN),” 14 มีนาคม 2565. [ออนไลน์]. Available: https://www.analyticsvidhya.com/blog/2022/03/introduction-to-densenets-dense-cnn/. [เข้าถึง 23 เมษายน 2566].

[16] S.-H. Tsang, “DenseNet — Dense Convolutional Network (Image Classification),” 25 พฤศจิกายน 2561. [ออนไลน์]. Available: https://towardsdatascience.com/review-densenet-image-classification-b6631a8ef803. [เข้าถึง 11 เมษายน 2566].

[17] S. Kanoktipsatharporn, “Quantization คืออะไร Post-Training Quantization มีประโยชน์อย่างไร กับ Deep Neural Network บนอุปกรณ์ Embedded,” 17 มกราคม 2563. [ออนไลน์]. Available: https://www.bualabs.com/archives/3573/what-is-quantization-benefits-of-quantization-deep-neural-network-tflite-ep-2/. [เข้าถึง11 เมษายน 2566].

[18] Soumio, “PhotoAI - Mobile Image Classification,” 9 มกราคม 2562. [ออนไลน์]. Available: https://play.google.com/store/apps/details?id=com.soumio.mikes.photoai. [เข้าถึง14 สิงหาคม 2565].

ภาคผนวก ก คู่มือการติดตั้งแอปพลิเคชันการคัดแยกความสุกของถั่วเหลือง

ดาวโหลดไฟล์จาก Google drive ลงในโทรศัพท์ระบบปฏิบัติการ Android ที่ลิงก์ https://drive.google.com/file/d/1bH1XoY4Dq6qGWEhSaqCdeb5q-VwjOH7T/view?fbclid=IwAR3gYCNwVe2ehh2EBquOz0vfp3apDMNg_5aJfr51DeNu7C7yszOyT9L8oP0

หลังจากดาวน์โหลดไฟล์ Mr. Soybean.apk เสร็จสิ้น จะแสดงหน้าต่างให้ติดตั้งแอปพลิเคชันลงในโทรศัพท์ โดยกดที่ “Install” (รูปภาคผนวก ก.1)

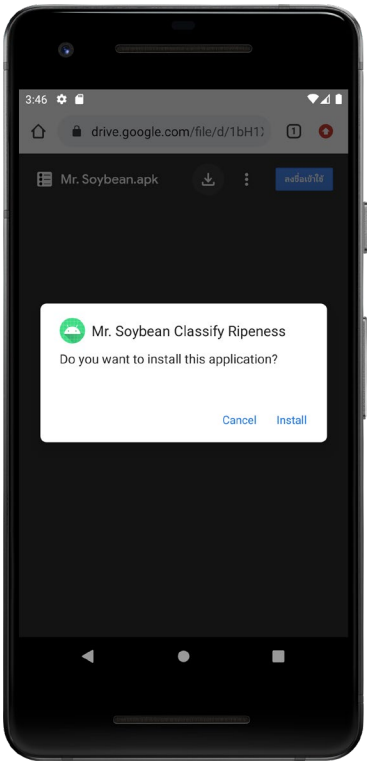

รูปผนวกที่ ก.1 ติดตั้ง Mr.Soybean

หลังจากการติดตั้งเสร็จสิ้น จะได้แอพพลิเคชั่นดังรูปภาพผนวกที่ ก.2

รูปผนวกที่ ก.2 แอปพลิเคชัน Mr.Soybean

ภาคผนวก ข คู่มือใช้งานแอปพลิเคชันการคัดแยกความสุกของถั่วเหลือง

แอปพลิเคชันการคัดแยกความสุกของถั่วเหลืองด้วยระบบปัญญาประดิษฐ์สามารถเข้าใช้ได้ผ่านทางโทรศัพท์มือถือระบบปฏิบัติการ Android

ข.1 ส่วนของการเข้าใช้งานของผู้ใช้งานแอปพลิเคชัน

เมื่อกดเข้าแอปพลิเคชันแล้ว ระบบจะแสดงหน้าเลือกวิธีการคัดแยกความสุกของถั่วเหลือง (รูปผนวกที่ ข.1) โดยให้เลือกระหว่างการอัพโหลดภาพ (รูปผนวกที่ ข.2) และการถ่ายภาพจากกล้อง (รูปผนวกที่ ข.3)

รูปผนวกที่ ข.1 รูปหน้าหลักเลือกวิธีการเลือกภาพ

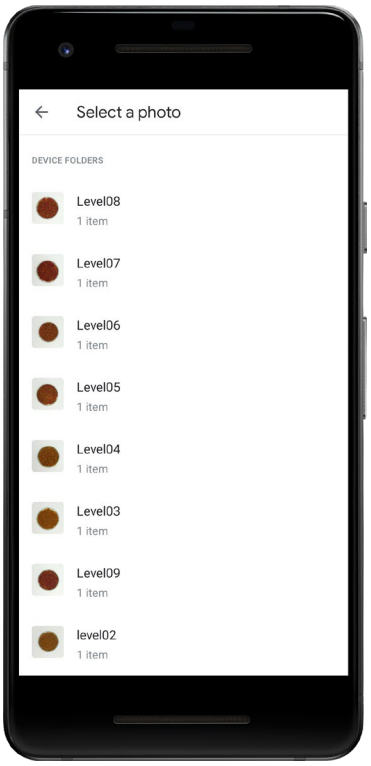

รูปผนวกที่ ข.2 รูปเลือกภาพจากคลังรูปภาพ

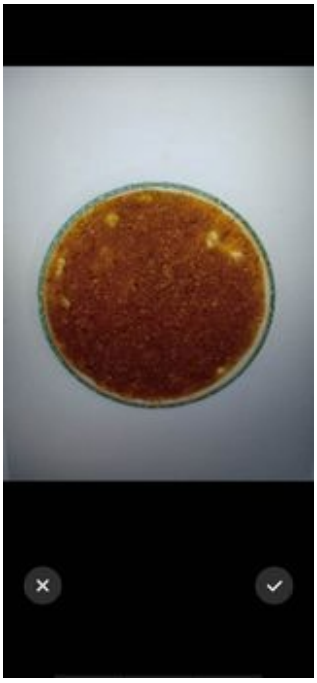

รูปผนวกที่ ข.3 รูปหน้าถ่ายรูปภาพ

ข.2 ส่วนการแสดงผลการทำนายของแอปพลิเคชัน

หลังจากการเลือกภาพที่ต้องการได้แล้วระบบจะทำการประมวลผลความสุกของถั่วเหลืองและค่าเปอร์เซ็นต์ความแม่นยำออกมาผ่านทางหน้าจอ (รูปผนวกที่ ข.4)

รูปผนวกที่ ข.4 รูปแสดงผลการทำนายความสุกของถั่วเหลือง

ภาคผนวก ค แบบประเมินความพึงพอใจของผู้ใช้งาน

แบบประเมินความพึงพอใจในการใช้แอปพลิเคชันการคัดแยกความสุกของถั่วเหลือง
ด้วยระบบปัญญาประดิษฐ์

เพศ [ ] ชาย [ ] หญิง อายุ ..... ปี

เกณฑ์การประเมินความพึงพอใจ	ระดับความพึงพอใจ				
	ดีมาก	ดี	ปานกลาง	น้อย	น้อยมาก
1. การออกแบบส่วนติดต่อกับผู้ใช้งาน					
1.1 ความถูกต้องของแอปพลิเคชัน					
1.2 ความสวยงามของแอปพลิเคชัน					
1.3 ความเหมาะสมของรูปแบบและตัวอักษร					
2. การใช้งานแอปพลิเคชัน					
2.1 แอปพลิเคชันใช้งานง่าย					
2.2 การแสดงผลลัพธ์ถูกต้อง					
3. ภาพรวมของแอปพลิเคชัน					
3.1 ประโยชน์ของแอปพลิเคชันและการนำไปใช้งานได้จริง					
3.2 ความน่าสนใจของแอปพลิเคชัน					

ข้อเสนอแนะ

.....

.....

.....