# ใบอนุมัติโครงงานปริญญานิพนธ์
# สาขาวิชาวิทยาการคอมพิวเตอร์ ภาควิชาคอมพิวเตอร์
# คณะวิทยาศาสตร์ มหาวิทยาลัยศิลปากร

**ชื่อปริญญานิพนธ์** การประมวลผลภาษาธรรมชาติ เพื่อปรับปรุงคำผิดที่เกิดจากวิธีการรู้จำอักขระ
Natural Language Processing to Improve the Errors Caused by
the Optical Character Recognition.

**ผู้จัดทำ** นายทวีศักดิ์ คุ้มภักดี

**ปีการศึกษา** 2565

**โครงงานปริญญานิพนธ์นี้ได้รับการอนุมัติให้เป็นส่วนหนึ่งของการศึกษาตาม**
**หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์**
**ภาควิชาคอมพิวเตอร์ คณะวิทยาศาสตร์ มหาวิทยาลัยศิลปากร**

..... ประธานกรรมการสอบ
( รองศาสตราจารย์ ดร.ปานใจ ธารทัศนวงศ์ )

..... กรรมการสอบ
( อาจารย์ อภิเษก หงษ์วิทยากร )

..... อาจารย์ที่ปรึกษาและกรรมการสอบ
( อาจารย์ ดร.สัจจาภรณ์ ไวจรรยา )

# การประมวลผลภาษาธรรมชาติ เพื่อปรับปรุงคำผิดที่เกิดจากวิธีการรู้จำอักขระ

# Natural Language Processing to Improve the Errors Caused by the Optical Character Recognition

ทวีศักดิ์ คุ้มภักดี

ปริญญานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาในหลักสูตรวิทยาศาสตรบัณฑิต
สาขาวิชาวิทยาการคอมพิวเตอร์ ภาควิชาคอมพิวเตอร์
คณะวิทยาศาสตร์ มหาวิทยาลัยศิลปากร
ปีการศึกษา 2565

**ชื่อปริญญานิพนธ์** การประมวลผลภาษาธรรมชาติ เพื่อปรับปรุงคำผิดที่เกิดจากวิธีการรู้จำอักขระ
Natural Language Processing to Improve the Errors Caused by
the Optical Character Recognition.

**ผู้จัดทำ** นายทวีศักดิ์ คุ้มภักดี

**อาจารย์ที่ปรึกษา** อาจารย์ ดร.สัจจาภรณ์ ไวจรรยา, ผู้ช่วยศาสตราจารย์ ดร.ณัฐโชติ พรหมฤทธิ์

**ชื่อปริญญา** วิทยาศาสตรบัณฑิต (วิทยาการคอมพิวเตอร์)

**ปีการศึกษา** 2565

# บทคัดย่อ

ปริญญานิพนธ์นี้นำเสนอการแก้ไขคำผิดที่เกิดขึ้นจากการรู้จำอักขระลายมือเขียนภาษาไทย การรู้จำอักขระลายมือเขียนภาษาไทยนั้นเป็นสิ่งที่ท้าทายเนื่องจากลายมือของคนแต่ละคนเขียนออกมาได้แตกต่างกัน ดังนั้นผลลัพธ์ที่ได้จากการรู้จำอักขระอาจเกิดผลลัพธ์ที่ผิดขึ้นได้แก่ คำที่อ่านออกเสียงไม่ได้หรือได้คำผิดที่ต้องมีการปรับให้ถูกต้อง ปริญญานิพนธ์นี้เป็นการนำงานด้านการประมวลผลธรรมชาติมาปรับปรุงผลลัพธ์ที่ได้จากการรู้จำอักขระให้ดียิ่งขึ้น โดยมีข้อมูลนำเข้า คือ ข้อความที่ได้จากการรู้จำอักขระลายมือเขียนภาษาไทยไปกรอกที่หน้าเว็บแอปพลิเคชันส่งไปแก้ไขโดยอาศัยความรู้จากหลักการออกเสียงพยางค์ในภาษาไทยมาใช้แก้ไขผลลัพธ์การรู้จำอักขระที่ผิด เมื่อแก้ไขแล้วข้อความนั้นจะถูกนำมารวมกันและหาคำที่มีความเหมือนกัน เริ่มที่พยางค์สูงสุดของคำในภาษาไทยคือ 7 พยางค์ไล่ไปจนถึง 1 พยางค์ โดยต้องมีความเหมือนกันอย่างน้อย 66% ของคำที่มี 1 พยางค์, 80% ของคำที่มี 2-3 พยางค์และ 90% ของคำที่มี 4 พยางค์ขึ้นไปจนถึง 7 พยางค์ โดยใช้ไลบรารีภาษาไพธอน คือ difflib และวัดผลการแก้ไขข้อความโดยใช้ Bleu Score แบบ unigram มาวัดผลการแก้ไขจากข้อความตัวอย่างได้คะแนน 0.66 หลังจากเสร็จสิ้นกระบวนการจะนำผลลัพธ์จากการแก้ไขไปแสดงผลบนหน้าเว็บแอปพลิเคชัน

**คำสำคัญ :** การแก้ไขคำผิด, การรู้จำอักขระ, การออกเสียงของพยางค์ภาษาไทย, การวัดผลความคล้ายคลึงกันของข้อความสองข้อความด้วย BLEU Score, ลายมือเขียนภาษาไทย

**Keyword :** fixing incorrect words, optical character recognition, Thai pronunciation of syllables, Measuring the similarity of two texts using a BLEU Score, Thai handwriting

# กิตติกรรมประกาศ

ปริญญานิพนธ์เรื่อง การประมวลผลภาษาธรรมชาติเพื่อปรับปรุงคำผิดที่เกิดจากการรู้จำอักขระ สามารถสำเร็จลุล่วงไปได้ด้วยดีนั้น สืบเนื่องมาจากการได้รับแนวทางสนับสนุนและความรู้จากบุคคลตามที่ข้าพเจ้าจะขอกล่าวถึงดังต่อไปนี้ ขอขอบพระคุณ อาจารย์ ดร.สัจจาภรณ์ ไวจรรยา อาจารย์ที่ปรึกษาโครงงาน รองศาสตราจารย์ ดร.ปานใจ ธารทัศนวงศ์, ผู้ช่วยศาสตราจารย์ ดร.ณัฐโชติ พรหมฤทธิ์, ผู้ช่วยศาสตราจารย์ ดร.คทา ประดิษฐวงศ์ และ อาจารย์อภิเษก หงษ์วิทยากรผู้ให้คำปรึกษาให้คำแนะนำในการศึกษาค้นคว้าขั้นตอนวิธีการ การแก้ไขรวมไปถึงแนะแนวทางในการเลือกตัวอย่างมานำเสนอให้สำเร็จลุล่วงไปได้ด้วยดี ขอกราบขอบพระคุณคณาจารย์มหาวิทยาลัยศิลปากรคณะวิทยาศาสตร์และภาควิชาคอมพิวเตอร์ที่ให้วิชาความรู้และสถานที่ในการจัดทำโครงงานวิทยานิพนธ์ การประมวลผลภาษาธรรมชาติเพื่อปรับปรุงคำผิดที่เกิดจากการรู้จำอักขระ มาโดยตลอด

ท้ายนี้ผู้จัดทำขอกราบขอบพระคุณมารดา และทุกคนในครอบครัวที่ให้กำลังใจทุกเรื่องเสมอมา ขอบพระคุณเพื่อนรุ่นพี่และผู้เกี่ยวข้องทุกท่านที่ช่วยทำให้โครงงานปรัญญานิพนธ์นี้สำเร็จและลุล่วงไปได้ด้วยดี

ทวีศักดิ์ คุ้มภักดี

# สารบัญ

หน้า


บทที่ 1 บทนำ ..... 1
1.1 ที่มาและความสำคัญของปัญหา ..... 1
1.2 วัตถุประสงค์ ..... 1
1.3 ลักษณะและขอบเขต ..... 1
1.4 อุปกรณ์และเครื่องมือที่ใช้ ..... 2
1.4.1 ฮาร์ดแวร์ ..... 2
1.4.2 ซอฟต์แวร์ ..... 2
1.5 ผลที่คาดว่าจะได้รับ ..... 2
บทที่ 2 ผลงานที่เกี่ยวข้อง ..... 3
2.1 ฟีเจอร์สแกนเอกสารของแอปพลิเคชันไลน์ ..... 3
2.1.1 ข้อเด่น ..... 3
2.1.2 ข้อด้อย ..... 4
2.2 ฟีเจอร์จับข้อความจากรูปภาพของ google docs ..... 4
2.2.1 ข้อเด่น ..... 5
2.2.2 ข้อด้อย ..... 5
2.3 Katproof.com ..... 6
2.3.1 ข้อเด่น ..... 7
2.3.2 ข้อด้อย ..... 7
บทที่ 3 ทฤษฎีและความรู้ที่เกี่ยวข้อง ..... 8
3.1 การประมวลผลภาษาธรรมชาติ ..... 8
3.1.1 PyThaiNLP ..... 8
3.2 Optical Character Recognition (OCR) ..... 9
3.3 difflib ..... 10
3.4 เสียงในภาษาไทยและตัวสะกด ..... 11
บทที่ 4 ขั้นตอนและแผนการดำเนินงาน ..... 15
4.1 ขั้นตอนการดำเนินงาน ..... 15
4.1.1 คิดหัวข้อโครงงานและรวบรวมข้อมูล ..... 15
4.1.2 กำหนดขอบเขตและวางแผนการดำเนินงาน ..... 15
4.1.3 ศึกษาความรู้และทฤษฎีที่เกี่ยวข้อง ..... 15
4.1.4 การวิเคราะห์และออกแบบระบบ ..... 15
4.1.5 พัฒนาโปรแกรม ..... 15
4.1.6 ทดสอบโปรแกรม ..... 15
4.1.7 จัดทำเอกสารประกอบโครงงาน ..... 16

4.2 แผนการดำเนินงาน ..... 16
บทที่ 5 การวิเคราะห์และออกแบบระบบ ..... 17
5.1 การวิเคราะห์คำผิดจากตัวอย่างข้อมูลนำเข้าที่ได้จากการรู้จำอักขระ ..... 17
5.2 ภาพรวมของหลักการทำงานของระบบ ..... 19
5.3 การทำงานของระบบ ..... 20
5.4 ส่วนติดต่อผู้ใช้ ..... 27
บทที่ 6 ผลการดำเนินงาน ข้อจำกัด และข้อเสนอแนะ ..... 28
6.1 ผลการดำเนินงาน ..... 28
6.1.1 การประเมินคุณภาพของข้อความที่ได้รับการแก้ไข ..... 28
6.1.2 ผลคะแนนของข้อความตัวอย่างที่ได้รับการแก้ไขแล้วกับข้อความต้นโดยใช้ BLEU Score ..... 29
6.1.3 การแก้ไขคำที่ผู้ใช้อาจเขียนผิดก่อนนำมารู้จำอักขระ ..... 30
6.2 ข้อจำกัด ..... 30
6.3 ข้อเสนอแนะ ..... 31
บรรณานุกรม ..... 32
ภาคผนวก ก การทำงานของ API ..... 34
ภาคผนวก ข การทำงานของหน้าเว็บแอปพลิเคชัน ..... 35

# สารบัญตาราง

**หน้า**

ตารางที่ 3.1 ตัวอย่างการเขียนพยางค์แบ่งตามตำแหน่งของรูปสระ ..... 12
ตารางที่ 4.1 แผนการดำเนินงาน..... 16
ตารางที่ 5.1 รูปแบบที่มี 2 ตัวอักษร 3 รูปแบบ ..... 21
ตารางที่ 5.2 รูปแบบที่มี 3 ตัวอักษร 10 รูปแบบ..... 21
ตารางที่ 5.3 รูปแบบที่มี 4 ตัวอักษร 17 รูปแบบ..... 22
ตารางที่ 5.4 รูปแบบที่มี 5 ตัวอักษรจำนวน 17 รูปแบบ ..... 22
ตารางที่ 5.5 รูปแบบที่มี 6 ตัวอักษรจำนวน 7 รูปแบบ..... 23
ตารางที่ 5.6 รูปแบบที่มี 7 ตัวอักษรจำนวน 2 รูปแบบ..... 23
ตารางที่ 6.1 ผลคะแนน BLEU ของข้อความที่ได้จากการรู้จำอักขระและข้อความต้น..... 29
ตารางที่ 6.2 ผลคะแนน BLEU ของข้อความที่ได้จากการรู้จำอักขระ ข้อความต้นและข้อความที่ผ่านวิธีการแก้ไขคำให้สามารถอ่านได้ ..... 29
ตารางที่ 6.3 ผลคะแนน BLEU ของข้อความที่ได้จากการรู้จำอักขระ ข้อความต้น ข้อความที่ผ่านวิธีการแก้ไขคำให้สามารถอ่านได้ และข้อความที่ผ่านวิธีการแก้ไขคำที่อ่านได้ให้เป็นคำที่ควรจะเป็น ..... 30

# สารบัญรูป

หน้า

รูปที่ 2.1 ตัวอย่างหน้าฟีเจอร์สแกนเอกสารของไลน์ ..... 3
รูปที่ 2.2 การทำงานของ google vision OCR ..... 4
รูปที่ 2.3 การเปิดรูปใน google drive ด้วย google docs ..... 4
รูปที่ 2.4 หน้า google docs ..... 5
รูปที่ 2.5 ส่วนของผลการสแกนใน google doc ..... 5
รูปที่ 2.6 หน้าเว็บ katproof.com ..... 6
รูปที่ 2.7 ลองใช้งาน ..... 6
รูปที่ 3.1 การนำเข้าไลบรารีสำหรับการใช้งานตัดคำ ..... 8
รูปที่ 3.2 การตัดคำโดยใช้อัลกอริทึม newmm, longest, multi_cut, deepcut ..... 9
รูปที่ 3.3 การทำ subword tokenization โดย Thai Character Cluster ..... 9
รูปที่ 3.4 การทำ subword tokenization โดยการแยกพยางค์ ..... 9
รูปที่ 3.5 ตัวอย่างการใช้ ฟังก์ชัน context_diff โดยเปรียบเทียบลิสต์ของคำสองลิสต์ ..... 10
รูปที่ 3.6 ตัวอย่างโค้ดการทำ get_close_match ..... 11
รูปที่ 3.7 แผนภูมิองค์ประกอบของพยางค์ ..... 11
รูปที่ 5.1 ตัวอย่างข้อมูลนำเข้า ..... 17
รูปที่ 5.2 ผลลัพธ์การรู้จำอักขระ ..... 17
รูปที่ 5.3 แสดงการทำงานโดยรวมของระบบปรับปรุงคำผิด ..... 19
รูปที่ 5.4 จัดการข้อความก่อนแก้ไข ..... 20
รูปที่ 5.5 ซูโดโค้ดแสดงการทำงานของส่วนของการแก้คำให้สามารถอ่านได้ ..... 25
รูปที่ 5.6 ซูโดโค้ดแสดงการทำงานของส่วนที่แก้คำที่อ่านได้ให้เป็นคำที่ควรจะเป็น ..... 26
รูปผนวกที่ ก.1 การทำงานของAPI ..... 34
รูปผนวกที่ ข.1 รูปแสดงหน้าส่วนติดต่อผู้ใช้ ..... 35
รูปผนวกที่ ข.2 รูปแสดงการกรอกข้อความ ..... 36
รูปผนวกที่ ข.3 รูปแสดงผลลัพธ์เมื่อกดปุ่มแก้ไข ..... 36

# บทที่ 1 บทนำ

## 1.1 ที่มาและความสำคัญของปัญหา

การทำ OCR ซึ่งย่อมาจาก Optical Character Recognition เป็นตัวช่วยอ่านข้อความจากเอกสาร รูปภาพหรือแม้กระทั่งสิ่งพิมพ์อิเล็กทรอนิกส์ แปลงออกมาเป็นข้อความ ตัวอักษรและตัวเลข เทคโนโลยี OCR ช่วยได้มากในการจัดเก็บเอกสาร เพราะสามารถนำข้อมูลที่แปลงออกมาไปใช้ในการวิเคราะห์งานต่อได้เลย ไม่ต้องมาไล่พิมพ์ใหม่เพื่อจัดเก็บ OCR ในโลกยุคปัจจุบันรองรับหลากหลายภาษา ซึ่งรวมถึงภาษาไทยด้วย การทำ OCR ลายมือเขียนภาษาไทยนั้นมีความท้าทายอย่างมาก เนื่องจากลายมือของแต่ละคนนั้นแตกต่างกัน ในยามปกติปราศจากความเร่งรีบการเขียนข้อความอะไรซักอย่างหนึ่ง เราเขียนตัวหนังสือที่มองแล้วอ่านง่ายและทำให้สแกนข้อความแล้วแปลงออกมาเป็นข้อความง่ายขึ้นอีกด้วย แต่เมื่อเกิดเหตุการณ์ที่ต้องเร่งรีบจดเร่งเขียนจนเขียนหวัดหรือเขียนติดกัน การทำ OCR ก็ไม่ได้ทำได้อย่างง่ายดายเช่นนั้นแล้ว เพราะอาจเจอเหตุการณ์ที่เมื่อทำ OCR แล้วได้ข้อความที่แปลงออกมาได้ไม่ตรงกับข้อความที่แท้จริงในเอกสาร

ข้อความที่มีลักษณะเป็นการเขียนด้วยลายมือ ในด้านการคิดวิเคราะห์ของมนุษย์เมื่อมองลายมือนั้นแล้วรู้ได้ว่าตัวภาษาของคำหรือประโยคที่มีการเขียนติดกันเป็นคำใดที่อยู่ในประโยคนั้น แต่ในมุมของคอมพิวเตอร์เมื่อเรานำเข้ารูปภาพไปสแกนข้อความจากลายมือที่เขียนติดกันหรือการเขียนหวัด ตัวระบบ OCR นั้นเรียนรู้รูปภาพที่เรานำเข้า จากนั้นก็เป็นกระบวนการตัดสินใจเลือกสิ่งที่คุ้นเคยและได้เรียนรู้มาก่อนแล้วแสดงผลลัพธ์ออกมา ซึ่งผลที่ได้อาจไม่ใช่ผลลัพธ์การสแกนที่เราต้องการ ตัวอย่างปัญหาที่พบจากการลองทำ OCR จากฟังก์ชันสแกนข้อความของแอปพลิเคชันแชทยอดนิยมแอปพลิเคชันหนึ่ง คือ มีกลุ่มของวลีที่ไม่สามารถอ่านได้ หรือมีสระซ้ำซ้อนกันในคำ ทำให้อ่านออกเสียงไม่ได้ตามหลักของการออกเสียงพยางค์ในภาษาไทย

จากปัญหาข้างต้นเมื่อศึกษาวิธีการต่าง ๆจึงได้เกิดงานการประมวลผลภาษาธรรมชาติ เพื่อปรับปรุงคำผิดที่เกิดจากวิธีการรู้จำอักขระ ซึ่งช่วยแก้ไขข้อผิดพลาดการแปลงข้อความที่เขียนติดกันหรือเขียนหวัดแล้วแสดงผลเป็นตัวคำที่อ่านไม่ออกแล้วทำให้ตัวข้อความที่แสดงออกมามีความถูกต้องมากขึ้น

## 1.2 วัตถุประสงค์

1) เพื่อลดคำผิดที่เกิดขึ้นจากการรู้จำอักขระ
2) เพื่อศึกษาวิธีการจากงานด้านการประมวลผลภาษาธรรมชาติที่นำมาปรับใช้กับการแก้ไขคำผิด

## 1.3 ลักษณะและขอบเขต

1) ข้อมูลรับเข้าเป็นข้อความที่ได้มาจากการนำไฟล์รูปภาพที่เป็นลายมือเขียนภาษาไทยไปทำการรู้จำอักขระ
2) ระบบจะแก้ไขคำผิดที่เกิดขึ้นโดยใช้หลักการการเกิดพยางค์และฟังก์ชัน difflib มาปรับปรุงคำ
3) สามารถทำให้ผลลัพธ์ของประโยคหรือคำที่จะแสดงออกมาเป็นผลลัพธ์ที่มีความถูกต้องมากขึ้น
4) ผู้ใช้งานสามารถคัดลอกข้อความที่แก้ไขแล้วไปใช้งานได้เลย

## 1.4 อุปกรณ์และเครื่องมือที่ใช้

### 1.4.1 ฮาร์ดแวร์

เครื่องคอมพิวเตอร์ Notebook Lenovo legion Y520

- หน่วยประมวลผลกลาง Intel(R) Core(TM) i7-7700HQ CPU ความเร็ว 2.80 GHz
- หน่วยความจำหลัก 12 GB
- หน่วยความจำสำรอง SSD 256 GB HDD 1 TB
- การ์ดจอ NVIDIA GeForce GTX 1050TI

### 1.4.2 ซอฟต์แวร์

- ระบบปฏิบัติการ Windows 10
- ภาษาที่ใช้พัฒนาโปรแกรม

  Python (Google Colab)

  Android Studio (Flutter)

  Visual code studio

## 1.5 ผลที่คาดว่าจะได้รับ

สามารถลดคำผิดที่เกิดขึ้นจากการรู้จำอักขระได้

# บทที่ 2 ผลงานที่เกี่ยวข้อง

ในบทนี้จะกล่าวถึงฟีเจอร์ของแอปพลิเคชันและเว็บไซต์ที่เกี่ยวข้องกับโครงงานนี้ ประกอบด้วยคุณสมบัติ ข้อเด่น และข้อด้อย ซึ่งผู้จัดทำโครงงานจะนำข้อเด่นข้อด้อยของแต่ละผลงานมาเป็นเป้าหมายของโครงงาน

## 2.1 ฟีเจอร์สแกนเอกสารของแอปพลิเคชันไลน์

ฟีเจอร์สแกนเอกสารของแอปพลิเคชันไลน์ ถูกเปิดตัวขึ้นในปี พ.ศ. 2562 สแกนข้อความได้โดยการนำเข้าข้อมูลรูปภาพ ซึ่งสามารถนำเข้าได้จากรูปภาพที่ถูกส่งเข้าไปในช่องแชทซึ่งทำได้บนแอปพลิเคชันไลน์บน PC, Mac และบนสมาร์ทโฟน หรือการใช้ฟีเจอร์กล้องของแอปพลิเคชันไลน์และเลือกฟังก์ชันสแกนเอกสาร เมื่อกดถ่ายรูปจะแสดงข้อความที่อยู่ในรูปออกมา ฟีเจอร์นี้มีให้ใช้บนสมาร์ทโฟน ตัวฟีเจอร์ดังกล่าว ใช้ API ชื่อว่า CLOVA OCR [3] ซึ่งมีการอธิบายว่า สามารถใช้กับรูปภาพและฟอร์ม และมีความยืดหยุ่นในการสแกนอักขระที่เขียนแบบไม่ได้ตรงบรรทัด มีความเอียง ความโค้งเวลาเขียน เขียนเป็นแนวตั้งหรือแนวนอนก็สามารถสแกนให้ผลลัพธ์ออกมาอย่างแม่นยำ สแกนได้ตั้งแต่เอกสารทั่วไปจนถึงเอกสารสำคัญ โดยระบบจะไม่มีการเก็บข้อมูลที่ผู้ใช้ได้สแกนไว้ แสดงการทำงานดังรูปที่ 2.1

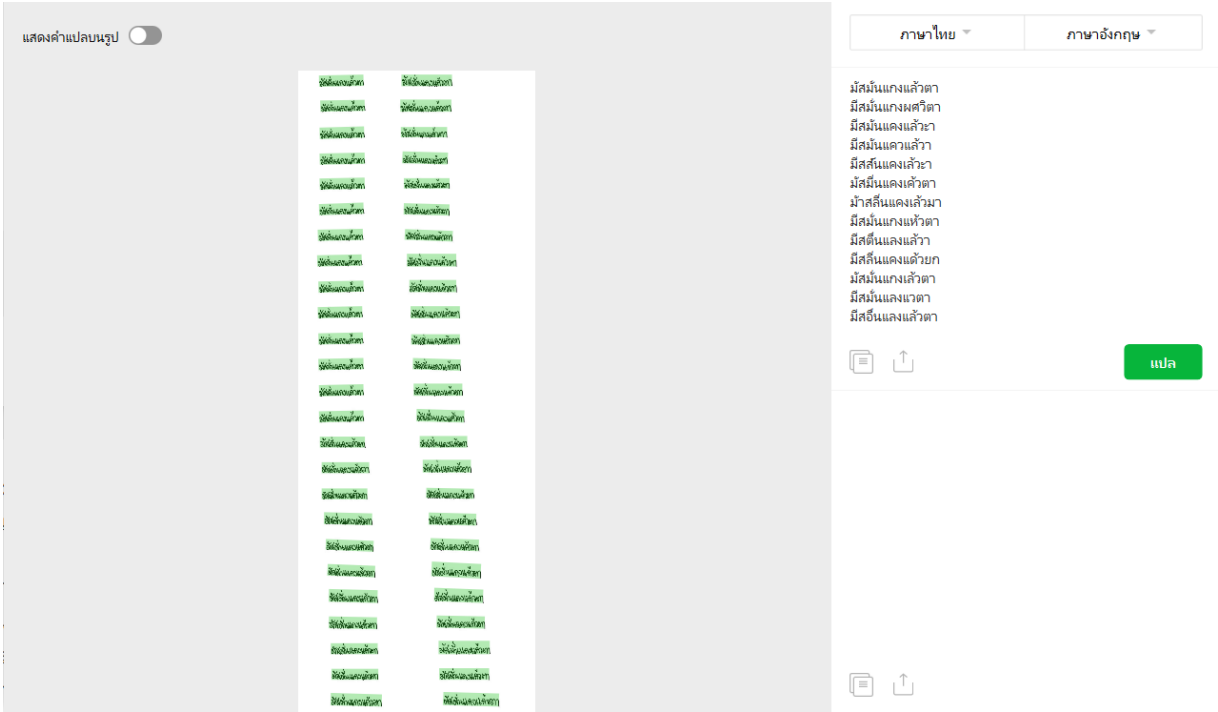


รูปที่ 2.1 ตัวอย่างหน้าฟีเจอร์สแกนเอกสารของไลน์

### 2.1.1 ข้อเด่น

- สามารถสแกนได้ผลลัพธ์ออกมาอย่างรวดเร็ว
- ไม่เสียค่าใช้จ่าย
- ความแม่นยำของผลลัพธ์อยู่ในเกณฑ์ที่ดีกับเอกสารที่เป็นฟอนต์ทั่วไป
- สามารถสแกนข้อความได้แบบยืดหยุ่น

### 2.1.2 ข้อด้อย

- เมื่อลองใช้สแกนข้อความภาษาไทยที่เขียนด้วยลายมือคนเขียนมีความแม่นยำอยู่ในระดับที่ไม่น่าพึงพอใจมากนัก

## 2.2 ฟีเจอร์จับข้อความจากรูปภาพของ google docs

ฟีเจอร์จับข้อความจากรูปภาพของ google docs [10] เป็นฟีเจอร์ที่เมื่อเปิดไฟล์รูปภาพใน google drive โดยใช้ google docs จะแสดงข้อความที่ปรากฏในรูป โดยตัวฟีเจอร์นี้ได้มาจากความสามารถของ Google Vision OCR [4] มีหลักการทำงานดังรูปที่ 2.2, 2.3, 2.4 และ 2.5

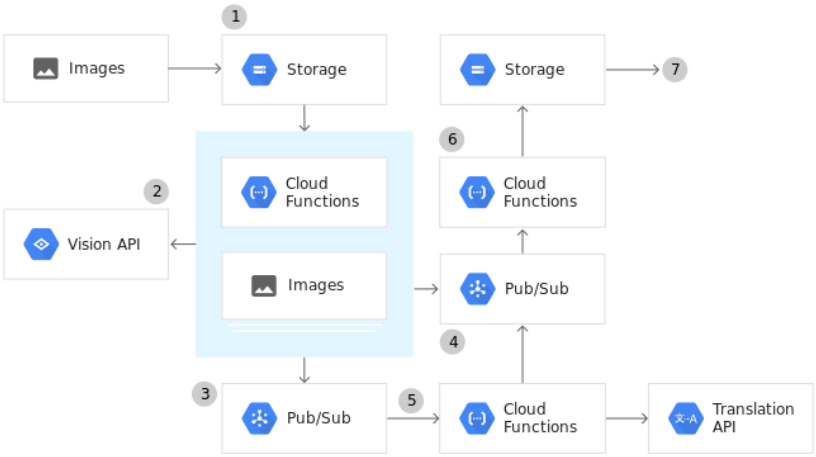


รูปที่ 2.2 การทำงานของ google vision OCR

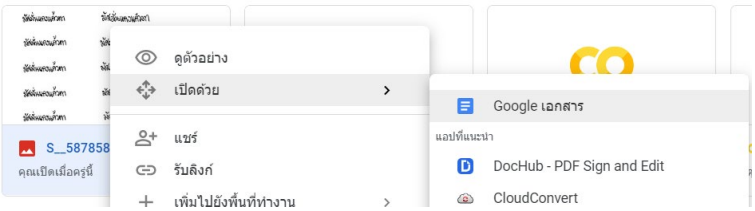


รูปที่ 2.3 การเปิดรูปใน google drive ด้วย google docs

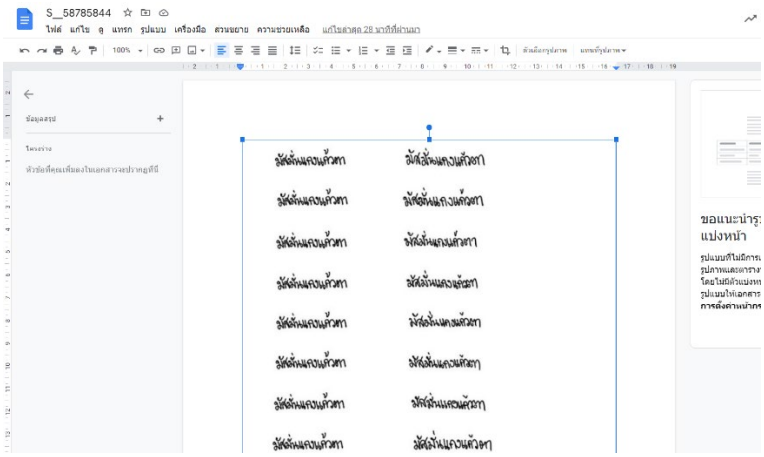

รูปที่ 2.4 หน้า google docs

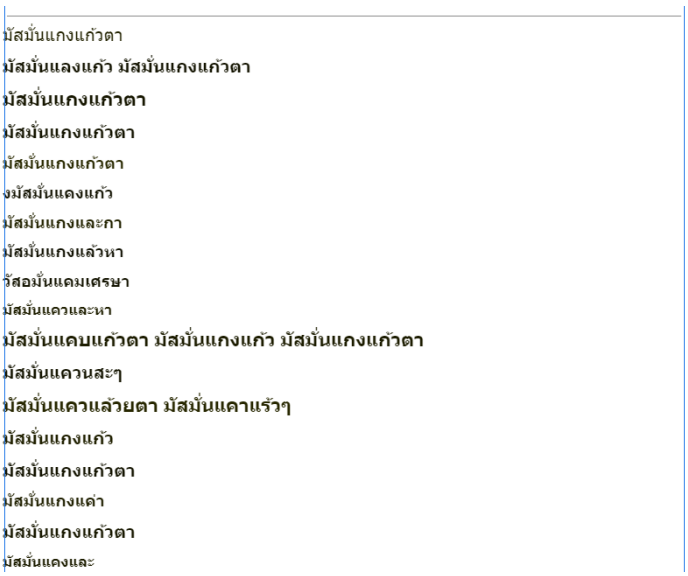

มัสมั่นแกงแก้วตา
มัสมั่นแลงแก้ว มัสมั่นแกงแก้วตา
มัสมั่นแกงแก้วตา
มัสมั่นแกงแก้วตา
มัสมั่นแกงแก้วตา
งมัสมั่นแดงแก้ว
มัสมั่นแกงและกา
มัสมั่นแกงแล้วหา
วัสอมั่นแดมเศรษา
มัสมั่นแดวและหา
มัสมั่นแคบแก้วตา มัสมั่นแกงแก้ว มัสมั่นแกงแก้วตา
มัสมั่นแดวนสะๆ
มัสมั่นแดวแล้วยตา มัสมั่นแดาแร้วๆ
มัสมั่นแกงแก้ว
มัสมั่นแกงแก้วตา
มัสมั่นแกงแด่า
มัสมั่นแกงแก้วตา
มัสมั่นแดงและ

รูปที่ 2.5 ส่วนของผลการสแกนใน google doc

### 2.2.1 ข้อเด่น

- ไม่เสียค่าใช้จ่าย
- ใช้เวลาในการสแกนไม่นาน
- มีความแม่นยำของผลลัพธ์ที่สแกนข้อความอยู่ในเกณฑ์ที่ดี

### 2.2.2 ข้อด้อย

- สแกนข้อความในเอกสารที่เป็นลายมือข้อความภาษาไทยได้ผลลัพธ์ที่ไม่น่าพึงพอใจนัก

## 2.3 Katproof.com

Katproof.com [5] เป็นเว็บไซต์ตรวจคำผิดในเอกสารภาษาไทย ซึ่งมีความแม่นยำในระดับสูง โดยอ้างอิงคำที่ถูกต้องมาจากฐานข้อมูลพจนานุกรมราชบัณฑิตยสถานทั้งคำไทยและคำทับศัพท์ โดยแบ่งการตรวจสอบเป็นสามแบบคือ สีแดงเป็นการแสดงคำผิด หรือคำที่ไม่มีในระบบ สีเหลืองเป็นคำที่ต้องสงสัยว่าจะผิดและแถบสีฟ้าแสดงการเว้นวรรคตอนผิดหลักราชบัณฑิตยสถาน แสดงวิธีการใช้ดังรูป 2.6 และ 2.7

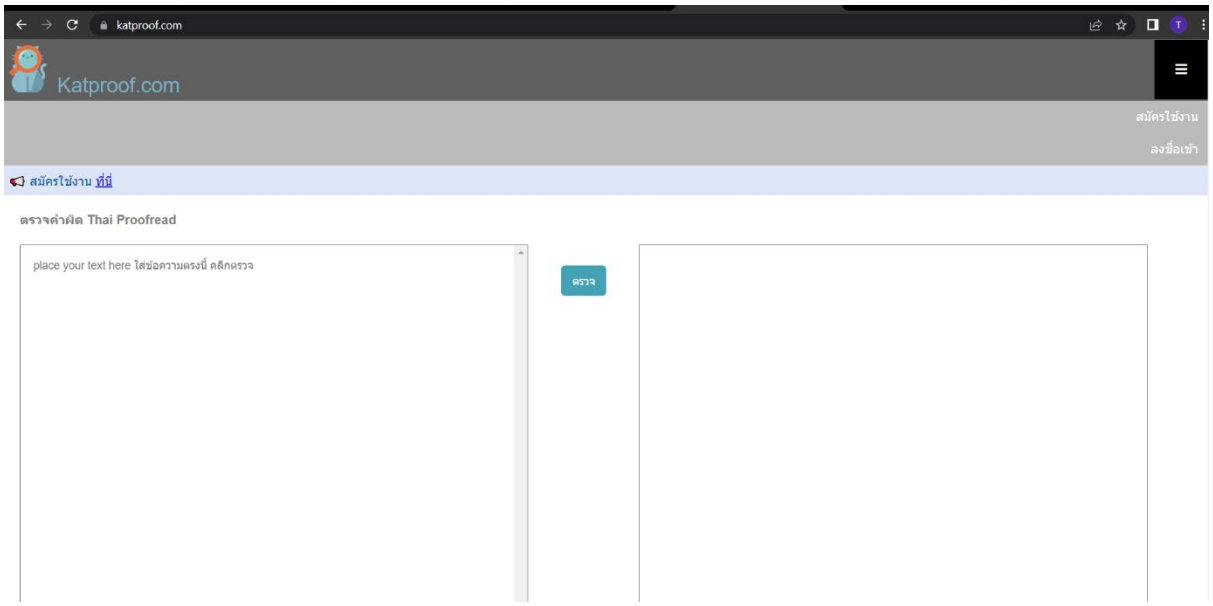


รูปที่ 2.6 หน้าเว็บ katproof.com

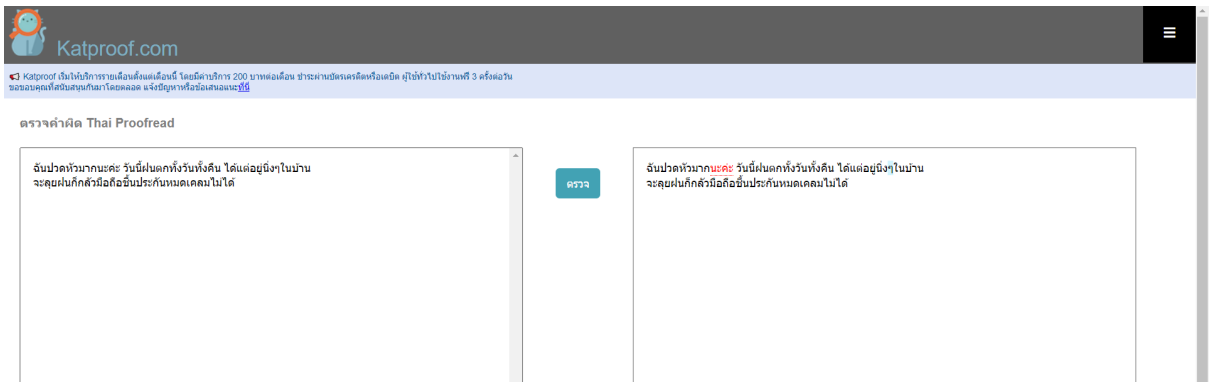


รูปที่ 2.7 ลองใช้งาน

### 2.3.1 ข้อเด่น

- ตรวจเช็คคำผิดหรือจุดควรแก้ไขได้อย่างรวดเร็วและแม่นยำ

### 2.3.2 ข้อด้อย

- เมื่อเจอคำศัพท์ที่ตัวฐานข้อมูลราชบัณฑิตยสถานไม่มีอาจจะทำให้ไม่สามารถตรวจสอบความถูกต้องได้
- สามารถใช้งานฟรีได้ 3 ครั้งต่อวัน

# บทที่ 3 ทฤษฎีและความรู้ที่เกี่ยวข้อง

ในบทนี้จะกล่าวถึงทฤษฎีและความรู้ที่เกี่ยวข้องเพื่อนำมาใช้ในทำโครงงานการประมวลผลภาษาทางธรรมชาติ เพื่อปรับปรุงคำผิดที่เกิดจากการรู้จำอักขระ

## 3.1 การประมวลผลภาษาธรรมชาติ

การประมวลผลภาษาธรรมชาติ (Natural language processing) [8] เป็นส่วนหนึ่งของเทคโนโลยีปัญญาประดิษฐ์ ซึ่งช่วยให้คอมพิวเตอร์สามารถเข้าใจในภาษาปกติที่มนุษย์สื่อสารกัน สามารถนำเข้าข้อมูลเพื่อไปประมวลผลหาสิ่งที่เป็นจุดมุ่งหมายของระบบการประมวลผลภาษาธรรมชาติที่ถูกองค์กรสร้างขึ้น หลังจากได้รับการสื่อสารจากมนุษย์จะสามารถตอบอะไรบางอย่างออกมาเป็นผลลัพธ์ของการนำเข้าข้อมูล เนื่องจากระบบไม่มีความเหนื่อยล้าจึงประมวลผลข้อมูลจำนวนมากได้โดยไม่มีขีดจำกัดทางด้านร่างกายแบบมนุษย์จึงสามารถสรุปจากข้อมูลได้รวดเร็วและครอบคลุม ซึ่งโครงงานนี้จะใช้ชุดคำสั่งจากงานด้านการประมวลผลภาษาธรรมชาติภาษาไทยเพื่อแก้คำผิด

### 3.1.1 PyThaiNLP

PythaiNLP [11] เป็นไลบรารีสำหรับงานด้านการประมวลผลภาษาไทย การวิเคราะห์ภาษา สามารถทำงานได้หลากหลาย เช่น เซตของตัวอักขระภาษาไทย การตรวจตัวสะกด แก้คำผิด การเรียงคำภาษาไทย การวิเคราะห์ชนิดของคำ การทำ Segment คำ โดยจะยกตัวอย่างโค้ดในการทำ Segment คำในภาษาไทย

การทำ Segment คำ โดยใช้ PyThaiNLP มีการรองรับอัลกอริทึมในการทำ segment มากมาย ดังตัวอย่างโค้ด

1. import library ที่จำเป็นดังรูปที่ 3.1

```
[1] %reload_ext autoreload
    %autoreload 2
    %matplotlib inline

[2] try:
        %tensorflow_version 2.x
    except:
        pass

    Colab only includes TensorFlow 2.x; %tensorflow_version has no effect.

    # dev version
    # !pip install https://github.com/PyThaiNLP/pythainlp/archive/dev.zip

    # release version
    ! pip install pythainlp

    !pip install epitran
    !pip install sklearn_crfsuite
    !pip install tensorflow deepcut
    !pip install attacut
```

รูปที่ 3.1 การนำเข้าไลบรารีสำหรับการใช้งานตัดคำ

2. การตัดคำโดยใช้อัลกอริทึมหลากหลายแบบ ดังรูปที่ 3.2

```
[6]  from pythainlp import sent_tokenize, word_tokenize

[7]  text = "สวัสดีวันอังคารขอให้พบพานกับสิ่งที่ดี สวัสดีวันพุธขอให้มั่งมีเงินทอง สวัสดีวันพฤหัสบดีขอให้ชีวิตสดใส"

     print("newmm    :", word_tokenize(text))  # default engine is "newmm"
     print("longest  :", word_tokenize(text, engine="longest"))
     print("multi_cut:", word_tokenize(text, engine="multi_cut"))
     print("deepcut  :", word_tokenize(text, engine="deepcut"))

     newmm    : ['สวัสดี', 'วัน', 'อังคาร', 'ขอให้', 'พบพาน', 'กับ', 'สิ่ง', 'ที่', 'ดี', ' ', 'สวัสดี', 'วัน', 'พุธ', 'ขอให้', 'มั่ง', 'มีเงินทอง', ' ', 'สวัสดี', 'วัน', 'พฤหัสบดี', 'ขอให้', 'ชีวิต', 'สดใส']
     longest  : ['สวัสดี', 'วัน', 'อังคาร', 'ขอให้', 'พบพาน', 'กับ', 'สิ่ง', 'ที่', 'ดี', ' ', 'สวัสดี', 'วัน', 'พุธ', 'ขอให้', 'มั่งมี', 'เงินทอง', ' ', 'สวัสดี', 'วัน', 'พฤหัสบดี', 'ขอให้', 'ชีวิต', 'สดใส']
     multi_cut: ['สวัสดี', 'วัน', 'อังคาร', 'ขอให้', 'พบพานกับ', 'สิ่ง', 'ที่', 'ดี', ' ', 'สวัสดี', 'วัน', 'พุธ', 'ขอให้', 'มั่งมีเงินทอง', ' ', 'สวัสดี', 'วัน', 'พฤหัสบดี', 'ขอให้', 'ชีวิต', 'สดใส']
     deepcut  : ['สวัสดี', 'วัน', 'อังคาร', 'ขอ', 'ให้', 'พบ', 'พาน', 'กับ', 'สิ่ง', 'ที่', 'ดี', ' ', 'สวัสดี', 'วัน', 'พุธ', 'ขอ', 'ให้', 'มั่ง', 'มี', 'เงินทอง', ' ', 'สวัสดี', 'วัน', 'พฤหัสบดี', 'ขอ', 'ให้', 'ชีวิต', 'สดใส']
```

รูปที่ 3.2 การตัดคำโดยใช้อัลกอริทึม newmm, longest, multi_cut, deepcut

3. การทำ subword tokenization

ทำโดย Thai Character Cluster ดังรูปที่ 3.3

```
[13] from pythainlp import subword_tokenize

[18] text = "สวัสดีวันอังคาร"

     subword_tokenize(text)  # default subword unit is TCC

     ['ส', 'วัส', 'ดี', 'วัน', 'อัง', 'คา', 'ร']
```

รูปที่ 3.3 การทำ subword tokenization โดย Thai Character Cluster

ทำโดยแยกเป็นพยางค์ ดังรูปที่ 3.4

```
[20] subword_tokenize(text, engine="ssg")

     ['สวัส', 'ดี', 'วัน', 'อัง', 'คาร']
```

รูปที่ 3.4 การทำ subword tokenization โดยการแยกพยางค์

## 3.2 Optical Character Recognition (OCR)

Optical character recognition [1][2] เป็นกระบวนการที่ทำการแปลงตัวอักขระในรูปภาพออกมาอยู่ในรูปแบบของข้อความ โดยแบ่งออกเป็นกระบวนการหลัก สองกระบวนการ คือ Pattern Recognition เป็นการจำแนกข้อความว่าตัวที่เห็นจากรูปเป็นตัวอักษรอะไร อาจจะจำแนกตัวอักษรได้ไม่ทั้งหมดเมื่อเจอฟอนต์หรือลายมือที่ผิดแปลกไป และ Feature Detection เป็นวิธีการจำแนกตัวอักษรโดยใช้กฎซึ่งจะมีความยืดหยุ่นใน การจำแนกตัวอักษรมากกว่าแบบ Pattern Recognition เนื่องจากจะดึงรูปแบบของตัวอักษรนั้นมาสังเกตว่ารูปแบบดังกล่าวเข้าหลักของกฎใดที่ตั้งไว้และจะให้ผลลัพธ์ที่ใกล้เคียงกับกฎนั้นออกมา ซึ่งในปัจจุบันมีการให้บริการการสแกนเอกสารเพื่อจัดเก็บด้วยวิธีนี้มากมาย โดยเทคโนโลยี OCR

ช่วยให้การนำเข้าข้อมูลไปทำการวิเคราะห์ด้วยการประมวลผลภาษาธรรมชาติได้อย่างรวดเร็วมากขึ้น เพียงแค่สแกนเอกสารก็สามารถนำข้อมูลที่อยู่บนเอกสารไปใส่ในระบบได้เพียงในไม่กี่นาที แต่ต้องทำการตรวจทานและแก้ไขก่อนที่จะนำไปใช้งาน

## 3.3 difflib

difflib [6] เป็นโมดูลที่เกี่ยวกับการเปรียบเทียบลำดับและความแตกต่างของไฟล์ในหลายฟอร์แมตรวมถึงไฟล์ html มีคลาสและฟังก์ชันให้ใช้อยู่หลายตัว โดยจะยกตัวอย่างคลาส ดังนี้

**- difflib.SequenceMatcher**

เป็นคลาสที่ใช้เปรียบเทียบคู่ของลำดับของรูปแบบการนำเข้าอะไรก็ได้ที่สามารถทำการแฮชได้ โดยจะมีสิ่งที่เรียกว่า Automatic junk heuristic คอยตรวจดูลำดับรูปแบบที่เกิดขึ้นซ้ำมากกว่า 1% ของลำดับทั้งหมด มีความยาวอย่างน้อย 200 ลำดับ จะถูกเช็คว่าเป็นลำดับยอดนิยม การทำงานลักษณะนี้สามารถปิดการทำงานได้ โดยกำหนดค่า autojunk เป็น false

**- difflib.Differ**

เป็นคลาสที่ใช้เปรียบเทียบลำดับบรรทัดข้อความ โดยจะใช้ SequenceMatcher ในการเปรียบเทียบบรรทัด ลำดับของอักขระในบรรทัดที่มีความคล้ายคลึงหรือใกล้เคียงกัน โดยจะมีรหัสดังนี้

'- ' หมายถึง บรรทัดนี้ไม่ซ้ำกับลำดับที่ 1
'+ ' หมายถึง บรรทัดนี้ไม่ซ้ำกับลำดับที่ 2
' ' หมายถึง บรรทัดนี้ เหมือนกับลำดับทั้งสอง
'? ' หมายถึงบรรทัดนี้ไม่มีอยู่ในลำดับทั้งสอง

**- difflib.context_diff**(*a, b, fromfile='', tofile='', fromfiledate='', tofiledate='', n=3, lineterm='\n'*)

เป็นฟังก์ชันที่ใช้เปรียบเทียบลิสต์ จากโค้ดคือ a กับ b และคืนค่าผลลัพธ์ที่เปลี่ยนไป จากการนำลิสต์สองตัวนี้มาเทียบกัน จาก head ที่ใส่ค่าไปให้ฟังก์ชันทำงาน ส่วนของ fromfile, tofile, fromfiledate และtofiledate จะใช้ String เป็นค่าที่ใส่ในตัวแปร ตัวแปรที่มีdateอยู่ถ้าไม่มีการกำหนดค่า จะใช้ค่าว่างเป็น default ดังรูปที่ 3.5

```
>>> s1 = ['bacon\n', 'eggs\n', 'ham\n', 'guido\n']
>>> s2 = ['python\n', 'eggy\n', 'hamster\n', 'guido\n']
>>> sys.stdout.writelines(context_diff(s1, s2, fromfile='before.py', tofile='after.py'))
*** before.py
--- after.py
***************
*** 1,4 ****
! bacon
! eggs
! ham
  guido
--- 1,4 ----
! python
! eggy
! hamster
  guido
```

รูปที่ 3.5 ตัวอย่างการใช้ ฟังก์ชัน context_diff โดยเปรียบเทียบลิสต์ของคำสองลิสต์
หน้าตัวที่มีการเปลี่ยนแปลงจะมี ! อยู่ด้านหน้า ส่วนตัวที่ไม่มีคือไม่ได้เปลี่ยนแปลง

- difflib.get_close_matches(word,possibilities,n=3,cutoff=0.6)

เป็นฟังก์ชันที่จะคืนค่าเป็นลิสต์ของคำที่ใกล้เคียงที่สุดกับคำที่เราใส่ลงไป ในฟังก์ชันจะมีการให้ใส่คำที่จะหาคำที่ใกล้เคียงที่สุด (word) ลิสต์ของคำที่จะหาว่ามีความใกล้เคียง (possibilities) จำนวนไอเทมในลิสต์ที่จะคืนค่าออกมา (n) ซึ่งหากไม่กำหนดเองจะมีค่า default เป็น n=3 และการกำหนดค่าที่ต่ำที่สุดในการดูความคล้ายที่เทียบกัน (cutoff) ถ้าไม่กำหนดเองจะมีค่า default เป็น cutoff=0.6 จะคืนผลลัพธ์ในรูปแบบลิสต์

ตัวอย่างโค้ดการทำ get_close_match ดังรูปที่ 3.6

```
>>> get_close_matches('appel', ['ape', 'apple', 'peach', 'puppy'])
['apple', 'ape']
>>> import keyword
>>> get_close_matches('wheel', keyword.kwlist)
['while']
>>> get_close_matches('pineapple', keyword.kwlist)
[]
>>> get_close_matches('accept', keyword.kwlist)
['except']
```

รูปที่ 3.6 ตัวอย่างโค้ดการทำ get_close_match

บรรทัดแรกจะหาคำใกล้เคียงกับคำว่า appel พบว่ามีคำสองคำที่ใกล้เคียง คือ ape กับ apple

บรรทัดที่ 3 ถึง 5 ได้ทำการเปรียบเทียบหาคำที่ใกล้เคียงกับ wheel pineapple accept โดยหาจากคำที่เป็นคีย์เวิร์ดของภาษาไพธอน ได้ผลลัพธ์ดังรูป

## 3.4 เสียงในภาษาไทยและตัวสะกด

พยางค์ [9] คือ เสียงที่เปล่งออกมา ซึ่งมีความหมายหรือไม่มีความหมายก็ได้ โดยการเปล่งเสียง 1 ครั้ง หมายถึงการเปล่งเสียง 1 พยางค์ โดยมีองค์ประกอบที่เขียนในรูปแผนภูมิตามหลักสัทวิทยาดังรูปที่ 3.7

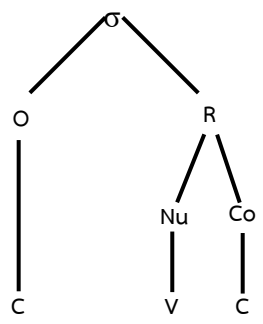


รูปที่ 3.7 แผนภูมิองค์ประกอบของพยางค์

โดย σ คือ พยางค์

O คือ พยัญชนะต้น ประกอบด้วยพยัญชนะ 44 รูป 21 เสียง โดยสามารถแตกกิ่งได้เป็นพยัญชนะควบ (Consonant Clusters)

R คือ ส่วนท้ายพยางค์ สามารถแยกได้เป็นสองส่วน ได้แก่ Nu คือ ส่วนของแกนพยางค์ คือ สระ(V) สามารถแตกกิ่งเป็นสระเสียงยาวหรือสระประสมได้และ Co เป็นส่วนท้ายของพยางค์ ได้แก่ ตัวสะกด(C) โดย Co สามารถแตกกิ่งออกได้เป็นพยัญชนะควบท้าย

จากรูปแบบของพยางค์ จะได้โครงสร้างของพยางค์เป็น 4 แบบ ได้แก่ [CV] [CCV] [CVC] [CCVC] เมื่อนำพยางค์ภาษาไทยไปเทียบกับรูปแบบข้างต้น จะพบว่าการเขียนและการออกเสียงพยางค์มีการเรียงลำดับตัวอักษรที่ทั้งเหมือนและไม่เหมือนกัน เพราะความพิเศษของแกนพยางค์หรือสระของภาษาไทยสามารถเขียนวางอยู่ในตำแหน่งใดๆของพยางค์ก็ได้[13] โดยมีได้ถึง 9 แบบ ได้แก่ สระหน้าประกอบไปด้วย เ- แ- โ- ไ- และ ใ- สระหลังประกอบไปด้วย -ะ -า -อ ฤ และ -ว สระบนประกอบไปด้วย ั ิ ี ึ ื และ ็ สระล่างประกอบไปด้วย ุ และ ู [12] สระที่อยู่ได้ตามลำพัง คือ ฤ ฦ ตำแหน่งของรูปสระข้างต้นสามารถนำมารวมกันเพื่อออกเสียงได้อีกแบบหนึ่ง ได้แก่ สระหน้าและสระหลัง เช่น เ-า แ-ะ โ-ะ เ-ะ เ-าะ เ-อะ และเ-อ สระบนและหลังเช่น ัวะ ัว ำ สระหน้า บนและหลัง เช่น เ-ียะ เ-ีย เ-ือะ เ-ือ และสุดท้ายคือ สระล่างและบนเช่น เ- เ็- อีกทั้งสระในภาษาไทยบางตัวจะมีการเปลี่ยนรูปและลดรูปเมื่อมีตัวสะกด การเปลี่ยนรูปได้แก่ สระอะเมื่อมีพยัญชนะจะเปลี่ยนตัวเองให้เป็นไม้หันอากาศเช่น ขะ เติมตัวสะกด น เขียนว่า ขัน สระเอะเมื่อมีตัวสะกดจะเปลี่ยนตัวเองเป็นสระเอ ไม้ไต่คู้เช่น เปะ เติมตัวสะกด ด เขียนว่าเป็ด สระแอะเมื่อมีตัวสะกดจะเปลี่ยนรูปเป็นสระแอ ไม้ไต่คู้ เช่น แขะ เติมตัวสะกด ง เขียนว่า แข็ง สระเออเมื่อมีตัวสะกดจะเปลี่ยนรูปเป็นสระเอ สระอิ เช่น เขอ เติมตัวสะกด น เขียนว่า เขิน สระที่มีการลดรูปนั้น คือ สระโอะเมื่อมีตัวสะกดจะลดรูปเหลือแค่พยัญชนะต้นตามด้วยสะกด เช่น โกะ เติมตัวสะกด ด เขียนว่า กด สระเออจะมีการลดรูปเมื่อมีตัวสะกดโดยจะลดรูปเหลือเพียงสระเอตามด้วยตัวสะกด เช่น เคอ เติมตัวสะกด ย อ่านว่า เคย สระอัวเมื่อมีตัวสะกดจะลดรูปเหลือเพียง ว เช่น งัว เติมตัวสะกด ง เขียนว่า งวง นอกเหนือจากสระแล้วอีกหนึ่งสิ่งที่การเขียนและอ่านพยางค์ภาษาไทยนั้นพิเศษคือการมีคือวรรณยุกต์ใช้กำกับการออกเสียง โดยวรรณยุกต์สามารถปรากฏได้อยู่บนพยัญชนะเมื่อสระนั้นไม่ใช่สระบน หากมีสระบน วรรณยุกต์ก็จะปรากฏอยู่บนสระบน ส่วนพยัญชนะภาษาไทยนั้นมี 44 รูป 21 เสียง ทุกตัวสามารถทำหน้าที่เป็นพยัญชนะต้นได้ แต่ไม่ใช่พยัญชนะทุกตัวที่สามารถทำหน้าที่เป็นตัวสะกดได้ คือ อ ฮ ผ ฝ ห ฉ และฌ ไม่สามารถออกเสียงเป็นตัวสะกดได้ เมื่อนำตัวอย่างการเขียนพยางค์แบ่งตามตำแหน่งของรูปสระและเทียบกับแผนภูมิองค์ประกอบของพยางค์โดยใช้ T แทนตำแหน่งของวรรณยุกต์ ได้ดังตารางที่ 3.1

ตารางที่ 3.1 ตัวอย่างการเขียนพยางค์แบ่งตามตำแหน่งของรูปสระ
และเทียบกับแผนภูมิองค์ประกอบของพยางค์โดยใช้ T แทนตำแหน่งของวรรณยุกต์

| **ตำแหน่งของแกนพยางค์** | **ตัวอย่างการเขียนพยางค์** | **รูปแบบการเขียนของพยางค์** | **การออกเสียง** | **รูปแบบการออกเสียงของพยางค์** |
|---|---|---|---|---|
| หน้า | ไป | VC | ป-ไอ-ไป | CV |
| | ไป่ | VCT | ป-ไอ-ไป-ไม้เอก-ไป่ | CVT |
| | ไหล | VCC | ห-น-ไอ-ไหล | CCV |
| | ไหร่ | VCCT | ห-ร-ไอ-ไหร-ไม้เอก-ไหร่ | CCVT |
| | โรง | VCC | ร-โอ-ง-โรง | CVC |
| | โล่ง | VCTC | ล-โอ-ง-โลง-ไม้เอก-โล่ง | CVCT |
| | โครง | VCCC | คร-โอ-ง-โครง | CCVC |
| | โคร่ง | VCCTC | คร-โอ-โง-โครง-ไม้เอก-โคร่ง | CCVCT |
| หลัง | นา | CV | น-อา-นา | CV |

| | | | | |
|---|---|---|---|---|
| | น่า | CTV | น-อา-ไม้เอก-น่า | CVT |
| | ปลา | CCV | ปล-อา-ปลา | CCV |
| | คร่า | CCTV | คร-อา-ครา-ไม้เอก-คร่า | CCVT |
| | บัง | CVC | บ-อะ-ง-บัง | CVC |
| | บั้ง | CTVC | บ-อะ-ง-บัง-ไม้โท-บั้ง | CVC |
| | คลัง | CCVC | คล-อะ-ง-คลัง | CCVC |
| | คลั่ง | CCVTC | คล-อะ-ง-คลัง-ไม้เอก-คลั่ง | CCVCT |
| บน | คือ | CV | ค-อือ-คือ | CV |
| | ชื่อ | CVT | ข-อือ-ชือ-ไม้เอก-ชื่น | CVT |
| | หรือ | CCV | หร-อือ-หรือ | CCV |
| | พรื่อ | CCVT | พร-อือ-พรือ-ไม้เอก-พรื่อ | CCVT |
| | กิน | CVC | ก-อิ-น-กิน | CVC |
| | ถิ่น | CVTC | ถ-อิ-น-ถิน-ไม้เอก-ถิ่น | CVCT |
| | กลืน | CCVC | กล-อือ-น-กลืน | CCVC |
| | คลื่น | CCVTC | คล-อือ-น-คลืน-ไม้เอก-คลื่น | CCVCT |
| ล่าง | ดู | CV | ด-อู-ดู | CV |
| | ดู่ | CVT | ด-อู-ดู-ไม้เอก-ดู่ | CVT |
| | กลู | CCV | กล-อู-กลู | CCV |
| | ครู่ | CCVT | คร-อู-ครู-ไม้เอก-ครู่ | CCVT |
| | ขุน | CVC | ข-อุ-น-ขุน | CVC |
| | ขุ่น | CVTC | ข-อุ-น-ขุน-ไม้เอก-ขุ่น | CVCT |
| | กรุ่น | CCVTC | กร-อุ-น-กรุน-ไม้เอก-กรุ่น | CCVCT |
| หน้าและหลัง | และ | VCV | ล-แอะ-และ | CV |
| | โป๊ะ | VCTV | ป-โอะ-โปะ-ไม้ตรี-โป๊ะ | CVT |
| | แกละ | VCCV | กล-แอะ-แกละ | CCV |
| | แบน | VCC | บ-แอะ-น-แบน | CVC |

| | | | | |
|---|---|---|---|---|
| | เล่น | VCTC | ล-เอะ-น-เลน-ไม้เอก-เล่น | CVCT |
| | เสร็จ | VCCVC | สร-เอะ-จ-เสร็จ | CCVC |
| บนและหลัง | กำ | CV | ก-อำ-กำ | CV |
| | ก่ำ | CTV | ก-อำ-กำ-ไม้เอก+ก่ำ | CVT |
| | พรำ | CCV | พร-อำ-พรำ | CCV |
| | พร่ำ | CCTV | พร-อำ-พรำ-ไม้เอก-พร่ำ | CCVT |
| | พวง | CVC | พ-อัว-ง-พวง | CVC |
| | พ่วง | CTVC | พ-อัว-ง-พวง-ไม้เอก-พ่วง | CVCT |
| | กลวง | CCVC | กล-อัว-ง-กลวง | CCVC |
| | กล้วย | CCVTC | กล-อัว-ย-กลวย-ไม้โท-กล้วย | CCVCT |
| ล่างและบน | เขิน | VCVC | ข-เออ-น-เขิน | CVC |
| | เปิ่น | VCVTC | ป-เออ-น-เปิน-ไม้เอก-เปิ่น | CVCT |
| | เกริม | VCCVC | กร-เออ-ม-เกริม | CCVC |
| | เกริ่น | VCCVTC | กร-เออ-น-เกริน-ไม้เอก-เกริ่น | CCVCT |
| หน้า บนและหลัง | เรือ | VCVV | ร-เอือ-เรือ | CV |
| | เรื่อ | VCVTV | ร-เอือ-เรือ-ไม้เอก-เรื่อ | CVT |
| | เพลีย | VCCVV | พล-เอีย-เพลีย | CCV |
| | เหยื่อ | VCVTVC | หย-เอือ-เหยือ-ไม้เอก-เหยื่อ | CCVT |
| | เรือง | VCVVC | ร-เอือ-เรือ | CVC |
| | เรื่อง | VCVTVC | ร-เอือ-ง-เรือง-ไม้เอก-เรื่อง | CVCT |
| | เคลือบ | VCCVVC | คล-เอือ-บ-เคลือบ | CCVC |
| | เกลี้ยง | VCCVTVC | กล-เอีย-ง-เกลียง-ไม้โท-เกลี้ยง | CCVCT |

# บทที่ 4 ขั้นตอนและแผนการดำเนินงาน

ในบทนี้จะกล่าวถึงรายละเอียดของงาน โดยจะประกอบด้วย Gantt Chart ที่แสดงให้เห็นขั้นตอนการดำเนินงาน เวลาที่ใช้ และอธิบายรายละเอียดในขั้นตอนการดำเนินงาน

## 4.1 ขั้นตอนการดำเนินงาน

### 4.1.1 คิดหัวข้อโครงงานและรวบรวมข้อมูล

- เลือกหัวข้อที่สนใจ
- รวบรวมข้อมูลที่เกี่ยวข้องกับหัวข้อ

### 4.1.2 กำหนดขอบเขตและวางแผนการดำเนินงาน

- กำหนดขอบเขตของโครงงาน
- วางแผนการดำเนินงานและเตรียมพัฒนางาน

### 4.1.3 ศึกษาความรู้และทฤษฎีที่เกี่ยวข้อง

- ศึกษาเกี่ยวกับวิธีการรู้จำอักขระ
- ศึกษาฟังก์ชันและคำสั่งที่ใช้จัดการผลลัพธ์การรู้จำอักขระที่ผิดพลาด
- ศึกษางานด้านการประมวลผลภาษาธรรมชาติที่เกี่ยวข้องกับโครงงาน
- ศึกษาการออกแบบหน้าเว็บแอปพลิเคชัน
- ศึกษาการทำระบบเพื่อปรับปรุงการรู้จำอักขระภาษาไทย

### 4.1.4 การวิเคราะห์และออกแบบระบบ

- เขียนข้อความแล้วลองหาผลลัพธ์จากการรู้จำอักขระ
- วิเคราะห์ลักษณะที่เป็นรูปแบบของคำผิดที่เกิดขึ้นเมื่อรู้จำอักขระ
- ออกแบบระบบการทำงาน ในการปรับปรุงคำผิดที่เกิดจากการรู้จำอักขระภาษาไทย
- ออกแบบรูปแบบการตอบสนองกับผู้ใช้

### 4.1.5 พัฒนาโปรแกรม

- เขียนโปรแกรมปรับปรุงคำผิดที่เกิดจากการรู้จำอักขระภาษาไทย ตามขอบเขตของงาน
- เขียนโปรแกรมหน้าเว็บแอปพลิเคชัน พร้อมการทำงานที่ได้กำหนดไว้ในขอบเขตงาน
- เขียนโปรแกรมส่วนที่เชื่อมต่อโปรแกรมลดคำผิดที่เกิดจากการรู้จำอักขระ (bank end) และหน้าเว็บ (front end)

### 4.1.6 ทดสอบโปรแกรม

- ทดสอบความสามารถของการปรับปรุงอักขระ
- ตรวจสอบและแก้ไขข้อผิดพลาดของโปรแกรม
- ทดสอบการใช้งานเว็บแอปพลิเคชัน

#### 4.1.7 จัดทำเอกสารประกอบโครงงาน

- จัดทำรายละเอียดของโครงงาน ตั้งแต่ขั้นตอนแรกจนถึงขั้นตอนสุดท้ายของโครงงาน

## 4.2 แผนการดำเนินงาน

ตารางที่ 4.1 แผนการดำเนินงาน

| ขั้นตอนการดำเนินงาน | เดือน | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|
| | ก.ค. 2565 | ส.ค. 2565 | ก.ย. 2565 | ต.ค. 2565 | พ.ย. 2565 | ธ.ค. 2565 | ม.ค. 2566 | ก.พ. 2566 | มี.ค. 2566 | เม.ย. 2566 |
| 1.คิดหัวข้อโครงงานและรวบรวมข้อมูล | | | | | | | | | | |
| 2.กำหนดขอบเขตและวางแผนการดำเนินงาน | | | | | | | | | | |
| 3.ศึกษาความรู้และทฤษฎีที่เกี่ยวข้อง | | | | | | | | | | |
| 4.วิเคราะห์และออกแบบงาน | | | | | | | | | | |
| 5.พัฒนาโปรแกรม | | | | | | | | | | |
| 6.ทดสอบโปรแกรม | | | | | | | | | | |
| 7.จัดทำเอกสารประกอบโครงงาน | | | | | | | | | | |

# บทที่ 5 การวิเคราะห์และออกแบบระบบ

## 5.1 การวิเคราะห์คำผิดจากตัวอย่างข้อมูลนำเข้าที่ได้จากการรู้จำอักขระ

ยกตัวอย่างข้อมูลนำเข้าจากข้อความต้นที่เป็นลายมือเขียนภาษาไทยว่า สวัสดีวันอังคารขอให้พบพานกับสิ่งที่ดี นำไปรู้จำอักขระและดูรูปแบบคำที่ผิด ได้ผลลัพธ์แสดงออกมาดังรูปที่ 5.1 และ 5.2

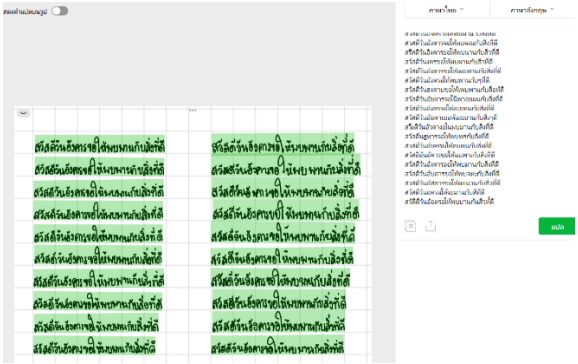

รูปที่ 5.1 ตัวอย่างข้อมูลนำเข้า

สวสดีวันอังคารจอให้ผบจงนกับสิ่งที่ดี
สรีสดีวันอิงคารยอให้พบนานกับสิ่วที่ดี
สวัสดีวันงครขอให้ผบผานกับสิ่วที่ดี
สวัสด์วันอังตารขอให้เผยพานกับสิ่งที่ดี
สวัสดีวันอังครอให้พบพานกับๆที่ดี
สวัสดีวันฮงคาบขอไห้เพบพานกับสิ่อห้ดี
สวัสดีวันอัยตารจอในีพาอยมนกับสิ่งที่ดี
สวัสดีวันอังครจอให้งบยหนกับสิ่งที่ดี
สวัสดีวันอ้อคาะยอห้เมยยานกับสิ่งๆดี
สวีะตีวันอัวคางอในผบมานกับสิ่งที่ดี
สวัสดีนฐทารจอให้พบพรกับสิ่งที่ดี
สวสดีวันอ้ะครขงให้คบพนกับสิ่งที่ดี
สวัสอีอันอ้คารขอให้นบพาเก้บสิ่งที่ดี
สวัสดีวันอังคารออให้พบมานกับสิ่งที่ดี
สวัสดีวันอับคารขอให้พบจทะกับสิ่งที่ดี
สวสดีวันอัสคารขอให้ผยนานกับสิ่วที่ดี
สวัสดีวันอครนให้งยมานกับสิ่ที่ดี
สวัดีดีวันอ้อตรอให้พบบานกันสิ่วห้ดี

รูปที่ 5.2 ผลลัพธ์การรู้จำอักขระ

**สวัสดี** ได้ผลลัพธ์ที่ผิดเป็น สวสดี, สรีสดี, สวัสด์, สะวีะตี, สวสดี ,สวัดีดี

**วัน** ได้ผลลัพธ์ที่ผิดเป็น อัน, นฐ

**อังคาร** ได้ผลลัพธ์ที่ผิดเป็น อิงคาร, งคร, อังตาร, อัยตาร, ฮงคาบ, อังคร, อ้อคาะ, ทาร, อัคาร, อ้ะคร, อัวคาร, อ้อต, อัสคาร, อครน, อับคาร

**ขอ** ได้ผลลัพธ์ที่ผิดเป็น จอ, งอ, ยอ, ขง, รอ

**ให้** ได้ผลลัพธ์ที่ผิดเป็น ไห้, ในี, ห้, ใน

**พบ** ได้ผลลัพธ์ที่ผิดเป็น ผบ, เผย, เพบ, พา, งบ, งย, นบ, คบ, ผย, เมย,

**พาน** ได้ผลลัพธ์ที่ผิดเป็น จงน, นาน, พาน, ยหน, อยมน, มาน, ยาน, จทะ, พาเ,

**กับ** ได้ผลลัพธ์ที่ผิดเป็น กัน

**สิ่ง** ได้ผลลัพธ์ที่ผิดเป็น สิ่ว สิ่อ สิ่

**ที่** ได้ผลลัพธ์ที่ผิดเป็น ทั, ทั้, ๆ,

**ดี** ไม่มีผลลัพธ์ที่ผิด

สรุปประเภทคำผิดที่ได้จากการรู้จำอักขระ

1. คำผิดที่อ่านไม่ได้ตามรูปแบบของพยางค์
2. คำผิดที่ต้องมีการปรับให้ถูกต้อง

จากรูปแบบของการเกิดพยางค์ สามารถวิเคราะห์คำผิดที่เกิดจากการรู้จำอักขระแล้วไม่สามารถอ่านได้ดังนี้

1. ผลลัพธ์การรู้จำอักขระ ปรากฏพยัญชนะไม่สามารถออกเสียงเป็นส่วนท้ายของพยางค์หรือตัวสะกดได้ เช่น **อัอ**
2. มีสระบน ปรากฏขึ้นตามหลังพยัญชนะต้นของพยางค์ที่มีสระหน้าขึ้นต้น และตัวสระหน้านั้นไม่สามารถรวมสระบนนั้นเพื่ออ่านออกเสียงแบบสระหน้า บนและหลังได้ หรือมีสระปรากฏขึ้นมาติดกัน โดยไม่ตรงกับรูปแบบตำแหน่งของสระที่อ่านออกเสียงได้ เกิดขึ้นกับผลการรู้จำอักขระของพยางค์ที่เป็นสามตัวอักษร เช่น **ในิ วีะ**
3. สระบางตัวอยู่ในสถานะเปลี่ยนรูปหรือลดรูปที่ต้องมีส่วนท้ายของพยางค์แต่ผลการรู้จำอักขระที่ออกมานั้นไม่มีส่วนท้ายของพยางค์ เช่น **สวัดีดี**

## 5.2 ภาพรวมของหลักการทำงานของระบบ

หลักการทำงานของระบบปรับปรุงคำผิดที่เกิดจากการรู้จำอักขระมีสองส่วนหลัก ประกอบด้วย 1) ส่วนติดต่อผู้ใช้ ประกอบด้วย ส่วนของหน้าหลัก ที่มีช่องกรอกข้อความ ปุ่มกดส่งข้อความไปแก้ไข กล่องข้อความแสดงผลลัพธ์ ปุ่มคัดลอก และปุ่มรีเซ็ต 2) ส่วนของระบบ โดยจะมีการรับข้อความที่ผู้ใช้กรอกเข้ามา จากนั้นนำไปปรับปรุงโดยเข้าระบบปรับปรุงคำผิด ประกอบด้วยการทำงานสองส่วนได้แก่ ส่วนของการแก้คำที่ไม่สามารถอ่านได้ หลังจากผ่านกระบวนการการแก้คำที่ไม่สามารถอ่านได้ จะทำส่วนแก้คำที่อ่านได้ให้เป็นคำที่ควรจะเป็น หลังจากทำครบทุกกระบวนการจะส่งผลลัพธ์ไปแสดงผลที่ส่วนติดต่อผู้ใช้

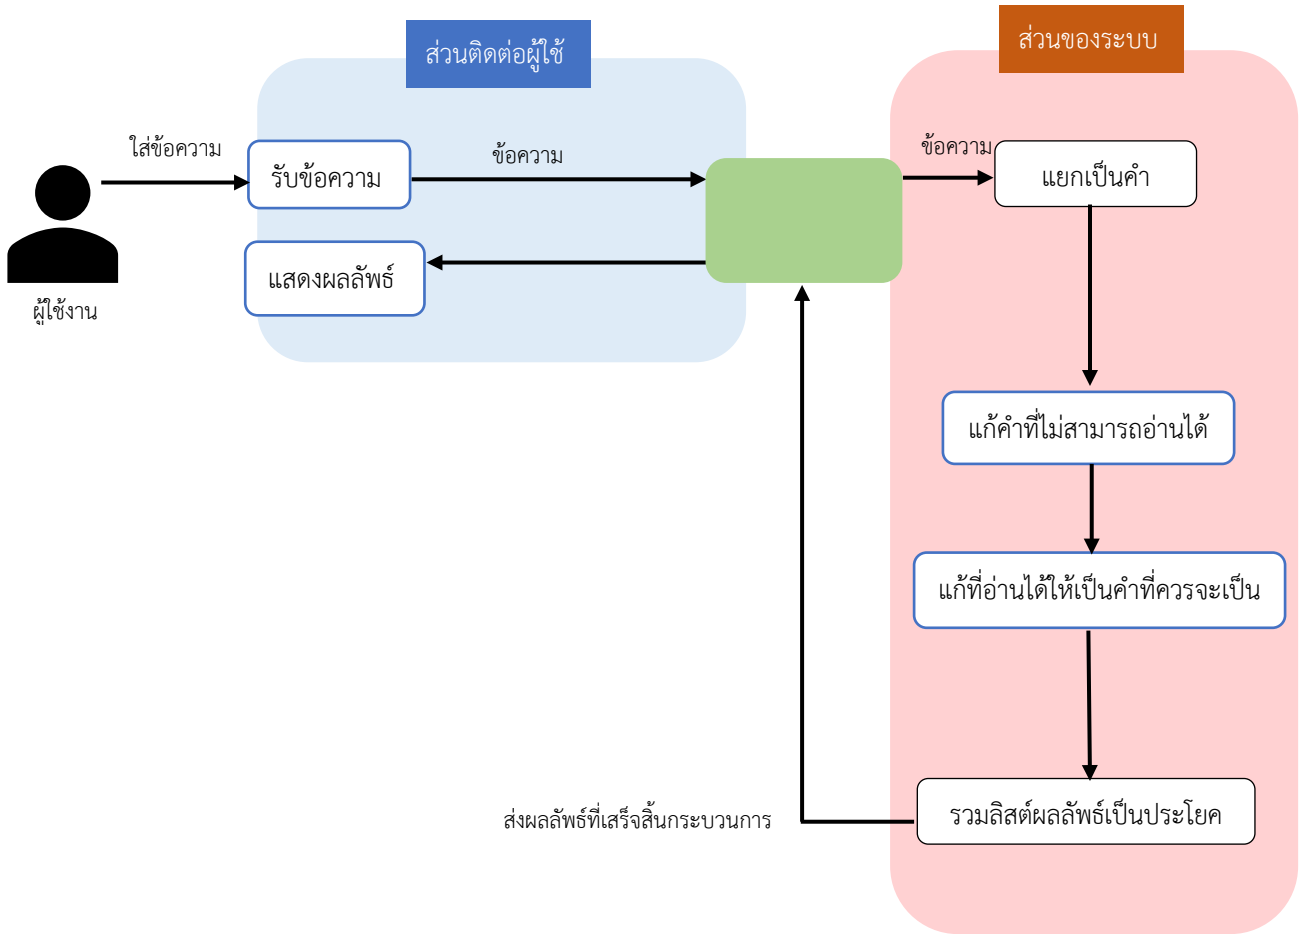


รูปที่ 5.3 แสดงการทำงานโดยรวมของระบบปรับปรุงคำผิด

## 5.3 การทำงานของระบบ

จะแบ่งการทำงานออกเป็น 3 ขั้นตอน

1.จัดการข้อความก่อนนำไปแก้ไข

2.นำลิสต์ข้อความย่อยไปเข้าระบบแก้คำผิด

3.ส่งผลลัพธ์การแก้ไขข้อความที่ผ่านการปรับปรุงกลับไปที่ผู้ใช้

ซึ่งแต่ละขั้นตอนมีรายละเอียดดังนี้

**1. จัดการข้อความก่อนนำไปแก้ไข**

หลังจากรับข้อความที่ได้จากการรู้จำอักขระของผู้ใช้งานที่ส่งผ่าน API มาแล้ว ใช้ word_tokenize เพื่อตัดคำให้อยู่ในรูปแบบของลิสต์ ทำผังงานดังรูปที่ 5.4

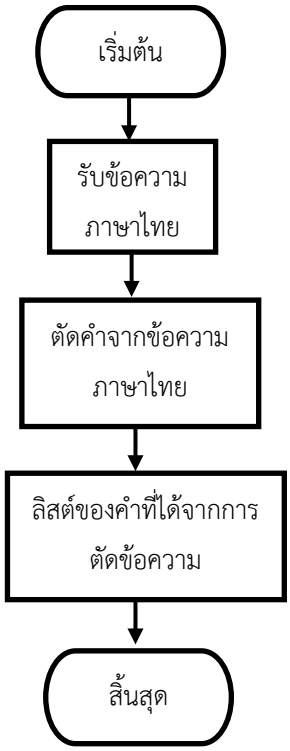


รูปที่ 5.4 จัดการข้อความก่อนแก้ไข

**2. นำลิสต์ของคำไปเข้าระบบแก้คำผิด**

การนำคำไปปรับปรุงโดยเข้าระบบปรับปรุงคำผิดประกอบด้วยการทำงานสองส่วนได้แก่

1. ส่วนของการแก้คำให้สามารถอ่านได้

จะนำลิสต์ของคำมาตรวจสอบว่ามีอยู่ในพจนานุกรมหรือไม่ทีละ 1 คำ หากมีจะรอนำไปทำในกระบวนการถัดไป หากไม่มีแสดงว่าอาจจะมีความผิดปกติจะนำคำมาตัดเป็นพยางค์ และแยกพยางค์ทีละ 1 พยางค์ออกเป็นลิสต์ของตัวอักษร จากนั้นจะนำลิสต์ของตัวอักษรไปหาจำนวนอักขระและเทียบรูปแบบของพยางค์เพื่อแก้ไขส่วนที่ทำให้พยางค์นั้นอ่านไม่ได้ โดยรูปแบบพยางค์ได้มาจากการเทียบการออกเสียงกับการเขียนรูปแบบพยางค์ภาษาไทย ซึ่งได้มารูปแบบหลักจำนวน 16 รูปแบบ ให้ C แทนตำแหน่งของพยัญชนะต้น, c แทนตำแหน่งของอักษรควบหรืออักษรนำ, V แทนตำแหน่งของสระ, Co แทนตำแหน่งของตัวสะกด มาใช้อธิบายรูปแบบหลักของพยางค์ เริ่มจากรูปแบบที่ขึ้นต้นด้วยพยัญชนะมี 4 รูปแบบ คือ CV, CcV, CVCo, CcVCo และรูปแบบขึ้นต้นด้วยสระมี 12 รูปแบบ แบ่งได้ 4 ประเภท ได้แก่ รูปแบบสระหน้าตัวเดียว 4 รูปแบบ คือ VC, VCc, VCCo, VCcCo รูปแบบที่เป็นสระหน้าและหลัง 2 รูปแบบ คือ VCV VCcV รูปแบบที่เป็นสระหน้า บน และหลัง 4 รูปแบบ คือ VCVV, VCVVCo, VCcVV, VCcVVCo สุดท้ายคือ รูปแบบที่เป็นสระหน้าและบน 2 รูปแบบ ได้แก่ VCVCo VCcVCo เมื่อนำรูปแบบ 16 รูปแบบไปเทียบพยางค์ 1 พยางค์จากคำที่พบบ่อย สามารถมีได้ 56 รูปแบบ โดยมีขนาดความยาวตั้งแต่ 2-7 ตัวอักษร และให้ T แทนตำแหน่งของวรรณยุกต์ ดังนี้

ตารางที่ 5.1 รูปแบบที่มี 2 ตัวอักษร 3 รูปแบบ

| ลำดับ | รูปแบบการเขียน | ตัวอย่างพยางค์ | ลำดับการเขียน | ลำดับการอ่าน | รูปแบบการอ่าน |
|---|---|---|---|---|---|
| 1 | CCo | กด | ก-ด | ก-โะ-ด-กด | CVC |
| 2 | CV | กา | ก-า | ก-า-กา | CV |
| 3 | VC | ไป | ไ-ป | ป-ไ-ไป | CV |

ตารางที่ 5.2 รูปแบบที่มี 3 ตัวอักษร 10 รูปแบบ

| ลำดับ | รูปแบบการเขียน | ตัวอย่างพยางค์ | ลำดับการเขียน | ลำดับการอ่าน | รูปแบบการอ่าน |
|---|---|---|---|---|---|
| 1 | CVCo | กัด | ก-ัด | ก-ั-ด-กัด | CVC |
| 2 | CVT | ปู่ | ปู-่ | ป-ู-ปู-่-ปู่ | CV |
| 3 | CTV | ป่า | ป-่า | ป-า-ปา-่-ป่า | CV |
| 4 | CTCo | ป่น | ป-่น | ป-โะ-น-ปน-่-ป่น | CVC |
| 5 | CcV | ปลา | ป-ล-า | ป-ล-า-ปลา | CCV |
| 6 | CcCo | ปลด | ป-ล-ด | ป-ล-โะ-ด-ปลด | CCVC |
| 7 | VCCo | เหว | เ-ห-ว | ห-เ-ว-เหว | CVC |
| 8 | VCc | เปล | เ-ป-ล | ป-ล-เ-เปล | CCV |
| 9 | VCV | เบา | เ-บ-า | บ-เา-เบา | CV |
| 10 | VCT | เป้ | เ-ป-้ | ป-เ-เป-้-เป้ | CV |

ตารางที่ 5.3 รูปแบบที่มี 4 ตัวอักษร 17 รูปแบบ

| ลำดับ | รูปแบบการเขียน | ตัวอย่างพยางค์ | ลำดับการเขียน | ลำดับการอ่าน | รูปแบบการอ่าน |
|---|---|---|---|---|---|
| 1 | CTVCo | บ้าน | บ-้า-น | บ-า-น-บาน---บ้าน | CVC |
| 2 | CVTCo | ปิ่น | ป-ิ-่น | ป-ิ-น-ปิน---ปิ่น | CVC |
| 3 | CCoตัวการันต์ | มนต์ | ม-น-ต- | ม-โะ-น-มน | CVC |
| 4 | CVตัวการันต์ | บาร์ | บ-า-ร- | บ-า-บา | CV |
| 5 | CcTV | คร่า | ค-ร-่-า | ค-ร-า-คร่า---คร่า | CCV |
| 6 | CcVT | หมู่ | ห-มู-่ | ห-ม---หมู---หมู่ | CCV |
| 7 | CcTCo | หล่น | ห-ล-่-น | ห-ล-โะ-น-หลน---หล่น | CCVC |
| 8 | CcVCo | ครีบ | ค-ร-ี-บ | ค-ร-ี-บ-ครีบ | CCVC |
| 9 | CVVC | ล็อก | ล-็-อ-ก | ล-เาะ-ก-ล็อก | CVC |
| 10 | VCตัวการันต์ | เมล์ | เ-ม-ล- | ม-เ-เม | CV |
| 11 | VCcT | ไหล่ | ไ-ห-ล-่ | ห-ล-ไ-ไหล---ไหล่ | CCV |
| 12 | VCcV | เพลา | เ-พ-ล-า | พ-ล-เา-เพลา | CCV |
| 13 | VCVV | เรือ | เ-ร-ื-อ | ร-เื-อ-เรือ | CV |
| 14 | VCVCo | เทอม | เ-ท-อ-ม | ท-เ-อ-ม-เทอม | CVC |
| 15 | VCTV | เป่า | เ-ป-่-า | ป-เา-เปา---เป่า | CV |
| 16 | VCTCo | เม่น | เ-ม-่-น | ม-เ-น-เมน---เม่น | CVC |
| 17 | VCcCo | เพลง | เ-พ-ล-ง | พ-ล-เ-ง-เพลง | CCVC |

ตารางที่ 5.4 รูปแบบที่มี 5 ตัวอักษรจำนวน 17 รูปแบบ

| ลำดับ | รูปแบบการเขียน | ตัวอย่างพยางค์ | ลำดับการเขียน | ลำดับการอ่าน | รูปแบบการอ่าน |
|---|---|---|---|---|---|
| 1 | CVCตัวการันต์ | ราวน์ | ร-า-ว-น์ | ร-า-ว-ราว | CVC |
| 2 | CVตัวการันต์C | การ์ด | ก-า-ร์-ด | ก-า-ด-กาด | CVC |
| 3 | CVTตัวการันต์ | รี่ส์ | ร-ี-่-ส- | ร-ี-รี---รี่ | CV |
| 4 | CTVตัวการันต์ | ล่าร์ | ล-่-า-ร- | ล-า-ลา---ล่า | CV |
| 5 | CcVTCo | กริ่ง | ก-ร-ิ-่-ง | ก-ร-ิ-ง-กริง---กริ่ง | CCVC |
| 6 | CcTVCo | กว้าง | ก-ว-้-า-ง | ก-ว-า-ง-กวาง---กว้าง | CCVC |
| 7 | CcVVCo | บล็อก | บ-ล-็-อ-ก | บ-ล-เ-าะ-ก-บล็ฮก | CCVC |
| 8 | CCoตัวการันต์ | ยนตร์ | ย-น-ต-ร- | ย-โ-ะ-น-ยน | CVC |
| 9 | VCTตัวการันต์ | เล่ห์ | เ-ล-่-ห- | ล-เ-เล---เล่ | CV |
| 10 | VCCoตัวการันต์ | เทนต์ | เ-ท-น-ต- | เ-ท-น-เทน | CVC |
| 11 | VCcตัวการันต์ | เพลย์ | เ-พ-ล-ย- | พ-ล-เ-เพล | CCV |
| 12 | VCcVV | เกลือ | เ-ก-ล-ื-อ | ก-ล-เื-อ-เกลือ | CCV |
| 13 | VCcVCo | แบล็ค | แ-บ-ล-็-ค | บ-ล-แ-ะ-ค-แบล็ค | CCVC |
| 14 | VCcTV | เหล่า | เ-ห-ล-่-า | ห-ล-เ-า-เหลา---เหล่า | CCV |

| | | | | | |
|---|---|---|---|---|---|
| 15 | VCcTCo | เหม่น | เ-ห-ม-่-น | ห-ม-เ-ะ-น-เหม็น-่-เหม่น | CCVC |
| 16 | VCVTV | เชื่อ | เ-ช-ื-่-อ | ช-เ-อ-เชือ-่-เชื่อ | CV |
| 17 | VCVVCo | เรียน | เ-ร-ี-ย-น | ร-เ-ย-น-เรียน | CVC |

ตารางที่ 5.5 รูปแบบที่มี 6 ตัวอักษรจำนวน 7 รูปแบบ

| ลำดับ | รูปแบบการเขียน | ตัวอย่างพยางค์ | ลำดับการเขียน | ลำดับการอ่าน | รูปแบบการอ่าน |
|---|---|---|---|---|---|
| 1 | CcVCoตัวการันต์ | กรานต์ | ก-ร-า-น-ต-์ | ก-ร-า-น-กราน | CCVC |
| 2 | CVCoตัวการันต์<br>(สระอิ/สระอุ-ทัณฑฆาต) | พันธุ์ | พ-ั-น-ธ-ุ-์ | พ-ะ-น-พัน | CVC |
| 3 | CcVการันต์<br>(สระอิ/สระอุ-ทัณฑฆาต) | ปรีดิ์ | ป-ร-ี-ด-ิ-์ | ป-ร-ี-ปรี | CCV |
| 4 | CVCoการันต์<br>(พยัญชนะ-พยัญชนะ-ทัณฑฆาต) | จันทร์ | จ-ั-น-ท-ร-์ | จ-ะ-น-จัน | CVC |
| 5 | VCcCoตัวการันต์ | แบรนด์ | แ-บ-ร-น-ด-์ | บ-ร-แ-น-แบรน | CCVC |
| 6 | VCcVTV | เพรื่อ | เ-พ-ร-ื-่-อ | พ-ร-เ-อ-เพรือ-่-เพรื่อ | CCV |
| 7 | VCcVVCo | เครียด | เ-ค-ร-ี-ย-ด | ค-ร-เ-ย-ด-เครียด | CCVC |

ตารางที่ 5.6 รูปแบบที่มี 7 ตัวอักษรจำนวน 2 รูปแบบ

| ลำดับ | รูปแบบการเขียน | ตัวอย่างพยางค์ | ลำดับการเขียน | ลำดับการอ่าน | รูปแบบการอ่าน |
|---|---|---|---|---|---|
| 1 | VCcVVตัวการันต์ | เคลียร์ | เ-ค-ล-ี-ย-ร-์ | ค-ล-เ-ย-เคลีย | CCV |
| 2 | VCcVTVCo | เคลื่อน | เ-ค-ล-ื-่-อ-น | ค-ร-เ-อ-น-เคลือน-่-เคลื่อน | CCVCT |

จะนำรูปแบบดังกล่าวไปเขียนโปรแกรมและตรวจสอบและแก้ไข โดยสิ่งที่ตรวจสอบอย่างแรก คือ หากขึ้นต้นด้วยสระมีตัวอักษรไม่เกิน 3 ตัวอักษรแล้วมีสระอื่นที่รวมกันแล้วไม่สามารถอ่านออกได้ปรากฏขึ้น จะแก้ไขโดยการไม่เก็บตัวอักขระที่เป็นสระที่เกินมาตัวนั้น จัดเก็บเพียงสิ่งที่เก็บครบตามรูปแบบพยางค์ใส่ในลิสต์เพื่อไปทำในกระบวนการถัดไป การตรวจสอบที่สอง ตรวจสอบที่ตำแหน่งของตัวสะกดว่าอักษรตัวนั้นสามารถทำหน้าที่เป็นตัวสะกดได้หรือไม่ หากไม่ก็จะถูกแก้ไขโดยนำตัวอักษรที่มีรูปคล้ายกันมาแทนที่ สิ่งที่ตรวจสอบและแก้ไขอีกอย่างคือหากสระนั้นอยู่ในรูปของการเปลี่ยนรูปหรือลดรูปแล้วไม่ปรากฏตัวสะกดในผลลัพธ์การรู้จำอักขระจะสุ่มตัวสะกดมาเพิ่มให้รูปแบบพยางค์ครบสมบูรณ์ โดยสรุปการแก้ไขทั้งหมดตามกฎได้ดังนี้

กฎการแก้ไขที่ได้จากหลักการเกิดพยางค์

1. เมื่อเจอสระเกินจากรูปสระที่มีไม่เกิน 3 ตัวอักษรจะไม่เก็บสระตัวนั้นเพื่อรวมกลับเป็นพยางค์
2. ที่ตำแหน่งตัวสะกด ตัวอักขระที่ไม่สามารถเป็นตัวสะกดได้จะดำเนินการดังนี้

    ผ จะเปลี่ยนเป็นตัวอักษรที่มีรูปเหมือนกันคือ พ

    ฝ จะเปลี่ยนเป็นตัวอักษรที่มีรูปเหมือนกันคือ ฟ

    ฉ จะเปลี่ยนเป็นตัวอักษรที่มีรูปเหมือนกันคือ น

    ฌ จะเปลี่ยนเป็นตัวอักษรที่มีรูปเหมือนกันคือ ณ

    ห จะเปลี่ยนเป็นตัวอักษรที่มีรูปเหมือนกันคือ ท

    ฮ จะเปลี่ยนเป็นตัวอักษรที่มีรูปเหมือนกันคือ ส

3. เมื่อตัวอักษรที่ได้จากการแยกพยางค์ไปตรงกับรูปแบบที่เป็นสระที่ต้องมีตัวสะกดแต่ไม่มีตัวสะกดในพยางค์นั้น จะสุ่มตัวสะกดมาใส่

เมื่อตรวจสอบเสร็จแล้วนำอักษรกลับไปรวมให้เป็นพยางค์ จากนั้นนำพยางค์ที่ผ่านการแก้ไปใส่ในลิสต์ที่รอนำไปทำในส่วนการแก้คำที่อ่านได้ให้เป็นคำที่ควรจะเป็น โดยเขียนเป็นซูโดโค้ดได้ดังรูปที่ 5.5

```
Pseudocode Can not read by Thai syllable ref. edited
Input = list of word
Output = list of Syllable
editSyllable = [], resultEdit = [], character=[]
for first word to last word do
 if word not in Thai dictionary then
  subword_tokenize(word)
  for first syllable to last syllable do
   for first character to last character in syllable do
     character collect character
   end for
   If When encountering a vowel that exceeds the syllable pattern have 3 letters then
     Not collect vowel character cannot be in that form and combine back to editSyllable
   if syllable patterns have vowel complete form and need spelling but didn't have spelling then
     random spelling for fix character pattern and combine back to editSyllable
   if syllable patterns have character in Spelling position can't be Spelling then
     if character in Spelling position is ฉ or ฌ or ผ or ฝ or ฮ or ห then
       Replace ฉ to น and combine back to edirSyllable
       Replace ฌ to ณ and combine back to editSyllable
       Replace ผ to พ and combine back to editSyllable
       Replace ฝ to ฟ and combine back to editSyllable
       Replace ฮ to ส and combine back to editSyllable
       Replace ห to ท and combine back to editSyllable
     end if
   if character all is in syllable patterns
     combine back to editSyllable
   end if
   resultEdit collect editSyllable
   clear sumSyllable, editSyllable, character
  end for
 else resultEdit collect word
end for
```

รูปที่ 5.5 ซูโดโค้ดแสดงการทำงานของส่วนของการแก้คำให้สามารถอ่านได้

2. ส่วนแก้คำที่อ่านได้แล้วให้เป็นคำที่ควรจะเป็น

เมื่อได้ลิสต์จากกระบวนการแก้คำที่ไม่สามารถอ่านได้ จะนำพยางค์ในลิสต์ไปรวมกันและใช้ difflib มาหาคำที่มีความเหมือนกัน โดยรวมสูงสุดที่ 7 พยางค์ไปจนถึง 1 พยางค์ อ้างอิงคำที่นำมาหาความเหมือนกันมาจากพจนานุกรมที่ได้มาจากคลังคำที่มีใน pythainlp ซึ่งตั้งเงื่อนไขให้ difflib คืนค่าคำที่ใช้ปรับปรุงก็ต่อเมื่อ หากรวม 1 พยางค์แล้วมีผลลัพธ์ต้องมีความเหมือนกัน 66% รวม 2-3 พยางค์แล้วมีผลลัพธ์ต้องมีความเหมือนกัน 80% รวม 4-7 พยางค์แล้วมีผลลัพธ์ต้องมีความเหมือนกัน 90% เมื่อเสร็จสิ้นกระบวนการแล้วจะรวมผลลัพธ์ทั้งหมดในลิสต์ให้เป็นประโยค เขียนเป็นซูโดโค้ดได้ดังรูปที่ 5.6

```
1.  Pseudocode Adjust the words that should be
2.  Input list result from Can not read by Thai syllable ref. edited process
3.  Output String sentence
4.  position = 0, allword= length of Syllable list, allofword = length of Syllable list, newword = [],
5.  sentence = ‘’, n = number between 1 to 6
6.  while allofword > 0 do
7.      if number of syllable >= 7 then
8.        if difflib return value from highest summary of word from 7 to 1 then
9.          Update position of Syllable , newword add value , allofword decrease
10.       If position >= allword-1 then
11.         break
12.       end if
13.     end if
14.     If number of syllable == n then
15.       If difflib return value from summary n words to 1 word then
16.         Update position of Syllable , newword add value, allofword decrease
17.       If position >= allword-1 then
18.         break
19.       end if
20.     end if
21. for i = 0 to length(newword) do
22.   sentence = newword[0] +...+ newword[last]
23. end loop
24. return sentence
```

รูปที่ 5.6 ซูโดโค้ดแสดงการทำงานของส่วนที่แก้คำที่อ่านได้ให้เป็นคำที่ควรจะเป็น

**3.ส่งผลลัพธ์การแก้ไขข้อความที่ผ่านการปรับปรุงกลับไปที่ผู้ใช้**

หลังจากแก้ไขข้อความแล้วจะข้อความที่ผ่านการแก้ไขผ่าน API ไปขึ้นบนหน้าแอปพลิเคชัน

## 5.4 ส่วนติดต่อผู้ใช้

หน้าเว็บแอปพลิเคชันประกอบไปด้วย ช่องกรอกข้อความ ให้ผู้ใช้งานกรอกข้อความลงไป เมื่อกรอกข้อความแล้วกดปุ่มแก้ไขข้อความ จะส่งข้อความผ่าน API ไปแก้ไข และจะรับผลลัพธ์ไปใส่ในช่องแสดงผลลัพธ์ ซึ่งมีปุ่มคัดลอกข้อความ ใช้ในการคัดลอกข้อความในกล่องข้อความแสดงผลลัพธ์ ปุ่มรีเซ็ตใช้กดรีเซ็ตค่าในช่องกล่องข้อความทุกช่อง

# บทที่ 6 ผลการดำเนินงาน ข้อจำกัด และข้อเสนอแนะ

## 6.1 ผลการดำเนินงาน

### 6.1.1 การประเมินคุณภาพของข้อความที่ได้รับการแก้ไข

การประเมินคุณภาพของข้อความที่ผ่านการแก้ไขแสดงผลโดยใช้อัลกอริทึม BLEU Score[7] ประเมินผลและใส่ค่าลงในตาราง โดย BLEU Score เป็นอัลกอริทึมที่ใช้ประเมินคุณภาพของข้อความโดยนำข้อความที่แปลด้วยเครื่องมาเปรียบเทียบกับข้อความที่แปลอ้างอิงโดยมนุษย์ว่ามีความตรงกันมากแค่ไหน โดยมีช่วงคะแนนตั้งแต่ 0 ถึง 1 ถ้าได้ BLEU คะแนนเท่ากับ 1 หมายความว่าข้อความที่มีการเปรียบเทียบกันมีความเหมือนกันทั้งข้อความ การเปรียบเทียบนั้นใช้การจับคู่ของ N-gram มี 4 แบบ ได้แก่ unigram คือ การเทียบคำต่อคำ, bigram คือ การเทียบทีละสองคำ, 3-gram คือ การเทียบทีละสามคำ, 4-gram คือ การเทียบทีละสี่คำ ซึ่งโครงงานนี้ใช้การคำนวณแบบ unigram

การคำนวณ BLEU score แบบ unigram มีการคำนวณดังนี้

$p_n$ คือ การคำนวณ N-Gram เป็นการวัดแบบ Precision โดยนับจากจำนวน n-gram ที่เลือกเทียบกัน (unigram, bigram, 3-gram, 4-gram) ที่เกิดขึ้นหารด้วยจำนวนคำทั้งหมด เรียกว่า modified n-gram precision ซึ่งมีสูตรการคำนวณที่แปลงมาจาก Precision ดังสมการที่ 1

$$p_n = \frac{\sum_{C\in\{Candidate\}}\sum_{n-gram\in C} Count_{clip}(n-gram)}{\sum_{C\in\{Candidate\}}\sum_{n-gram'\in C} Count(n-gram')} \qquad (1)$$

การคำนวณค่า p เมื่อคำนวณ Bleu Score แบบ unigram ได้ดังสมการที่ 2

$$p_1 = \frac{\sum_{C\in\{Candidate\}}\sum_{unigram\in C} Count_{clip}(unigram)}{\sum_{C\in\{Candidate\}}\sum_{unigram'\in C} Count(unigram')} \qquad (2)$$

$Count_{clip}(unigram)$ คือ จำนวนคำที่มีเหมือนกันน้อยที่สุดเมื่อดูจากการเทียบคำต่อคำของข้อความ Reference กับข้อความ Candidate

$Count(unigram')$ คือ จำนวนคำทั้งหมดของข้อความ Candidate

**Brevity Penalty(BP)** คือ การคำนวณบทลงโทษเมื่อจำนวนคำของตัวข้อความ Candidate น้อยกว่าจำนวนคำของตัวข้อความ Reference ที่มีจำนวนคำใกล้เคียงกันที่สุด โดยมีการคำนวณตามดังสมการที่ 3

$$BP = \begin{cases} 1 & \text{เมื่อ } c > r \\ e^{(1-\frac{r}{c})} & \text{เมื่อ } c \le r \end{cases} \qquad (3)$$

โดย c คือ จำนวนคำของ Candidate

r คือ จำนวนคำของ Reference

สมการคำนวณ BLEU score ดังสมการที่ 4

$$BLEU = BP \cdot \exp(\sum_{n=1}^{N} w_n \, log \, p_n) \quad (4)$$

โดย $w_n$ คือ น้ำหนักของ n-gram โดยแบบunigram เทียบแล้วตรงกันได้$w_1$คำละ 1, แบบbigram เทียบแล้วตรงกันได้$w_2$ คำละ 0.5, แบบ3-gram เทียบแล้วตรงกันได้$w_3$คำละ 0.33, แบบ4-gram เทียบแล้วตรงกันได้$w_4$คำละ 0.25 แทนค่าการคำนวณ Bleu Score แบบ unigram ได้ดังสมการที่ 5

$$BLEU = BP \cdot \exp(\sum_{n=1}^{N} w_1 \, log \, p_1) \quad (5)$$

**6.1.2 ผลคะแนนของข้อความตัวอย่างที่ได้รับการแก้ไขแล้วกับข้อความต้นโดยใช้ BLEU Score**

จากข้อความต้นที่เขียนว่า สวัสดีวันอังคารขอให้พบพานกับสิ่งที่ดี ได้ผลลัพธ์เมื่อรู้จำอักขระแล้วได้ผลออกมาเป็น สวัสอีอันอัวคาะขอให้พบนานกับสิ่วที่ดี นำไปตัดคำและวัดผลโดยใช้ BLEU Score แบบ unigram ได้ผล BLEU Score เป็นดังตารางที่ 6.1

ตารางที่ 6.1 ผลคะแนน BLEU ของข้อความที่ได้จากการรู้จำอักขระและข้อความต้น

| ข้อความ | BLEU Score |
|---|---|
| สวัสดีวันอังคารขอให้พบพานกับสิ่งที่ดี | 1.0 |
| สวัสอีอันอัวคาะขอให้พบนานกับสิ่วที่ดี | 0.21 |

จากผลการรู้จำอักขระข้างต้น เริ่มแก้ไขโดยวิธีแรก คือ การแก้ไขคำให้สามารถอ่านได้ เขียนโปรแกรมโดยอ้างอิงมาจากวิธีการออกเสียงพยางค์ภาษาไทยมาแก้ไขข้อความ เมื่อใช้ BLEU Score คำนวณคะแนน ได้ผลตามตารางที่ 6.2

ตารางที่ 6.2 ผลคะแนน BLEU ของข้อความที่ได้จากการรู้จำอักขระ ข้อความต้นและข้อความที่ผ่านวิธีการแก้ไขคำให้สามารถอ่านได้

| ข้อความ/วิธี | BLEU Score |
|---|---|
| สวัสดีวันอังคารขอให้พบพานกับสิ่งที่ดี | 1.0 |
| สวัสอีอันอัวคาะขอให้พบนานกับสิ่วที่ดี | 0.21 |
| สวัสอีอันอัวคาขอให้พบนานกับสิ่วที่ดี | 0.21 |

เมื่อแก้ไขโดยวิธีแรกพบว่าคะแนน BLEU ได้เท่าเดิม คือ 0.21 เนื่องจากการแก้ไขคำให้สามารถอ่านได้นั้น ใช้วิธีที่อ้างอิงมาจากการออกเสียงพยางค์ภาษาไทย สิ่งที่แก้ออกมาได้นั้นกลายเป็นผลลัพธ์ที่คล้ายเดิมแค่ปรับปรุงพยางค์ให้สามารถอ่านออกเสียงได้แล้วเท่านั้น ตัวข้อความที่แก้ได้ไม่ได้เปลี่ยนแปลงไปจากข้อความที่ได้จากการรู้จำอักขระมากนัก

จากการแก้ไขด้วยวิธีแรก นำมาสู่วิธีการที่สอง คือ การแก้คำที่อ่านได้ให้เป็นคำที่ควรจะเป็นโดยใช้ไลบรารี difflib ในการเลือกคำที่คล้ายกันจากพจนานุกรมกับคำที่ปรับปรุงให้อ่านได้ เมื่อใช้ BLEU score คำนวณคะแนนได้ผลดังตารางที่ 6.3

ตารางที่ 6.3 ผลคะแนน BLEU ของข้อความที่ได้จากการรู้จำอักขระ ข้อความต้น ข้อความที่ผ่านวิธีการแก้ไขคำให้สามารถอ่านได้ และข้อความที่ผ่านวิธีการแก้ไขคำที่อ่านได้ให้เป็นคำที่ควรจะเป็น

| ข้อความ/วิธี | BLEU Score |
|---|---|
| สวัสดีวันอังคารขอให้พบพานกับสิ่งที่ดี | 1.0 |
| สวัสอีอันอัวคาะขอให้พบนานกับสิ่วที่ดี | 0.21 |
| สวัสอีอันอัวคาขอให้พบนานกับสิ่วที่ดี | 0.21 |
| สวัสดีอันอั่วขอให้พบพานกับสิ่งที่ดี | 0.66 |

เมื่อแก้ไขด้วยวิธีการที่ 2 พบว่าคะแนนความเหมือนกันกับข้อความต้นที่ได้เพิ่มขึ้นมาจาก 0.21 เป็น 0.66 คะแนน หมายความว่ามีความเหมือนกันกับประโยคต้น 66% ที่แก้ไขออกมาได้ไม่ดีนัก เนื่องจากผลลัพธ์ที่ได้จากการรู้จำอักขระที่ได้มีบางคำที่ไม่เหมือนเค้าโครงเดิมของข้อความต้นเอาไว้ ทำให้การแก้ไขคำให้เป็นคำที่ควรจะเป็นนั้นจะได้ผลออกมาไม่ดีตามไปด้วย

### 6.1.3 การแก้ไขคำที่ผู้ใช้อาจเขียนผิดก่อนนำมารู้จำอักขระ

จากคำ 10 คำที่ผู้ใช้มักจะเขียนผิดนำไปแก้ไขได้ผลลัพธ์ที่เขียนถูกต้อง 9 คำจากทั้งหมด 10 คำ ดังตารางที่ 6.4

| ข้อความที่รับมา | ข้อความที่ถูก | ผลลัพธ์ที่ได้ |
|---|---|---|
| กระทันหัน | กะทันหัน | กะทันหัน |
| อินเตอร์เน็ต | อินเทอร์เน็ต | อินเทอร์เน็ต |
| ไอศครีม | ไอศกรีม | ไอศกรีม |
| รำคาน | รำคาญ | รำคาญ |
| จั๊กจั่น | จักจั่น | จักจั่น |
| สังเกตุ | สังเกต | สังเกต |
| คุ๊กกี้ | คุกกี้ | คุกกี้ |
| คำนวน | คำนวณ | สำนวน |
| นะค่ะ | นะคะ | นะคะ |
| อนุญาติ | อนุญาต | อนุญาต |

## 6.2 ข้อจำกัด

1) ผลลัพธ์ที่ได้ขึ้นอยู่กับผลการรู้จำอักขระที่นำมาแก้ไขนั้นมีการคงรูปแบบเดิมของข้อความต้นเหลือไว้แค่ไหน หากผิดไปจากเดิมมาก จะแก้ไขได้ไม่ดีนัก
2) สามารถปรับคำได้อย่างจำกัด เพราะการปรับคำนั้นอ้างอิงคำที่มีอยู่ในพจนานุกรมที่ใช้เท่านั้น
3) การแก้ไขคำมักเขียนผิดอาจจะทำได้ไม่มาก เนื่องจากพจนานุกรมที่นำมาใช้เอามาจากไลบรารีของ PythaiNLP มีคำมักเขียนผิดปะปนอยู่ จึงค้นหาคำมักเขียนผิดและลบคำนั้นออกไป แต่อาจจะยังลบได้ไม่หมด
4) เนื่องจากโค้ดที่เขียนอ้างอิงมาจาก 56 รูปแบบของพยางค์ที่พบบ่อยดังนั้น อาจจะมีพยางค์บางรูปแบบที่ไม่ค่อยพบเห็นได้บ่อยจึงไม่สามารถแก้ไขหรือจัดเก็บพยางค์ไปทำในส่วนแก้ไขคำที่อ่านได้ให้เป็นคำที่ควรจะเป็นได้

## 6.3 ข้อเสนอแนะ

1) หากมีพจนานุกรมที่ดีกว่านี้ จะช่วยให้ส่วนการปรับคำที่ควรจะเป็นทำงานได้ดีขึ้น

2) ภาษาไทยมีการเปลี่ยนแปลงเกิดขึ้นมาได้เสมอเช่นมีการแก้ไขวิธีการเขียนคำ การเกิดวลีใหม่ คำใหม่ ดังนั้นการปรับปรุงพจนานุกรมให้เท่าทันกับสิ่งที่เปลี่ยนแปลงจึงเป็นสิ่งที่จำเป็น

# บรรณานุกรม


[1] ทีมงานทรูปลูกปัญญา. (2021). *รูปสระ*. สืบค้น 25 มกราคม 2566, จาก https://www.trueplookpanya.com/learning/detail/539

[2] วิโรจน์ อรุณมานะกุล. (2007). *อักขรวิธีไทยและการถอดตัวอักษรระหว่างภาษาไทยและภาษาอังกฤษ.* กรุงเทพมหานคร: โครงการเผยแพร่งานวิชาการ คณะอักษรศาสตร์ จุฬาลงกรณ์มหาวิทยาลัย ลำดับที่ 122.

[3] Aigen. (2021). *เทคโนโลยี OCR คืออะไร และมีขั้นตอนการทำงานอย่างไร?.* สืบค้น 27 สิงหาคม 2565, จาก https://aigencorp.com/what-is-ocr/

[4] Ditto document intelligence. (2021). *สร้างการแปลงไฟล์ให้เกิดประสิทธิภาพด้วย OCR.* สืบค้น 19 กรกฎาคม 2565, จาก https://www.dittothailand.com/dittonews/ocr/

[5] Google Cloud Vision API. (2022). *Detect text in images.* สืบค้น 29 สิงหาคม 2565, จาก https://cloud.google.com/vision/docs/ocr

[6] I3uch. (2021). *Katproof เว็บไซต์ตรวจคำผิดภาษาไทยฝีมือคนไทย.* สืบค้น 3 กันยายน 2565, https://review.thaiware.com/2133.html

[7] Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. (2002). *Bleu: a Method for Automatic Evaluation of Machine Translation*. In *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, (หน้า 311–318). doi:10.3115/1073083.1073135

[8] Krupiyarerk. (2015). *องค์ประกอบของพยางค์และคำ.* สืบค้น 14 กันยายน 2565, จาก https://krupiyarerk.wordpress.com/tag/โครงสร้างของคำ/

[9] LINE Corporation. (2018). *CLOVA OCR.* สืบค้น 29 สิงหาคม 2565, จาก https://lineapiusecase.com/en/api/clovaocr.html

[10] Moonlighttkz. (2018). *วิธีใช้ Google OCR แปลงไฟล์ภาพเอกสาร PDF หรือภาพ JPEG ให้เป็นไฟล์ข้อความแบบฟรีๆ.* สืบค้น 29 สิงหาคม 2565. จาก https://tips.thaiware.com/1005.html

[11] Python. (2022). *Difflib-Helpers for computing deltas.* สืบค้น 7 กันยายน 2565, จาก https://docs.python.org/3/library/difflib.html

[12] STEP academy. (2021). *Natural Language Processing: การสื่อสารระหว่างภาษามนุษย์และ AI ที่มีผลต่อ Digital Marketing*. สืบค้น 7 กันยายน 2565, จาก https://stepstraining.co/foundation/natural-language-processing

[13] Surapong Kanoktipsatharporn. (2020). *PythaiNLP คืออะไร Tutorial สอนใช้งาน PythaiNLP Library NLP ภาษาไทย สำหรับ Python เบื้องต้น-PyThaiNLP-ep.1* สืบค้น 14 กันยายน 2565, จาก https://www.bualabs.com/archives/3234/what-is-pythainlp-tutorial-teach-basic-how-to-use-pythainlp-library-nlp-in-python-pythainlp-ep-1/

# ภาคผนวก ก การทำงานของ API

ในการเชื่อมต่อส่วนของโค้ดการแก้คำผิดกับหน้าเว็บแอปพลิเคชันให้ติดต่อส่งข้อความหากันได้ ต้องใช้การทำงานของ API โดยแบ่งการทำงานเป็นสองส่วน คือ ส่วนนำเข้าข้อมูล และส่วนการส่งออกข้อมูล เริ่มจากที่ผู้ใช้กรอกข้อความเข้ามาผ่านทางหน้าเว็บแอปพลิเคชัน ผ่าน @app.route("/text") ด้วย POST methods จากนั้นสร้างฟังก์ชัน text() เพื่อรับข้อความมาเก็บไว้ เรียกฟังก์ชันที่มาแก้ไขคำผิดและส่งค่ากลับไปที่หน้าเว็บแอปพลิเคชัน ดังรูปผนวกที่ ก.1

```
api.py > ...
1   from ocrthaitextedited import rtext
2   from flask import Flask,jsonify,make_response,request
3   from flask_cors import CORS
4   app = Flask(__name__)
5   CORS(app)
6   @app.route("/text",methods = ["POST"])
7   def text():
8       data = request.get_json()
9       res = rtext(data["text"])
10      return make_response(jsonify({"text":res}))
11  if __name__ == "__main__":
12      app.run(port = 8080,debug = True)
13
```

รูปผนวกที่ ก.1 การทำงานของ API

# ภาคผนวก ข การทำงานของหน้าเว็บแอปพลิเคชัน

หน้าเว็บแอปพลิเคชัน ประกอบด้วยช่องกรอกข้อความ 2 ช่องโดยช่องแรกไว้ใส่ข้อความที่ได้จากการรู้จำอักขระ ช่องที่สองมีไว้แสดงผลลัพธ์จากการรู้จำอักขระ โดยมีปุ่มแก้ไขใช้สำหรับกดส่งข้อความจากช่องแรกไปแก้ไข และมีปุ่มกดคัดลอกใช้สำหรับคัดลอกข้อความผลลัพธ์ที่ได้จากการแก้ไขข้อความ และปุ่มรีเซ็ตไว้เคลียร์ข้อความในช่องข้อความทั้งสอง

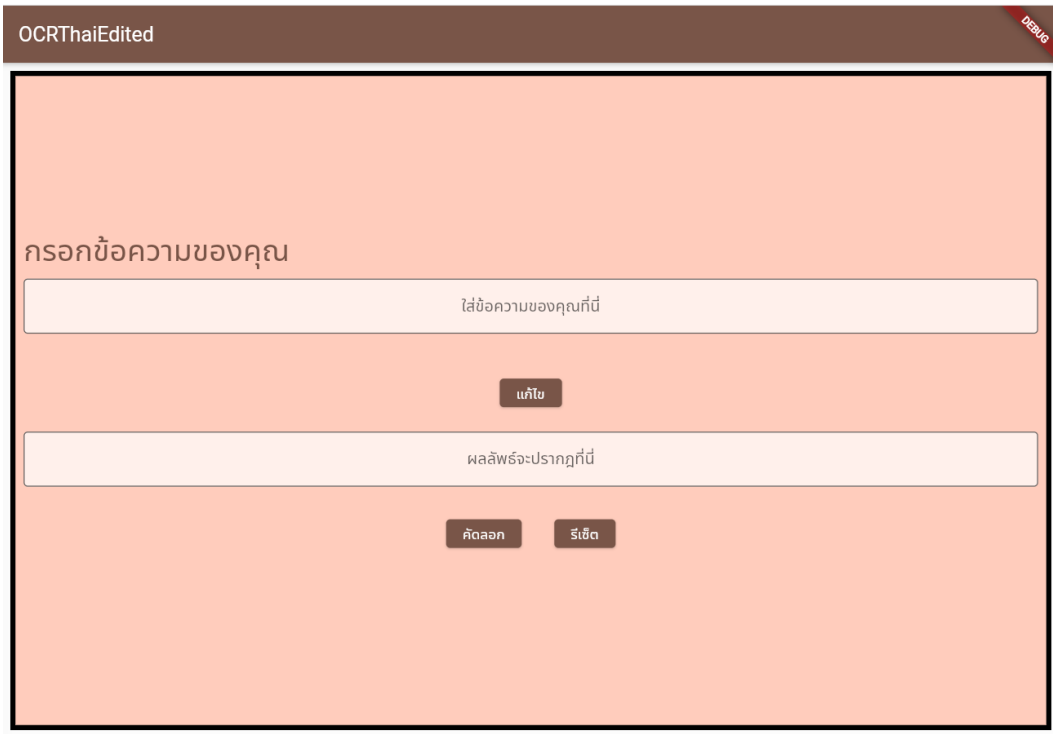


รูปผนวกที่ ข.1 รูปแสดงหน้าแอปส่วนติดต่อผู้ใช้

โดยข้อความที่จะกรอกส่งได้เฉพาะข้อความภาษาไทยเท่านั้นถึงจะแสดงผลลัพธ์กลับมา การทำงานเป็นดังรูปผนวกที่ ข.2 และรูปผนวกที่ ข.3

รูปผนวกที่ ข.2 รูปแสดงการกรอกข้อความ

รูปผนวกที่ ข.3 รูปแสดงผลลัพธ์เมื่อกดปุ่มแก้ไข