ใบอนุมัติโครงงานปริญญานิพนธ์
สาขาวิชาวิทยาการคอมพิวเตอร์ ภาควิชาคอมพิวเตอร์
คณะวิทยาศาสตร์ มหาวิทยาลัยศิลปากร

ชื่อปริญญานิพนธ์ แอปตรวจจับข่าวปลอมของไทย
App Thai Fake News Detection

ผู้จัดทำ นาย สุริยะ คำสีทา

ปีการศึกษา 2566

โครงงานปริญญานิพนธ์นี้ได้รับการอนุมัติให้เป็นส่วนหนึ่งของการศึกษาตาม
หลักสูตรวิทยาศาสตร์บัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์
ภาควิชาคอมพิวเตอร์ คณะวิทยาศาสตร์ มหาวิทยาลัยศิลปากร

..... ประธานกรรมการสอบ
(ผู้ช่วยศาสตราจารย์ ดร.สุนีย์ พงษ์พินิจภิญโญ)

..... กรรมการสอบ
(ผู้ช่วยศาสตราจารย์ ดร.ทัศนวรรณ ศูนย์กลาง)

..... อาจารย์ที่ปรึกษาและกรรมการสอบ
(ผู้ช่วยศาสตราจารย์ ดร.วีณาวดี ม่วงอ้น)

แอปตรวจจับข่าวปลอมของไทย

App Thai Fake News Detection

สุริยะ คำสีทา

ปริญญานิพนธ์นี้เป็นส่วนหนึ่งของการศึกษาในหลักสูตรวิทยาศาสตร์บัณฑิต
สาขาวิชาวิทยาการคอมพิวเตอร์ ภาควิชาคอมพิวเตอร์
คณะวิทยาศาสตร์ มหาวิทยาลัยศิลปากร
ปีการศึกษา 2566

ชื่อปริญญานิพนธ์ แอปตรวจจับข่าวปลอมของไทย

App Thai Fake News Detection

ผู้จัดทำ นาย สุริยะ คำสีทา

อาจารย์ที่ปรึกษา ผู้ช่วยศาสตราจารย์ ดร.วีณาวดี ม่วงอ้น

ชื่อปริญญา วิทยาศาสตร์บัณฑิต (วิทยาการคอมพิวเตอร์)

ปีการศึกษา 2566

บทคัดย่อ

บทความนี้เน้นถึงความสำคัญของปัญหาข่าวปลอมหรือเฟคนิวส์ในสังคมออนไลน์ และวัตถุประสงค์ของการวิจัยเพื่อพัฒนาเว็บแอปพลิเคชันที่สามารถแยกแยะข่าวจริงและข่าวปลอมโดยใช้เทคโนโลยีการเรียนรู้ของเครื่อง (Machine Learning) และการประมวลผลภาษาธรรมชาติ (NLP) เพื่อวิเคราะห์และจำแนกข้อมูลข่าวโดยการเน้นการใช้เทคนิค Supervised Learning หรือ การเรียนรู้แบบมีผู้สอนนั้นเป็นการทำให้คอมพิวเตอร์สามารถหาคำตอบของปัญหาได้ด้วยตัวเองหลังจากเรียนรู้จากชุดข้อมูลตัวอย่างไปแล้วระยะหนึ่งในกระบวนการนี้เราจะใช้ชุดข้อมูลที่มีการเรียนรู้มาก่อน (training data) ที่ประกอบไปด้วยคู่ข้อมูล input และ output ซึ่งเราจะนำมาสร้างโมเดลของโปรแกรมขึ้นมาเองโดยโมเดลนี้จะเรียนรู้จากข้อมูลในชุดข้อมูลตัวอย่างเหล่านั้นและใช้ในการทำนายหรือจำแนกประเภทของข้อมูลใหม่ที่ไม่เคยเห็นมาก่อน

การใช้ Supervised Learning ช่วยให้เราสร้างโมเดลที่มีความแม่นยำมากขึ้น เนื่องจากมีการให้โมเดลเรียนรู้จากชุดข้อมูลตัวอย่างที่มีความหลากหลายและจำนวนมาก เช่น การตรวจจับข่าวปลอมการใช้ Supervised Learning ช่วยให้โมเดลเรียนรู้จากข้อมูลข่าวจริงและข่าวปลอมที่มีอยู่แล้วเพื่อให้โมเดลสามารถจำแนกประเภทข่าวได้อย่างถูกต้องซึ่งโมเดลที่นำมาใช้จะมีทั้งหมด 4 โมเดลและมีผลลัพธ์หลังการเทรนดังนี้ 1.LSTM (Long Short-Term Memory) = 99% 2.SVM (Support Vector Machine) = 99% 3.KNN (K-Nearest Neighbors) = 97% 4.GBC (Gradient Boosting Classifier) = 99% โดยค่าเหล่านี้ค่าความถูกต้องของการจำแนกประเภทข่าวที่สามารถใช้งานในการตรวจจับข่าวปลอมหรือข่าวจริง

นอกจากนี้เรายังสามารถใช้เทคนิค Information Retrieval (IR) เพื่อค้นหาข้อมูลเพิ่มเติมที่เกี่ยวข้องกับข่าวที่ผู้ใช้ต้องการและให้ผู้ใช้มีข้อมูลเพิ่มเติมในการตัดสินใจซึ่งเป็นการเสริมสร้างประสิทธิภาพของแอปพลิเคชันในการให้บริการแก่ผู้ใช้และช่วยให้ผู้ใช้ทราบถึงข้อมูลที่มีประโยชน์ในการตัดสินใจของตนเองได้มากยิ่งขึ้นดังนั้นผลลัพธ์ที่ได้จะถูกนำมาแสดงผลในรูปแบบของเว็บแอปพลิเคชัน เพื่อการใช้งานที่สะดวกและเข้าถึงข้อมูลได้ง่ายขึ้นสำหรับผู้ใช้งาน

คำสำคัญ : เฟคนิวส์, ข่าวปลอม, การประมวลผลภาษาธรรมชาติ, โมเดลการเรียนรู้ของเครื่อง, การตรวจจับข่าวปลอม,สังคมออนไลน์

Keyword : fake news, natural language processing, machine learning model, supervised learning, information retrieval, social media, model

กิตติกรรมประกาศ

การวิจัยเรื่องแอปตรวจจับข่าวปลอมของไทยเพื่อการตรวจสอบข่าวสามารถดำเนินการจนประสบความสำเร็จลุล่วงไปด้วยดี เนื่องจาก ได้รับความอนุเคราะห์และสนับสนุนเป็นอย่างดียิ่งจาก ผู้ช่วยศาสตราจารย์ ดร.วีณาวดี ม่วงอ้น ที่ได้กรุณาให้คำปรึกษา ความรู้ ข้อคิด ข้อแนะนำ และปรับปรุงแก้ไขข้อบกพร่องต่าง ๆ จนกระทั่งการวิจัยครั้งนี้สำเร็จเรียบร้อยด้วยดี

ผู้ศึกษาขอกราบขอบพระคุณเป็นอย่างสูงไว้ ณ โอกาสนี้ขอขอบพระคุณ ขอขอบคุณเพื่อนและพี่น้องที่เป็นผู้ช่วยในแนะนำการเก็บข้อมูลและรวบรวมข้อมูลในการศึกษาเป็นอย่างดีคุณค่าและประโยชน์ของการศึกษาครั้งนี้ผู้วิจัยขอกราบขอบพระคุณเป็นอย่างสูงไว้ ณ ที่นี้ ด้วย

สุริยะ คำสีทา

สารบัญ

หน้า

บทคัดย่อ ..... ก

กิตติกรรมประกาศ ..... ข

สารบัญ ..... ค

สารบัญรูป ..... จ

สารบัญตาราง ..... ฉ

บทที่ 1 บทนำ 1

1.1 ที่มาและความสำคัญของปัญหา 1

1.2 วัตถุประสงค์ 1

1.3 ลักษณะและขอบเขต 1

1.4 อุปกรณ์และเครื่องมือที่ใช้ 2

1.4.1 ฮาร์ดแวร์ 2

1.4.2 ซอฟต์แวร์ 2

1.5 ผลที่คาดว่าจะได้รับ 2

บทที่ 2 ผลงานที่เกี่ยวข้อง 3

2.1 Thai Fake News Detection Based on Information Retrieval, Natural Language Processing and Machine Learning 3

2.2 Google Fact check tools 4

2.3 The Fight Against Fake News with Deep Learning 5

2.4 เปรียบเทียบความแตกต่าง 6

บทที่ 3 ทฤษฎีและความรู้ที่เกี่ยวข้อง 7

3.1 web crawler 7

3.2 Natural Language Processing 7

3.3 Machine Learning 8

3.4 Information Retrieval 9

บทที่ 4 ขั้นตอนและแผนการดำเนินงาน 11

4.1 ขั้นตอนการดำเนินงาน 11

4.1.1 รวบรวมข้อมูลและกำหนดขอบเขตของโครงงาน 11

4.1.2 ศึกษาทฤษฎีและความรู้ที่เกี่ยวข้อง 11

4.1.3 การออกแบบระบบและพัฒนาโปรแกรม 11

4.1.4 ทดสอบและปรับปรุง 11

4.1.5 จัดทำเอกสารประกอบโครงงาน 11

4.2 แผนการดำเนินงาน 12

บทที่ 5 วิธีการดำเนินงาน 13

5.1 โครงสร้างของระบบ 13
5.2 ผลการทดสอบ 16
บทที่ 6 ผลการดำเนินงาน ข้อจำกัด และข้อเสนอแนะ 22
6.1 ผลการดำเนินงาน 22
6.2 ข้อจำกัด 22
6.3 ข้อเสนอแนะ 23
บรรณานุกรม 24
ภาคผนวก ก 26
ก.1 หน้าแรกของแอปพลิเคชัน 26
ก.1.1 ส่วนการใส่เนื้อหาข่าว 26
ก.1.2 ผลการทำนาย 27
ก.2 หน้าที่สองของแอปพลิเคชัน 27
ก.2.1 ส่วนการค้นหาข่าว 27
ก.2.2 ตัวอย่างข่าวเพิ่มเติม 28
ก.2.3 ตัวอย่างของเว็บไซต์ 29

สารบัญรูป

หน้า

รูปที่ 2.1 ตัวอย่างเว็บแอปพลิเคชัน 3
รูปที่ 2.2 ตัวอย่างเว็บแอปพลิเคชัน 4
รูปที่ 2.3 ตัวอย่างเว็บแอปพลิเคชัน 5
รูปที่ 5.1โครงสร้างของระบบ 13
รูปที่ 5.2 ตัวอย่างข้อมูล 14
รูปที่ 5.3ตารางเปรียบเทียบค่า accuracy ของการเทรนด้วย title&body และ title และ ENG title 16
รูปที่ 5.4 ตารางเปรียบเทียบค่า accuracy ของการเทรนด้วย eng-title จำนวนข้อมูล 71,537 17

รูปผนวกที่ ก.1.1 รูปของหน้าแรก 26
รูปผนวกที่ ก.1.2 รูปของการแสดงผลระบบการทำนายข่าว 27

รูปผนวก ก.2.1 รูปของการแสดงผลระบบหาข่าวเพิ่มเติม 28
รูปผนวก ก.2.2รูปของการเลือกอ่านเพิ่มเติม 28
รูปผนวก ก.2.3 รูปของเว็บไซต์ข่าวศูนย์ต่อต้านข่าวปลอมประเทศไทย 29

สารบัญตาราง

หน้า

ตารางที่ 2.1 ตารางเปรียบเทียบความแตกต่าง 6
ตารางที่ 4.1 แสดงการดำเนินงาน 12
ตารางที่ 5.1 ค่า Accuracy และ จำนวนของ n_neighbors 15
ตารางที่ 5.2 ตารางการทดสอบด้วยข่าว 18

บทที่ 1 บทนำ

1.1 ที่มาและความสำคัญของปัญหา

เนื่องจากในปัจจุบันมีสื่อออนไลน์และโซเชียวลมีเดียมากมายทำให้มีข่าวที่สามารถเข้าถึงได้ทุกเพศทุกวัยและข่าวที่หลากหลายนั้นมีทั้งข่าวที่เป็นข่าวจริงและข่าวปลอมโดยเฉพาะข่าวที่สามารถเห็นได้ตามสื่อโซเชียวมีเดียแพลตฟอร์มต่าง ๆ นั้นสามารถสร้างขึ้นได้เองหรือนำมาจากช่องข่าวต่าง ๆ ซึ่งอาจจะทำให้มีข่าวที่เรียกว่าเฟคนิวส์หรือข่าวปลอมนั้นมีลักษณะกว้าง ๆ 3 ประการคือ 1. มีข้อมูลเท็จไม่ว่าจะเป็นข้อเท็จจริงเพียงบางส่วนหรือปราศจากข้อเท็จจริงเลย 2. กระตุ้นให้เกิดการแชร์ออกไป 3. เจตนาจะบิดเบือนหรือปิดบังความจริงด้วยการใช้อารมณ์

ผลกระทบของเฟคนิวส์ผู้รับได้ข้อมูลไม่ถูกต้องทำให้ตัดสินใจผิดพลาดอาจส่งผลเสียต่อชีวิตและทรัพย์สินอย่างเช่นข้อมูลการรักษาต่าง ๆ และการลงทุนถ้าหากได้รับข้อมูลที่เป็นเท็จเกี่ยวกับโรคระบาดต่าง ๆ จะทำให้แตกตื่นและเริ่มกักตุนอาหารเหมือนสถานการณ์โควิด19ที่เคยเกิดขึ้นดังนั้นจึงต้องมีการตรวจสอบข้อเท็จจริงและความน่าเชื่อถือของแหล่งข่าวให้ดีเช่นสำนักงานข่าวหน่วยงานที่เกี่ยวข้องและวันที่มีข่าวอาจเป็นข่าวเก่าที่เคยเกิดขึ้นแล้วในการตรวจสอบเบื้องต้นเพื่อความมั่นใจในการรับสาร

ผู้วิจัยจึงสนใจที่จะนำการเรียนรู้ของเครื่องมาประยุกต์ใช้ในการตรวจจับข่าวปลอมหรือเฟคนิวส์วิเคราะห์ลักษณะข่าวว่ามีความเป็นไปได้ที่จะเป็นข่าวปลอมมากแค่ไหนด้วยการเรียนรู้ของเครื่องจะมีความสำคัญในการจำแนกประเภทข่าวจริงข่าวปลอมโดยขึ้นอยู่กับข้อมูลที่โมเดลได้เรียนเรียนรู้เมื่อทำการทดสอบโมเดลและจะนำมาแสดงผลในรูปแบบของเว็บแอปพลิเคชันเพื่อสะดวกต่อการเรียกใช้งานของผู้ใช้พร้อมกับแสดงข่าวที่เกี่ยวข้องกับข่าวที่ผู้ใช้ต้องการได้ด้วย

1.2 วัตถุประสงค์

1) เพื่อพัฒนาเว็บแอปพลิเคชันที่แยกประเภทข่าวจริงและข่าวปลอม
2) เพื่อพัฒนาโมเดลที่มีค่าความถูกต้องมากที่สุดในการตรวจจับข่าวปลอม

1.3 ลักษณะและขอบเขต

แอปตรวจจับข่าวปลอมของไทยมีลักษณะการใช้การเรียนรู้ของเครื่องในการวิเคราะห์เนื้อหาของข่าวโดยจจำแนกประเภทข่าวจริงและข่าวปลอมด้วยเทคนิค การประมวลผลภาษาธรรมชาติ (NLP) ในการแบ่งประโยคออกเป็นวลีและลดความซับซ้อนของคำโดยทำให้เป็นรากศัพท์และการลบ Stop Word ออกเพื่อเตรียมข้อมูลสำหรับการเรียนรู้ของเครื่องจากลักษณะที่กล่าวไปเบื้องต้นจะทำงานวิจัยนี้โดย

1)เลือกใช้ข้อมูลเป็นข่าวภาษาไทยจากศูนย์ต่อต้านข่าวปลอมแห่งประเทศไทย(www.antifakenewscenter.com) เป็นข้อมูลในการเรียนรู้ของเครื่องโดยแบ่งข้อมูลทั้งหมดออกเป็น 2 ส่วนคือ 1.Training set(80%) 2.Test set (20%) และมีการจำแนกทั้งหมด 2 คลาสคือ ข่าวจริง และข่าวปลอม

2)หลังจากใช้เทคนิคการประมวลผลภาษาธรรมชาติเพื่อเตรียมข้อมูลแล้วสร้างเป็นโมเดลการเรียนรู้ของเครื่องโดยจะใช้เป็น supervised learning ซึ่งจะมี Algorithm ที่นิยมใช้ในการจำแนกประเภทกันมากคือ SVM, KNN, Gradient Boosting, LSTM (Long Short-Term Memory) เพื่อหาโมเดลที่ให้ค่าความถูกต้องในการทำนายข่าวปลอมที่ดีที่สุด

3)หลังจากนั้นจะมีการใช้เทคนิค Information retrieval (IR) ใช้ร่วมกับ crawler เพื่อการสืบค้นและค้นหาข้อมูลในเว็บไซต์เพื่อเพิ่มส่วนของข่าวที่ใกล้เคียงหรือมีความเกี่ยวข้องกับข่าวที่ผู้ใช้ต้องการมากที่สุดโดย Crawler ถูกใช้เพื่อสแกนและ

ดึงข้อมูลจากหน้าเว็บไซต์ต่าง ๆ และเก็บไว้ในฐานข้อมูลหรือไฟล์ต่าง ๆ เมื่อได้ข้อมูลที่ต้องการแล้วจะใช้ Vector Space Model ที่ใช้ในการวัดความสำคัญของคำในเอกสารโดยใช้เมทริกซ์ TF-IDF (Term Frequency-Inverse Document Frequency) จากนั้นจะจัดอันดับเอกสารตามค่า TF-IDF ของคำที่พบในคำขอค้นหาและนำข่าวที่เกี่ยวข้องมาแสดงผลให้ผู้ใช้ได้ตัดสินใจเพิ่มเติมในข่าวที่มี

4)เมื่อได้โมเดลที่คาดว่ามีค่าความถูกต้องที่ดีที่สุดแล้วผู้วิจัยจึงอยากจะนำมาพัฒนาให้ผู้ใช้คนไทยสามารถใช้งานได้โดยแสดงผลในรูปแบบของเว็บแอปพลิเคชันที่พัฒนาระบบด้วย Flutter และภาษา dart ซึ่งระบบจะมีการใช้งานดังนี้

4.1)ส่วนของอินพุตจะให้ผู้ใช้งานได้คัดลอกมาวางให้โมเดลการเรียนรู้ของเครื่องทำนายและจำแนกประเภทข่าว

4.2)ส่วนที่ 1 ของเอาต์พุตจะเป็นผลการทำนายประเภทข่าวจริงหรือข่าวปลอมและค่าความถูกต้อง

4.3)ส่วนที่ 2 ของเอาต์พุตระบบจะแสดงข่าวจากการค้นหาข่าวที่ใกล้เคียงหรือเกี่ยวข้องมาแสดงผลเพิ่มเติมเพื่อเป็นข้อมูลให้ผู้ใช้ตัดสินใจ

1.4 อุปกรณ์และเครื่องมือที่ใช้

1.4.1 ฮาร์ดแวร์

- CPU i3-10105F
- SSD 256 GB
- RAM 16.0 GB
- GPU AMD Radeon RX 6500 XT

1.4.2 ซอฟต์แวร์

- ระบบปฏิบัติการ Windows 11 Home Single Language
- โปรแกรมที่ใช้ในการพัฒนา Jupyter Notebook, Flutter
- ภาษาที่ใช้ในการพัฒนาโปรแกรม Dart, Python

1.5 ผลที่คาดว่าจะได้รับ

1) ได้โมเดลที่มีค่าความถูกต้องที่ดีที่สุดในการทำนาย
2) สามารถแสดงผลในเว็บแอปพลิเคชันได้เพื่อความง่ายในการใช้งาน
3) สามารถแสดงข่าวที่ใกล้เคียงหรือเกี่ยวข้องกับข่าวที่ผู้ใช้ต้องการ

บทที่ 2 ผลงานที่เกี่ยวข้อง

2.1 Thai Fake News Detection Based on Information Retrieval, Natural Language Processing and Machine Learning [1]

ลักษณะและวิธีการที่ถูกใช้ในงานวิจัยเพื่อตรวจสอบข่าวปลอมนี้มีขั้นตอนหลักสองขั้นตอนคือการเก็บข้อมูลและการสร้างโมเดลการเรียนรู้ของเครื่องโดยการทำงานประกอบด้วย 1.Information Retrieval 2. Natural Language Processing 3. Machine Learning เพื่อใช้ในการตรวจสอบข่าวปลอมยังมีการทดสอบและเปรียบเทียบโมเดลการจำแนกข่าวที่สร้างขึ้นและการนำโมเดลที่ดีที่สุดไปใช้ในแอปพลิเคชันเว็บสำหรับตรวจสอบข่าวปลอมสำหรับการเปรียบเทียบเลือกใช้โมเดลการจำแนกที่นิยมใช้กันเช่น Naive Bayesian, Logistic Regression, K-Nearest Neighbor, Multilayer Perceptron, Support Vector Machine, Decision Tree, Random Forest, Rule-Based Classifier และ Long Short-Term Memory (LSTM) การทดสอบแสดงให้เห็นว่า LSTM เป็นโมเดลที่ดีที่สุดและได้นำมันไปใช้งานในแอปพลิเคชันเว็บตรวจสอบข่าวปลอม

รูปที่ 2.1 ตัวอย่างเว็บแอปพลิเคชัน

ข้อเด่น

การทำงานที่มีขั้นตอนหลายหลายสำหรับการตรวจพบข่าวปลอมเช่น Information Retrieval , Natural Language Processing และ Machine Learning ช่วยให้งานวิจัยเป็นระบบและมีการตรวจสอบที่ดีขึ้นจากขั้นตอนทั้งหมดและการนำโมเดลการจำแนกที่ดีมาใช้ในการสร้างแอปพลิเคชันเว็บสำหรับตรวจสอบข่าวปลอมออนไลน์เพื่อช่วยให้ผู้ใช้สามารถตรวจสอบข่าวอย่างรวดเร็วและง่ายมากขึ้น

ข้อด้อย

งานวิจัยนั้นอาจมีข้อจำกัดในการควบคุมคุณภาพข้อมูลที่เก็บจากเว็บไซต์ข่าวออนไลน์ซึ่งอาจส่งผลต่อประสิทธิภาพของระบบในการตรวจพบข่าวปลอมเนื่องจากคุณภาพข้อมูลอาจแตกต่างกันขึ้นอยู่กับแหล่งข่าวและข้อมูลตามสถานการณ์และการนำเสนอรายละเอียดเพิ่มเติมอาจจะไม่ครอบคุมข้อมูลของข่าวทั้งหมดขึ้นอยู่กับแหล่งที่มาว่ามีการอัพเดตข่าวมากน้อยแค่ไหนตามเวลา

2.2 Google Fact check tools [2]

เครื่องมือเช็กข่าวปลอมจาก Google เช็กข่าวปลอมได้ทั่วโลก Fact Check Explorer เป็นเครื่องมือจาก Google สำหรับเช็กข่าวปลอม โดยนำข้อมูลมาจาก APIs ขององค์กรที่ดูแลเรื่องข่าวปลอมและสื่อชื่อดังทั่วโลก ทำให้เราสามารถค้นหาเรื่องราวที่เราสงสัยได้จากเครื่องมือตัวนี้มีฟีเจอร์ที่สำคัญคือ

1.การค้นหาและวิเคราะห์แหล่งข้อมูล

2.การตรวจสอบข้อมูลในฐานความรู้

3.การตรวจสอบข้อมูลในสื่อสังคมออนไลน์

การใช้งานเพียงใส่ประโยคที่เกี่ยวกับเนื้อข่าวที่เราต้องการลงไปในช่องค้นหาคล้ายกับการค้นหาผ่าน Google เลย หากมีองค์กรหรือสื่อที่เคยพูดถึงเรื่องดังกล่าวก็จะขึ้นรายการขึ้นมามีรายละเอียดตั้งแต่หัวข้อข่าว, เนื้อหาข่าว, รูปภาพ, ระดับการเผยแพร่และองค์ที่ยืนยันข่าวนี้ว่าเป็นข่าวจริงหรือข่าวปลอม

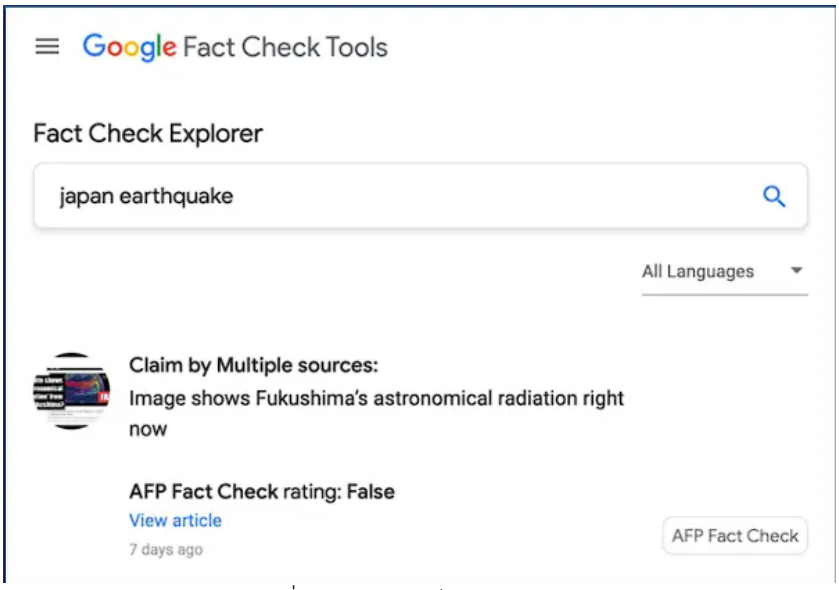

รูปที่ 2.2 ตัวอย่างเว็บแอปพลิเคชัน

ข้อเด่น

ความสะดวกในการใช้งาน Google Fact Check Explorer เป็นเครื่องมือที่ใช้งานง่าย โดยใครก็สามารถค้นหาข้อมูลเชิงสถิติได้โดยใช้คำค้นหาง่าย ๆ และการนำเสนอข้อมูลเพิ่มเติมเครื่องมือนี้จะแสดงข้อมูลเพิ่มเติมเกี่ยวกับเรื่องที่คุณค้นหาเช่นแหล่งตรวจสอบข้อมูลและข้อมูลการตรวจสอบความถูกต้อง เพื่อช่วยในการทำความเข้าใจส่วนความน่าเชื่อถือข้อมูลใน Google Fact Check Explorer มาจากแหล่งที่น่าเชื่อถือที่ตรวจสอบความถูกต้องของข้อมูลทำให้ผู้ใช้มีความมั่นใจในความถูกต้องของข้อมูล

ข้อด้อย

การค้นหาข้อมูลใน Google Fact Check Explorer อาจจำกัดในการแสดงผลเฉพาะข้อมูลที่ถูกตรวจสอบความถูกต้องจากแหล่งตรวจสอบข้อมูลที่รายงานถึง Google โดยอาจมีข้อมูลจากแหล่งอื่นที่ไม่ได้รวมเข้ามาด้วยและข้อมูลที่ยังไม่ครอบคลุมครบถ้วนไม่ใช่ทุกข่าวหรือเรื่องที่ถูกตรวจสอบความถูกต้องมีใน Google Fact Check Explorer และมีข้อมูลเฉพาะ

เรื่องบางประเทศและเรื่องบางอย่างที่ถูกค้นหาการตรวจสอบความถูกต้องของข้อมูลอาจมีผลมาจากแหล่งที่เป็นที่นิยมในสื่อและข้อมูลที่ไม่ได้รับความสนใจอาจไม่ถูกตรวจสอบความถูกต้องใน Google Fact Check Explorer

2.3 The Fight Against Fake News with Deep Learning [3]

เป็นเว็บแอปพลิเคชันที่เราสามารถทำให้ผู้ใช้สามารถใช้งานผ่านเว็บด้วยโมเดล 3 โมเดลคือ 1.Gensim Doc2Vec 2.LSTM model 3.BERT model ลักษณะของงานวิจัยนี้คือสร้างแบบจำลองที่สามารถตรวจจับได้ว่าหัวข้อของบทความข่าวว่าเป็นข่าวปลอมหรือไม่ด้วยการสร้างรูปแบบการจำแนกข้อความนี้ด้วยโมเดล LSTMs และ BERT และมีการเตรียมข้อมูลเพื่อจะทำให้เครื่องได้เรียนรู้ข้อมูลเหล่านั้นด้วยเทคนิคภาษาธรรมชาติ(NLP)เพื่อลดความซับซ้อนของข้อมูลลงมีฟีเจอร์ที่สำคัญคือ

1.มีโมเดลให้เลือกใช้งานได้3โมเดลที่แตกต่างกัน

2.แสดงผลว่าเป็นข่าวจริงหรือปลอม

3.แสดงผลความแม่นยำของการทำนาย

รูปที่ 2.3 ตัวอย่างเว็บแอปพลิเคชัน

ข้อเด่น

สามารถตรวจสอบข่าวปลอมและข่าวจริงได้ในเว็บแอปพลิเคชัน ทำให้ผู้ใช้สามารถรับรู้ข่าวที่ถูกปลอมได้ทันทีและไม่ต้องรอนานเพื่อค้นหาข้อมูลต่อเมื่อเจอข่าวสำคัญและยังมีโมเดลให้ได้เลือกใช้งานได้ถึง 3 โมเดลที่แตกต่างกันคือ 1.Gensim Doc2Vec 2.LSTM model 3.BERT model

ข้อด้อย

อาจไม่สามารถตรวจสอบข้อมูลที่เป็นข่าวที่ใหม่กว่าได้เพราะขึ้นอยู่กับข้อมูลที่เครื่องได้เรียนรู้ผู้ใช้อาจจะยังไม่สามารถตัดสินใจได้ว่าเป็นข่าวจริงหรือไม่ซึ่งในแต่ละโมเดลอาจจะได้ผลการทำนายที่แตกต่างกันออกไปค่าความถูกต้องอาจจะคลาดเคลื่อนกันบ้างในแต่ละโมเดล

2.4 เปรียบเทียบความแตกต่าง

ตารางที่ 2.1 ตารางเปรียบเทียบความแตกต่าง

	THAI D.I. MACHINE	Google Fact check tools	The Fight Against Fake News with Deep Learning	แอปตรวจจับข่าวปลอมของไทย
Machine Learning	LSTM	✗	1.ANN model 2.LSTM model 3.BERT model	1.SVM 2.KNN 3.Gradient Boosting 4.LSTM
แหล่งข้อมูล	เว็บไซต์ข่าวออนไลน์	APIs ขององค์กรที่ดูแลเรื่องข่าวปลอมและสื่อชื่อดังทั่วโลก	-	ศูนย์ต่อต้านข่าวปลอม ประเทศไทย
ระบบสมัครสมาชิก	✓	✗	✗	✗
การเลือกใช้งานหลายโมเดล	✗	✗	✓	✓
การแสดงข่าวเพิ่มเติม	✓	✓	✗	✓
ลักษณะข่าวที่ตรวจสอบ	หัวข้อข่าว+เนื้อหาข่าว	หัวข้อข่าว	หัวข้อข่าว	หัวข้อข่าว+เนื้อหาข่าว

บทที่ 3 ทฤษฎีและความรู้ที่เกี่ยวข้อง

3.1 web crawler [4]

เว็บครอว์เลอร์(Web Crawler) เป็นโปรแกรมหรือสคริปต์ที่ออกแบบมาเพื่อเรียกดูข้อมูลบนเว็บไซต์อัตโนมัติ โดยที่มีการเข้าถึงและสำรวจหน้าเว็บต่าง ๆ เพื่อเก็บข้อมูลที่ต้องการ เช่น ข้อความ รูปภาพ ลิงก์ และข้อมูลอื่น ๆ แล้วนำมาวิเคราะห์หรือบันทึกเพื่อประโยชน์ต่าง ๆ เช่น การทำการค้นหา การวิเคราะห์ข้อมูลทางธุรกิจ การวิเคราะห์แนวโน้ม และอื่น ๆ วิธีการทำงานของเว็บครอว์เลอร์มักจะเริ่มต้นด้วยการเริ่มจากหน้าเว็บหนึ่งและจากนั้นจะดำเนินการตามลำดับของลิงก์ที่พบบนหน้าเว็บนั้น ๆ โดยที่ลิงก์เหล่านี้จะชี้ไปยังหน้าเว็บอื่น ๆ และกระจายออกไปจนกระทั่งเว็บครอว์เลอร์ได้สำรวจหรือดึงข้อมูลบนหน้าเว็บหลาย ๆ หน้าเว็บครอว์เลอร์มักจะถูกนำมาใช้ในหลายสถานการณ์ เช่น

1) การทำการค้นหาเว็บไซต์ เว็บครอว์เลอร์จะถูกนำมาใช้ในการสแกนและเก็บข้อมูลจากเว็บไซต์ต่าง ๆ เพื่อใช้ในการทำการค้นหาบนเว็บ

2) การทำ SEO เว็บครอว์เลอร์ช่วยในการเก็บข้อมูลเพื่อทำการวิเคราะห์และปรับปรุงเว็บไซต์เพื่อให้เหมาะสมกับการทำ SEO (Search Engine Optimization)

3) การดึงข้อมูล เว็บครอว์เลอร์ใช้ในการดึงข้อมูลจากเว็บไซต์เพื่อนำมาใช้ในการวิเคราะห์หรือประมวลผล

การสร้าง Web Crawler หรือโปรแกรมตัวดึงข้อมูลเว็บไซต์เป็นงานที่ซับซ้อนและต้องอาศัยความรู้ในการโปรแกรมและการเขียนโค้ดอย่างแข่งขัน ข้างล่างนี้คือโครงสร้างหลักของ Web Crawler และขั้นตอนในการดึงข้อมูลเว็บไซต์เราจะใช้ Beautiful Soup (+ Requests)

Beautiful Soup เป็น Library ที่ Parse HTML จากนั้นเราสามารถค้นหา Tag หรือ Keyword ได้ สามารถใช้ได้กับ Static Site ได้ (หรือ Server Side Rendering ได้ในบางกรณีที่ไม่ต้องไปโหลดข้อมูลเพิ่มเติม)

Requests

Requests เป็น Module ที่สามารถใช้ในการ Get HTML มาได้

สามารถทำได้ตามขั้นตอนดังนี้

1) ติดตั้งไลบรารีที่จำเป็น ได้แก่ requests และ Beautiful Soup
2) กำหนด URL ของหน้าเว็บเพจที่ต้องการ Scraping
3) ทำการ Request ไปที่ URL ของหน้าเว็บเพจ
4) แปลงข้อมูล HTML ที่ได้รับจาก Response เป็น BeautifulSoup Object
5) ใช้ BeautifulSoup Object เพื่อค้นหาข้อมูลที่ต้องการ
6) บันทึกข้อมูลที่ต้องการลงในไฟล์หรือฐานข้อมูล

3.2 Natural Language Processing [5]

NLP หรือ Natural Language Processing (ประมวลผลภาษาธรรมชาติ)เป็นกลุ่มของเทคโนโลยีและวิธีการทางคอมพิวเตอร์ที่มุ่งหวังในการเข้าใจวิเคราะห์และประมวลผลภาษาธรรมชาติที่มนุษย์ใช้ในการสื่อสารเช่น ภาษาพูด และภาษาเขียน วัตถุประสงค์หลักของ NLP คือการทำให้คอมพิวเตอร์สามารถเข้าใจและจัดการกับภาษามนุษย์ได้อย่างมีประสิทธิภาพเพื่อนำข้อมูลและความรู้ที่อยู่ในข้อความเหล่านี้ไปใช้งานในลักษณะต่าง ๆ เช่น การตอบคำถามอัตโนมัติ การแปลภาษา การ

สร้างสรรค์เนื้อหาการวิเคราะห์และสรุปข้อมูลและอื่น ๆ NLP มีการทำงานที่หลากหลายรวมถึงการตัดคำ (Tokenization) แบ่งประโยคหรือข้อความยาว ๆ เป็นหน่วยที่เล็กกว่าเช่น คำหรือตัวอักษรเพื่อให้คอมพิวเตอร์เข้าใจและจัดการได้ง่ายขึ้น

การประมวลผลภาษาธรรมชาติหรือ Natural Language Processing ที่ใช้ในงานวิจัยนี้ได้แก่

1) การแยกคำ(Tokenization) คือการแบ่งข้อความออกเป็นประโยคย่อย ๆ เพื่อให้ง่ายต่อการประมวลผลต่อไป ตัวอย่างเช่น ข้อความ "ฉันชอบกินข้าว" จะถูกแยกออกเป็นประโยคย่อย ๆ 2 ประโยค คือ "ฉันชอบกิน" และ "ข้าว"

2) การกำจัดคำที่ไม่มีนัยสำคัญ (Stop word removal) คือการลบคำที่ไม่มีความหมายหรือมีความหมายน้อยออกไปจากข้อความ ตัวอย่างเช่น คำว่า "และ", "หรือ", "คือ", "ที่", "ใน" เป็นต้น

3) TF-IDF (Term Frequency-Inverse Document Frequency) เป็นเมทริกซ์ที่ใช้ในการวัดความสำคัญของคำในเอกสาร ประกอบด้วยสองส่วน คือ

Term Frequency (TF) คือการนับจำนวนครั้งที่คำหนึ่งปรากฏในเอกสาร

Inverse Document Frequency (IDF) คือการวัดความหายากของคำในเอกสาร เอกสารที่มีคำศัพท์ที่หายากจะมี IDF สูง

3.3 Machine Learning [6]

การเรียนรู้ของเครื่อง (machine learning) เป็นการศึกษาอัลกอริทึมของคอมพิวเตอร์ที่มีการพัฒนาการเรียนรู้ของเครื่องถูกมองว่าเป็นส่วนหนึ่งของปัญญาประดิษฐ์ โดยอัลกอริทึมสร้างแบบจำลองทางคณิตศาสตร์จากข้อมูลตัวอย่าง (เรียกว่าข้อมูลสอน) เพื่อที่จะคาดการณ์หรือตัดสินใจได้อย่างชัดเจน

การเรียนรู้ของเครื่องพัฒนามาจากการศึกษาการรู้จำแบบ เกี่ยวข้องกับการศึกษาและการสร้างอัลกอริทึมที่สามารถเรียนรู้ข้อมูลและทำนายข้อมูลได้ อัลกอริทึมนั้นจะทำงานโดยอาศัยโมเดลที่สร้างมาจากชุดข้อมูลตัวอย่างขาเข้าเพื่อการทำนายหรือตัดสินใจในภายหลัง แทนที่จะทำงานตามลำดับของคำสั่งโปรแกรมคอมพิวเตอร์ การเรียนรู้ของเครื่องมีเกี่ยวข้องอย่างมากกับสถิติศาสตร์ เนื่องจากทั้งสองสาขาศึกษาการวิเคราะห์ข้อมูลเพื่อการทำนายเช่นกัน นอกจากนี้ยังมีความสัมพันธ์กับสาขาการหาค่าเหมาะที่สุดในทางคณิตศาสตร์ที่แงของวิธีการ ทฤษฎี และการประยุกต์ใช้ การเรียนรู้ของเครื่องสามารถนำไปประยุกต์ใช้งานได้หลากหมาย ไม่ว่าจะเป็นการกรองอีเมล์ขยะ การรู้จำตัวอักษร เครื่องมือค้นหา และคอมพิวเตอร์วิทัศน์
ประเภทของการเรียนรู้ที่ใช้ในงานวิจัยนี้
การเรียนรู้แบบมีผู้สอน (supervised learning)

ข้อมูลตัวอย่างและผลลัพธ์ที่ "ผู้สอน" ต้องการถูกป้อนเข้าสู่คอมพิวเตอร์ เป้าหมายคือการสร้างกฎทั่วไปที่สามารถเชื่อมโยงข้อมูลขาเข้ากับขาออกได้การเรียนรู้ของเครื่องเกี่ยวข้องกับการสร้างแบบโมเดล (model) ซึ่งเกิดจากการสอนด้วยข้อมูลสอนและสามารถพยากรณ์ข้อมูลที่เข้ามาใหม่ได้ โมเดลมีหลากหลายรูปแบบ

1.SVM (Support Vector Machine) [7]

SVM เป็นอัลกอริทึมในการเรียนรู้เชิงประมวลผลที่ใช้ในงานการจำแนกประเภทและการวิเคราะห์แบบสองกลุ่ม (binary classification) หรือหลายกลุ่ม (multi-class classification) โดยการพิจารณาในการสร้างแนวแบ่ง (hyperplane) ที่มีระยะห่างระหว่างข้อมูลตัวอย่าง (instances) มากที่สุด

ข้อดี: มีประสิทธิภาพสูงในการจำแนกประเภทข้อมูลแบบเชิงเส้นและข้อมูลที่มีมิติสูงสามารถใช้ได้กับข้อมูลที่มีความซับซ้อนและขนาดใหญ่

ข้อเสีย: การปรับพารามิเตอร์อาจทำให้เกิดเวลาการฝึกและทดสอบที่ยาวนานแม่นยำของโมเดลอาจลดลงหากข้อมูลมี noise หรือมีความผิดพลาดในการตัดสินใจ

2. KNN (K-Nearest Neighbors) [8]

KNN เป็นอัลกอริทึมที่ใช้ในการจำแนกประเภทและการจำแนกกลุ่มข้อมูลโดยการค้นหาตัวอย่างข้อมูลที่ใกล้เคียงกับตัวอย่างข้อมูลที่ต้องการทำนาย

ข้อดี: ง่ายต่อการทำใช้งานและเข้าใจไม่ต้องมีการฝึกโมเดล และสามารถใช้งานกับข้อมูลที่มีโครงสร้างที่ซับซ้อนได้
ข้อเสีย: มีความต่ำประสิทธิภาพเมื่อมีข้อมูลมากและมีมิติสูงต้องคำนึงถึงค่า K ที่เหมาะสมที่จะให้ผลลัพธ์ที่ดี

3.Gradient Boosting [9]

Gradient Boosting เป็นเทคนิคการเรียนรู้เชิงสถิติที่ใช้ในการสร้างโมเดลปัญญาประดิษฐ์ โดยการเรียนรู้จากข้อผิดพลาดของโมเดลก่อนหน้าและพยายามแก้ไขโดยใช้ Gradient Descent

ข้อดี: สามารถทำนายได้ดีกับข้อมูลที่มีความซับซ้อนและข้อมูลที่มีความหลากหลายมีประสิทธิภาพสูง
ข้อเสีย: ต้องใช้เวลาในการฝึกโมเดลมากกว่าวิธีอื่นๆต้องระมัดระวังการตั้งค่าพารามิเตอร์เพื่อหลีกเลี่ยงการเกิด Overfitting

4.LSTM (Long Short-Term Memory) [10]

LSTM เป็นชนิดหนึ่งของโมเดล Deep Learning ที่ใช้ในงานประมวลผลภาษาธรรมชาติและการวิเคราะห์ลำดับข้อมูล โดยมีความสามารถในการจำกัดปัญหาที่เกิดขึ้นจากการสูญเสียสถานะในการฝึกโมเดล RNN (Recurrent Neural Network)

ข้อดี: สามารถจดจำลำดับข้อมูลได้ดี มีความสามารถในการป้องกันปัญหา Gradient Vanishing และ Gradient Exploding สามารถจัดการกับข้อมูลลำดับที่ยาวได้
ข้อเสีย: การฝึกโมเดลอาจใช้เวลานานและท่าทีในการปรับแต่งพารามิเตอร์ของโมเดลมีความซับซ้อนและต้องการข้อมูลการฝึกมากกว่าโมเดลอื่น ๆ

3.4 Information Retrieval [11]

Information retrieval (IR) ในความหมายของคอมพิวเตอร์และวิทยาการสารสนเทศคือกระบวนการในการค้นหาทรัพยากรระบบสารสนเทศที่เกี่ยวข้องกับความต้องการข้อมูลจากชุดข้อมูลนั้น ค้นหาสามารถทำขึ้นอย่างมีข้อความเต็ม (full-text) หรืออื่น ๆ ที่มีการจัดอันดับตามเนื้อหา เรื่องนี้เรียกว่า Information retrieval (IR) หรือการค้นหาข้อมูลในเอกสาร การค้นหาเอกสารเอง และการค้นหาเมตาดาต้าที่อธิบายข้อมูล รวมถึงฐานข้อมูลข้อความ รูปภาพ หรือเสียง

ระบบค้นหาข้อมูลอัตโนมัติถูกใช้เพื่อลดปัญหาที่เรียกว่าการบริหารข้อมูลที่เกินเกินไป ระบบ IR คือระบบซอฟต์แวร์ที่ให้การเข้าถึงหนังสือ เอกสาร และเอกสารอื่น ๆ ระบบนี้ยังจัดเก็บและบริหารจัดการเอกสารเหล่านั้นด้วย เครื่องมือค้นหาเว็บ (Web search engines) เป็นการใช้งาน IR ที่มองเห็นได้ชัดเจนที่สุด

Information Retrieval มีโมเดลหลายประเภทที่ถูกพัฒนาขึ้นเพื่อรับมือกับการค้นหาและคืนค่าข้อมูลให้กับผู้ใช้ โมเดลเหล่านี้มีลักษณะและวิธีการที่แตกต่างกัน นี่คือประเภทของโมเดลที่จะนำไปใช้ในงานวิจัยนี้ Vector Space Model แบบ Ranked TF-IDF Retrieval Model เป็นโมเดลการดึงข้อมูล (Information Retrieval) ที่ใช้ในการวัดความสำคัญของคำในเอกสารโดยใช้เมทริกซ์ TF-IDF (Term Frequency-Inverse Document Frequency) จากนั้นจะจัดอันดับเอกสารตามค่า TF-IDF ของคำที่พบในคำขอค้นหา

TF-IDF คำนวณดังนี้

TF-IDF = TF * IDF

โดยที่

TF คือ Term Frequency คือการนับจำนวนครั้งที่คำหนึ่งปรากฏในเอกสาร

IDF คือ Inverse Document Frequency คือการวัดความหายากของคำในเอกสาร

เอกสารที่มีคำศัพท์ที่หายากจะมี IDF สูง

Ranked TF-IDF Retrieval Model จะคำนวณ TF-IDF สำหรับคำทั้งหมดในเอกสาร จากนั้นจะจัดอันดับเอกสารตามค่า TF-IDF ของคำที่พบในคำขอค้นหา

เอกสารที่มีค่า TF-IDF สูงสำหรับคำที่พบในคำขอค้นหาจะมีอันดับสูงกว่าเอกสารที่มีค่า TF-IDF ต่ำ

ใน Vector Space Model เอกสารและคำขอค้นหาจะถูกแปลงให้เป็นเวกเตอร์ เวกเตอร์ของเอกสารจะประกอบด้วยค่า TF-IDF ของคำทั้งหมดในเอกสาร เวกเตอร์ของคำขอค้นหาจะประกอบด้วยค่า TF-IDF ของคำทั้งหมดในคำขอค้นหา

บทที่ 4 ขั้นตอนและแผนการดำเนินงาน

4.1 ขั้นตอนการดำเนินงาน

4.1.1 รวบรวมข้อมูลและกำหนดขอบเขตของโครงงาน

- รวบรวมข้อมูลที่มีความเกี่ยวข้องกับโครงงานนี้ได้แก่ผลงาน งานวิจัยและทฤษฎี
- กำหนดขอบเขตของโครงงานตามความเหมาะสม

4.1.2 ศึกษาทฤษฎีและความรู้ที่เกี่ยวข้อง

- ศึกษาภาษา Python
- ศึกษาการทำ Web crawling
- ศึกษาการเรื่อง NLP
- ศึกษาเรื่อง machine learning
- ศึกษาระบบ IR
- ศึกษาภาษา dart

4.1.3 การออกแบบระบบและพัฒนาโปรแกรม

- ออกแบบการทำโมเดล
- ออกแบบระบบการแสดงข้อมูลข่าวเพิ่มเติม
- ออกแบบ UX และUI

4.1.4 ทดสอบและปรับปรุง

- ทดสอบการทำนายของโมเดล
- ทดสอบการใช้งานแอปพลิเคชัน
- แก้ไขข้อผิดพลาดของแอปพลิเคชัน

4.1.5 จัดทำเอกสารประกอบโครงงาน

- ดำเนินการจัดทำเอกสารประกอบโครงงาน

4.2 แผนการดำเนินงาน

ตารางที่ 4.1 แสดงการดำเนินงาน

ขั้นตอนและการดำเนินงาน	เดือน								
	กรกฎาคม 2566	สิงหาคม 2566	กันยายน 2566	ตุลาคม 2566	พฤศจิกายน 2566	ธันวาคม 2566	มกราคม 2566	กุมภาพันธ์ 2566	มีนาคม 2566
รวบรวมข้อมูลและกำหนดขอบเขตของโครงงาน	↔	↔	↔						
ศึกษาทฤษฎีและความรู้ที่เกี่ยวข้อง		↔	↔						
การออกแบบระบบและพัฒนาโปรแกรม				↔	↔	↔	↔	↔	
ทดสอบและปรับปรุง							↔	↔	↔
จัดทำเอกสารประกอบโครงงาน	↔	↔	↔	↔	↔	↔	↔	↔	↔

บทที่ 5 วิธีการดำเนินงาน

5.1 โครงสร้างของระบบ

ระบบนี้จะแบ่งออกเป็น 2 ส่วนที่สำคัญดังรูป 5.1 คือ

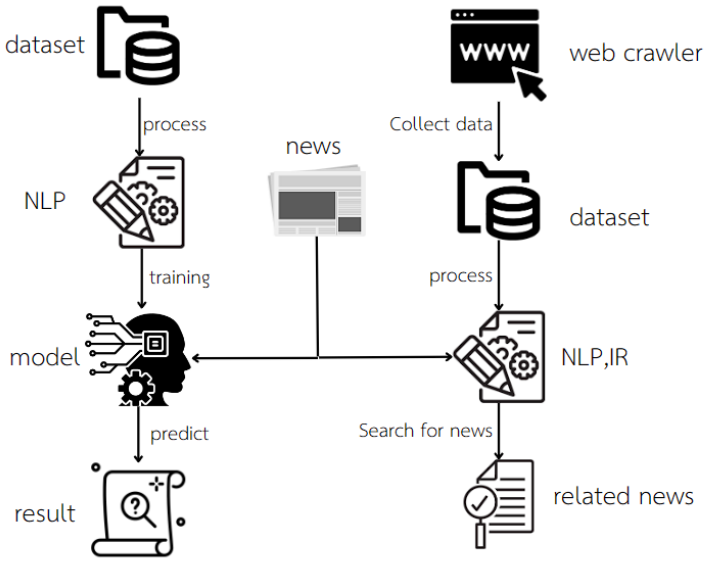

รูปที่ 5.1โครงสร้างของระบบ

1) ส่วนของการทำโมเดลซึ่งจะมีโมเดลที่จะใช้ในการตรวจจับข่าวปลอมคือ

SVM (Support Vector Machine) เป็นโมเดลที่ใช้ในการจำแนกข้อมูล หรือแบ่งกลุ่มข้อมูลโดยจะสร้างเส้นตรงที่ใช้แบ่งกลุ่มข้อมูล (Hyperplane) และหาเส้นที่ดีที่สุด เหมาะสำหรับการจำแนกและคำนวณทำนายในงานที่มีความซับซ้อน มักนิยมใช้สำหรับ Classification

KNN (K-Nearest Neighbors) เป็นวิธีการจัดหมวดหมู่ข้อมูลที่ใช้หลักการเปรียบเทียบความคล้ายคลึงระหว่างข้อมูลที่สนใจกับข้อมูลในชุดข้อมูลโดยการค้นหาข้อมูลที่ใกล้เคียงที่สุดจากข้อมูลที่กำลังสนใจแล้วให้คำตอบเป็นคลาสของข้อมูลที่ใกล้เคียงนั้น ไม่ต้องใช้ข้อมูลชุดเรียนรู้ในการสร้างแบบจำลองแต่ใช้ข้อมูลเพียงเท่านั้นในการจำแนกประเภทข้อมูล

Gradient Boosting เป็นโมเดลที่ใช้โครงสร้างแบบ Ensemble Learning และใช้ Gradient Descent เพื่อเรียนรู้และปรับค่าของโมเดล มีการสร้างโมเดลโดยการเรียนรู้ต่อจากโมเดลก่อนหน้าและพยายามปรับค่าของโมเดลให้ดีขึ้นในทุก ๆ รอบ

LSTM (Long Short-Term Memory) เป็นประเภทหนึ่งของสถาปัตยกรรม RNN ใน Deep Learning ที่ออกแบบมาเพื่อจดจำและใช้ Patterns ในช่วงเวลานาน ๆ มีประสิทธิภาพสำหรับการทำนายที่เป็น Sequential และสามารถแก้ปัญหา Long-term Dependency ได้ โดยมีประสิทธิภาพในการจดจำข้อมูลยาวนานโดยใช้ Gating Mechanisms เฉพาะตัวที่ช่วยในการป้องกันปัญหา Vanishing Gradient และมีความยืดหยุ่นที่ดีในการใช้งานกับทั้ง Long-term และ Short-term Temporal Sequences ด้วยการทำงานกับข้อมูลที่มีลำดับเวลาได้เป็นอย่างดี

และจะเริ่มทำโมเดลดังนี้

1.1) โหลดข้อมูลจากเว็บศูนย์ต่อต้านข่าวปลอมและทำการใช้เทคนิคประมวลผลภาษาธรรมชาติในการเตรียมข้อมูลด้วยการแยกคำ(Tokenization) ,การกำจัดคำที่ไม่มีนัยสำคัญ (Stop word removal) และแบ่งข้อมูลเป็นเทรน 80%/เทส 20% ใช้ส่วนของ หัวข้อข่าว,เนื้อข่าว,ประเภทข่าว และมีจำนวนของข่าวเท่ากับ 7419 ข่าว ซึ่งมีจำนวนคลาสทั้งหมด 2 คลาส คือ 1.ข่าวปลอม, 2.ข่าวจริง แบ่งข้อมูลเป็นเทรน 5988 ข่าว มีคลาส ข่าวปลอม 3106 ข่าว,ข่าวจริง 2882 ข่าว และแบ่งข้อมูลเป็นเทส 1497 ข่าว มีคลาส ข่าวปลอม 762 ข่าว,ข่าวจริง 735 ข่าว และมีลักษณะของข่าว ดังรูป 5.2

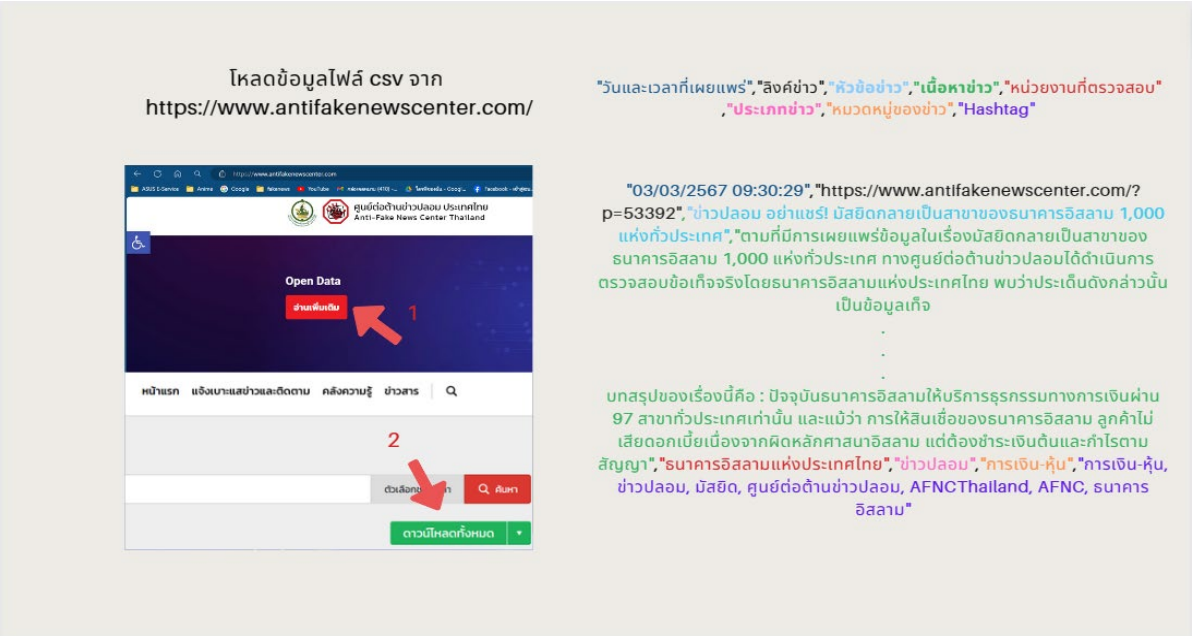

รูปที่ 5.2 ตัวอย่างข้อมูล

1.2) ทำการเทรนโมเดล LSTM เริ่มโดยการเตรียมข้อมูล

1.2.1) แบ่งข้อมูลเป็นเทรน 80%/เทส 20% ใช้ส่วนของ หัวข้อข่าว,เนื้อข่าว,ประเภทข่าวโดยการแบ่งข้อมูลนี้ทุก ๆ โมเดลจะจะมีข้อมูลที่เป็นเทรนและเทสเป็นข้อมูลที่เหมือนกันทุกโมเดลด้วยการกำหนด random state = 42 ค่า seed ที่กำหนดการ random กลุ่มข้อมูลจะเป็นเลขจำนวนเต็มถ้ากำหนดเลขเดิมผลการแบ่งก็จะเหมือนเดิม

1.2.2) ทำ Tokenizer เพื่อแปลงข้อความในเอกสารให้เป็นลำดับของตัวเลข

1.2.3) ทำ pad sequences เพื่อเติมข้อมูลให้มีความยาวเท่ากันโดยการเติม 0 ในกรณีที่มีความยาวน้อยกว่า maxlen ที่กำหนดไว้

1.2.4) สร้างโมเดล LSTM สร้างเลเยอร์ของโมเดล LSTM โดยใช้ Embedding เพื่อแปลงคำศัพท์ให้อยู่ในรูปแบบของเวกเตอร์, และใช้ LSTM เพื่อเรียนรู้ลำดับข้อความ

1.2.5) ฝึกโมเดลโดยตั้งค่าคอมไพล์โมเดลโดยใช้ optimizer = 'adam' และ Loss Function = 'binary_crossentropy' เพื่อการฝึกโมเดลแบบ binary classification ฝึกโมเดลด้วยชุดข้อมูลฝึก โดยใช้ชุดข้อมูล X_train กับ y_train โดยกำหนดจำนวน epoch เป็น 5 และ batch size เป็น 64เมื่อได้ทำการเทรนด้วยข้อมูลของเราแล้วจะทำการเปรียบเทียบโมเดลที่มีค่าความถูกต้องมากที่สุดในการทำนายข่าวของผู้ใช้งาน

1.3) ทำการเทรนโมเดล SVM,KNN,GBC โดยการเตรียมข้อมูล

1.3.1) ใช้ TfidfVectorizer เพื่อแปลงข้อความในชุดข้อมูลฝึก (X_train) และชุดข้อมูลทดสอบ (X_test) เป็นเวกเตอร์ TF-IDF max_features=20606 ระบุจำนวนคำสูงสุดที่จะใช้ในการสร้างเวกเตอร์ TF-IDF เพื่อลดความซับซ้อนของข้อมูล

1.3.2) สร้างและฝึกโมเดล ด้วยข้อมูลฝึกที่ผ่านการแปลง TF-IDF (X_train_tfidf) และ (y_train) โดยมีการตั้งค่าค่าพารามิเตอร์ดังนี้

- SVM = SVC(kernel='linear')
- GBC = GradientBoostingClassifier()
- KNN = KNeighborsClassifier(n_neighbors= 5)

ตารางที่ 5.1 ค่า Accuracy และ จำนวนของ n_neighbors

ค่า Accuracy	จำนวนของ n_neighbors
0.95	1
0.94	2
0.96	3
0.96	4
0.97	5
0.96	6
0.96	7
0.96	8

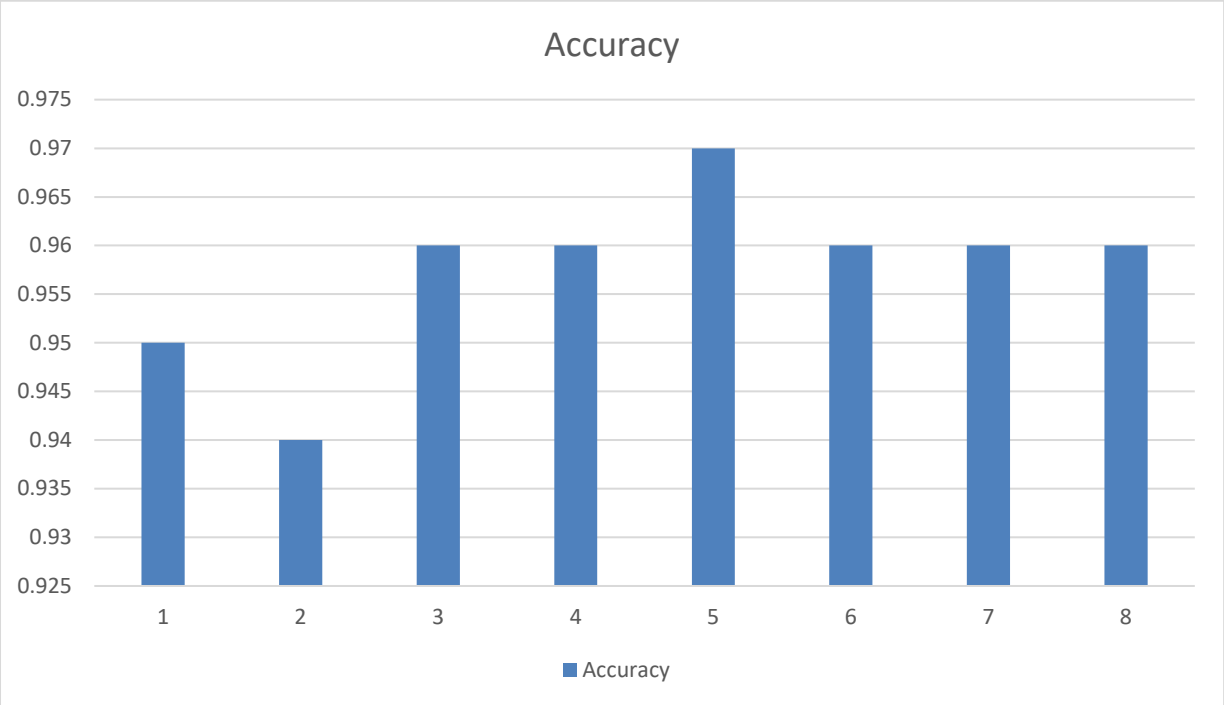

จากกราฟโดยเลือกจากค่า n = 5 เพราะเป็นค่าที่เยอะที่สุดจากกราฟและหลังจาก n = 5 ซึ่งถ้าค่า Accuracy ไม่เพิ่มขึ้นตามจำนวนของ n_neighbors และค่า Accuracy ไม่เพิ่มขึ้นตามจึงสรุปได้ว่า n = 5 คือค่าที่ดีที่สุดในกราฟนี้

2) ส่วนนี้จะเป็นการทำข้อมูลข่าวดังที่มีความเกี่ยวข้องเพิ่มเติมด้วยวิธีดังนี้

2.1) การรวบรวมข้อมูลข่าวด้วย Web crawler และจัดทำเป็นเอกสารเตรียมไว้

2.2) การเตรียมข้อมูลด้วยเทคนิคประมวลผลภาษาธรรมชาติเช่นการแยกคำ(Tokenization)การกำจัดคำที่ไม่มีนัยสำคัญ (Stop word removal)

2.3) การทำระบบค้นหาโดย

2.3.1) ใช้ TfidfVectorizer เพื่อคำนวณ TF-IDF ของข้อความ

2.3.2)ใช้การคำนวณ cosine similarity ระหว่าง query และเอกสารทั้งหมด

2.3.3)ค่าน้ำหนักของคำของทั้ง query และ document จะเข้าสูตร cosine similarity และหาค่าความคล้ายคลึงออกมา

2.3.4)ค่าความคล้ายคลึงก็จะมีค่า ตั้งแต่ 0-1

2.3.5)แสดงข่าวที่มีค่าความคล้ายคลึงจากมากไปน้อยทั้งหมด 10 ลำดับ

5.2 ผลการทดสอบ

ค่า accuracy ของการเทรนด้วย title&body และ title และ ENG title ดังรูปที่ 5.3

title&body	LSTM	SVM	KNN	Gradient Boosting
ข้อมูลภาษาไทย (7419)	0.99	0.99	0.97	0.99
title	**LSTM**	**SVM**	**KNN**	**Gradient Boosting**
ข้อมูลภาษาไทย (7419)	0.95	0.92	0.62	0.83
ENG title	**LSTM**	**SVM**	**KNN**	**Gradient Boosting**
ข้อมูลภาษาอังกฤษ (6335)	0.80	0.80	0.60	0.75

รูปที่ 5.3ตารางเปรียบเทียบค่า accuracy ของการเทรนด้วย title&body และ title และ ENG title

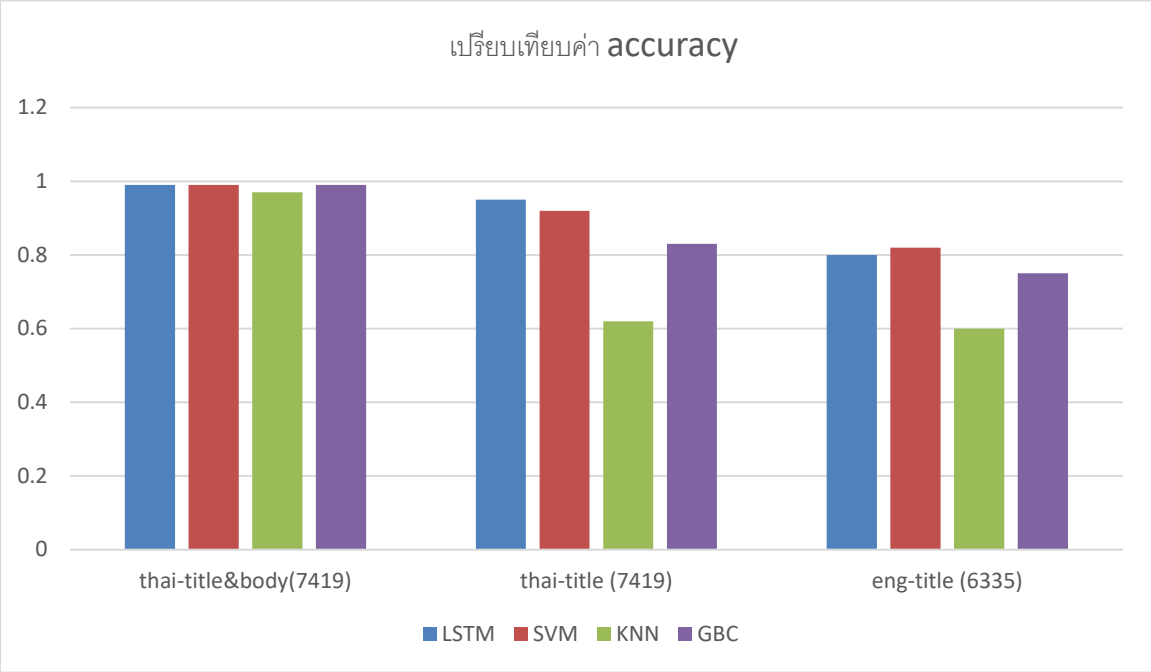

จากกราฟจะเห็นได้ว่า thai-title&body จะมีค่า accuracy ของ LSTM,SVM,KNN,GBC ที่สูงกว่าการเทรนแบบ title ซึ่งการกเทรนแบบ title&body มีข้อมูลที่เป็นเนื้อหาของข่าวซึ่งจะเยอะกว่าของ titie จึงอาจมีการเรียนรู้ที่ซับซ้อนและประโยคข้อความที่มีความยาวของคำที่มากกว่าจึงทำให้มีการเรียนรู้ที่เยอะ ถ้าหากเทียบกับ title จะมีค่า accuracy ที่น้อยกว่าในโมเดล LSTM,SVM,KNN,GBC

ค่า accuracy ของการเทรนด้วย ENG title ที่มีข้อมูลขนาดใหญ่ ดังรูปที่ 5.4

ENG title	LSTM	SVM	KNN	Gradient Boosting
ข้อมูลภาษาอังกฤษ (71537)	0.92	0.90	0.65	0.80

รูปที่ 5.4 ตารางเปรียบเทียบค่า accuracy ของการเทรนด้วย eng-title จำนวนข้อมูล 71,537

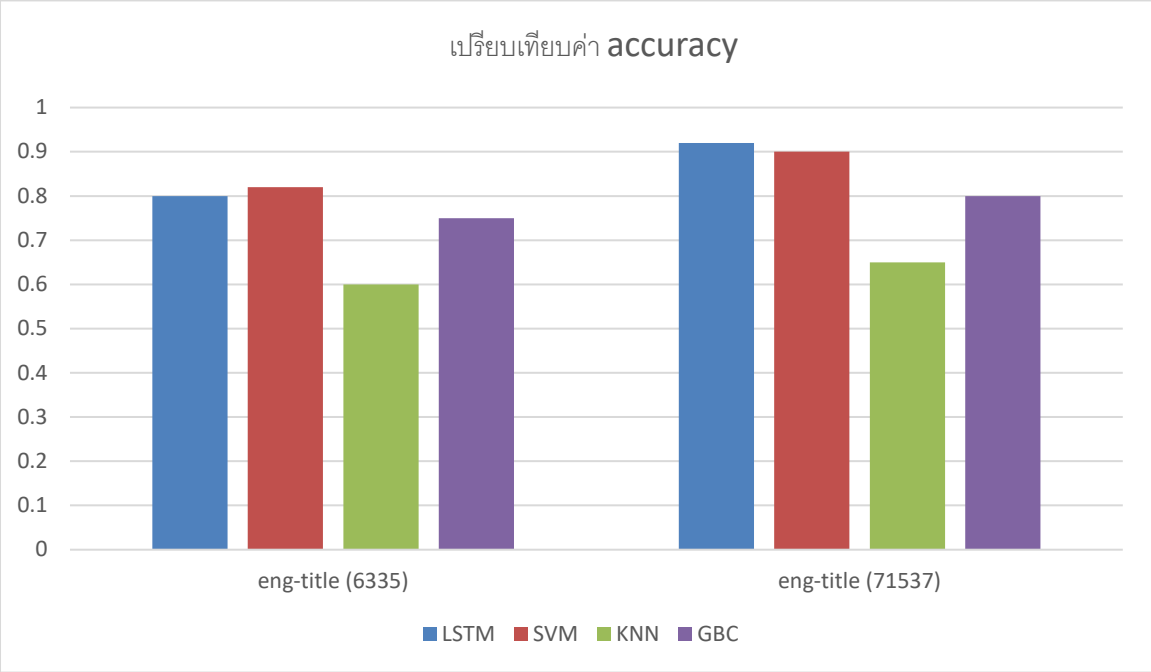

จากกราฟจะเห็นได้ว่า eng-title(71537) ซึ่งจะเป็นการเทรนด้วย title ไม่มี body จะมีค่า accuracy ที่สูงกว่าในการเทรนด้วย title ที่มีขนาดข้อมูลที่น้อยกว่าจากการกราฟนี้จึงสรุปได้ว่าถ้าหากมีข้อมูลที่มากขึ้นจะทำให้โมเดลมีการเรียนรู้ที่ดีกว่า

ตารางที่ 5.2 ตารางการทดสอบด้วยข่าว

โมเดล	ข่าวที่ใช้ทดสอบ	เวลาในการทำนาย	ผลการทำนาย
LSTM	ข่าวที่ 1 title	0.84 วินาที	ข่าวปลอม
	ข่าวที่ 2 title & body	0.66 วินาที	ข่าวปลอม
	ข่าวที่ 3 title & มีคำอังกฤษ	0.80 วินาที	ข่าวปลอม
	ข่าวที่ 4 title & body & มีคำอังกฤษ	0.76 วินาที	ข่าวปลอม
	ข่าวที่ 5 (ไม่ลบ,ลบ)	0.81 วินาที,0.71 วินาที	ข่าวปลอม,ข่าวปลอม
	ข่าวที่ 6 เนื้อข่าวที่ยาว	0.76 วินาที	ข่าวจริง
	ข่าวที่ 7 เนื้อข่าวที่ยาว	0.67 วินาที	ข่าวปลอม
SVM	ข่าวที่ 1 title	0.00 วินาที	ข่าวจริง
	ข่าวที่ 2 title & body	0.00 วินาที	ข่าวจริง
	ข่าวที่ 3 title & มีคำอังกฤษ	0.00 วินาที	ข่าวปลอม
	ข่าวที่ 4 title & body & มีคำอังกฤษ	0.00 วินาที	ข่าวปลอม
	ข่าวที่ 5 (ไม่ลบ,ลบ)	0.00 วินาที, 0.00 วินาที	ข่าวปลอม,ข่าวปลอม
	ข่าวที่ 6 เนื้อข่าวที่ยาว	0.00 วินาที	ข่าวจริง
	ข่าวที่ 7 เนื้อข่าวที่ยาว	0.00 วินาที	ข่าวจริง

KNN	ข่าวที่ 1 title	0.15 วินาที	ข่าวปลอม
	ข่าวที่ 2 title & body	0.16 วินาที	ข่าวปลอม
	ข่าวที่ 3 title & มีคำอังกฤษ	0.13 วินาที	ข่าวจริง
	ข่าวที่ 4 title & body & มีคำอังกฤษ	0.15 วินาที	ข่าวปลอม
	ข่าวที่ 5 (ไม่ลบ,ลบ)	0.13 วินาที, 0.16 วินาที	ข่าวปลอม,ข่าวปลอม
	ข่าวที่ 6 เนื้อข่าวที่ยาว	0.16 วินาที	ข่าวจริง
	ข่าวที่ 7 เนื้อข่าวที่ยาว	0.17 วินาที	ข่าวปลอม
GBC	ข่าวที่ 1 title	0.00 วินาที	ข่าวปลอม
	ข่าวที่ 2 title & body	0.00 วินาที	ข่าวปลอม
	ข่าวที่ 3 title & มีคำอังกฤษ	0.00 วินาที	ข่าวปลอม
	ข่าวที่ 4 title & body & มีคำอังกฤษ	0.00 วินาที	ข่าวปลอม
	ข่าวที่ 5 (ไม่ลบ,ลบ)	0.00 วินาที, 0.00 วินาที	ข่าวปลอม,ข่าวปลอม
	ข่าวที่ 6 เนื้อข่าวที่ยาว	0.00 วินาที	ข่าวปลอม
	ข่าวที่ 7 เนื้อข่าวที่ยาว	0.00 วินาที	ข่าวปลอม

รายละเอียดข่าวการทำนาย

สีเขียว หมายความว่าทำนายถูกต้อง

สีแดง หมายความว่าทำนายผิด

ข่าวที่ 1 title

"ดื่มน้ำเย็นตอนอากาศร้อนถึง 40 องศา หลอดเลือดเล็กอาจปริหรือระเบิดได้" ,เป็นข่าวปลอม

ข่าวที่ 2 title & body

“ดื่มน้ำเย็นตอนอากาศร้อนถึง 40 องศา หลอดเลือดเล็กอาจปริหรือระเบิดได้”, “จากกรณีที่มีการโพสต์ข้อมูลเตือนเกี่ยวกับอากาศร้อนถึง 40 องศา ไม่ควรดื่มน้ำเย็น เพราะหลอดเลือดเล็กอาจปริหรือระเบิดได้”,เป็นข่าวปลอม

ข่าวที่ 3 title & มีคำอังกฤษ

“สั่งดำเนินการให้เครื่องครัว stainless เป็นสินค้าควบคุม 7 รายการ หวั่นโลหะหนักปนเปื้อน”,เป็นข่าวจริง

ข่าวที่ 4 title & body & มีคำอังกฤษ

'ทำใบขับขี่ออนไลน์หรือต่ออายุใบขับขี่ออนไลน์ผ่านเพจ Department of Land Transport', ' กรมขนส่งทางบกเปิดให้ลงทะเบียน ทำใบขับขี่ออนไลน์ทางเพจศูนย์รับออกบัตรใบขับขี่ โดยตรงจากขนส่ง ทางกรมการขนส่งทางบกกระทรวงคมนาคม',เป็นข่าวปลอม

ข่าวที่ 5 ลบบ้างคำออก = (โลโก้)

“เตือน!! เพจ “DigitraPay” แอบอ้าง(โลโก้)กรมพัฒนาฝีแรงงานอย่าหลงเชื่อ”,เป็นข่าวจริง

ข่าวที่ 6 เนื้อข่าวที่ยาว

“สมศักดิ์ยัน รบ.ให้ความสำคัญกลุ่มชาติพันธุ์ พัฒนาชีวิต-ความเท่าเทียม", "เมื่อวันที่ 26 เม.ย. 67 นายสมศักดิ์ เทพสุทิน รองนายกรัฐมนตรี ในฐานะประธานคณะกรรมการขับเคลื่อนการฟื้นฟูวิถีชีวิตกลุ่มชาติพันธุ์ชาวเลและชาวกะเหรี่ยง พร้อมด้วย นายสุรสีห์ กิตติมณฑล เลขาธิการสำนักงานทรัพยากรน้ำแห่งชาติ (สทนช.), พล.ต.ต.บรรพต มุ่งขอบกลาง รองผู้บัญชาการตำรวจตระเวนชายแดน, และนายอภินันท์ ธรรมเสนา ผู้จัดการฝ่ายสื่อสารสังคมและขับเคลื่อนนโยบายสาธารณะ ศูนย์มานุษยวิทยาสิรินธร (องค์การมหาชน) ลงพื้นที่บ้านขุนแม่เหว่ย (แม่ปอคี) อ.ท่าสองยาง จ.ตาก โดยมีหัวหน้าส่วนราชการ เครือข่ายภาคประชาสังคม พี่น้องกลุ่มชาติพันธุ์กะเหรี่ยงบ้านขุนแม่เหว่ย (แม่ปอคี) นายดิษฐ์ชัย สันติกุล อดีตรองนายกองค์การบริหารส่วนจังหวัดตาก และนายชัยณรงค์ มะเดช นักการเมืองในพื้นที่ ให้การต้อนรับผู้สื่อข่าวรายงานว่า การลงพื้นที่ในครั้งนี้ของ นายสมศักดิ์ ต้องขึ้นเฮลิคอปเตอร์จากท่าอากาศยานนานาชาติแม่สอด เพื่อเปิดงานการสถาปนาเขตพื้นที่คุ้มครองวิถีชีวิตกลุ่มชาติพันธุ์ บ้านขุนแม่เหว่ย (แม่ปอคี) เนื่องจากระยะทางการเข้าพื้นที่เป็นไปด้วยความยากลำบาก พร้อมทั้งยังร่วมเป็นสักขีพยานในการลงบันทึก MOU ร่วมกับ 22 หน่วยงาน เช่น กระทรวงทรัพยากรธรรมชาติและสิ่งแวดล้อม (ทส.) กระทรวงศึกษาธิการ (ศธ.) กระทรวงสาธารณสุข (สธ.) กระทรวงพัฒนาสังคมและความมั่นคงของมนุษย์ (พม.) เป็นต้น พร้อมกันนี้ยังได้มีการลงพื้นที่ติดตามระบบโทรมาตรอัตโนมัติ ซึ่งเป็นเครื่องมือที่ใช้เก็บข้อมูล สถานการณ์น้ำ แผนการจัดการน้ำ เตือนอุทกภัยน้ำหลากโดย นายสมศักดิ์ กล่าวว่า ตนมีความยินดีอย่างยิ่งที่ได้มาเยือนและพบปะพี่น้อง กลุ่มชาติพันธุ์ชาวกะเหรี่ยง การร่วมสถาปนาเขตพื้นที่คุ้มครองวิถีชีวิตกลุ่มชาติพันธุ์บ้านขุนแม่เหว่ย (แม่ปอคี) เป็นพื้นที่คุ้มครองวิถีชีวิตกลุ่มชาติพันธุ์ลำดับที่ 22 ถือเป็นเรื่องที่น่ายินดีอย่างยิ่ง ตนในฐานะของตัวแทนรัฐบาลขอยืนยันว่า นายเศรษฐา ทวีสิน นายกรัฐมนตรี ให้ความสำคัญในเรื่องของกลุ่มชาติพันธุ์เป็นอย่างมาก ท่านนายกฯ ต้องการพัฒนาคุณภาพชีวิต การยอมรับความหลากหลายทางอัตลักษณ์ ความเสมอภาคเท่าเทียมและสิทธิพื้นฐานที่กลุ่มชาติพันธุ์จะได้รับนายสมศักดิ์ กล่าวต่อว่า ในส่วนเรื่องของกฎหมาย รัฐบาลได้ผลักดันพระราชบัญญัติคุ้มครองและส่งเสริมวิถีชีวิตกลุ่มชาติพันธุ์ ซึ่งรัฐบาลได้เสนอร่างดังกล่าวต่อสภาผู้แทนราษฎรไปเมื่อวันที่ 28 กุมภาพันธ์ 2567 โดยที่ประชุมมีมติ 414 เสียง และรับหลักการในวาระหนึ่งเป็นที่เรียบร้อย ปัจจุบันร่างกฎหมายดังกล่าว อยู่ระหว่างการพิจารณาของคณะกรรมการวิสามัญร่วมกับร่างกฎหมาย จากภาคประชาชนและพรรคการเมืองรวมเป็น 5 ฉบับ นี่ก็ทำให้เห็นว่าทุกภาคส่วนให้ความสำคัญกับพี่น้องทุกท่าน และผมหวังว่ากฎหมายฉบับนี้จะแล้วเสร็จได้อย่างรวดเร็วผมขอยืนยันว่า รัฐบาลให้การสนับสนุนพี่น้องกลุ่มชาติพันธุ์ทุกกลุ่มอย่างเสมอภาค เพื่อให้เกิดการอยู่ร่วมกันอย่างมีเกียรติ มีศักดิ์ศรี และอยากเห็นกลุ่มชาติพันธุ์มีคุณภาพชีวิตที่ดีขึ้น มีรายได้ มีที่ดินทำกิน ดังนั้นทุกท่านต้องให้ความร่วมมือกับส่วนราชการ เดินหน้าให้ชุมชนสร้างประโยชน์ในพื้นที่ และให้มีส่วนร่วมในการบริหารจัดการในพื้นที่ตัวเอง การสถาปนาในวันนี้จะช่วยส่งเสริมการอนุรักษ์ทรัพยากรธรรมชาติ และที่สำคัญที่สุด คือ การสร้างความมั่นคงให้กับชีวิต สามารถพึ่งพาตัวเองได้ และผมยังหวังว่าอีกไม่นานนี้ หากทุกท่านร่วมมือกันเราจะมีเขตพื้นที่คุ้มครองวิถีชีวิตชาติพันธุ์ ในระดับที่ 23 ต่อไปครับ รองนายกรัฐมนตรีกล่าวด้าน นายสุรสีห์ เปิดเผยว่า จากการติดตามในพื้นที่ของ สทนช.พบปัญหาด้านน้ำอุปโภคบริโภคยังไม่ได้คุณภาพ จากนี้ไปจะติดตามและประสานหน่วยงานเพื่อเร่งดำเนินการแก้ไขนอกจากนี้ นายสมศักดิ์ ยังกล่าวอีกว่า บ้านขุนแม่เหว่ยเป็นพื้นที่ประวัติศาสตร์ มากว่า 425 ปี เวลานี้มีประชากร 276 คน 51 หลังคาเรือน มีพื้นที่ 8,386 ไร่ ทำภาคเกษตรหมุนเวียนเป็นส่วนมาก ดังนั้นเวลานี้รัฐบาลโดยคณะรัฐมนตรีที่มีท่านนายกฯ เศรษฐาเป็นผู้นำ ได้เห็นชอบโครงการโคแสนล้าน เพื่อต้องการให้พี่น้องเกษตรกรมีรายได้เสริมและมีชีวิตความเป็นอยู่ที่ดีขึ้น ขณะเดียวกันพื้นที่นี้มีความเหมาะสมในการทำปศุสัตว์ เพราะโคไม่ไปทำลายต้นไม้ ดังนั้นจะประสานให้กองทุนหมู่บ้านทำความเข้าใจ และถ่ายทอดความรู้ให้แก่พี่น้องบ้านขุนแม่เหว่ยว่า จะเข้าร่วมโครงการได้แบบใดบ้างผู้สื่อข่าวรายงานว่า ในการลงพื้นที่โครงการโคแสนล้านได้รับความสนใจเป็นอย่างมาก จากพี่น้องชาวชาติพันธุ์เพราะมองว่าเป็นโอกาส พร้อมกันนี้รองนายกฯ ยังได้มอบเชือกวัดน้ำหนักโคให้เป็นที่ระลึกอีกด้วย",เป็นข่าวจริง

ข่าวที่ 7 เนื้อข่าวที่ยาว

"ใช้นิ้วนวดรอบดวงตา ทำให้สายตาดีขึ้นภายใน 2 เดือน ", "จากกรณีที่มีผู้ให้คำแนะนำว่า วิธีการทำให้สายตาดีขึ้นในระยะเวลา 2 เดือน ด้วยการใช้นิ้วกดจุด และนวดบริเวณคิ้ว รอบดวงตา สันจมูก ขมับ ใบหู ติ่งหูนั้น ทางกรมการแพทย์ กระทรวงสาธารณสุข ได้ตรวจสอบข้อมูลและชี้แจงว่า 6 วิธีการที่แชร์กันนั้น ยังไม่มีรายงานทางวิชาการที่สามารถวัดผลได้จริง หรือช่วยให้การรักษาดีขึ้น และหากนวดบริเวณรอบดวงตาไม่ถูกวิธี อาจมีผลทำให้เส้นเลือดฝอยใต้เยื่อบุตาแตกได้ หรืออาจมีผลร้ายแรงถึงขั้นตาบอด จากที่เส้นเลือดที่จอประสาทตาอุดตันหรือแตกได้ โดยภาวะสายตายาวเป็นความบกพร่องของสายตาที่ไม่สามารถแพ่งหรือมองวัตถุได้ชัดเจนในระยะใกล้ ๆ ซึ่งตามปกติแล้วสายตายาวเกิดขึ้นตามอายุ โดยเฉพาะในกลุ่มที่มีอายุ 40 ปีขึ้นไป และการรักษา คือ การสวมแว่นตามที่แพทย์สั่ง โดยการตรวจวัดค่าสายตาจากแพทย์",เป็นข่าวปลอม

บทที่ 6 ผลการดำเนินงาน ข้อจำกัด และข้อเสนอแนะ

6.1 ผลการดำเนินงาน

- เปลี่ยนจากโมบายแอปพลิเคชันเป็นเว็บแอปพลิเคชันแทนเพื่อความสะดวกในการอ่านข่าวเพิ่มเติม
- การเปลี่ยนจากการเทรนโมเดลเพียงแค่ด้วยหัวข้อข่าวเป็นการเทรนด้วยหัวข้อข่าวและเนื้อหาข่าวจะช่วยเพิ่มประสิทธิภาพในการทำนายข่าวปลอมหรือข่าวจริงของโมเดลโดยการใช้เนื้อหาข่าวในการเทรนโมเดลจะช่วยเพิ่มความละเอียดในข้อมูลที่โมเดลได้เรียนรู้และทำให้โมเดลมีความเข้าใจเกี่ยวกับเนื้อหาข่าวมากขึ้นและสามารถค้นพบลักษณะและรูปแบบของข่าวปลอมหรือข่าวจริงได้มากขึ้นเมื่อเทียบกับการเทรนเพียงแค่ด้วยหัวข้อข่าวเท่านั้น
- การเทรนด้วยเนื้อหาข่าวทำให้โมเดลมีข้อมูลมากขึ้นเพื่อใช้ในการตัดสินใจและลดความสับสนหรือข้อผิดพลาดที่อาจเกิดขึ้นในการทำนายนอกจากนี้ยังช่วยเพิ่มความสามารถในการจำแนกและตรวจสอบความถูกต้องของข่าวอย่างมีประสิทธิภาพยิ่งขึ้นในสถานการณ์ที่ซับซ้อนและหลากหลายของข้อมูลข่าว
- ผู้ใช้สามารถใส่ข่าวที่เป็นหัวข้อข่าวหรือเนื้อข่าวลงในช่องว่างเพียงอย่างเดียวแล้วกดปุ่ม "Predict" เพื่อทำนายผลในแต่ละโมเดล โดยโมเดลจะจำแนกประเภทของข่าวว่าเป็นข่าวปลอมหรือข่าวจริงในหน้าแรกของแอปพลิเคชัน
- สามารถกดค้นหาข่าวที่ใกล้เคียงได้โดยกดปุ่ม “Search News” เพื่อที่นำผู้ใช้ไปยังหน้าของข่าวเพิ่มเติมได้
- สามารถกดปุ่มอ่านข่าวเพิ่มเติมจากข่าวที่แสดงผลออกมาซึ่งจะเป็นข่าวที่ใกล้เคียงจากการทำระบบค้นหาข่าวจากฐานข้อมูลที่มีซึ่งระบบนี้จะใช้การคำนวณ cosine similarity ระหว่าง query และเอกสารทั้งหมดและเรียงลำดับจากค่าความคล้ายคลึงของเอกสารทั้งหมด 10 ลำดับโดยเรียงจากค่าความคล้ายคลึงจากมากที่สุดไปน้อยที่สุดเพื่อที่จะแสดงข่าวที่ใกล้เคียงมากที่สุดไว้ลำดับแรก ๆ ของหน้าอ่านข่าวเพิ่มเติมเพื่อให้ผู้ใช้ได้ใช้เลือกข่าวที่สนใจตามลำดับข่าวที่ใกล้เคียงกัน

6.2 ข้อจำกัด

- หากโมเดลทำนายข่าวปลอมไม่สามารถอัพเดตอย่างสม่ำเสมอเพื่อตรวจจับข่าวปลอมในลักษณะแบบใหม่ ๆ ได้ในอนาคตอาจเกิดปัญหาที่ผู้ใช้ได้รับข้อมูลที่ไม่สมบูรณ์และไม่ถูกต้องตามสถานการณ์ปัจจุบันได้เช่นการที่โมเดลไม่สามารถเรียนรู้และปรับปรุงตนเองในการตรวจจับข่าวปลอมที่มีลักษณะใหม่ ๆ อาจทำให้มีการรับรู้ข้อมูลที่เก่าหรือไม่ครอบคลุมอาจลดความไว้วางใจของผู้ใช้ในการใช้งานแอปพลิเคชันนั้น ๆ อีกทั้งการไม่สามารถอัพเดตโมเดลเพื่อตรวจจับข่าวปลอมในลักษณะใหม่ ๆ อาจทำให้ผู้ใช้ไม่ได้รับข้อมูลที่สมบูรณ์และครอบคลุมเนื่องจากข่าวที่ได้รับอาจไม่สอดคล้องกับเหตุการณ์หรือสถานการณ์ที่เปลี่ยนแปลงอยู่ในปัจจุบัน
- ควรมีระบบบันทึกประวัติการทำนายของผู้ใช้เพื่อให้ผู้ใช้สามารถตรวจสอบผลลัพธ์ที่ผ่านมาและสามารถย้อนดูข่าวที่เคยทำนายได้
- มีข้อจำกัดในเรื่องของการอัพเดตข่าวเพราะว่าข่าวมีการเพิ่มขึ้นทุกวันดังนั้นข่าวที่มีอาจจะล้าหลังและไม่ได้มีความคล้ายกับข่าวในปัจจุบัน
- เว็บไซต์ข่าวบางแห่งอาจมีเนื้อหาข่าวที่ถูกลบออกหรือมีการอัพเดตเนื้อหา ซึ่งอาจทำให้ผู้ใช้ไม่สามารถเข้าถึงข้อมูลที่เราสนใจได้อย่างสมบูรณ์หรือถูกต้องเนื่องจากข่าวที่เคยมีอาจถูกแก้ไขหรือลบไปแล้วส่งผลให้ผู้ใช้ไม่สามารถรับข้อมูลล่าสุดหรือตรวจสอบข้อมูลที่ครบถ้วนได้อย่างแม่นยำ
- การให้คำแนะนำเพิ่มเติมระบบควรสามารถให้คำแนะนำเพิ่มเติมเกี่ยวกับวิธีการตรวจสอบความถูกต้องของข่าวหรือแหล่งข้อมูลเพิ่มเติมที่สามารถเชื่อถือได้ เพื่อเสริมสร้างความเข้าใจและความมั่นใจให้แก่ผู้ใช้

6.3 ข้อเสนอแนะ

- การมี API ข่าวที่อัพเดตแบบวันต่อวันจะเป็นการแก้ไขข้อจำกัดของการอ่านข่าวเพิ่มเติมได้ เนื่องจาก API จะให้การเข้าถึงข้อมูลข่าวที่อัพเดตอยู่เป็นระยะเวลาใหม่ ๆ โดยตรง ทำให้ผู้ใช้สามารถเข้าถึงข่าวใหม่ที่ไม่มีอยู่ในฐานข้อมูลเดิมได้ โดยที่ไม่ต้องรอการอัพเดตหรือการปรับปรุงข้อมูลเก่า ทำให้ผู้ใช้ได้รับข้อมูลใหม่ที่ถูกต้องและสมบูรณ์ทันที

- หากผู้ใช้ไม่สามารถตัดสินใจได้ว่าข่าวเป็นข่าวจริงหรือข่าวปลอม ระบบค้นหาข่าวสามารถให้ความช่วยเหลือได้โดยการให้ผู้ใช้ค้นหาข่าวที่ใกล้เคียงเพื่อช่วยในการประกอบการตัดสินใจโดยระบบสามารถนำเสนอข่าวที่มีลักษณะคล้ายกันหรือเกี่ยวข้องกับข่าวที่ผู้ใช้กำลังพิจารณาอยู่ ซึ่งอาจช่วยให้ผู้ใช้มีข้อมูลเพิ่มเติมในการตัดสินใจได้ดีขึ้น

- ผู้ใช้สามารถกรอกข่าวที่มีภาษาอังกฤษที่เป็นชื่อเฉพาะปนมาด้วยได้โดยไม่ต้องเปลี่ยนเป็นตัวพิมพ์เล็ก ซึ่งช่วยให้การใช้งานแอปพลิเคชันมีความสะดวกและรวดเร็วมากยิ่งขึ้นเพราะชื่อเฉพาะอาจมีความสำคัญในการทำนายข่าวปลอม

- ในการแสดงผลของการทำนายข่าวปลอม โมเดลจะแสดงผลออกมาทั้งหมด 4 โมเดลซึ่งเรียงลำดับตามลำดับของโมเดลที่ใช้ โดยมีลำดับการแสดงดังนี้ LSTM, SVM, KNN, และ GBC โมเดลทุกตัวจะทำนายข่าวเป็นหนึ่งใน 2 ประเภทเท่านั้น คือข่าวปลอมหรือข่าวจริง

บรรณานุกรม

[1] P. Meesad, “Thai Fake News Detection Based on Information Retrieval, Natural Language Processing and Machine Learning,” 2021. [ออนไลน์]. Available: https://doi.org/10.1007/s42979-021-00775-6. [%1 ที่เข้าถึง20 December 2023].

[2] Nokkaew, “Fact Check Explorer เครื่องมือเช็กข่าวปลอมจาก Google เช็กข่าวปลอมได้ทั่วโลก,” 25 November 2019. [ออนไลน์]. Available: https://www.rainmaker.in.th/google-fact-check-explorer-fact-check/. [%1 ที่เข้าถึง20 December 2023].

[3] S. Farahmand, “The Fight Against Fake News with Deep Learning,” 23 February 2022. [ออนไลน์]. Available: https://towardsdatascience.com/the-fight-against-fake-news-with-deep-learning-6c41dd9eaae4. [%1 ที่เข้าถึง20 December 2023].

[4] “เว็บครอว์เลอร์คืออะไร ทำงานอย่างไร,” [ออนไลน์]. Available: https://www.geniuswebb.com/blog/what-is-web-crawler-and-how-does-it-work.html. [%1 ที่เข้าถึง22 March 2024].

[5] “Natural Language Processing – Overview,” 6 February 2024. [ออนไลน์]. Available: https://www.geeksforgeeks.org/natural-language-processing-overview/?ref=gcse. [%1 ที่เข้าถึง25 March 2024].

[6] “การเรียนรู้ของเครื่อง,” 1 June 2566. [ออนไลน์]. Available: https://th.wikipedia.org/wiki/%E0%B8%81%E0%B8%B2%E0%B8%A3%E0%B9%80%E0%B8%A3%E0%B8%B5%E0%B8%A2%E0%B8%99%E0%B8%A3%E0%B8%B9%E0%B9%89%E0%B8%82%E0%B8%AD%E0%B8%87%E0%B9%80%E0%B8%84%E0%B8%A3%E0%B8%B7%E0%B9%88%E0%B8%AD%E0%B8%87. [%1 ที่เข้าถึง10 March 2024].

[7] PradyaSin, “Support Vector Machines (SVM),” 4 October 2019. [ออนไลน์]. Available: https://medium.com/@pradyasin/support-vector-machines-svm-943f9a732a69. [%1 ที่เข้าถึง22 March 2024].

[8] “Machine Learning(EP.5) การคำนวณเพื่อนบ้านใกล้สุด (K-nearest Neighbors),” 23 January 2020. [ออนไลน์]. Available: https://kongruksiam.medium.com/%E0%B8%AA%E0%B8%A3%E0%B8%B8%E0%B8%9B-machine-learning-ep-4-%E0%B9%80%E0%B8%9E%E0%B8%B7%E0%B9%88%E0%B8%AD%E0%B8%99%E0%B8%9A%E0%B9%89%E0%B8%B2%E0%B8%99%E0%B9%83%E0%B8%81%E0%B8%A5%E0%B9%89%E0%B8%97%E0%B8%B5%E0%B9%88%E0%B8%AA%E0. [%1 ที่เข้าถึง22 March 2024].

[9] “Gradient Boosting in ML,” 31 March 2023. [ออนไลน์]. Available: https://www.geeksforgeeks.org/ml-gradient-boosting/?ref=header_search. [%1 ที่เข้าถึง22 March 2024].

[10] “Long Short Term Memory Networks Explanation,” 2 January 2023. [ออนไลน์]. Available: https://www.geeksforgeeks.org/long-short-term-memory-networks-explanation/. [%1 ที่เข้าถึง22 March 2024].

[11] A. Batista, “introduction-to-information-retrieval,” 2021. [ออนไลน์]. Available: https://www.kaggle.com/code/vabatista/introduction-to-information-retrieval/notebook. [%1 ที่เข้าถึง10 March 2024].

[12] “NLP - Information Retrieval,” [ออนไลน์]. Available: https://www.tutorialspoint.com/natural_language_processing/index.htm#. [%1 ที่เข้าถึง10 March 2024].

[13] Peratham, “Deep Learning คืออะไร?,” 10 january 2018. [ออนไลน์]. Available: https://peratham.medium.com/deep-learning-%E0%B8%84%E0%B8%B7%E0%B8%AD%E0%B8%AD%E0%B8%B0%E0%B9%84%E0%B8%A3-7f7d9e34f74. [%1 ที่เข้าถึง10 March 2024].

[14] mahajan, “Fake News Detection using Machine Learning,” 26 October 2022. [ออนไลน์]. Available: https://www.geeksforgeeks.org/fake-news-detection-using-machine-learning/. [%1 ที่เข้าถึง10 March 2024].

[15] meetpopat, “Natural Language Processing – Overview,” 21 April 2023. [ออนไลน์]. Available: https://www.geeksforgeeks.org/natural-language-processing-overview/?ref=gcse. [%1 ที่เข้าถึง10 March 2024].

[16] Shinde, “Machine learning with Flowchart,” 6 January 2021. [ออนไลน์]. Available: https://medium.com/analytics-vidhya/machine-learning-with-flowchart-696ff42f8aff. [%1 ที่เข้าถึง10 March 2024].

[17] siddh, “What is Information Retrieval?,” 3 july 2022. [ออนไลน์]. Available: https://www.geeksforgeeks.org/what-is-information-retrieval/?ref=gcse. [%1 ที่เข้าถึง10 March 2024].

ภาคผนวก ก การใช้งานแอปพลิเคชัน

ก.1 หน้าแรกของแอปพลิเคชัน

ก.1.1 ส่วนการใส่เนื้อหาข่าว

ในส่วนนี้ผู้ใช้สามารถใส่หัวข้อข่าวและเนื้อหาข่าวที่ต้องการทำนายได้โดยเมื่อกดปุ่ม "Predict" แอปพลิเคชันจะนำข้อมูลที่ผู้ใช้ป้อนมาไปใช้โมเดลที่ถูกฝึกเพื่อทำนายว่าข่าวดังกล่าวเป็นข่าวปลอมหรือจริงดังรูปผนวก ก.1.1

รูปผนวกที่ ก.1.1 รูปของหน้าแรก

ก.1.2 ผลการทำนาย

จะแสดงผลการทำนายทั้งหมด 4 โมเดลมี 1.LSTM 2.SVM 3.KNN 4.GBC ดังรูปผนวก ก.1.2

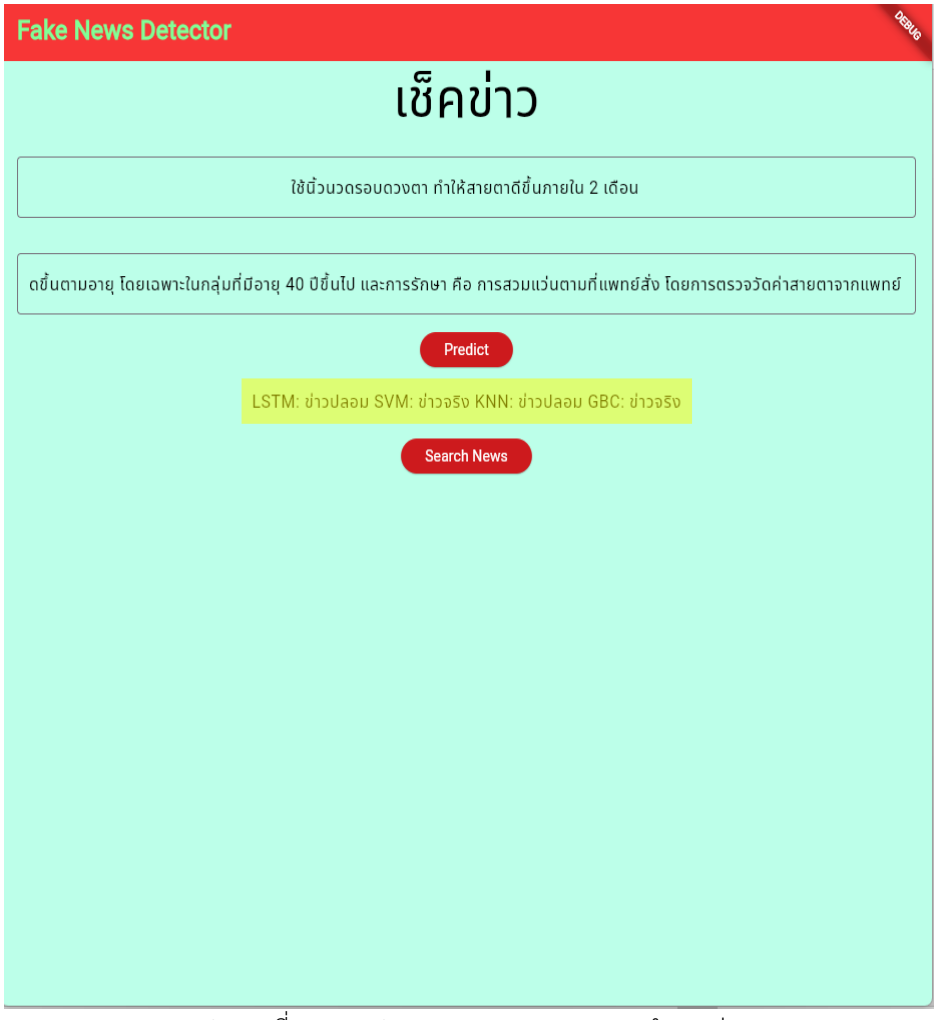

รูปผนวกที่ ก.1.2 รูปของการแสดงผลระบบการทำนายข่าว

ก.2 หน้าที่สองของแอปพลิเคชัน

ก.2.1 ส่วนการค้นหาข่าว

ในส่วนนี้ผู้ใช้มีการแสดงข่าวที่เกี่ยวข้องเพิ่มเติมมาด้วยกดปุ่ม Search News เพื่อช่วยให้ผู้ใช้งานได้เนื้อหาข่าวที่เกี่ยวข้องเพิ่มเติมดังรูปผนวก ก.2.1

รูปผนวก ก.2.1 รูปของการแสดงผลระบบหาข่าวเพิ่มเติม

ก.2.2 ตัวอย่างข่าวเพิ่มเติม

นี้คือตัวอย่างข่าวที่กดอ่านเพิ่มเติมจะสามารถเข้าไปยังเว็บไซต์ของข่าวได้ซึ่งข่าวนี้มาจากเว็บศูนย์ต่อต้านข่าวปลอมประเทศไทยดังรูปผนวก ก.2.2

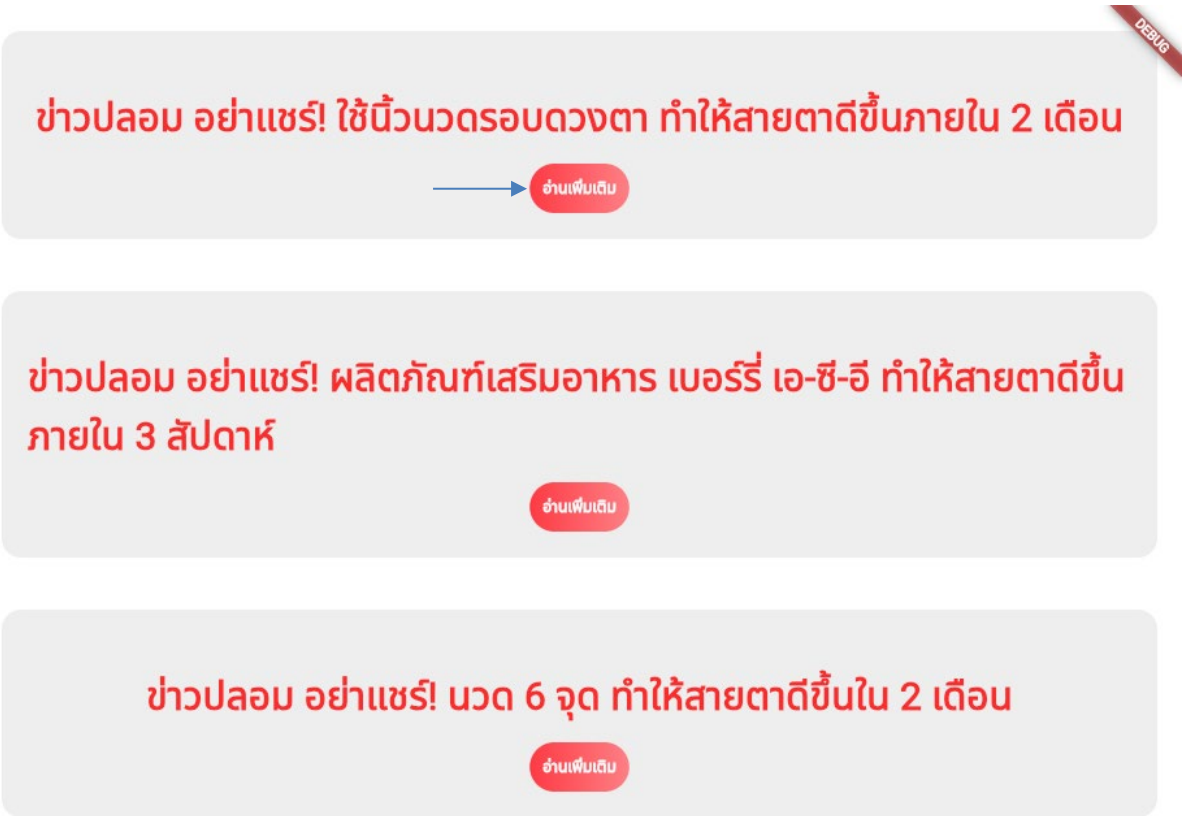

รูปผนวก ก.2.2รูปของการเลือกอ่านเพิ่มเติม

ก.2.3 ตัวอย่างของเว็บไซต์

เป็นเว็บไซต์ของข่าวที่มีข้อมูลของข่าวที่ใช้ในการประกอบการตัดสินใจในข่าวที่โมเดลได้ทำนายไว้ดังรูปผนวก ก.2.3

รูปผนวก ก.2.3 รูปของเว็บไซต์ข่าวศูนย์ต่อต้านข่าวปลอมประเทศไทย